

IP 파운데이션 월드모델 연구 노트 1

주장과 계수 사이의 2.75배

팝업스토어 수요 예측에서 라벨 정의 혼재가 모델 평가를 무력화하는 방식

Sweetspot 월드모델 연구

2026년 7월 28일

초 록

오프라인 팝업스토어의 방문객 수를 예측하는 모델을 구축해 왔다. 라벨 427건과 피처 132종을 갖추고 능선회귀·부스팅을 학습했으나, 교차검증에서 어떤 모델도 상수 중앙값을 유의하게 이기지 못하는 상태가 반복됐다. 통상적인 대응은 표본을 늘리거나 피처를 정교화하는 것이지만, 이 연구는 원인을 모델이 아니라 **라벨의 정의**에서 찾는다. 라벨 362건을 집계 기준별로 분해하자, 주최자가 발표한 수치($n=235$)의 중앙값이 현장 게이트 계수($n=49$)보다 $0.440\log_{10}$, 즉 2.75배 높았다. 같은 행사를 두 방식으로 켜 직접 대조 사례에서는 격차가 6.9배였다. 반면 같은 문서 안의 전사 오류 (부분합 누락 등)는 중앙 1.10배로 그 1/7에 불과했다. 즉 우리가 다뤄 온 오차는 부주의가 아니라 서로 다른 물리량을 한 컬럼에 담은 결과다. 결정적으로, 현재 모델의 예측 오차(2.37배)가 이 집계 기준 격차(2.75배)보다 작다. 혼재된 라벨 위에서 모델을 개선하는 작업은 이미 측정 해상도 아래에서 이루어지고 있다. 피처를 하나도 쓰지 않고 집계 기준별로 상수만 예측해도 오차가 15.5% 줄어드는데, 이는 132개 피처를 붙인 회귀의 개선폭(9.2%)보다 크다. 라벨 정의의 정리가 모델링에 선행해야 한다는 것이 이 스텝의 결론이다.

1. 배경

무엇을 만들고 있는가. 브랜드는 신제품이나 지식재산(IP)을 알리기 위해 짧게는 하루, 길게는 두 달간 백화점·쇼핑몰·거리에 임시 매장을 연다. 이를 팝업스토어라 한다. 국내 팝업 대행사인 Sweetspot은 연간 수백 건의 팝업을 기획·운영하며, 우리는 그 실행 이력을 학습 데이터로 삼아 개입(기획 내용)에서 소비자 반응(방문객·매출)을 예측하는 모델을 만들고 있다.

최종 목표는 팝업에 국한되지 않는다. 아이돌 데뷔의 초기 반응, 광고 모델 기용의 효과, 게임 출시의 흥행처럼 IP가 대중과 만나는 모든 접점의 반응을 하나의 모델로 다루는 것이 목표이며, 이를 IP 파운데이션 월드모델이라 부른다. 팝업은 그 첫 번째 도메인이다. 실행 이력이 문서로 남아 있고 결과가 숫자로 기록되기 때문이다.

왜 어려운가. 같은 IP라도 장소·시기·기획에 따라 방문객이 수백 명에서 수만 명까지 갈린다. 그리고 실행된 팝업만 기록에 남으므로 표본은 필연적으로 생존 편향을 갖는다. 무엇보다 **표본이 작다**. 방문객 라벨은 내부 99건, 언론·업계 보도에서 수집한 시장 라벨 328건이 전부다.

현재 상태. 방문객 총계를 실제 운영일수로 나눈 값(일평균 방문객)에 상용로그를 취해 타깃으로 삼고, 장소 등급·기간·IP 이력·기획 속성 등 132개 피처를 붙였다. 평가는 동일 IP가 학습·검증에 동시에 들어가지 않도록 IP 단위로 묶고, 검증 폴드가 항상 학습 폴드보다 미래이도록 시간 순서를 강제한다(IP-그룹 $\cap$ rolling-origin). 성능 지표는 로그 척도의 평균절대오차(MAE)이며, MAE = 0.3은 예측이 실측의 약 2배 안에 들어온다는 뜻이다.

표 1이 이 연구의 출발점이다. 두 모델 모두 점추정으

Table 1: 내부 라벨 전용 평가($n=82$, 4폴드). 어떤 모델도 상수를 유의하게 이기지 못한다. CI는 페어드 부트스트랩 95% 신뢰구간이며, 0을 포함하면 차이를 확정할 수 없다.

모델	MAE ($\log_{10}$)	상수 대비 차이
상수 중앙값	0.3754	—
능선회귀	0.3402	-0.0351 CI[-0.112, +0.045]
부스팅	0.3539	-0.0214 CI[-0.084, +0.038]

로는 상수보다 낮지만 신뢰구간이 0을 넘는다. 이런 상태가 여러 차례의 피처 추가와 라벨 확장에도 반복됐다.

여기서 두 가지 해석이 가능하다. (가) 표본이 부족해 신호를 검출할 검정력이 없다. (나) 라벨이 재는 것이 우리가 예측하려는 것과 다르다. 지금까지의 작업은 암묵적으로 (가)를 가정했다. 이 스텝은 (나)를 검증한다.

2. 라벨은 어디서 오는가

라벨의 출처는 둘이다.

내부 라벨은 우리가 운영한 팝업의 결과보고서에서 추출한다. 계측 도구가 문서에 명시된 경우가 많다 — 게이트 계수기, 웨이팅 시스템의 입장 로그, POS 결제 건수, 증정물 소진량 등이다.

시장 라벨은 언론 보도와 업계 발표에서 수집한다. 우리가 운영하지 않은 팝업까지 포함하므로 표본을 3배 이상 늘려 주지만, 그 숫자가 어떻게 산출됐는지는 대개 적혀 있지 않다.

두 출처의 라벨에는 집계 기준(counting basis) 태그가 붙어 있다. entry(입장 계수), participation(체험 참여), organizer_claim(주

Table 2: 같은 행사의 두 측정. RXPU2515는 이마트 측데이 연계 팝업으로, 내부 게이트 계수와 주최자 측 발표가 6.9배 차이 난다.

레코드	측정 방식	값
RXPU2515	게이트 계수	2,305
	주최자 발표	15,854
	격차	6.88배
RTPU2440	내부 집계	9,000
	언론 추정	7,500
	격차	0.83배

최자 발표), `media_estimate`(언론 추정) 등이다. 지금까지 이 태그는 메타데이터로만 다루졌고, 학습에서는 모든 라벨을 같은 타깃으로 섞었다.

3. 집계 기준별 분해

라벨 362건(일수까지 확보된 건)을 (출처, 집계 기준) 조합으로 나누고 각 집단의 $\log_{10}$ 일평균 방문객 분포를 그렸다.

그림 1에서 가장 큰 두 집단이 양 끝에 있다. 주최자 발표는 하루 1,429명, 게이트 계수는 하루 519명이 중앙값이다.

주장 1. 주최자 발표와 게이트 계수는 서로 다른 물리량이다. 격차는 $0.440 \log_{10}$, 즉 2.75배이며, 집계 기준이 타깃 분산의 23.3%(η^2)를 설명한다.

반증 조건. 두 기준의 표본이 서로 다른 종류의 행사에 치우쳐 있다면 — 예컨대 주최자가 발표하는 팝업이 애초에 더 큰 행사라면 — 이 격차는 측정 차이가 아니라 선택 편향이다. 장소 등급과 IP 규모를 통제된 뒤에도 격차가 남는지 확인해야 한다.

4. 같은 행사를 두 번 재기

집단 수준의 격차만으로는 측정 차이와 수요 차이를 구분할 수 없다. 같은 행사를 두 방식으로 켜 사례가 필요하다. 내부 레코드와 시장 레코드를 브랜드·기간·장소로 대조해 5쌍을 찾았다.

이 중 3쌍은 두 값이 정확히 일치했다. 이는 독립적인 두 측정이 아니라, 내부 라벨이 보도자료에서 옮겨 적힌 것이다. 우리 "내부" 라벨의 일부가 실은 주최자 발표라는 뜻이며, 그 자체로 별개의 오염이다.

독립적인 2쌍은 표 2와 같다.

주장 2. 같은 행사를 게이트로 세면 2,305명, 주최자가 발표하면 15,854명이다. 집단 수준 격차 2.75배는 개별 사례에서 6.9배까지 벌어진다.

반증 조건. 독립 대조가 2쌍뿐이고, 그중 결정적인 것은 1쌍이다. 이 사례가 예외적으로 극단적일 수 있다. 내부·시장 중복 사례를 전수 탐색해 격차의 분포를 확인해야 한다.

Table 3: 문서 내부 전사 오류. 전부 총계 쪽이 부분합이었고, 일별 표가 옳았다.

레코드	원인과 확인 방법	격차
RTPU2582	총계가 마지막 2일 절단. 리플렛 재고(입고 4,000 — 전시 150 — 잔여 652)로 검증	1.13배
RIPU2520	문서 내부 불일치 736명. 대조할 정산·POS 부재로 미해소	1.10배
RTPU2454	인쇄 총계가 12/19 행 누락. 같은 표의 다른 합계는 전부 정확	1.09배
RIPU2602	총계가 4/14 하루 누락. 일별 매출 합이 세금계산서와 원 단위 일치	1.08배

5. 전사 오류는 이보다 훨씬 작다

라벨이 틀리는 또 다른 경로가 있다. 문서 안에서 총계와 일별 표가 어긋나는 경우다. 원문 재발굴로 4건을 규명했다(표 3).

중앙값 $0.040 \log_{10} = 1.10$ 배다. 집계 기준 격차의 1/7 수준이다.

주장 3. 우리가 다뤄 온 오차는 전사 실수가 아니라 정의의 혼재다. 전사 오류 1.10배 $\ll$ 모델 오차 2.37배 < 기준 격차 2.75배.

반증 조건. 전사 오류 4건은 재발굴로 발견된 것만 세었다. 발견되지 않은 오류가 체계적으로 크다면 이 순서가 바뀔 수 있다. 무작위 표본을 뽑아 전수 대조해야 한다.

6. 함의

그림 2의 순서가 이 연구의 결론이다. 현재 모델 오차가 집계 기준 격차보다 작다. 자와 눈금이 2.75배 어긋난 상태에서 소수점을 다두고 있었던 셈이다.

이를 직접 보이기 위해, 피처를 하나도 쓰지 않고 집계 기준별로 중앙값만 예측해 보았다.

전체 혼재 풀에서 MAE 0.4095였던 것이 기준별로 나누면 0.346으로 떨어진다(15.5% 개선). 참고로 132개 피처를 붙인 능선회귀의 혼재 풀 개선폭은 9.2%였다.

주장 4. 정의를 정리하는 것이 피처를 붙이는 것보다 이 규모에서 효과가 크다. 피처 0개 + 기준 총화 = 15.5% 개선, 피처 132개 = 9.2% 개선.

반증 조건. 기준별 상수 예측은 예측 대상의 집계 기준을 안다고 가정한다. 실제 예측 시점에 그 라벨이 어떤 기준으로 집계될지 모른다면 이 개선은 실현되지 않는다. 다만 우리 용도에서는 예측 대상의 집계 방식을 우리가 정하므로 가정이 성립한다.




Figure 1: 집계 기준별 $\log_{10}$ 일평균 방문객. 점 하나가 팝업 하나이고, 세로 막대는 집단 중앙값이다. 붉은색은 주최자 발표, 푸른색은 게이트 계수, 회색은 그 외. 표본 5건 이상인 기준만 표시했다. 두 중앙값이 2.75배 벌어져 있다.




Figure 2: 오차 척도의 비교. 점선은 현재 상수 예측 오차. 전사 오류는 모델 오차보다 한참 작고, 집계 기준 격차는 모델 오차보다 크다.




Figure 3: 풀을 동질화하면 상수 예측 오차가 줄어든다. 모델을 쓰지 않고 정의만 정리한 결과다.

7. 한계와 다음 단계

이 연구는 진단이며 처방이 아니다. 확정된 것과 열린 것을 구분해 둔다.

확정. 라벨 풀은 최소 두 개의 물리량을 담고 있고 격차는 2.75배다. 전사 오류는 그 1/7이므로 데이터 위생 작업의 한계 효용은 여기까지다. 혼재 풀에서 측정한 모델 성능은 해석할 수 없다.

열린 것. 직접 대조 쌍이 2개뿐이라 격차의 분포를 모른다. 기준 격차 중 선택 편향으로 설명되는 부분을 통제하지 않았다. 무엇보다, 동질 풀 내부의 환원 불가능한 측정 오차 — 같은 기준으로 두 번 재도 남는 차이 — 는 아직 재지 못했다. 이를 재려면 같은 기준의 반복 측정이 필요한데 현재 0건이다.

다음 단계. (1) 내부·시장 중복 사례를 전수 탐색해 격차 분포를 얻는다. (2) 시장 라벨 263건의 집계 기준을 원문에서 재판정한다. 현재 235건이 organizer_claim으로 뭉뚱그려져 있는데, 그 안에 게이트 계수를 인용한

보도가 섞여 있을 수 있다. 이 작업이 동질 풀의 크기를 결정한다. (3) 동질 풀만으로 학습 파이프라인을 재구성하고 그 위에서 피쳐 절제를 다시 검정한다.

모든 수치는 저장소 상태 2026년 7월 28일 기준이며, 그림 생성 코드가 데이터에서 직접 계산한다. 라벨이 갱신되면 그림과 표도 함께 바뀐다. 재현: `python3 paper/figs.py`.