

IP 파운데이션 월드모델 연구 노트 2

언론은 일치하고, 우리가 나눈다

수집 라벨의 스코프 판정과 타깃 분모 오류

Sweetspot 월드모델 연구

2026년 7월 28일

초 록

연구 노트 1에서 우리는 주최자 발표 수치가 현장 게이트 계수보다 2.75배 높다는 것을 보였다. 그렇다면 발표 수치 자체는 얼마나 믿을 수 있는가? 언론 보도가 서로 얼마나 어긋나는가? 이 노트는 같은 행사를 두 매체 이상이 보도한 29쌍을 대조한다. 결과는 예상과 반대였다 — 언론 수치는 서로 잘 맞는다. 두 보도의 차이는 중앙 1.15배이고, 89.7%가 앞서 측정한 집계 기준 격차(2.75배)보다 작다. 크게 갈리는 소수(최대 12배)를 원문 인용문으로 추적하자, 그것은 측정 잡음이 아니라 스코프와 시점의 차이였다 — 중간 집계 대 최종 집계, 단일 행사 대 다회차 합산, 부스 대 상권 전체. 이를 판정하는 분류기를 만들어 수집 라벨 328건에 적용한 결과 27건(8.2%)이 타깃으로 쓸 수 없는 스코프였다. 더 중요한 것은 타깃 분모의 오류다. “개장 3일 만에 10만 명”이라는 중간 집계 라벨을 전체 운영 기간 25일로 나누면 일평균이 4,000명으로 나오지만 실제로는 33,333명이다. 이런 분모 오류가 21건 있었고 전부 같은 방향(과소평가)이었으며, 중앙 3.25배 어긋나 있었다. 언론 보도의 신뢰도를 문제 삼기 전에, 우리가 그 숫자를 어떤 창으로 나누는지를 먼저 확인해야 한다.

1. 앞선 노트에서 이어지는 물음

연구 노트 1은 라벨 풀이 두 개의 서로 다른 물리량을 담고 있음을 보였다. 우리가 직접 운영한 팝업의 게이트 계수(중앙 519명/일)와 언론에 보도된 주최자 발표(중앙 1,429명/일)가 2.75배 벌어져 있었고, 같은 행사를 두 방식으로 켜 사례에서는 6.9배까지 갈렸다.

여기서 자연스러운 다음 물음이 나온다. 주최자 발표 수치 자체는 얼마나 안정적인가? 만약 언론 보도가 서로 크게 어긋난다면, 2.75배라는 격차는 발표 수치의 잡음에 묻힐 것이다. 반대로 보도끼리 잘 맞는다면, 그 격차는 실재하는 체계적 편향이다.

이 물음에 답할 자료가 저장소에 있었다. 수집 과정에서 같은 행사를 다룬 다른 기사를 만나면 `alt_figures` 필드에 원문 인용과 함께 기록해 두었다. 지금까지 이 필드는 참고 메모로만 쓰였고 분석된 적이 없다.

2. 같은 행사, 다른 매체

`alt_figures`를 가진 수집 라벨에서 (주 수치, 대안 수치) 쌍 31개를 추출했다. 그중 2쌍은 대안 수치에 “단독 수치 아님” 같은 스코프 경고가 이미 붙어 있어 제외하고, 남은 29쌍의 로그 비율 차이를 보았다.

주장 1. 언론 보도 수치는 서로 잘 맞는다. 두 보도의 차이는 중앙 $0.062\log_{10} = 1.15$ 배이고, 29쌍 중 26쌍(89.7%)이 집계 기준 격차 2.75배보다 작게 어긋난다.

반증 조건. 이 일치는 독립성이 아니라 복제일 수 있다. 여러 매체가 같은 보도자료를 받아쓰면 수치가 같아진다. 각 인용문의 발행 매체와 날짜를 대조해 실제로 독립 취재인지 확인해야 한다. 표본도 29쌍뿐이다.




Figure 1: 같은 행사를 보도한 두 수치의 차이(누적분포). 파란 파선은 중앙값, 붉은 점선은 연구 노트 1에서 측정한 집계 기준 격차. 보도의 89.7%가 기준 격차보다 작게 어긋난다.

이 결과는 연구 노트 1의 주장을 강화한다. 발표 수치의 자체 산포(1.15배)가 게이트 대비 격차(2.75배)보다 훨씬 작으므로, 그 격차는 잡음이 아니라 체계적 편향이다.

3. 크게 갈리는 소수는 왜 갈리는가

그림 1의 오른쪽 꼬리 — 2.5배에서 12배까지 벌어진 5쌍 — 을 원문 인용문으로 추적했다. 결과는 표 1과 같다.

주장 2. 보도 간 큰 불일치는 측정 잡음이 아니라 스코프·시점의 차이이다. 다섯 사례 전부 “무엇을, 언제까지, 어디

Table 1: 크게 갈린 5쌍의 원인. 어느 것도 측정 오차가 아니다.

차이	원인
12.0배	8일 누적 총계 대 일평균 — 단위 차이
4.0배	종료 직전 누적 대 개장 3일 누적 — 시점 차이
2.7배	더현대 단독 대 3개 점포 합계 — 범위 차이
2.5배	2023-2025 시리즈 누적 대 단년 10일 — 기간 차이
2.2배	전체 운영 기간 대 공식 행사 4일 — 창 차이




Figure 2: 수집 라벨 328건의 스코프 판정. 붉은색은 타깃 분모가 잘못된 건으로, 스코프 오염과 별개의 결함이다.

까지 세었는가”가 달랐다.

반증 조건. 다섯 사례는 우리가 alt_figures를 기록해 둔 것만 본 것이다. 기록하지 않은 불일치가 다른 성격일 수 있다. 다만 기록 여부가 원인 유형과 상관될 이유는 없어 보인다.

4. 스코프 분류기

위 유형을 원문 인용문에서 판정하는 규칙 기반 분류기를 만들었다. 판정 축은 넷이다. 중간 집계(“개장 3일 만에”), 전망치(“넘어설 것으로”), 다회차 합산(“세 차례 팝업”), 범위 초과(“잠실 일대”). 이 중 하나라도 걸리면 최종 집계 타깃으로 쓸 수 없다.

설계에서 한 가지를 특히 조심했다. “누적”이라는 단 어만으로는 판정할 수 없다. “8일간 누적 1만 2천 명”은 단일 행사의 정당한 총계이고, “3회차 누적 17만 명”은 다른 행사들의 합이다. 회차나 점포를 세는 표현이 함께 있을 때만 다회차로 본다. 이 구분을 넣기 전 조잡한 규칙은 328건 중 118건(36%)을 오염으로 잡았으나, 대부분 정당한 총계였다.

5. 더 큰 문제 --- 타깃 분모

스코프 분류 과정에서 예상하지 못한 결함이 드러났다. 인용문이 말하는 기간과 우리가 저장한 운영일수가 어긋나는 경우다.




Figure 3: 분모 교정 전후. 각 섹션이 레코드 하나이며, 회색이 교정 전, 붉은색이 교정 후다. 21건 전부 오른쪽으로 — 즉 위로 — 움직인다.

우리 타깃은 총 방문객이 아니라 일평균 방문객이다. 팝업의 운영 기간이 하루에서 두 달까지 다르므로 총계를 그대로 쓰면 기간 길이가 타깃을 지배한다. 그래서 총계를 운영일수로 나눈다. 그런데 라벨이 중간 집계인데 분모로 전체 기간을 쓰면 어떻게 되는가?

“지난 4월 잠실 월드몰 일대에서 진행된 포켓몬타운 2025 팝업은 오픈 3일 만에 방문객 10만 명을 돌파했다.”

이 라벨의 저장된 운영일수는 25일이다. $100,000 \div 25 = 4,000$ 명/일로 계산되지만, 인용문이 말하는 것은 $100,000 \div 3 = 33,333$ 명/일이다. 8.3배 과소평가다. 인용문에 기간이 명시된 105건 중 21건에서 저장 일수와 25% 넘게 어긋났다. 그리고 전부 같은 방향이었다 — 저장 일수가 인용 일수보다 컸다. 교정 시 일평균이 중앙 0.512 $\log_{10}$ (3.25배), 최대 0.921(8.3배) 올라간다.

주장 3. 타깃 분모가 21건에서 틀렸고 전부 같은 방향이다. 중간 집계 라벨에 전체 운영 기간을 분모로 써서 일평균이 중앙 3.25배 과소평가됐다.

반증 조건. 인용문의 기간 표현을 정규식으로 뽑았으므로 오독이 있을 수 있다. 특히 “지난 3일까지 5일간”처럼 두 기간이 한 문장에 있으면 앞의 것을 잡는다. 21건은 수동 확인이 필요하다.

6. 왜 이 방향인가

21건이 모두 같은 방향이라는 사실이 우연이 아니다. 구조적 이유가 있다.

언론은 팝업이 화제일 때 기사를 쓴다. 그 시점은 대개 운영 초반이고, 그래서 기사에 실리는 수치는 중간 집계다. 반면 우리 수집 파이프라인은 그 팝업의 전체 운영 기간을 별도로 확인해 저장한다. 두 정보가 각각 옳지만 짝이 맞지 않는다.

이 구조는 편향의 방향을 고정한다. 중간 집계는 항상 전체 기간보다 짧은 창이므로, 전체 기간으로 나누면

항상 과소평가된다. 무작위 오차가 아니라 체계적 하향 편향이다.

7. 결과의 크기

솔직히 적으면, 이 교정이 풀 전체를 크게 바꾸지는 않는다. 328건 중 21건이므로 수집 라벨의 일평균 분포 중앙값은 움직이지 않았고, 표준편차가 0.538에서 0.549로 약간 넓어졌을 뿐이다.

그러나 개별 레코드 수준에서는 최대 8.3배의 교정이다. 그리고 이 21건은 우연히 모인 것이 아니라 “화제성이 높아 초기에 기사화된 팝업”이라는 특정 유형이다. 즉 교정 전 데이터는 **홍행한 팝업의 일평균을 체계적으로 낮게 기록하고 있었다**. 수요를 예측하려는 모델에게 이는 무해한 잡음이 아니다.

8. 한계와 다음 단계

확정. 언론 보도 수치는 서로 잘 맞는다(중앙 1.15배). 따라서 연구 노트 1의 2.75배 격차는 발표 수치의 잡음이 아니라 체계적 편향이다. 큰 불일치는 스코프·시점 차이이며 판정 가능하다. 타깃 분모가 21건에서 틀렸고 전부 같은 방향이다.

열린 것. 보도 간 일치가 독립 취재의 결과인지 보도자료 복제의 결과인지 구분하지 못했다. 분류기는 규칙 기반이므로 인용문이 짧거나 모호하면 판정하지 못한다 — 328건 중 기간이 명시된 것은 105건뿐이다. 나머지 223건의 분모는 검증되지 않은 채로 남아 있다.

다음 단계. (1) 인용문의 발행 매체와 날짜를 대조해 보도 독립성을 확인한다. (2) 기간이 명시되지 않은 223건에 대해 원문 URL을 다시 열어 장을 확정한다. (3) 스코프가 확정된 라벨만으로 학습 풀을 재구성하고, 그 위에서 모델을 다시 검증한다. 연구 노트 1과 2가 함께 말하는 것은, 이 재구성이 끝나기 전의 모든 모델 비교가 해석 불가능하다는 것이다.

분류기 구현은 `ingest/market_scope.py`, 그림 생성은 `paper/figs.py`에 있으며 모두 저장소 데이터에서 직접 계산한다. 라벨이 갱신되면 수치도 함께 바뀐다.