

IP 파운데이션 월드모델 연구 노트 4

접근성과 유인

라벨을 정리하자 다섯 축이 처음으로 상수를 이겼다

Sweetspot 월드모델 연구

2026년 7월 28일

초 록

앞선 세 노트는 전부 진단이었다. 라벨 풀이 두 물리량을 섞고 있고(노트 1), 스코프와 시점이 어긋나 있으며(노트 2), 주최자 발표는 측정이 아니라 이산 어휘였다(노트 3). 이 노트는 그 진단을 실행에 옮긴다. 실제 계수만 남긴 75건의 풀에서 피처를 132개에서 줄여 가며 검정한 결과, 다섯 개 속성에서 처음으로 상수 중앙값을 유의하게 이겼다(차이 -0.0540 , 95% 신뢰구간 -0.103 에서 -0.010). 132개 전부로는 이기지 못했고(차이 -0.0315 , 신뢰구간이 0을 포함), 셋으로 줄이면 다시 못 이겼다. 최적점은 다섯이다. 남은 다섯은 타깃 폭, 매장 노출도, 입장 허들, 미디어 투입, 굿즈 규모이며 — 정리하면 대상이 얼마나 넓은가, 당기 얼마나 쉬운가, 당으면 무엇을 얻는가의 세 축이다. 제거했을 때 오히려 성능이 좋아진 두 속성은 IP 인지 폭과 콜라보 강도였다. IP가 얼마나 유명한지는 방문객 수를 설명하지 못한다. 이 다섯 축은 팝업에 국한되지 않는 형태이며, IP 파운데이션 월드모델의 도메인 불변 골격 후보다.

1. 진단에서 실행으로

이 연구의 목표는 IP가 대중과 만나는 모든 접점의 반응을 하나의 모델로 다루는 것이다. 첫 도메인인 팝업스토어에서 우리는 오랫동안 같은 벽에 부딪혔다 — 어떤 모델도 상수 중앙값을 유의하게 이기지 못했다.

앞선 세 노트는 그 벽의 정체를 밝혔다. 라벨이 문제였다.

- 노트 1: 주최자 발표와 현장 계수가 2.75배 벌어져 한 컬럼에 섞여 있다.
- 노트 2: 중간 집계에 전체 기간을 분모로 써서 21건의 일평균이 중앙 3.25배 과소평가됐다.
- 노트 3: 주최자 발표 294건의 고유값은 86개뿐이고 상위 12개가 57%를 차지한다. 이산 어휘이며 정보가 소실됐다.

세 진단의 결론은 하나였다. 학습에 쓸 수 있는 것은 실제 계수 계열뿐이다. 게이트 계수 49건과 체험 참여 계수 29건, 스코프 게이트를 통과하고 신뢰등급 A/B인 75건이 그 전부다.

이 노트는 그 75건 위에서 처음으로 모델을 다시 세운다.

2. 피처가 많을수록 나쁘다

75건에 132개 피처는 명백히 과하다. Riley 등(2019)의 표본 크기 공식에 우리 조건을 대입하면 $p=132$, $R^2=0.15$ 일 때 필요 표본은 $n \approx 7,240$ — 현재의 97배다. $p=5$ 로 줄이면 $n \approx 274$ 로 3.7배까지 내려온다.

그래서 피처 집합을 단계적으로 줄이며 검정했다. 평가는 앞선 노트와 동일하게 IP 단위로 묶고 시간 순서를




Figure 1: 피처 개수와 성능. 점은 상수 대비 MAE 차이(아래가 좋음), 막대는 95% 신뢰구간. 푸른색이 신뢰구간이 0을 넘지 않는 — 즉 유의한 — 지점이다.

강제하는 교차검증이며, 상수 중앙값 대비 페어드 부트스트랩 95% 신뢰구간으로 판정한다.

주장 1. 피처를 132개에서 5개로 줄이자 처음으로 상수를 유의하게 이겼다 ($\Delta = -0.0540$, CI $[-0.103, -0.010]$). 132개로는 이기지 못했고 3개로 줄이면 다시 못 이겼다.

반증 조건. 다섯 개 집합은 열 개 안에서 leave-one-out 결과를 보고 고른 것이므로, 같은 데이터에서 고르고 같은 데이터에서 검정한 선택 편향이 있다. 새 표본에서 재현되는지 확인해야 한다. $n=75$, 4폴드에서 신뢰구간 상단이 -0.010 으로 0에 가깝다는 점도 감안해야 한다.

Table 1: 피쳐 집합별 결과. 계수 계열 $n=75$, 4폴드. 상수 MAE는 0.4427.

피쳐 집합	p	MAE	상수 대비
전체	132	0.4112	-0.0315 CI[-0.089, +0.027]
실질만	67	0.4053	-0.0375 CI[-0.102, +0.025]
기획 속성	10	0.4052	-0.0376 CI[-0.074, -0.004]
기여 속성	5	0.3888	-0.0540 CI[-0.103, -0.010]
상위 3종	3	0.4053	-0.0374 CI[-0.093, +0.013]



Figure 2: 속성별 기여. 양수(푸른색)는 제거 시 오차가 늘어나는 — 즉 기여하는 — 속성이고, 음수(붉은색)는 제거 시 오히려 좋아지는 속성이다.

3. 어느 속성이 기여하는가

열 개의 기획 속성은 모두 0~4 척도의 순서형이다. 원문 문서를 읽어 태깅한 것으로, 체험 요소의 밀도, 굿즈 규모, 포토존 수, 콜라보 강도, IP의 대중 인지 폭, 타깃 폭, 입장 허들, 미디어 투입, 시즌 적합성, 매장 내 노출도를 켜다. 각 속성을 하나씩 빼고 나머지 아홉으로 학습해, 뺀 때 오차가 얼마나 늘어나는지를 재었다.

다섯이 기여하고, 셋은 중립이며, 둘은 해롭다.

주장 2. IP 인지 폭과 콜라보 강도는 제거하면 성능이 좋아진다 (각각 -0.0117, -0.0116). IP가 얼마나 유명한지는 방문객 수를 설명하지 못한다.

반증 조건. 두 속성이 다른 다섯과 상관돼 있어 다중공선성으로 계수가 불안정해진 결과일 수 있다. 또한 우리 태깅에서 IP 인지 폭은 “대중 인지”를 재는데, 방문객을 결정하는 것은 인지가 아니라 동원력일 수 있다. 두 개념을 분리해 다시 태깅하면 결과가 바뀔 수 있다.

이 결과는 직관에 반하지만 개념적으로는 설명된다. 대중 인지도가 높은 IP — 예컨대 전 국민이 이름을 아는 연예인 — 라도 그 인지가 오프라인 방문으로 이어지지 않는다. 23년간 단독 공연을 한 번도 하지 않은 톱스타의 팝업과, 인지도는 낮지만 코어 팬덤이 단단한 IP의 팝업 중 어느 쪽에 사람이 더 오는가는 인지도로 답할 수 없다.

Table 2: 기여 속성과 타깃의 스피어만 상관($n=75$).

속성	ρ	p
타깃 폭	+0.362	0.001
매장 노출도	+0.358	0.002
미디어 투입	+0.273	0.018
굿즈 규모	+0.250	0.031
입장 허들	-0.236	0.041
콜라보 강도	+0.153	0.191
IP 인지 폭	—	—

4. 남은 다섯의 구조

기여하는 다섯을 늘어놓으면 세 갈래로 묶인다.

대상 --- 누구를 향하는가. 타깃 폭($\rho = +0.362$)이 가장 강한 단일 신호다. 코어 팬덤만 겨냥한 팝업과 전 연령을 겨냥한 팝업 사이에 방문객이 갈린다.

접근성 --- 닿기 얼마나 쉬운가. 매장 노출도(+0.358)와 입장 허들(-0.236)이 반대 부호로 짝을 이룬다. 1층 정면에 있으면 지나가다 들어오고, 유료 사전예약이면 작성하고 와야 한다.

유인 --- 닿으면 무엇을 얻는가. 미디어 투입(+0.273)과 굿즈 규모(+0.250)다. 알려야 오고, 살 것이 있어야 온다.

주장 3. 남은 다섯은 “대상 × 접근성 × 유인” 구조를 이룬다. IP의 유명세가 아니라, 그 IP를 향한 사람이 얼마나 쉽게 닿고 닿으면 무엇을 얻는가다.

반증 조건. 세 갈래 분류는 사후 해석이다. 다섯 속성이 실제로 세 잠재 요인으로 묶이는지는 요인분석 등으로 확인해야 하며, $n=75$ 에서는 그 검정 자체의 검정력이 부족하다.

5. 왜 이것이 파운데이션 모델의 골격인가

이 다섯 축은 팝업스토어의 언어로 쓰였지만, 팝업에만 있는 것이 아니다.

아이돌 데뷔를 생각해 보자. 대상 폭은 코어 팬덤을 겨냥한 앨범인지 대중을 겨냥한 곡인지다. 접근성은 음원 스트리밍(허들 0)과 콘서트 티켓(허들 4)의 차이이며, 음악방송 출연은 매장 노출도에 해당한다. 유인은 미디어 투입과 앨범 구성 (포토카드·특전)이다.

광고 모델 기용도 같은 구조로 읽힌다. 게임 출시도 마찬가지다. 반면 이번에 탈락한 “IP 인지 폭”은 도메인마다 의미가 달라지는 축이었다.

주장 4. 다섯 축은 도메인 불변 형태로 기술된다. IP 파운데이션 월드모델의 공유 표현 후보로서, 도메인별로 다른 것은 축의 값이지 축 자체가 아니다.

반증 조건. 이는 아직 가설이다. 아이돌 도메인에서 같은 다섯 축을 태깅해 전이가 실제로 일어나는지 검정하지 않았다. 앞선 문헌 검토에서 소표본 도메인 간 전이




Figure 3: 다섯 속성과 타깃의 관계. 각 패널은 0-4 척도별 분포이며 가로 막대는 중앙값이다. 색은 세 갈래를 구분한다 — 대상(보라), 접근성(파랑), 유인(주황).

는 부정적 결과가 지배적이었으므로 (Standley 등 2020, Ben-David 등 2010), 기대치를 낮게 잡아야 한다.

6. 한계

정직하게 적어야 할 것이 여럿이다.

선택 편향. 다섯 속성은 열 개 안에서 leave-one-out 을 보고 골랐고, 같은 데이터로 검정했다. 이 절차는 낙관적이다. 엄밀하게는 속성 선택을 폴드 안에서 수행하는 중첩 교차검증이 필요하다.

경계에 있는 유의성. $\Delta = -0.0540$ 의 신뢰구간 상단이 -0.010 이다. 0에서 멀지 않다. 표본이 몇 건 바뀌면 판정이 뒤집힐 수 있다 — 실제로 앞선 세션에서 라벨 5 건이 바뀌자 모델 순위가 뒤집힌 적이 있다.

여전히 작은 개선. 오차 배율로 보면 2.77배에서 2.45배다. 실무에서 “2.5배 안에 들어온다”는 것은 500명 예측에 200-1,250명 구간을 뜻한다. 쓸 만한 예측이라 하기 어렵다.

태깅의 주관성. 다섯 속성은 원문을 읽고 0-4로 매긴 값이다. 같은 문서를 다른 평가자가 매기면 얼마나 일치하는지 재지 않았다.

7. 다음 단계

즉시. 속성 선택을 폴드 안으로 넣은 중첩 교차검증으로 다섯 축의 유의성을 재확인한다. 그리고 태깅 재현성을 쟀다 — 같은 문서를 두 번 태깅해 일치도를 본다.

표본. Riley 기준으로 $p=5$ 에 필요한 표본은 $n \approx 274$ 다. 현재 75건에서 3.7배가 필요하다. 노트 3에서 확인했듯 발표 수치는 쓸 수 없으므로, 계수 라벨을 새로 확보하는 경로 — 웨이팅 시스템 로그, 유통사 층별 집계 — 를 열어야 한다.

도메인 확장. 아이돌 도메인의 레코드에 같은 다섯 축을 태깅하고, 전이가 일어나는지 검정한다. 이것이 파운데이션 모델 가설의 첫 시험이다.

평가 코드는 `state/evaluate.py`, 그림 생성은 `paper/figs.py`이며 모두 저장소 데이터에서 직접 계산한다. 라벨이 갱신되면 모든 수치가 함께 바뀐다.