

IP 파운데이션 월드모델 연구 노트 5

옳은 추과 찾을 수 있는 추

노트 4의 유의성은 선택 편향이었다 --- 그러나 다섯 추 자체는 살아남았다

Sweetspot 월드모델 연구

2026년 7월 28일

초 록

노트 4는 다섯 개 속성이 처음으로 상수를 유의하게 이겼다고 보고했다(차이 -0.0540 , 95% 신뢰구간 -0.103 에서 -0.010). 그 다섯은 열 개 후보 중에서 골랐는데, 고르는 데 쓴 데이터와 검정하는 데 쓴 데이터가 같았다. 이 노트는 그 편향을 중첩 교차검증으로 제거한다. 결과는 노트 4의 표제 주장을 철회시킨다. 폴드 안에서 다섯을 새로 고르게 하면 차이는 -0.0400 으로 줄고 신뢰구간이 0을 넘어간다. 그런데 같은 실험에서 예상 밖의 것이 살아남았다 — 선택을 아예 하지 않고 열 개를 전부 쓴 집합은 유의하게 이긴다(차이 -0.0376 , 신뢰구간 -0.0735 에서 -0.0042). 표본 75건에서 선택은 도움이 아니라 해악이었다. 한편 IP 무작위 분할을 40회 반복하면 노트 4의 고정 다섯 중은 40회 전부 상수를 이긴다(100%). 세 결과를 화해시키면 하나의 구분이 남는다: 그 다섯이 옳은가와, 데이터가 그 다섯을 알려줄 수 있는가는 다른 질문이다. 현재 표본은 앞의 질문에 그렇다고 답하고 뒤의 질문에 아니라고 답한다. 파운데이션 모델의 공유 추은 데이터에서 학습할 것이 아니라 선형적으로 설계하고 데이터로 검증해야 한다는 뜻이다.

1. 왜 노트 4를 다시 여는가

노트 4는 이 연구에서 처음으로 상수를 이긴 기록이었다. 라벨 폴을 정리해 실제 계수 75건만 남기고, 기획 단계에서 사람이 매긴 열 개의 서수 속성 중 다섯 개를 골라 썼을 때 평균절대오차가 상수 중앙값 대비 0.0540 낮아졌고 95% 신뢰구간이 0을 포함하지 않았다.

그 노트의 한계 절에 나는 이렇게 썼다.

다섯 개 집합은 열 개 안에서 leave-one-out 결과를 보고 고른 것이므로, 같은 데이터에서 고르고 같은 데이터에서 검정한 선택 편향이 있다.

이 문장은 정직했지만 충분하지 않았다. 편향이 있다고 적어 두는 것과 편향을 제거한 수치를 내놓는 것은 다르다. 표제에 유의성을 걸어 놓고 각주에 편향을 적어 두면 읽는 사람은 표제를 기억한다. 이 노트는 그 수치를 낸다.

선택 편향이 왜 생기나. 열 개 속성 중 다섯을 고르는 방법은 252가지다. 252가지를 전부 같은 75건에 시험하고 가장 좋은 것을 고르면, 그 다섯은 이 75건의 신호뿐 아니라 이 75건의 잡음에도 맞춰진다. 잡음에 맞춘 부분은 새 데이터에서 사라지므로, 같은 데이터로 잰 성능은 실제보다 좋다. 표본이 클수록 이 부풀림은 작아지지만 75건은 크지 않다.

2. 중첩 교차검증

교정 방법은 표준적이다. 성능을 재는 바깥 루프 안에 속성을 고르는 안쪽 루프를 넣는다. 바깥 폴드의 검정 데이터는 안쪽 선택 과정이 절대 보지 못한다.

Table 1: 중첩 교차검증 결과. 시간순 4폴드, 짝지는 부트스트랩 95% 신뢰구간. 음수가 상수보다 낫다는 뜻이다.

피쳐 집합	MAE	차이	95% 신뢰구간
상수 중앙값	0.4427	—	—
중첩 선택 5종	0.4027	-0.0400	$[-0.0913, +0.0035]$
전체 10종 (선택 없음)	0.4052	-0.0376	$[-0.0735, -0.0042]$
참고 — 노트 4 고정 5종 -0.0540 $[-0.103, -0.010]$ (선택 편향 포함, 철회 대상)			

- **바깥:** IP 그룹 $\times$ 시간순 4폴드. 같은 IP가 학습과 검정에 동시에 들어가지 않으며, 검정 구간은 항상 학습 구간보다 뒤다.
- **안쪽:** 각 바깥 폴드의 학습 데이터만으로 leave-one-out을 돌려 열 개 중 다섯을 고른다.
- **검정:** 고른 다섯으로 학습해 바깥 검정 폴드를 예측한다.

비교 대상은 셋이다. (a) 노트 4의 고정 다섯 중 — 전체 데이터를 보고 고른 것, (b) 폴드마다 새로 고른 다섯 중, (c) 선택 없이 열 개 전부.

주장 1. 노트 4의 표제 주장 “다섯 개 속성이 상수를 유의하게 이겼다”를 철회한다. 그 유의성은 선택 편향으로 부풀려진 값이다. 편향을 제거하면 차이는 -0.0400 이고 신뢰구간이 0을 넘어간다.

반증 조건. 같은 다섯을 미리 고정한 채 새로 수집한




Figure 1: 같은 다섯 축이 프로토콜에 따라 유의하기도 하고 아니기도 하다. 왼쪽 두 막대가 노트 4와 이 노트의 직접 비교다 — 선택을 폴드 안으로 넣자 신뢰구간이 0을 넘는다. 오른쪽 두 막대는 무작위 분할 반복 결과로, 다시 0을 넘지 않는다.




Figure 2: 폴드마다 다른 다섯을 고른다. 네 폴드 전부에서 뽑힌 것은 굿즈 규모와 콜라보 강도 둘뿐이다. 나머지 여덟 개는 폴드에 따라 들어갔다 나갔다 한다.

독립 표본에서 검정해 신뢰구간이 0을 넘지 않으면, 이 철회는 과했던 것이 된다.

3. 살아남은 것: 선택하지 않기

표에서 눈에 띄는 것은 세 번째 줄이다. 아무것도 고르지 않고 열 개를 전부 넣은 집합이 유의하게 이긴다. 차이의 크기는 중첩 선택보다 작지만(-0.0376 대 -0.0400) 신뢰구간이 훨씬 좁다.

이유는 분산이다. 중첩 선택의 평균 성능은 조금 더 좋지만 폴드마다 다른 다섯을 고르기 때문에 폴드 간 편차가 크다. 선택 자체가 잡음원이 된다. 열 개를 전부 쓰면 어떤 속성이 그 폴드에 안 맞아도 나머지가 흡수한다.

그리고 하나가 정면으로 어긋난다. 폴드별 선택 결과를 보면 콜라보 강도가 네 폴드 전부에서 뽑혔다. 그런데 노트 4는 콜라보 강도를 IP 인지 폭과 함께 제거했을 때 오히려 성능이 좋아지는 두 속성으로 지목했다. 같은 데이터, 같은 절차, 정반대 결론이다.

Table 2: IP 무작위 5폴드 × 40회 반복. 시간 순서 제약 없음.

피쳐 집합	차이 중앙	평균	표준편차	상수를 이긴 비율
기획 10종	-0.0290	-0.0282	0.0078	98%
고정 5종	-0.0442	-0.0420	0.0071	100%




Figure 3: 40회 반복의 차이 분포. 고정 다섯 종은 40회 전부 0의 왼쪽에 있다. 열 종보다 분포 전체가 왼쪽으로 밀려 있으며 폭은 비슷하다.

이 모순은 어느 쪽이 틀렸다는 뜻이 아니라 둘 다 표본 크기가 감당하지 못하는 판정을 했다는 뜻이다. $n=75$, 후보 10개에서 개별 속성의 기여를 순위 매기는 것은 데이터가 지탱하지 못한다.

주장 2. $n=75$ 에서 열 개 속성 중 어느 부분집합이 좋은지는 데이터로 결정할 수 없다. 같은 절차가 폴드마다 다른 답을 내고, 노트 4가 해롭다고 지목한 속성을 전 폴드에서 선택한다.

반증 조건. n 을 150 이상으로 늘렸을 때 폴드 간 선택 일치도(자카드)가 0.8을 넘으면 결정 가능해진 것이다. 현재 인접 폴드 간 일치도는 0.4에서 0.6이다.

4. 그런데 다섯 축은 왜 계속 이기나

여기서 끝내면 다섯 축은 폐기된다. 그런데 세 번째 실험이 반대 방향을 가리킨다.

시간순 4폴드는 검정 구간이 언제나 최근 데이터임으로 폴드가 넷뿐이고 각 폴드의 검정 표본이 얇다. 신뢰구간이 넓은 것은 당연하다. 시간 제약을 풀고 IP 단위 무작위 5폴드를 서로 다른 난수 40회로 반복하면 표본을 훨씬 촘촘히 쓸 수 있다. 미래 정보를 쓰므로 실전 성능의 상한이지 실전 추정치는 아니지만, 효과의 안정성을 재는 데는 낫다.

고정 다섯 종은 40회 중 40회 상수를 이겼고, 열 종보다 일관되게 더 나았다. 무작위 분할이 관대한 프로토콜이라는 점을 감안해도, 다섯이 열보다 나쁘다는 신호는 어디에도 없다.

5. 세 결과를 화해시키기

정리하면 이렇다.

1. 다섯을 고정해서 쓰면 안정적으로 이긴다 (40/40회).
2. 다섯을 데이터에서 고르게 하면 이득이 사라진다 (신뢰구간이 0을 넘음).
3. 아무것도 고르지 않고 열을 전부 쓰면 약하지만 이긴다 (신뢰구간이 0을 안 넘음).

1번과 2번이 모순처럼 보이지만 아니다. 두 문장은 서로 다른 것을 말한다.

그 다섯이 옳은 추인가? — 현재 증거로는 그렇다. 고정해 쓰면 반복 검증에서 언제나 이긴다.

데이터가 그 다섯을 알려줄 수 있나? — 아니다. 폴드 안에서 고르게 하면 매번 다른 답이 나오고 이득이 사라진다.

즉 다섯 측은 존재하지만 발견 가능하지 않다. $n=75$ 에서 그 다섯이 선택된 경로는 데이터가 아니라 데이터를 본 사람이었고, 그 경로는 재현되지 않는다.

주장 3. 다섯 측은 실재할 가능성이 높으나 현재 표본으로는 데이터에서 발견할 수 없다. 따라서 그 다섯을 쓰려면 데이터가 아니라 도메인 이론으로 정당화해야 한다.

반증 조건. n 이 충분히 커진 뒤 순수 데이터 기반 선택이 이 다섯에 수렴하면, “발견 불가”는 표본 문제였을 뿐 이론적 정당화는 불필요했던 것이 된다.

6. 파운데이션 모델 설계에 대한 함의

이 결과는 표본 크기에 관한 기술적 각주가 아니라 아키텍처 결정을 바꾼다.

파운데이션 월드모델의 핵심은 도메인을 가로지르는 공유 표현이다. 팝업, 아이돌 데뷔, 광고 모델, 게임 론칭이 같은 잠재 축 위에 놓여야 전이가 일어난다. 그 공유 축을 어떻게 정할 것인가에 두 갈래가 있다.

- **학습한다:** 다도메인 데이터를 넣고 공유 표현을 학습시킨다. 표준적인 멀티태스크 접근이다.
- **설계한다:** 축을 이론으로 고정하고 데이터는 검증과 보정에만 쓴다.

이 노트의 결과는 현재 데이터 규모에서 첫 갈래가 작동하지 않는다고 말한다. 열 개 후보에서 다섯을 고르는 것도 못하는 표본으로 자유로운 공유 표현을 학습시키면, 학습되는 것은 축이 아니라 잡음이다.

문헌도 같은 방향이다. Standley 등(2020)은 어떤 태스크가 어떤 태스크를 도울지 사전 유사성으로 예측할 수 없고 직접 시험해야만 알 수 있음을 보였으며, 데이터가 5%로 줄면 해로운 태스크 쌍의 비율이 40%에서 60%로 오른다고 보고했다. Maurer 등(2016)의 경계에서 공유 표현 항은 $1/\sqrt{nT}$ 로, 태스크 고유 항은 $1/\sqrt{n}$ 로 줄어든다 — 태스크 수 T 를 늘리는 것이 공유 항에는 도움이 되지만 태스크당 표본 n 이 작으면 고유 항이 지배한다. 우리는 $n = 75$, $T = 1$ 이다.

그래서 다음 설계는 이렇게 간다. 다섯 축(타깃 폭, 매장 노출도, 입장 허들, 미디어 투입, 굿즈 규모)을 학습 대상이 아니라 아키텍처의 고정 구조로 놓는다. 신경망의 첫 층을 이 다섯 축에 해당하는 슬롯으로 고정하고, 도메인별 인코더가 자기 문서를 이 다섯 슬롯에 사상하도록 학습시킨다. 축 자체는 데이터가 바꾸지 못한다. 데이터가 하는 일은 각 도메인의 원자료를 다섯 슬롯으로 번역하는 함수를 배우는 것뿐이다.

이 구조는 표본이 작을 때 유리하다. 자유도가 축 발견에 쓰이지 않고 전부 사상 함수에 쓰인다. 그리고 반증 가능하다 — 아이돌 도메인 라벨을 확보해 같은 다섯 축을 태깅했을 때 전이가 일어나면 축이 도메인 불변이라는 증거이고, 일어나지 않으면 축은 팝업 국소적이다.

7. 한계

- 무작위 5폴드 반복은 시간 순서를 쓰지 않는다. 실전 성능이 아니라 상한이며, 안정성 판정에만 쓸 수 있다.
- “다섯이 옳다”는 결론은 여전히 이 75건에서 그 다섯이 골라졌다는 사실에 의존한다. 완전히 독립적인 확증은 새 표본에서만 나온다.
- 시간순 폴드가 넷뿐이라 짝지은 부트스트랩의 유효 표본이 작다. 신뢰구간 자체가 넓게 나오는 구조적 이유이며, 유의하지 않음이 효과 없음을 뜻하지 않는다.
- 열 개 서수 속성은 사람이 매긴 것이고 평정자 간 일치도를 아직 재지 않았다. 속성 자체의 신뢰도가 성능 상한을 깔고 있을 수 있다.

8. 다음

1. 열 개 서수 속성의 평정자 간 일치도 측정 — 잡음 상한을 먼저 안다.
2. 아이돌 도메인 라벨 확보 후 같은 다섯 축 태깅, 전이 검증. 파운데이션 가설의 첫 직접 시험이다.
3. 다섯 슬롯 고정 구조의 최소 신경망 구현과 GBDT 대비 검증.
4. $n=150$ 도달 시 폴드 간 선택 일치도 재측정 — 발견 가능성이 표본 문제였는지 확인.

참고문헌

- Ben-David, S. et al. (2010). A theory of learning from different domains. *Machine Learning*, 79(1–2), 151–175.
- Maurer, A., Pontil, M., Romera-Paredes, B. (2016). The benefit of multitask representation learning. *JMLR*, 17(81), 1–32.
- Riley, R. D. et al. (2019). Minimum sample size for developing a multivariable prediction model. *Statistics in Medicine*, 38(7), 1262–1275.
- Standley, T. et al. (2020). Which tasks should be learned together in multi-task learning? *ICML 2020*, 9120–9132.
- Varma, S., Simon, R. (2006). Bias in error estimation when using cross-validation for model selection. *BMC Bioinformatics*, 7, 91.