

IP 파운데이션 월드모델 연구 노트 7

굵은 길과 곧은 길

문서에서 축으로는 비선형, 축에서 결과로는 선형 --- 레인 하나가 노트 5와 6을 갈랐다

Sweetspot 월드모델 연구

2026년 7월 28일

초 록

노트 6은 열린 층돌 하나를 남겼다. 다섯 축 태그를 트리 모델에 넣은 팔이 반복 분할에서 상수에 졌는데(승률 10%), 노트 5는 같은 프로토콜에서 같은 다섯 축이 40회 중 40회 이겼다고 보고했다. 재현해 보니 원인은 레인 하나였다 — 같은 축, 같은 75건, 같은 분할에서 ridge는 승률 100%(차이 -0.0354), 트리는 15%(차이 $+0.0276$)다. 둘 다 옳았고 모델류가 달랐을 뿐이다. 여기서 세 가지가 따라 나온다. 첫째, 다섯 축의 신호는 선형이다 — 제곱과 상호작용 항을 없애수록 성능이 단조로 무너지며, 15차원 상호작용에서 승률 33%로 붕괴한다. 둘째, 노트 5의 “축을 데이터로 발견할 수 없다”는 결론은 레인 탓이었다 — ridge로 폴드 안에서 고르게 하면 선택률 상위 여섯 중 다섯이 노트 4가 지목한 다섯이고, 트리에서 전 폴드 선택되던 콜라보 강도는 0.375로 일곱 번째로 밀린다. 셋째, 그럼에도 구조는 비대칭이어야 한다 — 신경망 헤드를 선형으로 바꾸면 좋아지지만(차이 $+0.0275 \rightarrow +0.0056$) 인코더까지 선형으로 벗기면 오히려 무너진다($+0.0571$, 승률 0%). 문서에서 축으로 가는 길은 굵어 있고, 축에서 결과로 나오는 길은 곧다.

Table 1: 같은 다섯 축, 같은 75건, IP 무작위 5폴드 40회 반복.

피쳐 집합	레인	차이 중앙	표준편차	이긴 비율
고정 5종	ridge	-0.0354	0.011	100%
고정 5종	트리	$+0.0276$	0.025	15%
기획 10종	ridge	-0.0079	0.015	70%
기획 10종	트리	$+0.0063$	0.023	42%

1. 층돌에서 시작한다

노트 6은 앵커된 다섯 슬롯 구조를 짓고, 마지막에 정칙하게 미결로 남긴 항목이 있었다.

열린 층돌: 다섯 축 태그를 트리 모델에 그대로 넣은 팔이 반복 분할에서 상수에 졌다 (중앙 $+0.036$, 승률 10%). 노트 5는 같은 프로토콜에서 고정 5종이 40회 중 40회 이겼다고 보고했다.

두 수치는 같은 75건, 같은 IP 무작위 5폴드, 같은 타깃에서 나왔다. 그런데 부호가 반대다. 둘 중 하나는 틀렸거나, 아니면 내가 같다고 여긴 무언가가 실은 달랐다. 노트 5의 반복 CV는 인라인으로 실행돼 코드가 남지 않았다. 그래서 재현부터 했다. 차이가 날 수 있는 축을 전부 열었다 — 피쳐 표현(원값 대 0-1 정규화), 마스크 컬럼 유무, 표본 가중치 유무, 그리고 레인.

2. 레인 하나가 부호를 뒤집는다

첫 네 조합에서 답이 나왔다.

노트 5는 ridge를, 노트 6의 2단 실험은 트리를 썼다. 둘 다 맞았다. 층돌은 사라졌지만 훨씬 중요한 질문이 남았다 — 왜 선형 모델만 이 신호를 보는가.




Figure 1: 레인을 바꾸면 결론이 뒤집힌다. 노트 5는 왼쪽 첫 막대를, 노트 6의 2단 실험은 두 번째 막대를 보고 있었다. 오차 막대는 반복 표준편차의 두 배다.

주장 1. 같은 다섯 축이 선형 모델에서는 40회 중 40회 상수를 이기고 트리 모델에서는 40회 중 6회만 이긴다. 레인은 구현 세부가 아니라 결론을 정하는 선택이다.

반증 조건. 표본을 두 배로 늘렸을 때 트리가 ridge를 따라잡으면 원인은 신호의 형태가 아니라 표본 크기였던 것이다.

3. 신호는 선형이다

가설 둘을 가른다. 신호가 실제로 선형이어서 트리가 헛돈 것인가, 아니면 신호는 비선형인데 $n=75$ 에서 트리가 그것을 학습하지 못한 것인가.

다섯 축에 제곱 항과 상호작용 항을 단계적으로 얹고

Table 2: 다섯 축의 비선형 확장. ridge, IP 무작위 5폴드 40회 반복.

확장	차원	차이 중앙	이긴 비율
선형만	5	-0.0354	100%
+제공	10	-0.0267	95%
+상호작용	15	+0.0071	33%
전부	20	-0.0061	57%




Figure 2: 비선형 향을 더할수록 무너진다. 막대 위 숫자는 40회 중 상수를 이긴 비율이다. 상호작용 열 항이 가장 해롭다.

같은 ridge로 재본다. 신호에 비선형 성분이 있다면 확장이 도움이 돼야 한다.

확장은 도움이 되지 않았고 상호작용은 결정적으로 해로웠다. 다만 이 결과가 “비선형 성분이 없다”를 증명하지는 못한다 — 학습 폴드가 60건인데 상호작용만 열 개를 더하면 어떤 신호든 묻힌다. 정확히 말할 수 있는 것은 현재 표본에서 비선형 향은 이득이 없고, 선형 향만 남기는 것이 최선이라는 사실이다.

주장 2. 현재 표본에서 다섯 축은 선형으로 쓰는 것이 최선이며, 제공과 상호작용을 더하면 단조로 나빠진다.

반증 조건. 표본이 커진 뒤 상호작용 항이 순수 선형을 이기면, 신호는 원래 비선형이었고 $n=75$ 가 감당하지 못한 것이다.

4. 노트 5의 “발견 불가”를 다시 본다

노트 5의 핵심 주장은 이랬다 — 폴드마다 다른 다섯을 고르므로 축을 데이터로부터 발견할 수 없다. 그 근거로 든 것이 콜라보 강도였다. 네 폴드 전부에서 선택됐는데 노트 4는 그것을 제거 대상으로 지목했으므로, 같은 데이터가 정반대 답을 낸다는 증거로 삼았다.

그 중첩 선택의 레인이 기록되지 않았다. ridge로 다시 돌렸다. IP 무작위 5폴드 8회 반복, 학습 폴드 안에서만 leave-one-out으로 열 개를 다섯으로 줄인다.

ridge에서 데이터는 노트 4의 다섯을 거의 정확히 가리킨다. 유일한 침입자는 포토존 수 (0.525)가 미디어 투입 (0.500)을 간발로 앞선 것뿐이다. 노트 5가 모순의 증거로 든 콜라보 강도는 0.375로 일곱 번째다.




Figure 3: 폴드 선택률. 진한 막대가 노트 4가 지목한 다섯이다. ridge에서는 상위 여섯 중 다섯이 그 다섯이고, 트리에서 공동 1위였던 콜라보 강도는 0.375로 밀린다. 점선은 절반이다.

Table 3: ridge 폴드 선택률 (40 폴드). 굵은 것이 노트 4의 다섯.

속성	선택률	속성	선택률
타깃 폭	0.875	콜라보 강도	0.375
굵즈 규모	0.850	시즌 적합	0.200
매장 노출도	0.825	IP 인지 폭	0.100
입장 허들	0.675	체험 밀도	0.075
포토존 수	0.525		
미디어 투입	0.500		

그러나 절반만 철회한다. 축의 정체는 ridge에서 회복된다. 그런데 폴드마다 새로 고르는 절차는 여전히 상수를 이기지 못한다(차이 +0.0019, 승률 50%). 고정해 쓰면 100% 이기는데도 그렇다. 선택 절차 자체가 분산원이기 때문이다.

그래서 노트 5의 두 문장은 이렇게 갈라진다.

철회. “데이터가 그 다섯을 알려줄 수 없다” — 알려줄 수 있다. 선형 레인에서 선택률이 명확히 그 다섯을 가리킨다.

유지. “폴드마다 새로 고르면 이득이 사라진다” — 그대로다. 선택은 한 번만 하고 고정해야 한다.

주장 3. 축을 데이터로 식별하는 것과 매 폴드에서 다시 고르는 것은 다르다. 앞은 선형 레인에서 가능하고, 뒤는 어느 레인에서도 손해다. 한 번 고르고 고정하라.

반증 조건. 독립 표본에서 ridge 선택률 상위 다섯이 이 다섯과 어긋나면 식별 가능성 주장은 무너진다.

5. 구조는 비대칭이어야 한다

노트 6의 신경망은 상수를 이기지 못했다(승률 25%). 신호가 선형이라면 원인은 명백해 보였다 — 헤드가 MLP, 즉 비선형이었다. 비선형을 한 겹씩 벗기며 재봤다.

Table 4: 선형 사다리. 앵커 16, IP 무작위 5폴드 20회 반복.

구조	차이 중앙	표준편차	이긴 비율
MLP 인코더 + MLP 헤드	+0.0275	0.025	25%
MLP 인코더 + 선형 헤드	+0.0056	0.020	35%
선형 인코더 + 선형 헤드	+0.0571	0.026	0%
선형(항등) + 선형 헤드	+0.1638	0.057	0%




Figure 4: 비선형을 벗기는 순서가 중요하다. 헤드를 벗기면 좋아지고 인코더까지 벗기면 무너진다. 예측이 반증된 지점이다.

앞쪽 절반은 예측대로였다. 헤드를 선형으로 바꾸자 결손이 절반 아래로 줄었다 (+0.0275 → +0.0056). 그런데 인코더까지 선형으로 벗기자 오히려 크게 나빠졌다 (+0.0571, 20회 중 0회 승리). 시그모이드마저 뎀 항등 사상은 +0.1638로 완전히 무너졌다.

내 예측은 절반만 맞았다. “신호가 선형이니 전부 선형으로”는 틀렸다. 맞는 문장은 이것이다.

- 문서 → 축은 비선형이다. “타깃 폭”이나 “입장 허들” 같은 의미 축은 문서의 수치들로부터 임계와 범주를 거쳐 만들어진다. 선형 사상으로는 복원되지 않는다.
- 축 → 결과는 선형이다. 축이 주어지면 결과는 그 합으로 설명된다.

주장 4. 앵커된 슬롯 구조에서 인코더는 비선형이어야 하고 헤드는 선형이어야 한다. 둘을 같은 종류로 맞추면 어느 쪽으로 맞추든 나빠진다.

반증 조건. 인코더를 선형으로 두고도 비선형 인코더와 같은 성능이 나오면, 문서에서 축으로 가는 길이 굵었다는 진단이 틀린 것이다.

6. 그래서 다음 질문

이 비대칭은 새 질문을 만든다. 인코더가 실제로 문서에서 축을 얼마나 복원하는가. ridge가 100%로 이기는 이유가 선형이어서가 아니라 사람이 매긴 축을 그대로 받기 때문이라면, 앵커 구조의 병목은 헤드가 아니라 인코더다. 그리고 그것이 사실이면 함의가 크다 — 사람 태깅은 문서의 중복 정보가 아니라 새 정보이고, 아이돌

도메인 전이는 아이돌 태깅 없이는 불가능하며, 파운데이션 모델의 입력은 문서가 아니라 태그여야 한다.

폴드 밖에서 문서만으로 각 축을 예측해 사람 태그와 대조하는 측정을 돌리고 있다. 다음 노트의 주제다.

7. 한계

- 비선형 확장 실험은 “비선형 성분이 없다”를 증명하지 못한다. 학습 폴드 60건에 상호작용 열 개는 어떤 신호든 묻는다. 표본이 커진 뒤 재측정해야 한다.
- ridge 선택물은 8회 반복 40 폴드에서 나왔다. 트리 쪽 비교는 노트 5의 시간순 4폴드 결과를 그대로 썼으므로 폴드 수가 다르다. 트리 쪽 반복 재계산은 중첩 leave-one-out 비용 때문에 아직 돌고 있다.
- 기획 10중의 반복 CV 수치가 노트 5(차이 -0.0290, 98%)와 이번 재현 (-0.0079, 70%)에서 어긋난다. 마스크 컬럼과 정규화를 포함한 32개 변형 전수 비교를 돌리고 있으며, 결과에 따라 노트 5의 해당 수치를 조정한다. 고정 5중 수치는 노트 5(-0.0442, 100%)와 재현(-0.0354, 100%)이 부합하므로 이 노트의 결론에는 영향이 없다.
- 모든 반복 분할은 시간 순서를 쓰지 않는다. 실전 성능이 아니라 안정성 판정용이다.

8. 다음

1. 축 복원 검정 — 문서만으로 다섯 축을 얼마나 맞히는가. 앵커 구조의 병목 확정.
2. 32개 변형 전수 비교 완료 후 노트 5 수치 정정.
3. 태그 순열 대조군 — 노트 6이 남긴 반증 조건.
4. 아이돌 다섯 축 태깅. 축 복원이 어렵다는 결과가 나오면 이것은 선택이 아니라 필수다.

참고문헌

- Grinsztajn, L., Oyallon, E., Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on typical tabular data? NeurIPS 2022.
- Hastie, T., Tibshirani, R., Friedman, J. (2009). The Elements of Statistical Learning, 2nd ed. Springer.
- Hollmann, N. et al. (2025). Accurate predictions on small data with a tabular foundation model. Nature, 637, 319–326.
- Varma, S., Simon, R. (2006). Bias in error estimation when using cross-validation for model selection. BMC Bioinformatics, 7, 91.