

IP 파운데이션 월드모델 연구 노트 9

건너간 것과 건너가지 못한 것

아이들에서도 측은 상수를 이긴다 --- 그러나 넷 중 둘만 같은 부호로 옮겨갔다

Sweetspot 월드모델 연구

2026년 7월 28일

초 록

이 노트는 이 연구의 전체를 처음으로 직접 시험한다. 세 단계를 거쳤다. 첫째, 노트 8의 설명을 철회한다 — 측은 복원 실패의 원인을 “측퇴”로 추정했으나 직교화로 승률이 전혀 회복되지 않았고(변화 0.00) 복원 측은 사람 태그보다 오히려 덜 상관돼 있었다. 측별 상관을 재보니 넷이 $r=0.43-0.55$ 로 실질 복원된다. 원인은 측퇴도 정보 부족도 아니라 회귀 희석이었다. 둘째, 그렇다면 얼마나 정확해야 쓸모가 있는지 답할 수 있다. 사람 태그를 통제된 잡음으로 열화시켜 재보니 승률 90%에는 $r \geq 0.79$, 50%에는 $r \geq 0.52$ 가 필요하다. 현재 문서 복원 수준 0.45는 문턱 아래다. 셋째, 노트 8이 지정한 수집 과정을 실행해 아이돌 데뷔 앨범의 버전 수와 정가를 81건 중 69건 확보하고, 태깅률 0%였던 두 측은 채운 뒤 전이를 검정했다. 결과가 갈린다. 아이돌 도메인에서도 네 측은 상수를 이긴다(차이 -0.0574 , 승률 97%) — 측이 팝업 국소적이지 않다는 첫 증거다. 그런데 전이는 실패한다. 부호가 일치하는 측이 넷 중 둘뿐이고 계수 상관은 -0.309 다. 살아남은 둘은 미디어 투입과 굿즈 규모이며, 입장 허들은 부호가 뒤집혔다 — 앨범 가격은 허들이 아니라 규모 신호였다.

Table 1: 측퇴 가설의 직접 검정. IP 무작위 5폴드 20회 반복.

	평균 $ r $	최대 $ r $	제1주성분 설명
사람 태그	0.236	0.540	0.372
문서 복원	0.177	0.465	0.322
	차이 중앙	표준편차	이긴 비율
참 측	-0.0313	0.011	100%
복원 측	$+0.0254$	0.028	5%
복원 측 직교화	$+0.0243$	0.028	5%

Table 2: 문서 피쳐로 각 측은 예측했을 때 참값과의 상관(20회 반복 중앙값).

측	ridge	트리
입장 허들	0.311	0.548
굿즈 규모	0.383	0.470
매장 노출도	0.438	0.378
타깃 폭	0.235	0.429
미디어 투입	0.143	0.193

1. 먼저 노트 8을 고친다

노트 8은 문서에서 복원한 측으로 결과를 예측하면 승률 100%가 5%로 무너진다고 보고하고, 원인을 이렇게 추정했다.

각 측을 같은 문서 피쳐로 예측하면 복원 오차가 서로 독립이 아니다. ... 그러면 복원된 다섯 측은 실질적으로 하나의 “규모” 측으로 측퇴하고, 다섯 측이 서로 다른 것을 재기 때문에 생기던 이득이 사라진다.

같은 노트의 반증 조건도 함께 적어 두었다 — 직교화로 회복되면 표현 문제, 안 되면 정보 문제. 돌렸다.

두 방향 모두 가설과 어긋난다. 측퇴가 사실이면 복원 측이 사람 태그보다 더 상관돼 있어야 하는데 덜 상관돼 있다(0.177 대 0.236). 그리고 직교화로 승률이 전혀 움직이지 않는다(5% → 5%).

주장 1. 노트 8의 “측퇴” 설명을 철회한다. 복원 측은 사람 태그보다 덜 상관돼 있고 직교화로 아무것도 회복되지 않는다.

반증 조건. 다른 직교화 방식(주성분, 백색화)에서 회복되면 철회가 성급했던 것이다.

1.1 그러면 정보가 없는가 --- 그것도 아니었다


다음 후보는 “문서에 정보가 없다”였다. 측별 복원 상관을 재봤다.

넷이 0.43–0.55로 복원된다. 잡음이 아니다. 그런데 도 쓸모가 없다.

남는 설명은 회귀 희석이다. 측정 오차가 있는 예측변수는 그 효과를 신뢰도만큼 감쇠시킨다. 참 측의 효과가 애초에 크지 않으므로(차이 -0.0313), 신뢰도 0.45로 감쇠되면 남는 것이 없다.

Table 3: 축 측정 신뢰도에 따른 성능. IP 무작위 5폴드 40회 반복, ridge.

신뢰도 r	차이 중앙	이진 비율
1.00	-0.0371	100%
0.95	-0.0339	100%
0.90	-0.0269	97%
0.80	-0.0180	93%
0.70	-0.0101	68%
0.60	-0.0085	75%
0.50	+0.0031	45%
0.45	+0.0144	45%
0.30	+0.0178	23%

Figure 1: 신뢰도 문턱. 승률 90%를 지키려면 $r \geq 0.79$, 절반이라도 지키려면 $r \geq 0.52$ 가 필요하다. X 표시가 현재 문서 복원 수준이다.

2. 그래서 얼마나 정확해야 하는가

이 진단은 답할 수 있는 질문으로 바뀐다. 사람 태그를 통제된 잡음으로 열화시켜 목표 상관 r 을 맞춘 뒤, r 이 얼마일 때 상수를 이기기 시작하는지 재면 된다. 표준화한 참값 z 에 대해 $z' = rz + \sqrt{1 - r^2}e$ 로 만들면 $\text{corr}(z, z') = r$ 이 된다.

주장 2. 축 측정의 신뢰도가 0.79 아래로 내려가면 이 표본에서 축은 실용적 가치를 잃는다. 이것은 태깅 품질에 대한 공학 규격이다 — 평정자 간 일치도가 이 문턱 아래면 태깅 설계를 다시 해야 한다.

반증 조건. 표본이 커지면 같은 신뢰도에서도 효과가 살아난다. $n=150$ 에서 문턱이 0.6 아래로 내려가면 이 수치는 표본 크기에 딸린 값이지 축의 성질이 아니다.

이 숫자는 실무 지침이 된다. 사람 태깅의 평정자 간 일치도를 아직 재지 않았는데, 그것이 0.8을 넘지 못하면 지금 쓰고 있는 태그 자체가 문턱 아래일 수 있다. 다음 측정 과제다.

3. 수집을 실행했다

노트 8은 아이돌 도메인에서 입장 허들과 굿즈 규모의 태깅률이 0%라고 보고하고 수집 과제로 지정했다. 실행

Table 4: 아이돌 한터 확정 81건의 축 태깅률 변화.

축	수집 전	수집 후
미디어 투입	96%	96%
타깃 폭	91%	91%
입장 허들	0%	85%
굿즈 규모	0%	85%
매장 노출도	32%	32%




Figure 2: 도메인 안에서는 둘 다 이기고, 건너가면 둘 다 진다.

했다.

음반 유통 상품 페이지에 버전 수와 정가가 그대로 있다. 그룹명과 앨범명이 둘 다 상품 제목에 있어야 채택하는 규약으로 81건 중 69건(85%)을 확보했다. 이 프로젝트의 크롤링 사고는 전부 “비슷해 보이는 것을 같은 것으로 본” 데서 났으므로 — 4개 그룹 합동 기사 수치를 한 그룹에 귀속시킨 사건, 그룹 전체 유통인구를 한 팝업에 넣은 사건 — 채택한 상품 제목과 상품 번호를 전부 기록했다.

버전 수 세기에서 한 번 과대 계상이 났다. 한 걸그룹의 데뷔 앨범이 12종으로 잡혔는데, 제목의 “버전별 CD 알판 12종 중 랜덤삽입”을 센 것이었다. 12종은 알판 그림이지 앨범 버전이 아니다. 실제 버전은 COLOR와 ROSE 두 종이다. 규칙을 고쳐 — 버전 표기가 있으면 그것을 세고 없을 때만 N종 표기로 넘어가도록 — 바로 잡았다.

4. 전이 검증

두 도메인의 라벨은 물리량이 다르다. 그래서 도메인 안에서 y 를 표준화하고 축도 각각 표준화한다. 검증하는 것은 절대값이 옮겨지는가가 아니라 축과 결과의 관계가 옮겨지는가이며, 후자가 파운데이션 가설이 실제로 주장하는 바다. 매장 노출도는 아이돌 태깅률이 32%뿐이라 뺐다.

좋은 소식. 아이돌 도메인에서도 네 축은 상수를 이긴다 (차이 -0.0574, 40회 중 39회). 팝업에서 만든 축 어휘가 다른 도메인에서 처음으로 검증됐다. 축이 팝업 국소적인 발견이 아니라는 첫 증거다.

Table 5: 도메인 내부와 교차. 팝업 75건, 아이돌 63건(네 축 완전 케이스).

	차이	이긴 비율
팝업 내부	-0.0510	100%
아이돌 내부	-0.0574	97%
아이돌 → 팝업	+0.0696	—
팝업 → 아이돌	+0.0026	—

Table 6: 도메인별 표준화 회귀계수. 부호 일치 2/4, 계수 상관 -0.309.

축	팝업	아이돌	
미디어 투입	+0.127	+0.226	일치
굿즈 규모	+0.189	+0.287	일치
타깃 폭	+0.202	-0.016	아이돌에서 무효
입장 허들	-0.201	+0.229	부호 반전




Figure 3: 표준화 회귀계수. 미디어 투입과 굿즈 규모는 같은 부호로 건너갔고, 입장 허들은 뒤집혔으며, 타깃 폭은 아이돌에서 사실상 0이다.

나쁜 소식. 교차는 둘 다 진다. 아이돌에서 배운 계수로 팝업을 예측하면 대상 도메인 상수보다 0.0696 나쁘고, 반대 방향은 0.0026 나쁘다(거의 비김).

5. 왜 안 건너갔는가

계수를 보면 진단이 나온다.

입장 허들의 부호 반전이 결정적 단서다. 팝업에서는 입장 허들이 높을수록 방문자가 준다(-0.201). 아이돌에서는 앨범 가격이 높을수록 초동이 는다(+0.229). 같은 축이라면 있을 수 없는 일이다.

확인해 보니 원인은 내 매핑이었다. 아이돌 데이터에서 앨범 가격은 진입 비용이 아니라 규모 신호다.

- 버전 수가 늘수록 평균 정가가 오른다: 1종 13,495원 → 2종 18,157원 → 3종 이상 19,693원.
- 가격과 버전 수의 상관 +0.198, 가격과 초동의 상관 +0.262, 버전 수와 초동의 상관 +0.345.

비싼 앨범은 두꺼운 포토북과 많은 특전을 뜻한다. 즉 앨범 가격은 “입장 허들”이 아니라 “굿즈 규모”의 다른 얼굴이었다. 나는 두 축에 같은 신호를 넣고 서로 다른 것을 재기를 기대한 셈이다.

주장 3. 전이 실패의 원인은 축이 도메인 특수해서가 아니라 아이돌 쪽 축 매핑이 틀렸기 때문이다. 앨범 가격은 입장 허들이 아니라 굿즈 규모다.

반증 조건. 앨범 가격을 굿즈 규모로 옮기고 입장 허들

의 다른 대응물을 넣었을 때도 부호가 어긋나면, 그때는 매핑이 아니라 축 자체가 도메인 특수한 것이다.

타깃 폭도 다시 짜야 한다. 아이돌 쪽 계수가 -0.016으로 사실상 0이다. 인원 수·성별·서바이벌 출신으로 만든 대리변수가 팝업의 “대상이 얼마나 넓은가”와 같은 것을 재지 않는다.

6. 그래서 무엇이 남았나

- 도메인 불변 후보 2개 — 미디어 투입, 굿즈 규모. 두 도메인에서 같은 부호이고 크기도 비슷하다. 파운데이션 모델의 공유 슬롯은 여기서 시작한다.
- 재설계 대상 2개 — 입장 허들(아이돌 대응물을 팬덤 진입 비용 쪽에서 다시 찾는다), 타깃 폭(대리변수 재설계).
- 측정 규격 1개 — 축 신뢰도 0.79. 사람 태깅의 평정자 간 일치도를 재서 이 문턱을 넘는지 확인해야 한다.

7. 한계

- 아이돌 축은 규칙 기반 유도이며 사람 태깅이 아니다. 팝업 쪽 태그와 같은 종류의 물건이라는 보장이 없고, 신뢰도도 재지 않았다. 전이 실패의 일부가 여기서 올 수 있다.
- 교차 검정은 단일 적합이라 신뢰구간이 없다. 반복 분할로 다시 재야 한다.
- 아이돌 완전 케이스가 63건이다. 계수 추정 자체의 분산이 크다.
- 신뢰도 문턱 0.79는 이 표본(n=75)에 딸린 값이다. 표본이 커지면 내려간다.

8. 다음

1. 앨범 가격을 굿즈 규모로 재배치하고 전이 재검정 — 부호 반전이 해소되는가.
2. 입장 허들의 아이돌 대응물 재설계 — 팬클럽 가입 비용, 예약 경쟁 구조.
3. 교차 검정에 반복 분할과 신뢰구간 부여.
4. 사람 태깅의 평정자 간 일치도 측정 — 0.79 문턱을 넘는지.

참고문헌

- Ben-David, S. et al. (2010). A theory of learning from different domains. *Machine Learning*, 79(1–2), 151–175.
- Carroll, R. J. et al. (2006). *Measurement Error in Nonlinear Models*, 2nd ed. Chapman & Hall.
- Spearman, C. (1904). The proof and measurement of association between two things. *American Journal of Psychology*, 15(1), 72–101.
- Standley, T. et al. (2020). Which tasks should be learned together in multi-task learning? *ICML 2020*, 9120–9132.