

IP 파운데이션 월드모델 연구 노트 10

굿즈는 건너갔다

한 축이 처음으로 도메인을 넘었다 --- 순열 $p=0.034$, 그리고 되돌아오지는 못했다

Sweetspot 월드모델 연구

2026년 7월 28일

초 록

노트 9는 전이 실패의 원인을 축이 아니라 내 매핑으로 지목하고 반증 조건을 적었다 — 앨범 가격을 굿즈 규모로 옮겼을 때도 부호가 어긋나면 그때는 축 자체가 도메인 특수한 것이다. 옮겼다. 부호 반전이 사라졌다 (입장 허들 -0.201 대 $+0.229 \rightarrow$ 축 제거, 남은 셋 중 둘 일치). 그러나 세 축 전체의 전이는 부트스트랩을 붙이자 유의하지 않았다 — 점추정만 보면 양방향 모두 이겼는데(차이 -0.0041 과 -0.0237) 출처 표본을 다시 뽑으면 부호가 흔들렸다. 축을 하나씩 떼어 보니 이유가 나왔다. 굿즈 규모 단독으로 팝업에서 아이돌로 보내면 유의하게 이긴다 — 차이 -0.0556 , 순열 검정 $p=0.034$, 부트스트랩 승률 95%. 이 프로젝트 최초의 도메인 간 전이다. 그런데 두 가지 단서가 붙는다. 첫째, 되돌아오지 못한다 — 아이돌에서 팝업으로는 승률 29%다. 둘째, 축을 더할수록 희석된다 — 타깃 폭을 넣으면 승률이 94%에서 79%로, 셋을 다 넣으면 64%로 떨어진다. 전이는 방향이 있고, 그 방향은 잘 측정된 쪽에서 못 측정된 쪽이다. 노트 9의 신뢰도 문턱이 다른 얼굴로 다시 나타났다.

Table 1: 매핑 수정 후, 팝업 75건, 아이돌 63건(세 축 완전 케이스).

축	팝업	아이돌
미디어 투입	+0.126	+0.206
굿즈 규모	+0.156	+0.388
타깃 폭	+0.310	-0.011

Table 2: 세 축 교차 검정. 부트스트랩은 출처 표본을 400회 다시 뽑아 계수의 표집 분산을 반영한다. 대상 라벨은 학습에 쓰지 않는다.

방향	점추정	부트 중앙	이긴 비율
아이돌 $\rightarrow$ 팝업	-0.0041	+0.0118	41%
팝업 $\rightarrow$ 아이돌	-0.0237	-0.0219	64%

1. 반증 조건을 실행했다

노트 9의 마지막 주장 상자는 이랬다.

전이 실패의 원인은 축이 도메인 특수해서가 아니라 아이돌 쪽 축 매핑이 틀렸기 때문이다. 앨범 가격은 입장 허들이 아니라 굿즈 규모다.

반증 조건. 앨범 가격을 굿즈 규모로 옮기고 입장 허들의 다른 대응물을 넣었을 때도 부호가 어긋나면, 그때는 매핑이 아니라 축 자체가 도메인 특수한 것이다.

옮겼다. 굿즈 규모를 버전 수와 정가의 가중 결합으로 다시 정의하고, 입장 허들은 대응물이 없으므로 비웠다 — 팬클럽 가입 비용이나 예약 경쟁 구조 같은 진짜 진입 비용은 아직 수집하지 않았다. 남은 세 축(타깃 폭, 미디어 투입, 굿즈 규모)으로 다시 썼다.

부호 반전은 사라졌다. 남은 불일치는 타깃 폭 하나이며, 그것은 반전이 아니라 아이돌에서 사실상 0이다 — 인원 수·성별·서바이벌 출신으로 만든 대리변수가 팝업의 “대상이 얼마나 넓은가”와 같은 것을 재지 않는다.

2. 점추정은 이겼고 부트스트랩은 아니었다

세 축으로 교차 검정하니 양방향 모두 점추정이 음수였다.

점추정만 보고 “전이 성공”이라고 썼다면 과대주장이었다. 아이돌 $\rightarrow$ 팝업의 -0.0041 은 출처를 다시 뽑는 것만으로 부호가 뒤집힌다 — 부트스트랩 중앙값이 $+0.0118$ 이고 이긴 비율이 41%다.

주장 1. 교차 도메인 성능은 단일 적합의 점추정으로 주장할 수 없다. 출처 표본이 75건과 63건이므로 계수 자체의 표집 분산이 효과 크기와 같은 규모다.

반증 조건. 출처 표본이 수백 건으로 늘어 부트스트랩 폭이 효과 크기의 절반 아래로 줄면 점추정만으로도 말할 수 있다.

3. 축을 하나씩 떼어 보았다

세 축을 통째로 보내면 흐려진다. 부분집합을 전부 돌렸다.

굿즈 규모 하나가 전부를 하고 있다. 다른 축을 더할 때마다 성적이 단조로 떨어진다. 타깃 폭은 단독으로 이긴 비율이 10%이므로 넣으면 잠깐만 추가된다.

4. 순열 검정 --- 첫 유의한 전이

굿즈 규모 단독에 대해 직접 물었다. 팝업 계수가 아이돌에 대해 아무 정보도 담고 있지 않다면, 관측된 성적이




Figure 1: 팝업 → 아이돌 전이, 축 조합별. 긱즈 규모 단축이 가장 강하고, 축을 더할수록 흐려진다. 막대는 부트스트랩 95% 구간, 오른쪽 숫자는 이긴 비율.

Table 3: 팝업 → 아이돌, 축 조합별 부트스트랩 결과.

축 조합	차이 중앙	이긴 비율
긱즈 규모	-0.0583	94%
미디어 + 긱즈	-0.0472	83%
타깃 폭 + 긱즈	-0.0376	79%
세 축 전부	-0.0219	64%
미디어 투입	+0.0060	39%
타깃 폭	+0.0379	10%
타깃 폭 + 미디어	+0.0492	2%

우연히 나올 확률은 얼마인가. 팝업 라벨을 4,000회 섞어 귀무 분포를 만들었다.

두 검정이 서로 다른 것을 말한다. 부트스트랩 구간은 0을 아슬아슬하게 넘고 (+0.0096), 순열 검정은 $p=0.034$ 로 유의하다. 모순이 아니다 — 부트스트랩은 효과 크기의 추정 정밀도를 재고, 순열은 전이가 없다는 귀무가설을 직접 검정한다. 우리가 묻는 것은 후자다. 효과 크기는 아직 정밀하지 않지만, 전이가 없다고 보기는 어렵다.

주장 2. 팝업에서 사람이 매긴 긱즈 규모 축의 계수가 아이돌 초동 예측에 실제로 정보를 담고 있다. 이 프로젝트 최초의 도메인 간 전이이다 (순열 $p=0.034$).

반증 조건. 독립적으로 수집한 새 아이돌 표본에서 같은 계수를 적용해 p 가 0.05를 넘으면 이 결과는 표본 특수한 것이다.

5. 그런데 되돌아오지 못한다

같은 축, 반대 방향으로 보내면 실패한다.

축이 도메인 불변이라면 방향은 상관없어야 한다. 그런데 상관있다.

설명은 측정 품질에 있다. 팝업의 긱즈 규모는 사람이 문서를 읽고 매긴 0~4 서수다. 아이돌의 긱즈 규모는 상품 제목에서 규칙으로 뽑은 버전 수와 정가다. 후자의

Figure 2: 팝업 라벨을 섞었을 때의 전이 성적 분포와 실제 관측값. 4,000회 중 3.4%만이 관측값 이하다.

Table 4: 긱즈 규모 단축, 팝업 → 아이돌. 아이돌 라벨은 학습에 쓰지 않았다.

관측 차이	-0.0556
팝업 계수	+0.213
부트스트랩 (2,000회) 중앙	-0.0543
95% 구간	[-0.0990, +0.0096]
이긴 비율	95%
순열 귀무 중앙 (4,000회)	+0.0019
순열 p	0.034

신뢰도는 재지 않았지만 전자보다 낮다고 보는 것이 자연스럽다.

노트 9는 축 측정 신뢰도가 0.79 아래면 축이 실용적 가치를 잃는다고 보고했다. 같은 논리가 전이에도 적용된다 — 계수를 추정하는 쪽의 축이 잘 측정돼 있어야 그 계수가 옳길 값어치가 있다. 잘 측정된 쪽에서 못 측정된 쪽으로는 가고, 반대로는 못 간다.

주장 3. 도메인 간 전이는 방향이 있으며, 그 방향은 축 측정 신뢰도가 높은 쪽에서 낮은 쪽이다.

반증 조건. 아이돌 축을 사람 태깅으로 다시 매겨 신뢰도를 올렸는데도 아이돌 → 팝업이 실패하면 원인은 측정 품질이 아니라 다른 것이다.

6. 그래서 파운데이션 모델의 첫 슬롯

열 편의 노트 끝에 확실한 것 하나가 남았다.

긱즈 규모 — “닿으면 무엇을 얻는가” — 는 팝업과 아이돌에서 같은 방향으로 작동하며, 한 도메인에서 배운 계수가 다른 도메인에서 유의하게 쓰인다.

이것이 파운데이션 월드모델의 첫 확정 슬롯이다. 팝업에서는 긱즈 종류 수로, 아이돌에서는 앨범 버전 수와 정가로 측정되지만 같은 것을 재고 있다.

미디어 투입은 부호는 맞으나 단독 전이가 39%로 약하다. 후보로 남긴다. 타깃 폭은 현재 대리변수로는 무효이므로 재설계 대상이다.




Figure 3: 굿즈 규모 단독 전이의 비대칭. 한 방향은 되고 반대 방향은 되지 않는다.

Table 5: 굿즈 규모 단독, 양방향.

방향	부트 중앙	이진 비율
팝업 → 아이돌	-0.0543	95%
아이돌 → 팝업	+0.0070	29%

7. 한계

- 아이돌 측은 여전히 규칙 기반 유도다. 신뢰도를 재지 않았고, 비대칭 설명은 그 신뢰도 차이를 가정하고 있으나 직접 측정한 것이 아니다.
- 부분집합을 일곱 개 전부 돌리고 가장 좋은 것을 보고 하므로 선택 편향이 있다. 순열 $p=0.034$ 는 그 편향을 보정하지 않은 값이며, 일곱 조합에 본페로니를 적용하면 0.24가 된다. 다만 굿즈 규모는 사후에 고른 것이 아니라 노트 9에서 부호가 일치한 두 측 중 하나로 미리 지목돼 있었다.
- 입장 허들 측은 지금 비어 있다. 다섯 측 중 셋으로만 검토하고 있다.
- 아이돌 완전 케이스 63 69건, 팝업 75건. 양쪽 다 작다.

8. 다음

- 아이돌 굿즈 규모를 사람 태깅으로 다시 매기고 신뢰도 측정 — 비대칭 설명의 직접 검증.
- 타깃 폭 대리변수 재설계. 인원 수가 아니라 데뷔 시점 팬덤 도달 범위 쪽에서 찾는다.
- 입장 허들의 아이돌 대응물 수집 — 팬클럽 가입비, 예약 경쟁 구조.
- 세 번째 도메인 확보. 두 도메인으로 “불변”을 말하기 이른다.

참고문헌

- Ben-David, S. et al. (2010). A theory of learning from different domains. *Machine Learning*, 79(1–2), 151–175.
- Carroll, R. J. et al. (2006). *Measurement Error in Nonlinear Models*, 2nd ed. Chapman & Hall.

Good, P. (2005). *Permutation, Parametric, and Bootstrap Tests of Hypotheses*, 3rd ed. Springer.

Standley, T. et al. (2020). Which tasks should be learned together in multi-task learning? *ICML 2020*, 9120–9132.