

IP 파운데이션 월드모델 연구 노트 14

라벨 없이 예측한다

두 도메인으로 학습한 공유 헤드가 세 번째 도메인의 라벨을 한 번도 보지 않고 상수를 이긴다 --- 셋 중 하나에서

Sweetspot 월드모델 연구


2026년 7월 28일

초 록

열세 편의 노트가 설계를 좁혔다. 슬롯은 둘(노트 13), 학습으로 정하지 않고 앵커로 고정(노트 5-6), 인코더는 비선형이고 헤드는 선형(노트 7), 축은 문서에서 복원되지 않으므로 측정해야 한다(노트 8). 이 노트는 그 설계를 실제로 짓고 가장 어려운 검정을 건다 — 도메인 하나 빼기. 두 도메인으로 공유 헤드를 학습하고, 세 번째 도메인에서는 축만 재고 라벨은 한 번도 보지 않은 채 예측한다. 결과는 셋으로 갈린다. 아이돌에서 성공한다 — 상수 0.6474 대비 0.5823 (차이 -0.0650 , 순열 $p < 0.001$)이고, 아이돌 라벨을 전부 본 상한 0.5708에 0.0115까지 접근한다. 상수에서 상한까지의 구간 중 85%를 라벨 없이 간다. 팝업에서는 상수를 이기지만 유의하지 않고($p=0.130$), 게임에서는 실패한다($p=0.510$) — 노트 13이 예고한 대로다. 파운데이션 가설은 증명되지 않았지만, 라벨 없는 새 접점에서 상수보다 나은 예측이 가능하다는 것이 한 도메인에서 실증됐다.

Table 1: 설계 결정과 그 근거가 된 노트.

결정	근거
슬롯 2개	노트 13 — 세 도메인 공통 관측 가능 축
앵커 고정	노트 5 — n 이 작으면 축을 발견 못 함 노트 6 — 같은 용량에서 앵커가 17/20 승
인코더 비선형	노트 7 — 선형 인코더는 무너짐
헤드 선형	노트 7 — MLP 헤드는 나빠짐
축은 측정	노트 8 — 문서 복원 시 승률 100→5%
도메인 내 탈출세	노트 11, 13 — 추세 방향이 도메인마다 반대



학습: 두 도메인 · 검정: 나머지 하나 (대상 라벨 미)

1. 설계는 이미 정해져 있었다

이 노트에는 새 아이디어가 없다. 앞선 열세 편이 하나씩 좁혀 놓은 제약을 그대로 조립할 뿐이다.

2. 가장 어려운 검정을 건다

파운데이션 모델이 실제로 주장하는 바는 하나다 — 새 접점에 결과 라벨이 없어도 예측할 수 있다. 그 주장을 그대로 검정한다.

1. 두 도메인으로 인코더와 공유 헤드를 함께 학습한다.
2. 헤드를 열린다.
3. 세 번째 도메인에서 인코더만 새로 학습하는데, 라벨 대신 앵커만 쓴다 — 그 도메인의 축은 젤 수 있지만 결과는 모른다는 상황이다.
4. 열린 헤드로 예측하고 그 도메인의 상수와 비교한다.
비교 대상 넷을 나란히 둔다.

- 상수 — 도메인 내 중앙값. 모델-프리 하한.

Figure 1: 구조. 도메인마다 인코더는 다르지만 슬롯과 헤드는 하나다. 슬롯의 의미는 학습이 바뀌지 못한다 — 각 도메인에서 측정된 축이 앵커로 붙잡는다.

- 평균 쌍 전이 — 단일 출처에서 옮긴 성적의 평균. 최선만 보고하면 신탁이다 — 실전에서는 어느 출처가 나을지 미리 알 수 없다.
- 파운데이션 — 두 도메인 공동 학습.
- 상한 — 대상 도메인 라벨을 전부 본 ridge. 표본 내 적합이므로 낙관적이며, 도달 불가능한 눈금으로만 쓴다.

유의성은 순열로 잔다. 출처 도메인의 라벨을 섞어 200회 다시 학습하고, 관측 성적이 그 귀무 분포에서 얼마나 드문지 본다.




Figure 2: 도메인 하나 빼기. 낮을수록 좋다. 아이돌에서만 파운데이션이 평균 쌍 전이를 넘어 상한에 근접한다.

Table 2: 도메인 하나 빼기 결과. 평균절대오차, 도메인 내 표준화 눈금.

대상	상수	평균 쌍	파운데이션	상한	p
아이돌	0.6474	0.5896	0.5823	0.5708	<0.001
팝업	0.7596	0.7230	0.7298	0.6857	0.130
게임	0.7701	0.7813	0.7874	0.7581	0.510

3. 결과 --- 셋으로 갈린다

3.1 아이돌 --- 성공

파운데이션 모델이 아이돌 초동을 예측한다. 아이돌 라벨을 한 번도 보지 않았는데 상수를 0.0650 이긴다(순열 $p < 0.001$). 평균 쌍 전이(0.5896)보다도 낮다 — 두 출처를 함께 쓰는 것이 어느 하나를 고르는 것보다 낫다는 뜻이다.

더 말이 되는 눈금은 상수와 상한 사이의 거리다. 상한 0.5708은 아이돌 라벨을 전부 보고 적합한 모델이므로 도달 불가능한 목표다. 상수 0.6474에서 그 상한까지의 구간 중 파운데이션 모델은 85%를 라벨 없이 간다.

주장 1. 두 도메인에서 학습한 공유 헤드가 세 번째 도메인의 라벨을 전혀 보지 않고 그 도메인의 상수를 유의하게 이긴다(아이돌, 차이 -0.0650 , 순열 $p < 0.001$). 상수에서 상한까지의 85%를 간다.

반증 조건. 네 번째 도메인을 넣었을 때 아이돌 성적이 무너지면 이 결과는 두 출처(팝업·게임)의 특수한 조합 덕이었던 것이다.

3.2 팝업 --- 이기지만 유의하지 않다

상수 0.7596 대비 0.7298로 0.0298 낮지만 순열 $p = 0.130$ 이다. 그리고 평균 쌍 전이(0.7230)보다 약간 나쁘다 — 공동 학습이 도움이 되지 않았다.

팝업이 어려운 이유는 짐작할 수 있다. 팝업의 측은 사람이 문서를 읽고 매긴 것이고 다른 두 도메인의 측은 규칙으로 유도한 것이다. 눈금의 성격이 다르다. 노트 9의 신뢰도 문턱($r \geq 0.79$)을 두 출처가 넘지 못하면 그

Figure 3: 상수에서 상한까지의 구간 중 라벨 없이 간 비율. 아이돌에서 85%다.

계수로 팝업을 맞히기 어렵다.

3.3 게임 --- 실패

상수보다 나쁘다(차이 $+0.0173$, $p = 0.510$). 노트 13이 예고한 그대로다 — 리뷰 총계는 출시 시점 조건이 아니라 이후 수년의 누적 동역학을 반영하므로 출시 시점 측이 담을 수 없다. 지금 출시 후 30일 창으로 라벨을 다시 채는 수집을 돌리고 있으며, 그 결과가 이 실패의 원인을 가른다.

4. 읽는 방법

이 결과를 과대해석하지 않도록 경계를 명확히 해 둔다.

증명된 것. 라벨이 없는 새 접점에서 상수보다 나은 예측이 가능하다. 한 도메인에서, 순열 검정 $p < 0.001$ 로.

증명되지 않은 것. 그것이 세 도메인 모두에서 된다는 것. 셋 중 하나만 성공했고 하나는 유의하지 않으며 하나는 실패했다.

반증된 것 없음. 실패한 두 도메인 각각에 구체적 원인 가설과 반증 조건이 붙어 있다 — 팝업은 측 눈금의 성격 차이, 게임은 라벨의 시간 구조. 둘 다 검정 가능하다.

주장 2. 현재 파운데이션 모델은 세 도메인 중 하나에서만 작동한다. “도메인 불변 공유 표현”이라고 부를 수 있는 단계가 아니다.

반증 조건. 팝업의 측 눈금을 맞추고 게임 라벨을 출시 창으로 바꾼 뒤에도 셋 중 하나만 성공하면, 문제는 실행이 아니라 가설이다.

5. 한계

- 상한(내부 ridge)은 표본 내 적합이라 낙관적이다. 교차검증 상한과 비교하면 85%는 더 커진다 — 즉 이 수치는 보수적이다.
- 슬롯이 둘뿐이다. 두 개의 잠재 변수로 이루어진 모델의 설명력은 본질적으로 작다.
- 아이돌·게임의 측은 규칙 유도이며 신뢰도를 재지 않았다. 노트 9의 문턱($r \geq 0.79$)을 넘는지 모른다.

- 도메인이 셋뿐이므로 “도메인 하나 빼기”의 학습 출처가 돌밖에 없다. 실제 파운데이션 모델은 수십 개 도메인으로 학습한다.
- 순열 검정은 출처 라벨만 섞는다. 대상 도메인의 측정 자체가 정보를 담고 있을 가능성은 이 검정으로 배제되지 않는다.

6. 다음

1. 출시 30일 창 라벨로 게임 재검정 — 실패 원인을 가른다.
2. 아이돌·게임 축의 신뢰도 측정 — 노트 9의 문턱을 넘는지.
3. 네 번째 도메인 — 출처가 셋이 되면 공동 학습의 이득이 커져야 한다.
4. 대상 측 측정만으로 얻는 정보를 배제하는 대조군 설계.

참고문헌

- Caruana, R. (1997). Multitask learning. *Machine Learning*, 28(1), 41–75.
- Ben-David, S. et al. (2010). A theory of learning from different domains. *Machine Learning*, 79(1–2), 151–175.
- Maurer, A., Pontil, M., Romera-Paredes, B. (2016). The benefit of multitask representation learning. *JMLR*, 17(81), 1–32.
- Standley, T. et al. (2020). Which tasks should be learned together in multi-task learning? *ICML 2020*, 9120–9132.
- Hollmann, N. et al. (2025). Accurate predictions on small data with a tabular foundation model. *Nature*, 637, 319–326.