

IP 파운데이션 월드모델 연구 노트 15

DLC는 결과였다

반증 조건 하나가 누출을 드러내고 노트 14를 철회시켰다 --- 그리고 노트 13은 살아남았다

Sweetspot 월드모델 연구

2026년 7월 28일

초 록

노트 13은 게임 도메인이 대상으로서 어려운 이유를 라벨 성질로 돌리고 반증 조건을 적었다 — 출시 후 30일 리뷰만 라벨로 쓰면 설명력이 올라야 하며, 오르지 않으면 문제는 라벨이 아니라 축 매핑이다. 434건에 대해 30일 창 라벨을 수집해 재봤다. 오르지 않았다. 오히려 나빠졌다 — 도메인 내부 모델조차 상수와 같아졌다 (0.8010 대 0.8004). 축 매핑을 추적하니 누출이 나왔다. Steam이 주는 DLC 목록은 현재 DLC이지 출시 시점 DLC가 아니다. 출시 1년 미만 게임의 평균 DLC는 3.09종이고 6년 이상은 18.47종이다. 성공한 게임이 DLC를 더 낸다 — 역인과다. 전체 리뷰와의 상관 +0.180이 30일 창 리뷰와는 +0.084로 반토막 난다. 이 축을 비우고 다시 봤다. 결과가 같린다. 노트 13은 살아남는다 — 여섯 방향 중 넷이 여전히 유의하고, 게임이 낀 유의한 두 방향은 타깃 폭 하나만으로도 $p < 0.0001$ 이다. 노트 14는 철회한다 — 공유 슬롯이 하나로 줄자 세 도메인 공동 학습이 어디서도 유의하지 않다($p = 0.085, 0.520, 0.215$). 부수적으로 노트 14의 정규화 버그도 찾아 고쳤다.

Table 1: 게임 라벨 정의별 성적($n=434$). 낮을수록 좋다.

라벨	상수	도메인 내부	평균 쌍 전이
전체 리뷰	0.7793	0.7649	+0.0078
출시 30일 리뷰	0.8004	0.8010	+0.0404

1. 반증 조건을 실행했다

노트 13의 마지막 주장 상자는 이랬다.

게임 도메인이 대상으로서 어려운 것은 표본 크기가 아니라 라벨의 성질 때문이다. 리뷰 총계는 출시 시점 조건이 아니라 출시 이후 수년의 누적 동역학을 반영한다.

반증 조건. 출시 후 첫 30일 리뷰 수만 라벨로 쓰면 출시 시점 축의 설명력이 올라가야 한다. 오르지 않으면 라벨 성질이 아니라 축 매핑이 문제다.

Steam 리뷰 API는 날짜 창을 받는다. 482건 중 창이 이미 닫힌 434건에 대해 출시 후 30일 안에 달린 리뷰 수를 수집했다. 창 라벨은 전체의 중앙 21.2%다.

올라가지 않았다. 그리고 더 나쁜 것은 도메인 내부 성적이다. 게임 라벨을 전부 보고 적합한 모델이 상수와 같다(0.8010 대 0.8004). 축이 출시 시점 반응에 대해 아무 정보도 담고 있지 않다.

반증 조건이 말한 대로 문제는 라벨이 아니라 축 매핑이다.




Figure 1: 30일 창으로 바꾸면 도메인 내부 모델조차 상수와 같아진다. 축이 출시 시점 반응에 대해 아무것도 말하지 못한다는 뜻이다.

2. 누출을 찾았다

두 축 중 굵게 규모를 의심했다. 게임에서 그것은 DLC 수였다.

Steam appdetails의 dlc 목록은 조회 시점의 현재 DLC다. 출시 시점 DLC가 아니다. 6년 이상 된 게임의 평균 DLC가 1년 미만 게임의 6.0배다.

이것은 두 겹의 문제다.

- 시간 누적 — 오래된 게임일수록 DLC가 많다. 탈추 세로 상당 부분 제거되지만 완전하지 않다.
- 역인과 — 성공한 게임이 DLC를 더 낸다. 이쪽이 본질이다. 전체 리뷰와의 상관 +0.180이 30일 창 리뷰와는 +0.084로 반토막 난다. 출시 시점 반응과는 관계가 약하고 누적 성공과 관계가 강하다.




Figure 2: DLC 수는 출시 후 계속 늘어났다. 출시 시점 피쳐가 아니다.

Table 2: 출시 경과별 DLC 수(n=482).

출시 후	n	평균 DLC	0종 비율
1년 미만	173	3.09	40%
1-3년	127	5.69	28%
3-6년	90	11.27	23%
6년 이상	92	18.47	16%

팝업에서 결과보고서의 일별 표로 운영일수를 세면 누출이라고 했던 것과 같은 구조다. 다른 점은 여기서는 내가 그것을 알아채지 못한 채 세 노트를 썼다는 것이다.

주장 1. 게임 도메인의 굿즈 규모 축(DLC 수)은 누출이다. 출시 시점 조건이 아니라 출시 후 누출된 사후 정보이며, 그 상당 부분이 반응의 결과다.

반증 조건. 출시 시점 에디션 수(디럭스·컬렉터)를 따로 수집해 같은 자리에 넣었을 때 30일 창 라벨에 대한 설명력이 생기면, 문제는 '굿즈 규모'라는 축이 아니라 그 측정 방법이었다.

팝업과 아이돌은 누출이 아니다. 팝업의 굿즈 종류 수는 기획서에 적히고, 아이돌의 앨범 버전 수는 발매 시점에 확정된다. 둘 다 출시 시점 피쳐다. 누출은 게임 도메인에 국한된다.

3. 그래서 무엇이 남았나

게임의 굿즈 규모를 비우고 전부 다시 썼다. 굿즈 규모가 유효한 팝업-아이돌 사이는 두 축으로, 게임이 낀 방향은 타깃 쪽 하나로 검정한다.

노트 13은 살아남는다. 여섯 방향 중 넷이 여전히 유의하고, 게임이 낀 유의한 두 방향은 타깃 쪽 하나만으로 $p < 0.0001$ 이다. 그 방향들이 작동한 이유는 누출된 축 때문이 아니었다.

계수 부호도 유지된다 — 타깃 쪽은 팝업 +0.335, 아이돌 +0.441, 게임 +0.187로 세 도메인 모두 양수다.




Figure 3: 누출 제거 후 여섯 방향. 넷이 유의하게 남는다.

Table 3: 누출 제거 후 전이. 순열 3,000회.

방향	축	n	차이	p
팝업 → 아이돌	2	63	-0.0744	0.0013
게임 → 팝업	1	75	-0.0470	<0.0001
아이돌 → 팝업	2	75	-0.0467	0.0480
게임 → 아이돌	1	74	-0.0185	<0.0001
팝업 → 게임	1	482	-0.0069	0.2147
아이돌 → 게임	1	482	+0.0059	0.5770

4. 그러나 노트 14는 철회한다

파운데이션 모델은 사정이 다르다. 공유 슬롯이 둘에서 하나로 줄었기 때문이다.

셋 다 유의하지 않다. 노트 14가 보고한 성공은 게임을 출처로 쓸 때 그 도메인의 누출된 굿즈 축이 헤드에 실려 있었기 때문이다.

주장 2. 노트 14의 “두 도메인으로 학습한 공유 헤드가 세 번째 도메인의 라벨 없이 상수를 이긴다”를 철회한다. 누출을 제거하면 세 도메인 공동 학습은 어디서도 유의하지 않다.

반증 조건. 출시 시점 에디션 수를 수집해 공유 슬롯이 다시 둘이 됐을 때 유의성이 돌아오면, 철회 사유는 누출이 아니라 슬롯 개수였던 것이다.

4.1 왜 쌍 전이는 되는데 공동 학습은 안 되나

계수 크기가 도메인마다 다르기 때문으로 보인다. 타깃 쪽 계수가 팝업 +0.335, 아이돌 +0.441, 게임 +0.187로 2.4배 차이가 난다. 공유 헤드는 하나의 기울기를 써야 하므로 세 값의 절충으로 끌려간다. 슬롯이 여럿이면 다른 슬롯이 보정할 여지가 있지만 하나면 그럴 수 없다.

주장 3. 공유 헤드가 작동하려면 계수의 부호만 같아서는 부족하고 크기도 비슷해야 한다. 슬롯이 하나일 때 이 제약이 가장 세다.

반증 조건. 도메인별 스케일 항을 하나 더 두어 (공유 기울기 × 도메인 배율) 유의성이 돌아오면, 문제는 부호가 아니라 눈금이었던 것이다.

Table 4: 도메인 하나 빼기, 슬롯 1개(타깃 폭)로 재실행.

대상	상수	파운데이션	차이	p
팝업	0.7596	0.7239	-0.0357	0.085
아이돌	0.6588	0.6622	+0.0034	0.520
게임	0.7701	0.7630	-0.0072	0.215

5. 부수 발견 --- 노트 14의 정규화 버그

노트 14를 쓰면서 앵커 타깃을 도메인마다 min-max로 0-1에 맞췄다. min-max는 극단값이 눈금을 정하므로 도메인 사이의 축 눈금이 어긋난다. 실제로 아이돌 → 팝업 전이가 노트 13의 -0.0467에서 -0.0064로 무너져 있었다.

모든 도메인에 같은 함수(로지스틱)를 쓰도록 고치자 -0.0642로 돌아왔다. 비교 가능한 눈금을 만들려면 도메인별 통계가 아니라 공통 변환을 써야 한다.

6. 한계

- 게임의 출시 시점 에디션 수를 아직 수집하지 못했다. 굿즈 규모 축이 게임에서 정말 작동하는지는 미결이다.
- 30일 창 라벨은 48건(창이 안 닫힌 최신작)을 제외했다. 최신 편향이 남는다.
- 팝업·아이돌의 굿즈 규모가 누출이 아니라는 것은 논증이지 검정이 아니다. 같은 30일 창 방식의 검정을 두 도메인에서도 해야 한다.
- 계수 크기 차이가 공동 학습 실패의 원인이라는 설명은 아직 검정하지 않았다.

7. 다음

1. 게임 출시 시점 에디션 수 수집 — 공유 슬롯을 둘로 되돌린다.
2. 도메인별 배율 향을 둔 공유 헤드 — 계수 크기 가설의 직접 검정.
3. 팝업·아이돌 굿즈 축의 누출 검정 — 논증을 검정으로 바꾼다.
4. 다른 축들의 누출 점검 — 미디어 투입(퍼블리셔 사전 실적)은 시간 인과적으로 계산했으나 같은 종류의 문제가 없는지 확인.

참고문헌

- Kaufman, S., Rosset, S., Perlich, C. (2012). Leakage in data mining: formulation, detection, and avoidance. ACM TKDD, 6(4), 1–21.
- Good, P. (2005). Permutation, Parametric, and Bootstrap Tests of Hypotheses, 3rd ed. Springer.
- Standley, T. et al. (2020). Which tasks should be learned together in multi-task learning? ICML 2020, 9120–9132.
- Ben-David, S. et al. (2010). A theory of learning from different domains. Machine Learning, 79(1–2), 151–175.