

IP 파운데이션 월드모델 연구 노트 17

시드가 결론을 삼킨다

시드 스무 개로 재보니 공유 헤드의 우위가 잡음 안에 있었다 --- 그리고 단순한 쪽이 이긴다

Sweetspot 월드모델 연구

2026년 7월 28일

초 록

노트 16은 신경망의 시드 분산이 크다는 것을 한계로 적고 정량화를 다음 과제로 남겼다. 시드 20개로 재봤다. 분산이 효과 크기를 삼킨다 — 팝업에서 공유 헤드의 상수 대비 이득이 0.0149인데 시드 표준편차가 0.0783이다. 5.3배다. 게임은 이득이 음수이고(즉 상수보다 나쁘고) 표준편차가 0.0848이다. 이어서 노트 15가 남긴 마지막 반증 조건 — 공유 헤드를 포기한 대조군 — 을 돌렸다. 출처마다 따로 학습해 예측을 평균만 내면 공유 헤드보다 낮고 분산도 절반이다(게임 0.8454 대 0.7872, 표준편차 0.085 대 0.049). 공동 학습은 이득이 아니라 손해다. 그리고 세 방법 모두 ridge 쌍 전이보다 나쁘다(세 도메인 평균 0.6702 대 0.7244·0.7490). 결론은 노트 6이 이미 말한 것이다 — 이 표본에서 신경망은 아직 이른다. 노트 14를 완전히 철회하고, 파운데이션 구조를 “측정된 축 → 선형 모델 → 도메인 간 계수 전이”로 확정한다. 공유 표현 주장 자체는 살아 있다(노트 16의 전이 넷은 결정론적 ridge에서 나왔다). 무너진 것은 신경망 구현이다.




Figure 1: 시드 20개, 평균 ± 1 표준편차. 가로줄이 상수와 ridge 쌍 전이다. 오차 막대가 두 가로줄 사이 거리보다 크다.

1. 시드를 스무 개 돌렸다

노트 16의 한계 절에 이렇게 적었다.

신경망의 시드 분산이 크다. 같은 설정에서 팝업 예측 MAE가 시드 수에 따라 0.7357에서 0.7733까지 움직였다. ... 보고한 파운데이션 수치는 이 분산 안에 있다.

“분산 안에 있다”고 짐작만 하고 넘어갔다. 재봤다. 팝업에서 공유 헤드는 상수를 0.0149 이긴다. 시드 표준편차는 0.0783이다. 잡음이 신호의 5.3배다. 시드 하나만 보고 “이겼다”고 쓰면 동전을 한 번 던지고 결론을 내는 것과 같다.

Figure 2: 효과 크기와 시드 표준편차의 비율. 잡음이 신호의 몇 배다.

주장 1. 이 표본에서 신경망 결과는 시드 하나로 보고할 수 없다. 시드 분산이 상수 대비 효과 크기의 4~5배다(팝업 5.3배, 아이돌 4.5배). 게임은 효과가 음수라 비율 자체가 의미를 잃는다.

반증 조건. 표본이 커져 시드 표준편차가 효과 크기의 3분의 1 아래로 내려가면 단일 시드 보고가 가능해진다.

Table 2: 공동 학습 대 단순 앙상블(시드 20개).

대상	공유 헤드	출처별 앙상블
팝업	0.7447 ± 0.078	0.7440 ± 0.051
아이돌	0.6568 ± 0.042	0.6421 ± 0.026
게임	0.8454 ± 0.085	0.7872 ± 0.049

Table 3: 세 도메인 평균 MAE.

방법	평균 MAE
ridge 쌍 전이	0.6702
출처별 앙상블 (신경망)	0.7244
상수	0.7257
공유 헤드 (신경망)	0.7490




Figure 3: 세 도메인 평균. 단순한 쪽이 이긴다.

2. 공유 헤드를 포기해 봤다

노트 15는 공유 헤드가 쌍 전이보다 못한 이유를 계수 크기 차이로 지목하고 반증 조건을 적었다 — 방향까지 도메인별로 풀었을 때(공유 헤드를 포기했을 때) 격차가 커지면 문제는 눈금이 아니라 공유 자체다.

대조군은 단순하다. 두 출처 도메인을 함께 학습하지 않고 따로 학습한 뒤 예측을 평균만 낸다. 공유되는 것이 없다.

세 대상 모두 앙상블이 낮고, 분산은 절반 수준이다. 게임에서는 격차가 0.058로 크다.

주장 2. 공동 학습은 이득이 아니라 손해다. 출처마다 따로 학습해 예측을 평균만 내는 편이 세 대상 모두에서 낮고 분산도 절반이다.

반증 조건. 도메인 수가 늘어(다섯 이상) 공동 학습이 앙상블을 넘어서면, 이 결과는 출처가 둘뿐이라 생긴 것이다.

이것은 노트 15가 세운 배울 가설의 마지막 반증이기도 하다. 문제는 계수 눈금이 아니라 공유 자체였다. 출처가 둘뿐인 상태에서 하나의 헤드를 강요하면 두 도메인의 절충으로 끌려갈 뿐 얻는 것이 없다.

3. 그리고 셋 다 선형 모델보다 나쁘다

측정된 축을 ridge에 그대로 넣고 계수만 옮기는 것이 신경망 어느 구성보다 낮다. 공유 헤드는 상수보다도 나쁘다.

주장 3. 노트 14를 완전히 철회한다. 파운데이션 구조의 신경망 구현은 이 표본에서 정당화되지 않으며, 측정된 축을 선형 모델에 넣고 계수를 옮기는 것이 모든 신경망

4. 그러면 무엇이 남았나

무너진 것과 남은 것을 분명히 갈라 둔다

무너진 것 --- 신경망 구현. 행해진 슬롯, 도메인별 인코더, 공유 전이 헤드. 노트 5-7이 제약을 좁혀 만든 구조인데, 그 제약들은 팝업 단일 도메인에서 도출됐고 표본이 75건이었다. 세 도메인으로 넓히자 시드 분산이 결과를 삼켰다.

남은 것 --- 공유 표현 주장. 노트 16이 보고한 전이 넷은 전부 결정론적 ridge에서 나왔다. 시드가 없으므로 이 결과들은 이 노트의 비판을 받지 않는다.

- 팝업 → 아이돌 $p=0.0013$
- 게임 → 아이돌 $p<0.0001$
- 아이돌 → 팝업 $p=0.0480$
- 게임 → 팝업 $p=0.0003$

두 축(타깃 폭, 굵즈 규모)이 세 도메인에서 같은 부호로 작동하고 계수가 옮겨진다는 사실은 그대로다.

그래서 확정 구조.

도메인마다 축을 측정하고, 축에서 결과로 가는 선형 관계를 한 도메인에서 추정해 다른 도메인에 옮긴다. 인코더도 공동 학습도 현재 표본에서는 불필요하다.

이것은 노트 6이 이미 말한 것이다 — “ $n=75$ 에서 신경망은 아직 이른다.” 그것을 확립해 놓고 노트 14에서 다시 신경망을 지었다. 도메인이 셋이 됐으니 괜찮을 것이라 가정했는데, 도메인이 늘어도 도메인당 표본은 그대로였다.

5. 한계

- 시드 20개는 표준편차 추정에 충분하지만 평균 추정에는 넉넉하지 않다. 보고한 평균 자체가 ± 0.02 정도 흔들린다.
- 신경망 하이퍼파라미터(층 폭 16, 드롭아웃 0.15, 앵커 8.0)를 조율하지 않았다. 조율하면 분산이 줄 수 있으나, 조율에 쓸 검증 표본이 없다.

- ridge 쌍 전이의 “최선”은 사후 선택이므로 신탁이다. 평균 쌍 전이와 비교하면 격차가 줄어든다.
- 앙상블은 출처 둘의 단순 평균이다. 가중을 배우면 라벨이 필요해진다.

6. 다음

1. 입장 허들의 진짜 측정 — 게임의 최소 사양 요구, 지역 제한 등 가격과 분리된 접근 난이도.
2. 팝업·아이돌 굿즈 축의 누출 검정 — 게임에서 쓴 30 일 창 방식을 옮긴다.
3. 네 번째 도메인 — 공동 학습이 앙상블을 넘어서려면 출처가 더 필요하다.
4. 도메인당 표본 확대 — 신경망 재도전의 전제 조건.

참고문헌

- Bouthillier, X. et al. (2021). Accounting for variance in machine learning benchmarks. MLSys 2021.
- Dietterich, T. G. (2000). Ensemble methods in machine learning. Multiple Classifier Systems, 1 – 15.
- Grinsztajn, L., Oyallon, E., Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on typical tabular data? NeurIPS 2022.
- Standley, T. et al. (2020). Which tasks should be learned together in multi-task learning? ICML 2020, 9120 – 9132.