

IP 파운데이션 월드모델 연구 노트 20

더 재는 것이 항상 낫지는 않다

공통 축을 셋으로 늘렸더니 전이가 나빠졌다 --- 축은 개수가 아니라 정의의 정합성이다

Sweetspot 월드모델 연구

2026년 7월 28일

초 록

노트 19는 프로크루스테스 정렬로 라벨 0개 전이를 완성하면서 한계 하나를 적었다 — 공통 축이 둘이라 적재 행렬이 2×2 고 회전에 여유가 없으니 셋으로 늘리라고, 늘렸다. 게임의 미디어 투입이 38%였던 원인은 퍼블리셔 사전작 부족이었는데, 자체 배급 여부로 매우면 100%가 된다. 신호도 옳다 — 자체 배급 218건의 평균 반응이 -0.138 , 퍼블리셔가 붙은 216건이 $+0.139$ 다($r=-0.139$). 그런데 전이가 나빠졌다. 유의 방향이 다섯에서 넷으로 줄고, 평균 차이가 -0.0527 에서 -0.0466 으로, 팝업 → 게임은 $p=0.019$ 에서 0.154 로 무너졌다. 정렬 기준 축의 부분집합을 전부 돌려 범인을 찾았다 — 미디어 투입을 포함한 모든 조합이 나쁘다(미디어+굿즈만 쓰면 유의 방향 1개). 원인은 정의의 불일치다. 세 도메인의 “미디어 투입”이 서로 다른 것을 켜다 — 팝업은 기획서의 홍보 계획, 아이돌은 서바이벌과 사전 화제, 게임은 퍼블리셔 실적. 정렬 축에서 빼도 인자 공간을 통해 영향이 남아 축 자체를 되돌렸다. 공통 축은 개수가 아니라 정의의 정합성으로 고른다.




Figure 1: 자체 배급 여부와 출시 30일 반응. 신호의 방향은 옳다.

1. 공통 축을 셋으로 늘려 봤다

노트 19의 한계 절 첫 줄은 이랬다.

공통 축이 둘이라 적재 행렬이 2×2 다. 회전이 과소결정되지는 않지만 여유도 없다. 공통 축이 셋 이상이면 정렬이 훨씬 안정될 것이다.

같은 노트의 “다음” 첫 항목도 그것이였다 — 미디어 투입을 게임에서 관측 가능하게 만든다. 게임의 미디어 투입은 퍼블리셔 사전 실적으로 정의했는데 482건 중 185건(38%)에만 있었다. 표본의 퍼블리셔 대부분이 그 이전 출시작이 없기 때문이다.

매우는 방법이 있었다. 자체 배급 여부다. 퍼블리셔가 개발사와 다르다는 것 자체가 홍보 투입의 신호이고, 이것은 100% 관측된다.

사전 실적이 있으면 그것을 쓰고 없으면 자체 배급 여부로 대신하도록 결합했다. 커버리지 100%, 방향도 맞는다. 공통 축이 셋이 됐다.

Table 1: 미디어 투입 후보($n=434$).

후보	커버리지	창 라벨과 r
퍼블리셔 사전 실적	38%	$+0.338$
자체 배급 여부	100%	-0.139




Figure 2: 축을 추가하기 전과 후, 여섯 방향 중 넷이 나빠진다.

2. 그런데 나빠졌다

관측을 늘렸는데 성능이 떨어졌다. 팝업 → 게임이 유의성을 잃고, 게임 → 팝업이 $p=0.0005$ 에서 0.036 으로 약해졌다. 이득은 아이돌 → 게임의 부호가 $+0.0019$ 에서 -0.0072 로 바뀐 것뿐인데, 둘 다 유의하지 않으므로 실질 이득이 아니다.

Table 2: 게임 미디어 투입 추가 전후, 프로크루스테스 정렬, 순열 2,000회.

방향	축 2개		축 3개	
	차이	p	차이	p
팝업 → 아이돌	-0.0716	0.0015	-0.0716	0.0015
아이돌 → 팝업	-0.0765	0.0330	-0.0765	0.0330
게임 → 아이돌	-0.0752	<0.0001	-0.0631	<0.0001
게임 → 팝업	-0.0671	0.0005	-0.0409	0.0360
팝업 → 게임	-0.0280	0.0190	-0.0205	0.1540
아이돌 → 게임	+0.0019	0.4025	-0.0072	0.3285
유의 방향	5		4	
평균 차이	-0.0527		-0.0466	

Table 3: 정렬 기준 축 조합(순열 2,000회).

조합	유의 방향	평균 차이
타깃 폭 + 굿즈 규모	4	-0.0466
타깃 폭 + 미디어 + 굿즈	4	-0.0450
타깃 폭 + 미디어	3	-0.0271
미디어 + 굿즈	1	+0.0021

Table 4: 도메인별 미디어 투입의 정의.

도메인	측정 방법
팝업	기획서의 홍보 계획을 사람이 0-4로 매김
아이돌	서바이벌 출신 + 데뷔 전 화제 + 소속사 실적
게임	퍼블리셔 사전 실적 + 자체 배급 여부




Figure 3: 정렬 기준 축 조합별 성적. 미디어 투입이 들어가면 나빠진다.

주장 1. 축을 더 관측 가능하게 만드는 것이 항상 이득은 아니다. 게임의 미디어 투입 커버리지를 38%에서 100%로 올리자 유의 전이 방향이 다섯에서 넷으로, 평균 차이가 -0.0527에서 -0.0466으로 나빠졌다.

반증 조건. 같은 축을 세 도메인에서 같은 방식으로 정의한 뒤 추가했을 때도 나빠지면, 문제는 정의가 아니라 축의 개수 자체다.

3. 범인을 찾았다

정렬 기준으로 쓸 축의 부분집합을 전부 돌렸다.

미디어 투입이 들어간 조합이 전부 나쁘다. 미디어와 굿즈만으로 정렬하면 유의 방향이 하나로 무너지고 평균 차이가 양수가 된다.

정렬 축에서 빼도 소용없다. 미디어를 정렬 기준에서 빼도 여전히 축 2개 때보다 나쁘다(위 표에서 타깃 폭 + 굿즈 규모 조합이 -0.0466인데, 게임에서 미디어 축 자체를 비우면 -0.0527이다). 정렬 기준이 아니어도 그 축이 게임의 인자 공간에 들어가기 때문이다. 주성분은 관측된 축 전부의 상관 구조에서 나온다.

그래서 축 자체를 되돌렸다. 값은 기록해 두되 마스크를 0으로 되돌려 인자 공간에서 뺐다.

4. 왜 미디어 투입만 이런가

세 도메인의 “미디어 투입”이 서로 다른 것을 잔다.

팝업은 계획된 투입을, 아이돌은 사전 노출의 결과를, 게임은 배급 구조를 잔다. 이름만 같고 물리량이 다르다.

타깃 폭과 굿즈 규모는 그렇지 않다. 타깃 폭은 세 도메인 모두 “몇 명에게 닿을 수 있게 만들었나”를 재고(대상 연령대 폭 / 그룹 구성과 대중 노출 / 지원 언어와 플랫폼 수), 굿즈 규모는 “닿으면 무엇을 얻나”를 잔다(굿즈 종류 / 앨범 버전 / Steam 기능). 측정 도구는 달라 도 재는 것이 같다.

주장 2. 공통 축은 개수가 아니라 정의의 정합성으로 고른다. 이름이 같아도 도메인마다 다른 물리량을 재면 인자 공간을 왜곡한다.

반증 조건. 미디어 투입을 세 도메인에서 같은 물리량으로 — 예컨대 개시 시점 이전 90일간의 언론 노출 건수로 — 통일해 다시 넣었을 때 전이가 개선되면, 축은 옳고 측정만 어긋났던 것이다.

이것은 노트 1이 라벨에 대해 말한 것을 축에 대해 되풀이한다. 거기서는 주최자 발표와 게이트 계수가 한 컬럼에 섞여 2.75배 벌어져 있었다. 여기서는 세 가지 다른 측정이 한 축 이름에 섞여 있다. 이름이 같다고 같은 것이 아니다 — 라벨에서도, 축에서도.

5. 그래서 노트 19의 권고를 수정한다

노트 19는 “공통 축이 셋 이상이면 정렬이 훨씬 안정될 것”이라고 적었다. 절반만 맞다. 정확히는 이렇다.

공통 축을 늘리면 정렬이 안정된다 — 단, 늘리는 축이 세 도메인에서 같은 물리량을 재 때만. 정의가 어긋난 축은 늘릴수록 해롭다.

실행 순서도 바뀐다. 새 축을 공통 축에 넣기 전에 커버리지가 아니라 정의의 정합성을 먼저 확인해야 한다. 커버리지는 쉬운 문제이고 정합성은 어려운 문제인데, 쉬운 쪽부터 손대면 이번처럼 된다.

6. 한계

- 정의 불일치가 원인이라는 것은 진단이지 검정이 아니다. 세 도메인의 미디어 투입을 같은 물리량으로 통일해 재확인해야 한다.
- 부분집합 검정은 조합 넷뿐이다. 공통 축 후보가 늘면 다중비교가 문제가 된다.
- 자체 배급 여부의 상관이 -0.139 로 약하다. 더 강한 신호였다면 정의 불일치를 이겨냈을 수도 있다.
- 되돌린 결정은 이 표본에서의 판단이다. 표본이 커지면 뒤집힐 수 있다.

7. 다음

1. 미디어 투입을 세 도메인에서 같은 물리량으로 재정의 — 개시 이전 일정 기간의 언론 노출 건수처럼 도메인 독립적인 정의.
2. 나머지 축(매장 노출도, 입장 허들)도 정의 정합성 관점에서 재검토.
3. 네 번째 도메인 — 정합성 원칙이 도메인이 늘어도 유지되는지.
4. 절대량 복원 — 노트 19가 남긴 과제.

참고문헌

- Schönemann, P. H. (1966). A generalized solution of the orthogonal Procrustes problem. *Psychometrika*, 31(1), 1–10.
- Meredith, W. (1993). Measurement invariance, factor analysis and factorial invariance. *Psychometrika*, 58(4), 525–543.
- Guyon, I., Elisseeff, A. (2003). An introduction to variable and feature selection. *JMLR*, 3, 1157–1182.
- Ben-David, S. et al. (2010). A theory of learning from different domains. *Machine Learning*, 79(1–2), 151–175.