

IP 파운데이션 월드모델 연구 노트 24

실패에는 특별한 이유가 없었다

여섯 방향이 출처와 대상의 합으로 97% 설명된다 --- 누구를 가르치느냐가 누가 가르치느냐보다 네 배 중요하다

Sweetspot 월드모델 연구

2026년 7월 28일

초 록

아이돌 → 게임 방향은 노트 13부터 한 번도 성공한 적이 없다. 스물세 편 동안 그것을 특수한 문제로 다뤘다 — 게임 라벨의 시간 구조, 아이돌 표본 크기, 축 매핑 오류를 차례로 의심했다. 이 노트는 여섯 방향 전부에 부트스트랩 구간을 붙이고 가법 모형을 적합해 본다. $\text{효과} = \text{출처 강도} + \text{대상 난이도}$ 라는 모형이 97.3%를 설명하고 잔차가 여섯 셀 모두 ± 0.0054 로 균일하다. 상호작용이 없다. 아이돌 → 게임은 예외가 아니라 가장 약한 출처와 가장 어려운 대상이 만난 셀일 뿐이다 — 모형 예측 $+0.0034$, 관측 $+0.0088$. 더 중요한 것은 두 요인의 크기 차이다. 출처 강도의 범위가 0.0175인데 대상 난이도의 범위는 0.0657로 3.8배다. 누구를 가르치느냐가 누가 가르치느냐보다 네 배 중요하다. 그리고 이것이 노트 13의 표현을 정정한다 — 게임의 출처 점수는 -0.0049 로 팝업(-0.0063)과 거의 같다. 게임은 특별히 좋은 선생이 아니었고, 특별히 나쁜 학생일 뿐이었다(대상 점수 $+0.0415$).

1. 스물세 편째 미해결

아이돌 → 게임은 노트 13에서 처음 실패한 뒤 한 번도 유의해진 적이 없다. 그 사이 여러 가설을 세우고 검정했다.

- 노트 13 — 표본 크기? 도메인마다 63건으로 맞춰도 실패(승률 15%).
- 노트 15 — 게임 라벨의 시간 구조? 출시 30일 창으로 바뀌도 실패.
- 노트 16 — 축 매핑? DLC를 Steam 기능 수로 고쳐도 실패.
- 노트 23 — 아이돌 축 커버리지? 33%에서 90%로 올려도 실패($p=0.412$).

네 번의 시도가 모두 이 셀을 살리지 못했다. 그런데 그 시도들은 전부 이 셀에 특별한 문제가 있다는 전제 위에 서 있었다. 전제를 검정한 적이 없다.

2. 여섯 방향에 구간을 붙인다

먼저 노트 23이 남긴 과제부터 — 효과 자체에 신뢰구간을 준다. 출처 도메인을 800회 재추출해 계수의 표집 분산을 반영했다.

순열 검정으로는 다섯이 유의했는데(노트 23) 부트스트랩 구간으로는 셋만 0을 배제한다. 모순이 아니다 — 노트 10에서 정리한 대로 순열은 “전이가 없다”는 귀무가설을 직접 치고, 부트스트랩은 효과 크기의 추정 정밀도를 잴다. 전이의 존재는 다섯에서 확인되고, 효과 크기가 정밀한 것은 셋이다.




Figure 1: 여섯 방향의 부트스트랩 95% 구간. 셋만 0을 확실히 배제한다.

3. 가법 모형이 97%를 설명한다

여섯 셀을 “ $\text{효과} = \text{출처 강도} + \text{대상 난이도}$ ”로 적합했다. 모수는 출처 셋, 대상 셋, 절편 하나인데 식별을 위해 각 블록을 중심화하면 자유도 다섯이다. 여섯 셀에 다섯 모수이므로 포화에 가깝지만, 문제는 적합도가 아니라 잔차의 패턴이다.

잔차가 여섯 셀 모두 크기가 같고 부호만 다르다. 상호작용이 있다면 특정 셀에 잔차가 몰려야 하는데 그렇지 않다.

아이돌 → 게임의 잔차는 $+0.0054$ 로 다른 다섯과 똑 같다. 이 셀에 특별한 문제가 없다는 뜻이다. 가장 약한 출처와 가장 어려운 대상이 만나면 모형이 예측하는 값이 $+0.0034$ 이고, 관측이 $+0.0088$ 이다.

Table 1: 부트스트랩 800회, 대상 라벨 미사용.

방향	효과	95% 구간
게임 → 아이돌	-0.0838	[-0.1053, -0.0564]
팝업 → 아이돌	-0.0744	[-0.1118, -0.0108]
게임 → 팝업	-0.0660	[-0.0952, -0.0341]
아이돌 → 팝업	-0.0607	[-0.0996, +0.0156]
팝업 → 게임	-0.0196	[-0.0342, +0.0072]
아이돌 → 게임	+0.0088	[-0.0332, +0.0780]




Figure 2: 관측과 가법 모형 예측, 점선이 완전 적합선이다.

주장 1. 아이돌 → 게임의 실패는 그 조합에 특유한 문제가 아니라 출처 강도와 대상 난이도의 합으로 완전히 설명된다. 스물세 편 동안 이 셀을 특수 사례로 다룬 것은 잘못이었다.

반증 조건. 네 번째 도메인을 넣어 셀이 열둘이 됐을 때 가법 모형의 설명력이 크게 떨어지면, 여섯 셀에서의 적합은 모수 수가 셀 수에 가까워 생긴 착시였다.

4. 대상이 출처보다 네 배 중요하다

모형에서 두 요인을 뽑았다.

대상 난이도의 범위가 출처 강도의 3.8배다. 어느 도메인에서 배우느냐보다 어느 도메인을 맞히느냐가 훨씬 중요하다.

주장 2. 도메인 간 전이 성능은 대상 도메인의 성질이 지배한다. 대상 난이도의 분산이 출처 강도의 3.8배다.

반증 조건. 다른 축 집합이나 다른 모델류에서 두 범위가 비슷해지면, 이 비율은 현재 구성에 딸린 값이다.

4.1 노트 13의 표현을 정정한다

노트 13의 제목은 “좋은 선생, 나쁜 학생”이었고 게임을 그렇게 묘사했다. 절반만 맞다.

게임의 출처 점수는 -0.0049로 팝업(-0.0063)과 사실상 같다. 게임은 특별히 좋은 선생이 아니다. 게임이 출처일 때 성적이 좋아 보였던 것은 그 상대가 아이돌과 팝업 — 둘 다 쉬운 대상 — 이었기 때문이다.

특별한 것은 학생 쪽이다. 게임의 대상 점수 +0.0415

Table 2: 가법 모형 잔차.

방향	관측	예측	잔차
게임 → 아이돌	-0.0838	-0.0784	-0.0054
팝업 → 아이돌	-0.0744	-0.0799	+0.0054
게임 → 팝업	-0.0660	-0.0714	+0.0054
아이돌 → 팝업	-0.0607	-0.0553	-0.0054
팝업 → 게임	-0.0196	-0.0142	-0.0054
아이돌 → 게임	+0.0088	+0.0034	+0.0054

잔차 RMS 0.0054 · 관측 SD 0.0329 · 설명력 97.3%




Figure 3: 출처 강도와 대상 난이도. 대상 쪽 분산이 훨씬 크다.

는 다른 둘(-0.0172, -0.0242)과 자릿수가 다르다. 게임은 평범한 선생이고 매우 나쁜 학생이다.

5. 그래서 무엇을 고칠 것인가

이 결과는 노력의 방향을 바꾼다.

개별 방향을 고치려 하지 않는다. 아이돌 → 게임을 살리려고 네 번 시도했는데, 그 셀에 특유한 문제가 없으므로 셀 단위 개선은 성립하지 않는다. 두 요인 중 하나를 고쳐야 한다.

대상 난이도를 먼저 본다. 분산이 네 배 크므로 여기가 지렛대다. 게임이 어려운 이유는 노트 15에서 이미 진단했다 — 리뷰 총계가 출시 이후 수년의 누적 동역학을 반영하고, 출시 30일 창으로 바뀌도 도메인 내부 모델조차 상수와 같았다. 게임 도메인의 라벨 자체가 출시 시점 조건으로 예측 가능한 양이 아닐 수 있다.

새 도메인 선택 기준이 생긴다. 네 번째 도메인을 고를 때 “좋은 출처가 될까”보다 “예측 가능한 대상일까”를 먼저 물어야 한다. 대상으로서 어려운 도메인은 넣어도 여섯 셀 중 둘을 버리게 된다.

6. 한계

- 여섯 셀에 다섯 모수라 모형이 포화에 가깝다. 설명력 97.3%는 그 자체로는 증거가 약하고, 잔차가 균일하다는 점이 실제 근거다.

Table 3: 가법 모형 계수(중심화). 출처는 음수일수록 좋은 선생, 대상은 양수일수록 어려운 학생이다.

도메인	출처 강도	대상 난이도
팝업	-0.0063	-0.0172
게임	-0.0049	+0.0415
아이돌	+0.0112	-0.0242
범위	0.0175	0.0657

- 부트스트랩은 출처만 재추출한다. 대상 표본의 불확실성은 반영되지 않았다.
- 출처 강도와 대상 난이도가 도메인의 고정 성질이라는 가정이 들어 있다. 축 구성이 바뀌면 둘 다 바뀔 수 있다.
- 세 도메인으로 뽑은 두 요인이므로 새 도메인에 외삽할 근거가 약하다.

7. 다음

1. 게임 대상 난이도의 원인 분리 — 라벨의 성질인지 축의 부족인지.
2. 네 번째 도메인을 “대상으로서 예측 가능한가” 기준으로 선정.
3. 셀이 열둘이 됐을 때 가법 모형 재검정.
4. 대상 표본까지 재추출하는 이중 부트스트랩.

참고문헌

- Tukey, J. W. (1949). One degree of freedom for non-additivity. *Biometrics*, 5(3), 232–242.
- Efron, B., Tibshirani, R. (1993). *An Introduction to the Bootstrap*. Chapman & Hall.
- Good, P. (2005). *Permutation, Parametric, and Bootstrap Tests of Hypotheses*, 3rd ed. Springer.
- Ben-David, S. et al. (2010). A theory of learning from different domains. *Machine Learning*, 79(1–2), 151–175.