

IP 파운데이션 월드모델 연구 노트 27

덜 관측된 학생이었다

팝업에서 두 축을 빼자 게임보다 어려워졌다 --- 게임의 난이도는 도메인 성질이 아니라 관측 부족이다

Sweetspot 월드모델 연구

2026년 7월 28일

초 록

노트 24는 게임을 “매우 나쁜 학생”으로 규정했다. 노트 25가 배선 오류를 고쳐 난이도를 $+0.0415$ 에서 $+0.0289$ 로 낮췄지만 여전히 가장 어려운 대상이었고, 남은 부분의 원인은 미결이었다. 이 노트가 반사실로 답한다. 팝업에서 게임에 없는 두 축(매장 노출도, 입장 허들)을 빼자 팝업이 게임보다 어려워졌다 — 팝업 $+0.0238$ 대 게임 $+0.0113$. 관측 축을 같은 셋으로 맞추면 게임이 오히려 쉬운 대상이다. 게임의 잔여 난이도는 도메인 성질이 아니라 관측 부족이다. 노트 24의 “나쁜 학생” 규정을 철회한다 — 게임은 나쁜 학생이 아니라 덜 관측된 학생이었다. 함께 노트 26이 남긴 제거 강도 곡선도 그렸다. 팝업 제1주성분을 α 만큼 빼며 전이를 재니 $\alpha=0.2$ 에서 아주 약간 개선되고 ($-0.0780 \rightarrow -0.0794$) 0.4부터 급락한다(-0.0175), 0.6에서 부호가 뒤집힌다 ($+0.0706$). 제1주성분의 20% 정도는 빼도 되는 성분일 수 있으나 나머지 80%는 신호다. 노트 26의 결론이 유지되면서 경계가 정해졌다.




Figure 1: 제거 강도와 전이 성능. 0.2까지는 평평하고 0.4부터 급락한다.

Table 1: 제거 강도 곡선. 낮을수록 좋다.

α	팝업 낀 4방향	여섯 방향 전체
0.0	-0.0780	-0.0762
0.2	-0.0794	-0.0770
0.4	-0.0175	-0.0361
0.6	+0.0706	+0.0232
1.0	+0.0628	+0.0182

(상관은 신호다)이 유지되며, 경계가 $\alpha \approx 0.3$ 에 있다.

반증 조건. 다른 도메인의 제1주성분에서도 같은 20% 경계가 나오면 일반 규칙이고, 도메인마다 다르면 팝업 태깅의 성질이다.

이 곡선은 노트 26의 진단을 정교하게 만든다. 상관이 전부 실체는 아닐 수 있다 — 20%쯤은 후광 편향일 여지가 있다. 그러나 그것을 골라낼 방법이 없고, 넉넉히 빼면 신호를 함께 잃는다.

1. 제거 강도를 조절해 봤다

노트 26은 팝업 태그의 제1주성분을 통째로 빼자 팝업이 낀 네 방향이 전부 붕괴하는 것을 보고 “상관은 편향이 아니라 실제”라고 결론지었다. 같은 노트의 한계 절에 “제거 방식이 제1주성분 잔차화 하나뿐이다. 더 온건한 축소에서는 결과가 다를 수 있다”고 적었다.

α 를 0에서 1까지 두고 제1주성분의 α 배만 뺐다.

$\alpha=0.2$ 에서 아주 약간 나아진다 (-0.0780 에서 -0.0794). 개선폭이 0.0014로 미미하므로 실질적 이득이라 하기 어렵다. 중요한 것은 그 뒤의 급락이다 — 0.4에서 -0.0175 , 0.6에서 $+0.0706$ 으로 부호가 뒤집힌다.

주장 1. 팝업 제1주성분의 20% 정도는 빼도 성능이 유지되지만 그 이상 빼면 급격히 무너진다. 노트 26의 결론

2. 반사실 --- 팝업에서 두 축을 빼면

노트 25는 게임의 배선 오류를 고쳐 난이도를 $+0.0415$ 에서 $+0.0289$ 로 낮췄지만 게임은 여전히 가장 어려운 대상이었고, “배선이 원인의 전부는 아니다”를 한계로 남겼다.

남은 원인 후보는 관측 축 수다. 게임은 둘, 아이들은 넷, 팝업은 다섯을 관측한다. 확인 방법은 반사실이다 — 팝업에서 게임에 없는 축을 빼면 팝업이 게임만큼 어려워지는가.

축을 뺄수록 팝업이 어려워지고, 둘을 다 빼면 팝업이 게임보다 어려워진다 ($+0.0238$ 대 $+0.0113$). 게임과 같




Figure 2: 팝업에서 축을 제거했을 때의 대상 난이도. 둘 다 빼면 팝업이 게임을 넘는다.

Table 2: 반사실 실험. 팝업의 관측 축만 바꾸고 나머지는 그대로 둔다.

팝업 구성	팝업 난이도	게임 난이도
전부 사용 (5축)	-0.0102	+0.0289
입장 허들 제거 (4축)	-0.0034	+0.0245
매장 노출도 제거 (4축)	+0.0164	+0.0152
둘 다 제거 (3축)	+0.0238	+0.0113

은 조건으로 맞추면 게임이 오히려 쉬운 대상이다.

주장 2. 게임의 대상 난이도는 도메인 성질이 아니라 관측 축 부족이다. 팝업의 관측 축을 게임과 같은 셋으로 줄이면 팝업이 게임보다 어려워진다.

반증 조건. 축 수를 맞춘 뒤에도 게임이 더 어려운 구성이 나오면 관측 부족만으로는 설명되지 않는다.

3. 노트 24를 철회한다

노트 24는 이렇게 썼다.

게임은 평범한 선생이고 매우 나쁜 학생이다. ... 게임의 대상 점수 +0.0415는 다른 둘(-0.0172, -0.0242)과 자릿수가 다르다.

두 노트가 그 진단을 무너뜨렸다.

- 노트 25 — 배선 오류를 고치자 +0.0415에서 +0.0289로 내려갔다. “도메인 성질”의 30%가 실은 내 배선 실수였다.
- 이 노트 — 나머지는 관측 축 부족이다. 조건을 맞추면 게임이 더 쉽다.

게임은 나쁜 학생이 아니라 덜 관측된 학생이었다. 그리고 그 관측 부족은 도메인의 숙명이 아니라 우리가 아직 측정 경로를 못 찾은 상태다.




Figure 3: 관측 축 수와 대상 난이도. 팝업의 네 구성과 게임이 같은 직선 위에 있다.

Table 3: 도메인 성질로 오인했던 것들.

노트	진단했던 것	실제
13	게임은 좋은 선생	상대가 쉬운 대상이었을 뿐 (노트 24)
15	게임 라벨의 시간 구조	축 배선 누출 (노트 25)
24	게임은 나쁜 학생	관측 축 부족 (이 노트)
26	팝업 태그의 후광 편향	실제 규모 공변 (노트 26)

주장 3. 노트 24의 “게임은 매우 나쁜 학생”을 철회한다. 대상 난이도는 도메인의 고유 성질이 아니라 그 도메인에서 관측된 축 수의 함수다.

반증 조건. 관측 축 수가 같은 두 도메인에서 난이도가 크게 다르면, 축 수 말고 다른 도메인 성질이 있다.

4. 그러면 무엇이 도메인 성질인가

스물일곱 편에서 “도메인 성질”로 지목했던 것들이 차례로 다른 것으로 밝혀졌다.

네 번 모두 도메인을 타냈다가 측정 쪽으로 돌아왔다. 패턴이 뚜렷하므로 규칙으로 적어 둔다.

어떤 도메인이 유독 다르게 보일 때, 먼저 무엇을 얼마나 재고 있는가를 확인한다. 도메인의 성질이라는 결론은 측정 조건을 맞춘 뒤에만 내린다.

5. 한계

- 반사실은 팝업 하나에서만 했다. 아이돌에서 축을 빼는 실험은 관측 축이 넷뿐이라 여유가 적다.
- 축을 뺀 팝업과 원래 게임은 축 개수만 같을 뿐 축의 종류가 다르다. 완전한 통제가 아니다.
- $\alpha=0.2$ 의 개선폭 0.0014는 잡음 범위일 수 있다. 반복 없이 단일 측정이다.
- 관측 축 수와 난이도의 관계는 네 점(팝업 3 5축, 게임 2축)에서 그렸다.

6. 다음

1. 게임에서 매장 노출도·입장 허들의 측정 경로 재탐색 — 이제 그 값어치가 정량화됐다(난이도 $+0.0289$ 대 부분).
2. 아이돌에서도 반사실 — 축을 빼면 난이도가 오르는 지.
3. 평정자 간 자료 — 노트 26의 20% 경계가 후광인지 확인.
4. 네 번째 도메인.

참고문헌

- Pearl, J. (2009). Causality: Models, Reasoning, and Inference, 2nd ed. Cambridge University Press.
- Thorndike, E. L. (1920). A constant error in psychological ratings. *Journal of Applied Psychology*, 4(1), 25–29.
- Meredith, W. (1993). Measurement invariance, factor analysis and factorial invariance. *Psychometrika*, 58(4), 525–543.
- Ben-David, S. et al. (2010). A theory of learning from different domains. *Machine Learning*, 79(1–2), 151–175.