

IP 파운데이션 월드모델 연구 노트 29

4분의 3만 섞는다

도메인 고유 축을 0.75배로 축소하면 축을 늘려도 정렬이 버틴다

Sweetspot 월드모델 연구

2026년 7월 28일

초 록

노트 28은 축을 하나 더하는 것만으로 인자 기하가 회전해 정렬이 깨지는 것을 보고, 정렬 방법 대안을 미결로 남겼다. 두 방향을 시험했다. 먼저 극단 — 도메인 고유 축을 공유 공간에 아예 넣지 않고 **교란 통제**로만 쓰는 부분 계수 전이다. 축 추가에 완전히 강건하지만(축을 커도 -0.0535 에서 -0.0537 로 변화 없음) 성능이 낮다(유의 5, 평균 -0.0573 대 프로크루스테스의 -0.0762). 두 방법이 정보량과 안정성을 맞바꾸고 있으므로 사이를 이었다 — 고유 축을 λ 배로 축소해 공유 공간에 섞고 λ 를 쏘였다. $\lambda=0.75$ 가 답이다. 게임 매장 노출도를 커든 끄든 여섯 방향이 모두 유의하다(-0.0691 과 -0.0675). $\lambda=1.0$ 은 축을 끄면 가장 좋지만(-0.0762) 커면 다섯으로 무너진다(-0.0666). 문제는 고유 축의 존재가 아니라 **지배**도였다 — 공유 축과 동등하게 섞으면 공간을 흔들고, 4분의 3으로 줄이면 정보는 남기고 흔들림은 사라진다. 부수적으로 구현 함정 하나를 기록한다 — 상관행렬로 주성분을 뽑으면 λ 축소가 표준화에 지워지므로 공분산을 써야 한다.

Table 1: 부분 계수 전이. 순열 3,000회.

구성	유의 방향	평균 차이
공유 축만	5	-0.0573
고유 축 통제 (매장축 끄)	5	-0.0535
고유 축 통제 (매장축 켜)	5	-0.0537
[참고] 프로크루스테스	6	-0.0762

1. 두 극단을 먼저 재봤다

노트 28의 문제는 이랬다. 게임에 매장 노출도를 넣으면 그 도메인의 인자 공간이 회전해 다른 도메인에서 온 계수가 맞지 않는다. 축 자체는 유용한데(게임이 출처일 때 개선) 정렬을 해친다.

원인은 구조에 있다. 인자 공간을 관측된 축 전부로 만들고 그 공간을 회전으로 맞추므로, 축이 하나 늘면 공간 전체가 달라진다.

1.1 극단 하나 --- 고유 축을 아예 넣지 않는다

공유 축(타깃 폭, 굵기 규모)만으로 공간을 만들고, 도메인 고유 축은 출처에서 **교란 통제**로만 쓴다. 즉 출처에서 $y \sim$ 공유 축 + 고유 축을 적합하고 공유 축의 부분 계수만 대상에 적용한다.

축 추가에 완전히 강건하다 — 게임 매장 노출도를 커도 -0.0535 에서 -0.0537 로 사실상 변화가 없다. 노트 28의 문제가 사라진다.

그런데 성능이 낮다. 프로크루스테스의 -0.0762 에 견주면 25% 약하고, 유의 방향도 다섯이다. 그리고 고유 축을 통제로 쓰는 것 자체는 이득이 없다($-0.0573 \rightarrow -0.0535$ 로 오히려 조금 나쁘다).

이유는 분명하다. 프로크루스테스에서는 도메인 고유




Figure 1: 혼합 비율에 따른 성능. 빈 원이 여섯 방향 모두 유의한 점이다.

축이 인자를 통해 공유 공간에 기여한다 — 팍업의 다섯 축이 만든 두 성분이 옮겨지므로 다섯 축의 정보가 실린다. 부분 계수 방식은 그 경로를 막는다.

주장 1. 프로크루스테스와 부분 계수는 정보량과 안정성을 맞바꾼다. 전자는 고유 축의 정보를 옮기지만 축 추가에 취약하고, 후자는 강건하지만 공유 축 둘의 정보만 쓴다.


반증 조건. 고유 축을 통제로 쓴 부분 계수가 프로크루스테스를 넘어서면 이 절충 자체가 없는 것이다.

2. 사이를 이었다

두 극단이 각각 $\lambda=0$ (고유 축 배제)과 $\lambda=1$ (고유 축 동등 혼합)에 해당한다. 고유 축을 λ 배로 축소해 공유 공간에 섞고 쏘였다.

Table 2: λ 스윙. 순열 1,500회. 괄호 안이 유의 방향 수.

λ	게임 매장축 끄	게임 매장축 켜
0.00	-0.0573 (5)	-0.0573 (5)
0.25	-0.0587 (5)	-0.0587 (5)
0.50	-0.0629 (5)	-0.0626 (5)
0.75	-0.0691 (6)	-0.0675 (6)
1.00	-0.0762 (6)	-0.0666 (5)

Figure 2: 유의 방향 수. $\lambda=0.75$ 에서만 두 구성이 모두 여섯이다.

$\lambda=0.75$ 가 유일하게 두 구성 모두에서 여섯 방향을 유지한다. $\lambda=1.0$ 은 축을 끄면 가장 좋지만(-0.0762) 켜면 다섯으로 무너진다.

주장 2. 도메인 고유 축을 0.75배로 축소해 공유 공간에 섞으면 축을 추가해도 정렬이 버틴다. 문제는 고유 축의 존재가 아니라 지배도였다.

반증 조건. 다른 도메인 조합이나 다른 축을 추가했을 때 0.75가 무너지면, 이 값은 현재 구성에 딸린 것이지 일반 상수가 아니다.

3. 검증

$\lambda=0.75$ 를 기본값으로 적용하고 순열을 3,000회로 올려 다시 봤다.


두 구성 모두 여섯 방향이 유의하다. 축을 켜면 아이돌 → 게임이 -0.0428에서 -0.0330으로 약해지지만 유의성은 유지된다($p=0.0393$).

4. 구현 함정 하나

λ 축소를 넣고 처음 돌렸을 때 고유값 분해가 발산했다. 원인은 주성분을 상관행렬에서 뽑고 있었기 때문이다. 상관행렬은 각 열을 표준편차로 나누므로 λ 축소가 그 단계에서 지워진다 — $\lambda=0$ 에서는 축소된 열이 전부 0이 되어 분모가 0이 된다.

공분산행렬로 바꿔야 축소가 보존된다. 축 간 눈금이 이미 표준화돼 있으므로 공분산을 써도 특정 축이 지배하지 않는다.

기록해 두는 이유. 이 프로젝트에서 상관과 공분산을 바꿔 쓴 실수는 처음이 아니다. 노트 15에서 도메인마다

Figure 3: $\lambda=0.75$ 에서 게임 매장축을 켜고 끄는 두 구성. 여섯 방향이 모두 유의하다.Table 3: $\lambda=0.75$, 순열 3,000회. 대상 라벨 미사용.

방향	매장축 끄 차이	p	매장축 켜 차이	p
게임 → 아이돌	-0.0931	0.0000	-0.0922	0.0000
팝업 → 아이돌	-0.0842	0.0003	-0.0842	0.0003
게임 → 팝업	-0.0784	0.0000	-0.0807	0.0000
아이돌 → 팝업	-0.0683	0.0407	-0.0683	0.0407
팝업 → 게임	-0.0477	0.0003	-0.0466	0.0003
아이돌 → 게임	-0.0428	0.0107	-0.0330	0.0393

min-max로 정규화해 눈금이 어긋난 일이 있었다. 규칙으로 적어 둔다 — 가중을 넣은 뒤에는 표준화하지 않는다. 표준화가 가중을 지운다.

5. 그래서 확정된 절차

1. 도메인마다 관측 가능한 축을 켜다.
2. 공유 축은 그대로, 고유 축은 0.75배로 축소해 공분산 주성분을 뽑는다.
3. 공유 축의 적재로 기준 도메인에 직교 정렬한다(라벨 불필요).
4. 출처 도메인의 선형 계수를 대상에 적용한다.
5. 절대량이 필요하면 대상에서 8-20건을 실측해 중심과 중앙절대편차를 잡는다 (노트 21).

노트 19에서 확정된 파이프라인에 λ 하나가 추가됐고, 그 대가로 축을 늘려도 정렬이 버틴다.

6. 한계

- $\lambda=0.75$ 는 게임 매장 노출도 하나를 켜고 끄며 고른 값이다. 다른 축을 추가할 때도 같은 값이 최적이라는 보장이 없다.
- λ 격자가 다섯 점뿐이다. 0.75와 1.0 사이에 더 나은 값이 있을 수 있다.

- 축을 끈 상태만 보면 $\lambda=1.0$ 이 더 좋다(-0.0762 대 -0.0691). 안정성을 위해 9%의 성능을 지불하는 선택이다.
- 부분 계수 방식에서 고유 축 통제가 이득이 없던 이유를 규명하지 않았다.

7. 다음

1. λ 를 도메인별로 두는 방식 — 축이 많은 도메인만 더 줄인다.
2. 입장 허들의 게임 측정 경로 — 여전히 미해결.
3. 네 번째 도메인에서 $\lambda=0.75$ 재확인.
4. 절대량 파이프라인을 $\lambda=0.75$ 위에서 다시 측정(노트 21 갱신).

참고문헌

- Schönemann, P. H. (1966). A generalized solution of the orthogonal Procrustes problem. *Psychometrika*, 31(1), 1–10.
- Hoerl, A. E., Kennard, R. W. (1970). Ridge regression: biased estimation for nonorthogonal problems. *Technometrics*, 12(1), 55–67.
- Jolliffe, I. T. (2002). *Principal Component Analysis*, 2nd ed. Springer.
- Ben-David, S. et al. (2010). A theory of learning from different domains. *Machine Learning*, 79(1–2), 151–175.