

IP 파운데이션 월드모델 연구 노트 30

접치는 만큼 줄인다

 λ 를 튜닝하지 않고 데이터에서 유도한다 --- 고유 축이 공유 축과 접치는 비율의 역수

Sweetspot 월드모델 연구

2026년 7월 28일

초 록

노트 29는 도메인 고유 축을 0.75배로 축소하면 축을 늘려도 정렬이 버틴다는 것을 찾았지만, 그 값은 격자에서 고른 것이었고 “다른 축을 추가할 때도 같은 값이 최적이라는 보장이 없다”를 한계로 남겼다. 이 노트는 λ 를 튜닝 없이 유도한다. 먼저 도메인별로 나눠 격자를 돌렸다 — 팝업 0.75, 아이돌 1.0이 최선이고 균일 0.75보다 낫다(매장축을 켜 상태에서 -0.0736 대 -0.0675). 그런데 “고유 축이 많은 도메인을 더 줄인다”는 단순 공식 ($1/\sqrt{k}$)은 오히려 나쁘다(-0.0528 , 유의 5). 왜 팝업만 줄여야 하는지 찾았다. 고유 축 수도(3 대 2) 내부 상관도 (0.147 대 0.124) 아니고 고유 축이 공유 축과 접치는 정도였다 — 팝업 0.318, 아이돌 0.244다. 접치는 축이 공유 공간의 방향을 혼든다. 그래서 $\lambda_d = \min_d(\text{접침}) / \text{접침}_d$ 로 정했더니 팝업 0.768, 아이돌 1.0이 나왔고 격자 최적을 미세하게 넘었다(-0.0738 대 -0.0736). 새 도메인이 와도 격자 탐색 없이 계산된다. 절대량도 갱신했다 — 아이돌에서 여덟 건이면 4.17배, 승률 92%(노트 21의 4.28배, 90%에서 개선).

Table 1: λ 격자(게임 매장축 끄). 괄호 안이 유의 방향 수.

팝업 λ	아이돌 0.50	아이돌 0.75	아이돌 1.00
0.50	-0.0629 (5)	-0.0662 (6)	-0.0711 (6)
0.75	-0.0658 (6)	-0.0691 (6)	-0.0743 (6)
1.00	-0.0662 (5)	-0.0696 (5)	-0.0762 (6)

Table 2: 방식별 성능. 순열 2,000회.

방식	매장축 끄	매장축 켜
균일 0.75	-0.0691 (6)	-0.0675 (6)
균일 1.00	-0.0762 (6)	-0.0666 (5)
팝업 0.75 · 아이돌 1.0	-0.0743 (6)	-0.0736 (6)
고유축수 역비례 ($1/\sqrt{k}$)	-0.0664 (6)	-0.0528 (5)




Figure 1: 방식별 비교. 숫자는 유의 방향 수이고 붉은 것이 여섯 미만이다.

1. 도메인별로 나눠 봤다

노트 29는 균일 $\lambda=0.75$ 를 채택하며 한계를 적었다 — 게임 매장 노출도 하나를 켜고 끄며 고른 값이므로 일반성이 없다. 첫 개선은 도메인별로 두는 것이다.

균일 1.0이 가장 좋아 보이지만 그것은 매장축을 끈 상태다. 노트 29의 요점은 켜를 때 무너진다는 것이었다. 켜 상태까지 함께 봐야 한다.

팝업만 줄이는 구성이 두 상태 모두에서 여섯을 유지하고 성능도 가장 좋다. 그리고 “축이 많은 도메인을 더 줄인다”는 그럴듯한 공식은 오히려 나쁘다.

주장 1. λ 는 도메인별로 두는 편이 낫고, 고유 축 수에 반비례시키는 단순 공식은 틀렸다.

반증 조건. 다른 도메인 집합에서 $1/\sqrt{k}$ 가 격자 최적과 일치하면 이 반증은 이 세 도메인의 특성이다.

2. 왜 팝업만 줄여야 하나

세 후보를 켜다.

축 수는 3 대 2로 1.5배 차이인데 최적 λ 는 0.75 대 1.0으로 1.33배다. 내부 상관은 0.147 대 0.124로 1.19배다. 접침이 0.318 대 0.244로 1.30배이며 λ 비($1/1.33$)와 가장 가깝다.

해석도 자연스럽다. 고유 축이 공유 축과 무관하면 공유 공간에 섞여도 직교 방향으로만 기여하므로 정렬을 흔들지 않는다. 겹치면 공유 축이 만드는 방향 자체를 밀어낸다.




Figure 2: 도메인별 고유 축의 세 성질. 팝업과 아이돌이 뚜렷이 갈리는 것은 오른쪽뿐이다.

Table 3: 고유 축의 성질.

도메인	고유 축 수	내부 평균 r	공유 축과 겹침
팝업	3	0.147	0.318
아이돌	2	0.124	0.244

3. 그래서 유도한다

$$\lambda_d = \frac{\min_{d'} \text{겹침}_{d'}}{\text{겹침}_d}$$

가장 덜 겹치는 도메인이 1.0을 받고 나머지는 겹치는 만큼 줄어든다. 우리 데이터에서 팝업 0.768, 아이돌 1.0이 나온다.

유도값이 격자 최적을 미세하게 넘는다. 차이는 0.0002로 실질적이지 않지만, 중요한 것은 성능이 아니라 격자 탐색이 필요 없다는 점이다. 새 도메인이 오면 겹침만 계산하면 된다.

주장 2. λ 는 고유 축과 공유 축의 평균 절대 상관에 반비례하게 두면 된다. 격자 탐색 없이 계산되고 격자 최적과 같거나 낮다.

반증 조건. 네 번째 도메인에서 유도값이 격자 최적과 크게 어긋나면 이 규칙은 세 도메인의 우연이다.

최종 여섯 방향은 이렇다 — 팝업 → 아이돌 $-0.0917(p=0.0007)$, 팝업 → 게임 $-0.0476(p=0.0003)$, 아이돌 → 팝업 $-0.0835(p=0.0147)$, 아이돌 → 게임 $-0.0476(p=0.0013)$, 게임 → 팝업 $-0.0791(p<0.0001)$, 게임 → 아이돌 $-0.0975(p<0.0001)$.

4. 절대량을 갱신한다

노트 21의 실무 숫자를 새 파이프라인에서 다시 잴. 여덟 건이면 4.17배에 승률 92%다. 게임도 개선됐다 — $k=50$ 에서 승률이 4%에서 19%로 올랐지만 여전히 상수에 진다.

Table 4: 격자 최적과 유도값의 비교. 순열 2,000회, 내부 평균 |r|, 공유 축과 겹침

방식	격자 최적	유도값	격자 최적	유도값
팝업	0.75	0.768	0.318	0.318
아이돌	1.0	1.0	0.244	0.244




Figure 3: 눈금 보정 라벨 수에 따른 승률.

5. 현재 절차

1. 도메인마다 관측 가능한 축을 쟀다.
2. 고유 축이 공유 축과 겹치는 정도를 재고 λ_d 를 유도한다.
3. 공유 축은 그대로, 고유 축은 λ_d 배로 축소해 공분산 주성분을 뽑는다.
4. 공유 축의 적재로 기준 도메인에 직교 정렬한다. 라벨 불필요.
5. 출처 도메인의 선형 계수를 대상에 적용한다.
6. 절대량이 필요하면 대상에서 8–20건을 실측해 중심과 중앙절대편차를 잡는다.

노트 19의 파이프라인에서 2번 한 단계가 늘었고, 그 대가로 축을 늘려도 정렬이 버티며 튜닝 상수가 사라졌다.

6. 한계

- 겹침 규칙은 두 도메인(팝업, 아이돌)에서만 검증했다. 게임은 고유 축이 없어 λ 가 무의미하다.
- 유도값과 격자 최적의 차이가 0.0002로 작아, 규칙이 옳다는 증거로는 약하다. 두 값이 가까운 것이 우연일 수 있다.
- 겹침을 평균 절대 상관으로 잴. 정준상관 같은 다른 척도에서는 다른 λ 가 나올 수 있다.
- 게임은 여전히 절대량 단계에서 상수에 진다(승률 19%).

7. 다음

1. 입장 허들의 게임 측정 경로 — 여러 노트째 미해결.

Table 5: 아이돌 도메인의 배수 오차. 괄호가 노트 21 값.

k	파이프라인	상수	이긴 비율
5	4.68 (4.85)	5.29	90% (85%)
8	4.17 (4.28)	4.87	92% (90%)
12	4.05 (4.15)	4.86	93% (90%)
20	3.92 (3.96)	4.74	90% (89%)

2. 네 번째 도메인 — 겹침 규칙과 여섯 방향 성공의 일 반성을 가른다.
3. 게임 절대량 실패의 원인 — 순위는 되는데 눈금이 안 되는 이유.
4. 겹침 척도를 정준상관으로 바꿔 재확인.

참고문헌

- Schönemann, P. H. (1966). A generalized solution of the orthogonal Procrustes problem. *Psychometrika*, 31(1), 1–10.
- Hotelling, H. (1936). Relations between two sets of variates. *Biometrika*, 28(3–4), 321–377.
- Jolliffe, I. T. (2002). *Principal Component Analysis*, 2nd ed. Springer.
- Ben-David, S. et al. (2010). A theory of learning from different domains. *Machine Learning*, 79(1–2), 151–175.