

IP 파운데이션 월드모델 연구 노트 31

유익한 것과 쓸모 있는 것

절대량의 성패는 순위 상관이 정한다 --- 게임은 $p < 0.001$ 로 유의한데 $r = 0.344$ 라 진다

Sweetspot 월드모델 연구

2026년 7월 28일

초 록

게임은 순위 전이가 유의한데(팝업 → 게임 $p = 0.0003$, 아이돌 → 게임 $p = 0.0013$) 절대량 단계에서는 상수에 진다(승률 19%). 노트 30이 그 모순을 미결로 남겼다. 분해했다. 순위 상관이 전부를 설명한다 — 아이돌 $r = +0.681$ 이 가능한 개선폭의 35.7%를 달성하고, 팝업 $r = +0.445$ 가 1.3%, 게임 $r = +0.344$ 가 -9.1%다. 순서가 정확히 상관 순서다. 그리고 눈금에는 문제가 없다 — 순위를 완전히 안다고 가정하면 배수 오차가 팝업 1.12배, 게임 1.22배, 아이돌 1.76배까지 내려간다. 중심과 중앙절대편차 두 모수로 잡는 눈금은 충분하고, 병목은 순위 품질이다. 여기서 이 프로젝트의 통계 관행에 대한 교훈이 나온다 — 순열 검정이 통과했다고 쓸 수 있는 것이 아니다. 게임은 $n = 482$ 라 $r = 0.344$ 도 $p < 0.001$ 이 된다. 유의성은 “전이가 없다”를 기각할 뿐 “예측에 쓸 만하다”를 말하지 않는다. 실무 문턱을 $r \geq 0.5$ 로 잡는다 — 그 아래에서는 절대량 단계로 넘어가지 않는다.

Table 1: 도메인별 진단. 배수 오차는 전량 눈금 기준.

도메인	순위 상관	상수	현재	완전 순위
아이돌	+0.681	4.41배	3.47배	1.76배
팝업	+0.445	2.66배	2.64배	1.12배
게임	+0.344	3.53배	3.74배	1.22배

1. 모순을 분해한다

노트 30까지 두 사실이 나란히 있었다.

- 게임을 대상으로 한 순위 전이가 유의하다 — 팝업 → 게임 $p = 0.0003$, 아이돌 → 게임 $p = 0.0013$.
- 그런데 절대량 단계에서 상수에 진다 — $k = 50$ 에서 승률 19%.

절대량은 순위에 눈금을 얹는 것이므로, 순위가 되는데 절대량이 안 된다면 눈금이 문제이거나 순위의 질이 문제다. 갈랐다.

2. 눈금은 문제가 아니다

순위를 완전히 안다고 가정하면 — 즉 예측 대신 실제 잔차 순위를 넣으면 — 배수 오차가 팝업 1.12배, 게임 1.22배, 아이돌 1.76배가 된다.

중심과 중앙절대편차 두 모수로 잡는 눈금이 그 정도까지 간다는 뜻이다. 상수 대비 58%에서 66%를 줄인다. 눈금은 충분하다.

주장 1. 절대량 파이프라인의 눈금(중심 + 중앙절대편차)은 병목이 아니다. 순위를 완전히 알면 배수 오차가 1.1 – 1.8배까지 내려간다.




Figure 1: 상수, 현재, 완전 순위의 배수 오차. 완전 순위와 현재의 간격이 크다.

Table 2: 순위 품질과 달성률.

도메인	순위 상관	개선 여지	달성률
아이돌	+0.681	60.1%	35.7%
팝업	+0.445	58.0%	1.3%
게임	+0.344	65.5%	-9.1%

반증 조건. 눈금을 더 정교하게 잡아 (분위수 사상 등) 완전 순위 조건에서 1.1배 아래로 내려가면 눈금에도 여지가 있는 것이다.

3. 순위 상관이 전부를 설명한다

가능한 개선폭 중 실제로 달성한 비율을 보면 순서가 명확하다.




Figure 2: 순위 상관과 달성률. 세 점이 직선 위에 있다.




Figure 3: 순위 상관과 순열 p. 유의성은 셋 다 높은데 상관은 두 배 차이 난다.

개선 여지는 셋 다 58%에서 66%로 비슷한데 달성률이 갈린다. 그리고 그 순서가 정확히 순위 상관의 순서다. 게임은 달성률이 음수다 — 순위 예측을 옳으면 상수보다 나빠진다. $r=0.344$ 짜리 순위에 폭을 곱하면 맞는 만큼 틀리는 것이 더 크다.

주장 2. 절대량 단계의 성패는 순위 상관이 정한다. 눈금 여지는 도메인마다 비슷하고, 달성률만 상관 순서를 따른다.

반증 조건. 네 번째 도메인에서 상관은 높은데 달성률이 낮거나 그 반대가 나오면 다른 요인이 있다.

4. 유의성은 쓸모를 보장하지 않는다

여기서 이 프로젝트의 통계 관행에 대한 교훈이 나온다. 게임의 순위 전이는 $p=0.0003$ 으로 매우 유의하다. 그런데 상관이 0.344다. $n=482$ 이므로 그 정도 상관도 우연으로 나오기 어렵다 — 유의성은 표본 크기에 딸린다. 순열 검정이 기각하는 것은 “전이가 전혀 없다”이지 “예측에 쓸 만하다”가 아니다. 이 프로젝트는 스몰여섯 편 동안 순열 p로 방향을 판정해 왔고, 그 판정 자체는 옳았다. 다만 그것을 “쓸 수 있다”로 읽으면 안 된다.

실무 문턱을 $r \geq 0.5$ 로 잡는다. 순위 상관이 그

아래면 전이가 유의해도 절대량 단계로 넘어가지 않는다. 현재 아이돌만 넘고(0.681) 팝업은 경계(0.445), 게임은 못 넘는다(0.344).

주장 3. 순열 유의성과 실용 가능성은 다른 기준이다. 표본이 크면 낮은 상관도 유의해지므로, 전이 판정 뒤에 순위 상관을 따로 봐야 한다.

반증 조건. 상관이 0.5 아래인데 절대량이 상수를 안정적으로 이기는 사례가 나오면 문턱을 낮춰야 한다.

5. 부수 --- 진단 스크립트에서 낸 실수

이 분석을 처음 돌렸을 때 팝업의 배수 오차가 무한대, 아이돌이 NaN으로 나왔다. 원인은 `raw_labels`의 반환 순서를 잘못 받은 것이었다 — 세 번째 값이 추세가 아니라 관측 시점인데 추세로 썼다. 파이프라인 본체는 올바르게 쓰고 있었고 임시 진단 스크립트만 틀렸다.

기록해 두는 이유는 이상한 수치가 나왔을 때의 순서다. 무한대와 NaN을 보고 데이터나 방법을 의심하기 전에 배열 정렬부터 확인했더니 5분이면 끝났다. 노트 25에서 배운 것 — “요약 통계가 이상할 때는 도메인을 의심하기 전에 배선을 의심한다” — 이 코드 수준에서도 같다.

6. 그래서 무엇을 해야 하나

순위 상관을 올리는 것이 유일한 지렛대다. 두 경로가 있다.

축을 늘린다. 노트 27이 보였듯 관측 축이 늘면 대상으로서 쉬워진다. 게임은 공유 축 둘뿐이고 입장 허들은 여러 노트째 미해결이다.

출처를 늘린다. 현재 순위 예측은 다른 두 도메인 예측의 단순 평균이다. 도메인이 늘면 평균의 분산이 줄어 상관이 오를 수 있다. 노트 22는 표본 확대의 수익이 200건에서 끝난다고 했지만 도메인 확대는 다른 축이다.

7. 한계

- 세 점으로 상관과 달성률의 관계를 그렸다. 직선으로 보이지만 점이 셋이다.
- “완전 순위”는 대상 라벨을 그대로 쓰므로 도달 불가능한 기준이다. 실현 가능한 상한은 그보다 낮다.
- $r \geq 0.5$ 문턱은 세 도메인의 배치에서 눈으로 그은 선이다. 이론적 근거가 없다.
- 순위 상관은 전량 라벨로 잴다. 실전에서는 k건으로 추정해야 하는데 그 추정의 분산을 보지 않았다.

8. 다음

1. k건으로 순위 상관을 추정하는 방법 — 문턱 판정을 실전에서 쓰려면 필요하다.
2. 입장 허들의 게임 측정 경로.
3. 네 번째 도메인 — 출처 확대로 순위 상관이 오르는지.

4. 눈금을 분위수 사상으로 바꿔 완전 순위 조건의 하한 재측정.

참고문헌

- Cohen, J. (1988). Statistical Power Analysis for the Behavioral Sciences, 2nd ed. Lawrence Erlbaum.
- Wasserstein, R. L., Lazar, N. A. (2016). The ASA statement on p-values. The American Statistician, 70(2), 129–133.
- Good, P. (2005). Permutation, Parametric, and Bootstrap Tests of Hypotheses, 3rd ed. Springer.
- Ben-David, S. et al. (2010). A theory of learning from different domains. Machine Learning, 79(1–2), 151–175.