

IP 파운데이션 월드모델 연구 노트 32

문턱은 눈금보다 비싸다

눈금은 여덟 건이면 되는데 문턱 판정은 십 건이 필요하다

Sweetspot 월드모델 연구

2026년 7월 28일

초 록

노트 31은 절대량 단계로 넘어갈 실무 문턱을 순위 상관 $r \geq 0.5$ 로 잡았다. 실전에서 그 판정을 하려면 대상 도메인 라벨 k 건으로 상관을 추정해야 한다. 몇 건이 필요한지 봤다. 추정 자체는 거의 편향이 없다 — 팝업 참값 $+0.445$ 에 대해 $k=8$ 에서 $+0.42$, $k=50$ 에서 $+0.45$ 다. 표준편차만 k 에 따라 줄어든다 ($0.32 \rightarrow 0.07$). 그런데 문턱 판정 정확도는 훨씬 늦게 오른다. $k=8$ 에서 세 도메인 모두 56–57%로 동전 던지기 수준이고, $k=20$ 에서 63–74%, $k=50$ 에서야 78–96%가 된다. 가장 어려운 것은 팝업이다 — 참값 $+0.445$ 가 문턱 0.5에 가까워 $k=50$ 에서도 78%에 그친다. 눈금 보정은 여덟 건, 문턱 판정은 십 건. 같은 파이프라인 안에서 필요한 라벨이 여섯 배 차이 난다. 그리고 이 비대칭은 절차의 순서를 바꾼다 — 문턱을 사전에 확정하려 하면 절대량 자체보다 비싸지므로, 보수적 하한으로 판정하거나 사후 검증으로 돌리는 편이 낫다.




Figure 1: k 건으로 추정한 순위 상관. 점선이 각 도메인의 참값, 굵은 파선이 문턱이다.

1. 문턱을 실전에서 쓰려면

노트 31은 순위 상관이 절대량의 성패를 정한다는 것을 보이고 $r \geq 0.5$ 를 실무 문턱으로 제시했다. 그런데 그 상관은 전량 라벨로 봤다. 새 도메인에서는 라벨이 없으므로 k 건으로 추정해야 한다.

노트 21이 눈금 보정에 8–20건이면 된다고 했으니 문턱 판정도 비슷할 것이라 짐작했다. 재봤다.

2. 추정은 정확한데 판정은 아니다

추정 자체는 좋다. 팝업은 $k=8$ 에서 이미 $+0.42$ 로 참값 $+0.445$ 에 가깝고, 아이돌만 작은 k 에서 아래로 치우친다 ($k=8$ 에서 $+0.52$ 대 참값 $+0.681$) — 상관 추정량이 0 쪽으로 수축하는 알려진 성질이다.

문제는 표준편차다. $k=8$ 에서 $0.32-0.36$ 이면 참값

Table 1: 순위 상관 추정. 400회 반복 평균 $\pm$ 표준편차.

도메인	참 r	$k=8$	$k=20$	$k=50$
팝업	$+0.445$	$+0.42 \pm .32$	$+0.43 \pm .18$	$+0.45 \pm .07$
아이돌	$+0.681$	$+0.52 \pm .32$	$+0.62 \pm .19$	$+0.67 \pm .07$
게임	$+0.344$	$+0.38 \pm .36$	$+0.35 \pm .23$	$+0.35 \pm .15$




Figure 2: 문턱 판정 정확도. $k=8$ 에서는 세 도메인 모두 동전 던지기다.

이 0.44든 0.68이든 추정치가 0.5의 양쪽에 절반씩 떨어진다.

$k=8$ 에서 셋 다 56–57%다. 동전을 던지는 것과 같다.

주장 1. 순위 상관 추정은 여덟 건에서도 거의 편향이 없지만, 문턱 판정은 십 건이 있어야 80% 이상 맞는다. 추정의 정확도와 판정의 정확도는 다른 문제다.

반증 조건. 문턱을 0.5가 아니라 도메인 참값에서 먼 곳

Table 2: “참 r 이 0.5를 넘는가”를 k 건으로 맞히는 정확도.

도메인	참 r	$k=8$	$k=20$	$k=30$	$k=50$
아이돌	+0.681	56%	74%	83%	96%
게임	+0.344	57%	70%	81%	84%
팝업	+0.445	57%	63%	67%	78%

눈금 보정	8건	중심 + 중앙절대편차 두 모수
문턱 판정	50건	순위 상관 0.5를 넘는가

같은 파이프라인인데 필요한 라벨이 여섯 배 차이 난다

Figure 3: 같은 파이프라인 안에서 두 단계의 라벨 비용.

(예: 0.3)에 두면 적은 k 로도 판정할 수 있다. 문턱 위치를 바꿔 재보면 이 결론의 일반성을 알 수 있다.

팝업이 가장 어렵다. 참값 +0.445가 문턱 0.5에 가장 가깝기 때문이다. $k=50$ 에서도 78%에 그친다. 경계에 있는 값은 표본을 아무리 늘려도 판정이 어렵다 — 이것은 추정의 문제가 아니라 문턱을 참값 근처에 둔 것의 문제다.

3. 비대칭이 절차를 바꾼다

여섯 배 차이이다. 문턱을 사전에 확정하려면 눈금 보정보다 여섯 배 많은 실측이 필요하고, 그 정도면 “쓸지 말지”를 정하는 데 “쓰는 것”보다 비싼 값을 치르는 셈이다.

그러면 내부 모델을 쓰면 되지 않나. 50건이 있으면 그 도메인 자체로 모델을 만들 수 있을 것 같다. 그런데 노트 25가 그것을 막는다 — 가용 피쳐 전부를 넣고 교차검증하면 팝업이 -10.6%, 아이돌이 -10.4%로 상수보다 나쁘다. 도메인당 표본이 작아 내부 학습이 되지 않는다. 전이는 여전히 옳은 접근이고, 다만 그 적합성을 싸게 판정할 방법이 없다.

주장 2. 문턱 판정 비용이 눈금 보정 비용의 여섯 배이므로, 문턱을 사전 확정 조건으로 쓰면 안 된다.

반증 조건. 순위 상관을 라벨 없이 추정하는 방법(예: 출처 도메인 간 상관의 일관성으로 대리)이 나오면 이 비대칭이 사라진다.

4. 그래서 절차를 이렇게 고친다

1. 순위 전이가 순열 검정을 통과하는지 본다. **라벨 불필요.**
2. 통과하면 8-20건을 실측해 눈금을 잡고 절대량을 낸다.

Table 3: 단계별 필요 라벨.

단계	k	무엇을 정하나
눈금 보정	8	중심과 중앙절대편차 두 모수
문턱 판정	50	순위 상관 0.5를 넘는가

3. 같은 8-20건으로 순위 상관을 추정만 한다. 판정에 쓰지 않는다. 추정치가 낮으면(0.3 미만) 결과를 보수적으로 읽는다.
4. 실측 건수가 50건을 넘어가면 그때 문턱을 판정하고 계속 쓸지 정한다.

사전 게이트를 사후 점검으로 바꾼 것이다. 노트 31은 “문턱 아래면 절대량 단계로 넘어가지 않는다”고 썼는데, 그 판정을 미리 할 수 없으므로 실행 순서를 뒤집는다.

5. 한계

- 문턱 0.5는 노트 31에서 세 도메인 배치를 보고 그은 선이다. 이론적 근거가 없으므로 이 노트의 판정 비용도 그 선에 달려 있다.
- 상관 추정에 피어슨을 썼다. 스피어만이나 축소 추정량에서는 표준편차가 다를 수 있다.
- k 건은 무작위 추출을 가정한다. 노트 22에서 시간순 추출이 아이돌에서 위험함을 보였는데, 상관 추정에서도 같을 수 있다.
- 세 도메인 모두 참 r 이 0.34-0.68 구간에 있다. 훨씬 높거나 낮은 도메인에서는 판정이 쉬울 것이다.

6. 다음

1. 라벨 없이 순위 상관을 대리 추정하는 방법 — 이 비대칭을 없애는 유일한 길.
2. 입장 허들의 게임 측정 경로 — 여러 노트째 미해결.
3. 네 번째 도메인.
4. 시간순 k 건에서 상관 추정의 편향 확인.

참고문헌

- Fisher, R. A. (1915). Frequency distribution of the values of the correlation coefficient in samples from an indefinitely large population. *Biometrika*, 10(4), 507-521.
- Cohen, J. (1988). *Statistical Power Analysis for the Behavioral Sciences*, 2nd ed. Lawrence Erlbaum.
- Efron, B., Tibshirani, R. (1993). *An Introduction to the Bootstrap*. Chapman & Hall.
- Ben-David, S. et al. (2010). A theory of learning from different domains. *Machine Learning*, 79(1-2), 151-175.