

IP 파운데이션 월드모델 연구 노트 33

전이는 이미 최적이다

전이 상관이 대상의 자기 상관과 같다 --- 출처를 바꿔도 소용없고 대상의 측정만이 지렛대다

Sweetspot 월드모델 연구

2026년 7월 28일

초 록

노트 32는 순위 상관을 라벨 없이 대리 추정하는 방법을 유일한 출구로 지목했다. 후보를 찾다가 그보다 큰 것을 발견했다. 여섯 개 전이 셀에서 무엇이 전이 상관을 설명하는지 재보니 **대상 도메인의 자기 상관**이 $+0.988$ 로 사실상 완전히 설명한다. 출처 자기 상관은 -0.436 , 출처 표본 수는 $+0.360$, 출처 측 수는 -0.243 이다. 비율로 보면 더 분명하다 — 전이 상관을 대상 자기 상관으로 나누면 **여섯 셀 모두 1.03 ± 0.07 이다**. 즉 전이는 대상 도메인의 예측 가능 상한에 이미 도달해 있다. 대상 도메인의 라벨을 전부 보고 교차검증한 모델과 같은 수준을 그 도메인 라벨을 한 번도 보지 않고 낸다. 이것은 두 가지를 뜻한다. 첫째, **출처 선택은 무의미하다** — 어느 도메인에서 배우든 결과가 같다. 둘째, **개선 여지는 전적으로 대상 도메인의 측정에 있다** — 측을 더 재거나 더 잘 재는 것 외에 방법이 없다. 노트 24의 “대상이 출처보다 네 배 중요”와 노트 27의 “게임은 덜 관측된 학생”이 하나의 메커니즘으로 합쳐진다.

Table 1: 라벨 없는 대리 후보(세 도메인).

대상	참 r	출처 간 일치	정렬 잔차
팝업	+0.445	+0.989	0.000
아이돌	+0.681	+0.946	0.428
게임	+0.344	+0.965	0.221
참 r과의 상관		-0.643	+0.669

Table 2: 여섯 전이 셀.

출처 → 대상	전이 r	출처 자기 r	대상 자기 r
게임 → 아이돌	+0.675	+0.349	+0.654
팝업 → 아이돌	+0.668	+0.404	+0.654
아이돌 → 팝업	+0.452	+0.654	+0.404
게임 → 팝업	+0.433	+0.349	+0.404
아이돌 → 게임	+0.354	+0.654	+0.349
팝업 → 게임	+0.324	+0.404	+0.349

1. 대리 후보를 찾다가

노트 32의 결론은 이랬다 — 문턱 판정에 50건이 필요하고 눈금 보정에는 8건이면 되므로, 판정이 실행보다 비싸다. 유일한 출구는 라벨 없이 순위 상관을 대리 추정하는 것이다.

세 후보를 세웠다.

- **출처 간 일치도** — 두 출처의 예측이 대상에서 서로 얼마나 맞나. 대상 라벨이 필요 없다.
- **정렬 잔차** — 프로크루스테스가 공통 축 적재를 얼마나 잘 맞췄나.
- **예측 분산** — 예측이 얼마나 퍼져 있나.

둘 다 부호가 직관과 반대다 — 출처끼리 일치할수록 나쁘고, 정렬이 안 맞을수록 좋다. 그리고 점이 셋뿐이며 팝업의 정렬 잔차 0.000은 기준 도메인이라 자기 자신과 비교한 값이다. 아무것도 말할 수 없다.

셀을 여섯으로 늘렸다. 각 (출처, 대상) 쌍마다 그 출처 단독 예측의 상관을 잰다.

Table 3: 전이 상관을 무엇이 설명하나.

후보	전이 r과의 상관
대상 자기 상관	+0.988
출처 표본 수	+0.360
출처 측 수	-0.243
출처 자기 상관	-0.436

2. 대상의 자기 상관이 전부다

여기에 후보를 하나 더 넣었다 — **자기 상관**. 도메인이 자기 측으로 자기 라벨을 얼마나 맞히는가(교차검증). 출처 쪽과 대상 쪽을 각각 본다.

대상 자기 상관이 $+0.988$ 이다. 나머지는 잡음 수준이거나 부호가 반대다.

3. 비율이 1이다

더 직접적인 표현은 비율이다.

여섯 셀 모두 1에서 ± 0.09 안에 있다. 평균 1.031이다.




Figure 1: 전이 상관과 대상 자기 상관. 점선이 완전 일치선이다.




Figure 2: 후보별 설명력. 하나만 압도적이다.

주장 1. 전이 상관은 대상 도메인의 자기 상관과 같다(설명 상관 +0.988, 비율 1.03±0.07). 전이는 대상의 예측 가능 상한에 이미 도달해 있다.

반증 조건. 네 번째 도메인에서 비율이 1에서 크게 벗어나면 이 등식은 세 도메인의 우연이다. 특히 1보다 뚜렷이 작으면 전이에 개선 여지가 남아 있다는 뜻이다.

무슨 뜻인가. 대상 도메인의 자기 상관은 그 도메인 라벨을 전부 보고 교차검증한 값이다. 전이는 그 도메인 라벨을 한 번도 보지 않고 같은 수준을 낸다.

4. 두 가지 귀결

출처 선택은 무의미하다. 출처 자기 상관이 -0.436, 출처 표본 수가 +0.360, 출처 축 수가 -0.243이다. 어느 것도 전이 성능을 설명하지 못한다. 게임(n=482, 자기 상관 0.349)에서 배우든 아이돌(n=62, 0.654)에서 배우든 결과가 대상에 의해 정해진다.

이것은 노트 24가 가법 모형으로 얻은 결과 — 대상 난이도의 분산이 출처 강도의 3.8배 — 의 극단 형태다. 실은 출처 강도가 사실상 0이었다.

지렛대는 대상의 측정뿐이다. 개선하려면 대상 도메인의 자기 라벨을 더 잘 설명하게 만들어야 한다. 축을 더 재




Figure 3: 전이 상관을 대상 자기 상관으로 나눈 값. 여섯 셀이 1 근처에 모인다.

Table 4: 전이 상관 ÷ 대상 자기 상관.

출처 → 대상	비율
게임 → 아이돌	1.032
팝업 → 아이돌	1.021
아이돌 → 팝업	1.118
게임 → 팝업	1.072
아이돌 → 게임	1.014
팝업 → 게임	0.931
평균	1.031

거나 더 잘 재는 것 외에 방법이 없다.

노트 27이 반사실로 보인 것 — 팝업에서 축 둘을 빼면 게임보다 어려워진다 — 과 정확히 맞물린다. 축을 빼면 자기 상관이 떨어지고, 자기 상관이 떨어지면 전이도 그만큼 떨어진다.

전이 알고리즘을 더 손볼 이유가 없다. 정렬 방법(노트 19, 29, 30)도, 출처 선택도, 공동 학습도 상한에 붙어 있는 값을 바꾸지 못한다. 남은 일은 각 도메인에서 무엇을 어떻게 재느냐뿐이다.

5. 그리고 노트 32의 문제는 어떻게 되나

라벨 없는 대리 추정은 여전히 못 찾았다. 다만 문제의 무게가 달라졌다.

전이 상관 ≈ 대상 자기 상관이므로, 물어야 할 것은 “이 전이가 잘 될까”가 아니라 “이 도메인이 자기 라벨을 설명할 수 있을까”다. 후자는 도메인을 설계할 때 — 어떤 축을 어떻게 썰지 정할 때 — 판단할 수 있는 질문이고, 라벨을 모으기 전에도 부분적으로 답할 수 있다.

주장 2. 순위 상관을 사전에 알고 싶으면 전이가 아니라 대상 도메인의 측정 설계를 봐야 한다.

반증 조건. 측정 설계에서 자기 상관을 예측하는 규칙이 만들어지지 않으면, 이 재구성은 문제를 옮겼을 뿐 풀지 않은 것이다.

6. 한계

- 여섯 셀에 대상이 셋뿐이므로 $+0.988$ 은 세 점의 상관을 여섯 번 센 것에 가깝다. 네 번째 도메인이 반드시 필요하다.
- 자기 상관을 5폴드 교차검증으로 잴다. 폴드 수나 분할 방식에 따라 값이 흔들린다.
- 비율이 1을 조금 넘는다(평균 1.031). 전이가 자기 상관을 넘는 것은 이상하며, 자기 상관 추정이 교차검증 때문에 보수적이어서일 수 있다.
- 팝업 → 게임만 비율이 1 아래다(0.931). 여섯 중 유일한 예외의 원인을 보지 않았다.

7. 다음

1. 네 번째 도메인 — 이 노트의 모든 결론이 그것 하나에 달려 있다.
2. 측정 설계에서 자기 상관을 예측하는 규칙 — 축 수, 축의 품질, 표본 크기의 함수.
3. 팝업 → 게임 비율 0.931의 원인.
4. 자기 상관 추정의 폴드 민감도.

참고문헌

- Ben-David, S. et al. (2010). A theory of learning from different domains. *Machine Learning*, 79(1–2), 151–175.
- Schoppe, O. et al. (2016). Measuring the performance of neural models. *Frontiers in Computational Neuroscience*, 10, 10.
- Maurer, A., Pontil, M., Romera-Paredes, B. (2016). The benefit of multitask representation learning. *JMLR*, 17(81), 1–32.
- Cohen, J. (1988). *Statistical Power Analysis for the Behavioral Sciences*, 2nd ed. Lawrence Erlbaum.