

IP 파운데이션 월드모델 연구 노트 34

자기 상관도 배선의 함수였다

네 번째 도메인이 노트 33을 확인하고 동시에 정제한다 --- 대상 자기 상관도 지배하지만 그것 자체가 고칠 수 있는 값이다

Sweetspot 월드모델 연구

2026년 7월 28일

초 록

노트 33은 “전이 상관 = 대상 자기 상관”(설명 +0.988)을 세 도메인 여섯 셀에서 얻고, 모든 결론을 네 번째 도메인에 걸었다. 도서 출간을 확보했다 — 알라딘 상품 페이지의 JSON-LD에서 396건, 다섯 축 중 넷을 99–100% 관측한다. 열두 셀에서 대상 자기 상관의 설명력이 +0.930으로 유지된다(출처 자기 상관은 -0.219). 노트 33이 확인됐다. 그런데 확인 과정에서 그 결론을 정제해야 할 것이 나왔다. 도서를 처음 넣었을 때 자기 상관이 0.100으로 최저였고 대상으로 쓴 세 방향이 모두 실패했다 — 노트 33의 예측대로다. 그런데 도서 라벨은 가용 피처 전부로 44.1%가 설명된다. 네 도메인 중 압도적 1위다. 신호가 있는데 축이 담지 못한 것이다. 개별 변수를 훑으니 굵기 규모에 넣은 쪽수가 -0.015, 타깃 쪽에 넣은 장르 수가 -0.073으로 둘 다 무효였고, 진짜 신호는 판형이었다(높이 -0.282). 타깃 쪽을 판형으로 다시 배선하자 자기 상관이 0.100에서 0.344로 3.4배 오르고, 도서를 출처로 쓴 세 방향이 전부 유의해졌으며, 전체 유의 방향이 7에서 9로 늘었다. 자기 상관은 도메인의 고정 성질이 아니라 배선의 함수다.

Table 1: 도서 도메인. 396건, 1998–2026년 출간.

축	태깅률	측정
타깃 쪽	100%	판형(뒤에서 고침)
매장 노출도	100%	출판사 사전 출간 건수
입장 허들	100%	정가
굵기 규모	100%	쪽수
미디어 투입	0%	대응 필드 없음

1. 네 번째 도메인

노트 33의 한계 절 첫 줄은 이랬다 — “여섯 셀에 대상이 셋뿐이므로 +0.988은 세 점의 상관을 여섯 번 센 것에 가깝다. 네 번째 도메인이 반드시 필요하다.”

선정 기준도 그 노트가 바뀌 놓았다. 출처로서의 품질은 무의미하고 대상으로서 자기 라벨을 설명할 수 있는 지가 전부이므로, 라벨이 명확하고 축이 많이 관측되는 도메인을 찾았다.

크라우드펀딩을 먼저 시도했다 — 모금액이 곧 반응이고 최저 후원 금액이 순수한 진입 비용이라 여러 노트째 실패한 입장 허들 축을 살릴 수 있었다. 텀블벅은 SPA, 와디즈는 403으로 막혔다.

도서로 갔다. 알라딘 상품 페이지에서 판매지수(Sales Point)를 라벨로 쓴다.

파서를 한 번 돌아보았다. 정규식으로 굵을 때 12건 중 2건만 채택됐다. 원인이 둘이었다 — 베스트셀러 목록에 LP와 DVD가 섞여 들어왔고(첫 후보가 영화음악 LP였다), 출간일과 가격이 본문 텍스트가 아니라 JSON-LD 구조화 데이터에 있었다. @type: Book으로 도서 여부까




Figure 1: 열두 셀에서의 전이 상관과 대상 자기 상관. 점선이 완전 일치선이다.

지 걸러지므로 채택률이 90%로 올랐다.

2. 노트 33이 확인된다

대상 자기 상관도 여전히 지배한다. 출처 쪽은 여전히 무관하거나 음의 관계다.

실패한 셋은 모두 도서가 대상인 방향이다. 무작위였다면 흩어졌을 것이다.

3. 그런데 도서 라벨은 예측 가능했다

도서를 처음 넣었을 때 자기 상관이 0.100으로 네 도메인 중 최저였다. 노트 33의 규칙대로라면 대상으로서 실패해

Table 2: 설명 요인 비교. 셀 수가 여섯에서 열둘로 늘었다.

	3 도메인 (6셀)	4 도메인 (12셀)
대상 자기 상관	+0.988	+0.930
출처 자기 상관	-0.436	-0.219
비율 평균	1.031	0.936
유의 방향	6/6	9/12




Figure 2: 열두 방향의 성적. 실패가 무작위가 아니라 도서 열로 몰린다.

야 하고 실제로 실패했다 — 예측이 맞은 것이다.

그런데 확인차 라벨 자체의 예측 가능 상한을 줬다 (노트 25에서 쓴 방법 그대로, 가용 피쳐 전부를 넣고 5 폴드).

도서가 압도적 1위다. 신호가 없어서 자기 상관인 낮은 것이 아니라, 축이 그 신호를 담지 못한 것이다.

4. 배선이 또 틀렸다

개별 변수와 라벨의 상관을 훑었다.

내가 축에 넣은 둘이 가장 약하고, 가장 강한 둘은 축에 없었다.

판형의 의미는 분명하다. 작은 판형은 문고본과 실용서이고 대중을 향한다. 큰 판형은 전문서와 양장본이다. 즉 판형은 “몇 명에게 닿을 수 있게 만들었나”를 재며 타깃 폭의 자리다.

쪽수가 무효인 것이 뜻밖이다. 게임에서 최소 설치 용량을 굵게 규모로 쓴 것이 잘 작동했으므로 (노트 25) 쪽수도 같은 논리로 잘 줄 알았다. 콘텐츠 분량이라는 점은 같은데 결과가 다르다. 두꺼운 책이 더 팔리지 않는다 — 오히려 진입 장벽에 가깝고, 그렇다면 굵게 규모가 아니라 다른 자리일 수 있다. 이 노트에서는 검정하지 않았다.

Table 3: 라벨의 예측 가능 상한. 가용 피쳐 전부, 5폴드 GBDT.

도메인	n	설명력
도서	396	+44.1%
게임	425	+13.0%
팝업	75	-10.6%
아이돌	79	-10.4%




Figure 3: 도서 개별 변수의 신호. 붉은 것이 원래 축에 넣었던 변수 —

5. 다시 배선하자 3.4배 올랐다

타깃 폭을 판형 중심으로 다시 짰다(높이 가중 1.0, 너비 0.7, 장르 수 0.3).

같은 데이터, 같은 라벨, 같은 표본인데 축 하나를 바꾸자 자기 상관인 3.4배 오르고 도서를 출처로 쓴 세 방향이 전부 유의해졌다.

주장 1. 자기 상관도 도메인의 고정 성질이 아니라 축 배선의 함수다. 도서에서 축 하나를 고치자 0.100에서 0.344로 올랐다.

반증 조건. 배선을 최적화한 뒤에도 도메인 간 자기 상관 차이가 남으면 그 잔여분이 진짜 도메인 성질이다.

6. 노트 33을 정제한다

노트 33은 이렇게 끝났다 — “전이 알고리즘을 더 손볼 이유가 없다. 남은 일은 각 도메인에서 무엇을 어떻게 재느냐뿐이다.”

앞 문장은 유지된다. 뒤 문장은 강화된다. 자기 상관이 배선의 함수이므로, “무엇을 재느냐”는 관측 가능성의 문제만이 아니라 어느 축에 넣느냐의 문제이기도 하다. 도서에서는 필요한 값을 이미 다 수집해 놓고도 잘못된 자리에 넣어 자기 상관을 3분의 1로 깎았다.

대상 자기 상관인 전이 성능을 지배한다(노트 33). 그리고 자기 상관도 축 배선으로 바꿀 수 있다(이 노트). 두 문장을 합치면 — 전이 성능은 배선으로 바꿀 수 있고, 그것이 유일하게 남은 지렛대다.

같은 실수의 세 번째다. 노트 25에서 게임의 굵게 규모가 폭 인자에 실려 신호의 75%를 놓쳤고, 노트 28에서 매장

Table 4: 도서 변수와 판매지수의 상관(탈추세 후).

변수	r	원래 배치
높이	-0.282	축에 없음
너비	-0.221	축에 없음
정가	+0.205	입장 허들
리뷰 수	+0.160	—
별점	-0.141	—
무게	-0.093	—
장르 수	-0.073	타깃 폭
쪽수	-0.015	굿즈 규모

Table 5: 도서 축 재배선 전후.

	재배선 전	재배선 후
도서 자기 상관	0.100	0.344
도서 → 팝업	p=0.0000	p=0.0000
도서 → 아이돌	p=0.0773	p=0.0030
도서 → 게임	p=0.0677	p=0.0097
전체 유의 방향	7/12	9/12

노출도가 기하를 흔들어 되돌렸으며, 여기서 도서의 두 축이 무효였다. 매번 의미로는 맞아 보이는 배선이였다. 노트 28에 적은 규칙이 다시 확인된다 — 의미로 판단할 수 있는 것은 후보 자격까지이고, 채택은 검정으로만 정한다.

7. 한계

- 재배선을 판형 하나로만 했다. 정가나 리뷰 수를 재배치하면 더 오를 수 있고, 그 탐색은 하지 않았다.
- 도서 자기 상관 0.344는 여전히 라벨 상한(44.1%)에 한참 못 미친다. 축 네 개로 담을 수 있는 뭉치 그만쯤 인지, 배선이 아직 부족한지 모른다.
- 도서를 대상으로 한 세 방향은 재배선 후에도 유의하지 않다(가장 가까운 것이 팝업 → 도서 p=0.060).
- 비율 평균이 0.936으로 1보다 작다. 도서가 낀 셀에서 상한에 못 미치는데, 출처 품질이 완전히 무관하다는 노트 33의 표현은 과했을 수 있다.
- 판매지수는 알라딘 단독 지표다. 실제 판매량과의 관계를 확인하지 않았다.

8. 다음

1. 도서 축 배선 탐색 — 정가·리뷰 수·쪽수의 자리를 검정으로 정한다.
2. 나머지 세 도메인도 같은 방식으로 배선 점검 — 놓친 신호가 있는지.
3. 비율 0.936의 원인 — 출처 품질 하한이 있는지.
4. 쪽수가 굿즈 규모가 아니라면 무엇인지.




Figure 4: 도메인별 자기 상관도 대상으로서의 성적.

Ben-David, S. et al. (2010). A theory of learning from different domains. Machine Learning, 79(1–2), 151–175.

Meredith, W. (1993). Measurement invariance, factor analysis and factorial invariance. Psychometrika, 58(4), 525–543.

Guyon, I., Elisseeff, A. (2003). An introduction to variable and feature selection. JMLR, 3, 1157–1182.

Kaufman, S., Rosset, S., Perlich, C. (2012). Leakage in data mining. ACM TKDD, 6(4), 1–21.