

IP 파운데이션 월드모델 연구 노트 41

손잡이는 반대로 돌아갔다

법칙에서 예측을 세워 검증했더니 예측은 틀렸고, 반대 방향에서 스무 중 열아홉을 얻었다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 40이 다섯 도메인에서 상충을 법칙 수준으로 확인했다 — 자기 상관과 대상 전이 $r = +0.992$, 출처 전이 $r = -0.992$. 지금까지는 그 법칙을 관찰했으니 이번에는 조종 손잡이로 써 보기로 했다. 인자 공간은 공유 축 블록과 고유 축 블록을 λ 로 섞어 만든다. 고유 축은 그 도메인에만 있으므로 λ 가 클수록 인자 공간이 특수해진다. 법칙이 맞다면 출처 역할에서는 λ 를 줄여야 한다 — 일반적이어야 남에게 옮겨지니까. 예측은 틀렸다. $\lambda = 0$ 으로 줄이면 20셀 중 16개로 나빠지고, 유도값(0.67–1.0)에서 17개, 1.5로 키우면 19개가 된다. 응답이 매끄럽고 단조이며 순열 씨앗 넷에서 유의 개수가 정확히 같았다. 그리고 비대칭이 핵심이다 — 같은 1.5를 대상 쪽에 걸면 14개로 무너진다. λ 는 특수성 손잡이가 아니라 정보량 손잡이었다. 출처는 회귀 계수를 학습하는 쪽이라 인자 공간이 많이 담을수록 계수가 안정되고, 대상은 그 계수를 받는 쪽이라 특수해지면 계수가 안 맞는다. 같은 매개변수가 두 역할에서 다른 의미를 갖는다. 이득은 아이돌에 몰렸다 — 노트 40이 “출처로 살릴 배선을 찾아야 한다”고 남긴 세 셀이 배선이 아니라 λ 하나로 살아났다($p\ 0.252 \rightarrow 0.017$, $0.472 \rightarrow 0.048$, $0.599 \rightarrow 0.077$). 남은 실패는 아이돌 → 편딩 하나다.

1. 법칙을 손잡이로 쓴다

노트 38과 40은 배선을 바꿔 가며 상충을 관찰했다. 자기 상관이 오르면 대상 성적이 오르고 출처 성적이 내렸다. 다섯 도메인에서 $|r|$ 이 0.99를 넘었다.

관찰이 법칙이라면 조종할 수 있어야 한다. 인자 공간을 만드는 식에 마침 손잡이가 하나 있다.

공유 축 블록과 고유 축 블록을 λ 로 섞어 공분산 주성분을 뽑는다. 고유 축은 그 도메인에만 있는 축이므로, λ 가 클수록 인자 공간이 그 도메인에 특수해진다.

법칙이 시키는 방향은 분명하다.

- 대상 역할 — λ 를 키운다. 특수해도 좋다. 자기 라벨만 맞으면 되니까.
- 출처 역할 — λ 를 줄인다. 일반적이어야 남에게 옮겨진다. $\lambda = 0$ 이면 공유 축만으로 인자 공간을 만든다.

이것은 탐색이 아니라 예측이다. 후보를 훑어 최댓값을 고르는 것이 아니라 법칙이 시키는 방향으로 손잡이 하나를 돌린다.

2. 예측이 틀렸다

정확히 반대다. 줄이면 나빠지고 키우면 좋아진다.

세 가지가 이것이 잡음이 아님을 말한다. 응답이 매끄럽고 단조이고 (16, 16, 16, 17, 19), 순열 씨앗 넷에서 유의 개수가 정확히 같았으며 (19, 19, 19, 19), 뒤에서 보듯 방향을 뒤집으면 명확히 무너진다.




Figure 1: 출처 역할의 λ 만 바꾼 것. 대상은 유도값을 유지했다.

3. 비대칭이 핵심이다

같은 λ 를 대상 쪽에 걸면 어떻게 되는지 봤다.

방향을 뒤집으면(대상만 키우면) 14/20으로 무너진다. 둘 다 키우면 $\lambda = 2$ 부터 급격히 나빠져 $\lambda = 8$ 에서 8/20에 이득이 음수가 된다.

주장 1. λ 는 특수성 손잡이가 아니라 정보량 손잡이다. 출처는 회귀 계수를 학습하는 쪽이라 인자 공간이 많이 담을수록 계수가 안정되고, 대상은 그 계수를 받는 쪽이라 특수해지면 계수가 안 맞는다. 같은 매개변수가 두 역할에서 다른 의미를 갖는다.

반증 조건. λ 가 정보량이라면 표본이 큰 도메인일수록

Table 1: 출처 λ 스윙. 대상은 겹침 유도값(0.67~1.0).

출처 λ	유의	평균 이득
0.00 (예측한 방향)	16/20	+0.0397
0.25	16/20	+0.0422
0.50	16/20	+0.0428
0.75	17/20	+0.0449
유도값(현행)	17/20	+0.0463
1.00	17/20	+0.0472
1.50	19/20	+0.0492




Figure 2: 다섯 구성. 순열 씨앗 넷에서 유의 개수가 같았다.

큰 λ 가 좋아야 한다. 도메인별 λ 를 나눠 재면 그 예측을 검증할 수 있고, 관계가 없으면 이 설명이 틀린 것이다.

상충 법칙 자체가 틀린 것은 아니다. 그 법칙은 무엇을 재느냐(배선)에 대한 것이었고, λ 는 얼마나 섞느냐다. 두 손잡이가 다른 축에 있었는데 나는 같은 축이라고 가정했다.

4. 아이들이 살아났다

노트 40의 마지막 항목은 “아이들을 출처로 살리는 배선 — 상충의 극단이므로 가장 얻을 것이 많다”였다. 배선을 건드리지 않고 λ 하나로 둘이 살아났다.


왜 아이들만인가. 아이들은 관측 축이 다섯으로 가장 많고 그중 둘(입장 허들, 미디어 투입)이 고유 축이다. λ 를 키우면 그 둘의 기여가 커진다. 게임은 공통 축 셋만 관측하므로 고유 축이 없고 λ 에 전혀 반응하지 않는다(네 셀 모두 값이 소수점 넷째 자리까지 같다). 도서와 편딩은 미세하게 나빠졌지만 유의는 유지했다.

5. 현재 상태

정렬은 쌍마다 둘이 함께 관측한 공통 축으로 하고(노트 40), 출처 인자 공간은 $\lambda = 1.5$, 대상은 겹침 유도값을 쓴다(이 노트).

Table 2: 역할별 λ 조합.

구성	유의	평균 이득
현행 (둘 다 유도값)	17/20	+0.0463
출처 1.5 · 대상 유도값	19/20	+0.0492
출처 1.25 · 대상 유도값	17/20	+0.0489
출처 유도값 · 대상 1.5	14/20	+0.0322
출처 1.5 · 대상 1.0	18/20	+0.0499

Figure 3: 아이들을 출처로 쓴 세 방향의 순열 p. 출처는 1.5, 대상은 유도값. 출처별 평균도값 대상 유도값 대상 유도값 대상 $\lambda=1.5$ 대상 $\lambda=1.0$

6. 한계

- λ 값 여섯 개를 훑어 최댓값을 골랐다. 예측 검정으로 시작했지만 1.5라는 값 자체는 선택된 것이고, 1.25가 17/20이라 격자가 성기다.
- λ 를 도메인 공통으로 걸었다. 도메인마다 다른 값이 맞을 수 있고, 그러면 매개변수가 다섯 개가 되어 선택 편향이 커진다.
- “정보량 손잡이” 설명은 관찰을 사후에 정리한 것이다. 표본 크기와의 관계로 검증하지 않았다.
- 겹침 유도 규칙(노트 29)이 출처 역할에서는 너무 보수적이라는 뜻인데, 그 규칙 자체를 다시 유도하지 않고 상수로 뒀었다.
- 아이들 → 편딩($p=0.077$) 하나가 남았다. 편딩 매장 노출도가 아직 비어 있어 그 셀은 공통 축 둘로만 정렬한다.

7. 다음

- 창작자 색인 완성 → 편딩 매장 노출도 → 마지막 셀 재검정.
- λ 가 정보량이라는 설명을 표본 크기와의 관계로 검증한다.
- 겹침 유도 규칙을 역할별로 다시 유도한다 — 상수 1.5를 대체할 공식.
- 이중 배선(노트 39)을 이 파이프라인 위에서 다시 검증한다.

Table 3: 아이돌을 출처로 쓴 세 셀.

셀	현행 p	$\lambda = 1.5$	
아이돌 → 게임	0.2517	0.0170	유의
아이돌 → 도서	0.4718	0.0480	유의
아이돌 → 펀딩	0.5988	0.0767	남은 하나

Table 4: 정본 파이프라인. 다섯 도메인 · 쌍별 정렬 · 역할별 λ .

	유의	평균 이득
노트 39 (네 도메인)	11/12	+0.0594
노트 40 (다섯 도메인)	17/20	+0.0463
노트 41	19/20	+0.0492

참고문헌

Ben-David, S. et al. (2010). A theory of learning from different domains. *Machine Learning*, 79(1–2), 151–175.

Hoerl, A. E., Kennard, R. W. (1970). Ridge regression: biased estimation for nonorthogonal problems. *Technometrics*, 12(1), 55–67.

Schönemann, P. H. (1966). A generalized solution of the orthogonal Procrustes problem. *Psychometrika*, 31(1), 1–10.

Cawley, G. C., Talbot, N. L. C. (2010). On over-fitting in model selection and subsequent selection bias in performance evaluation. *JMLR*, 11, 2079–2107.

Standley, T. et al. (2020). Which tasks should be learned together in multi-task learning? *ICML*, 9120–9132.