

IP 파운데이션 월드모델 연구 노트 42

눈금이 맞았을 뿐 신호는 그대로였다


노트 41을 한 노트 만에 철회한다 --- 순열 검정이 MAE 기준이라 축소를 개선으로 읽었다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 41은 출처 λ 를 1.5로 키워 19/20을 얻고 “정보량 손잡이”라고 설명하면서 반증 조건을 함께 적었다 — “표본이 큰 도메인일수록 큰 λ 가 좋아야 한다.” 그대로 검정했다. 반증됐다: 도메인별 최선 λ 와 $\log_{10}$ (표본 크기)의 상관이 -0.412 로 예측과 부호가 반대다(경쟁 설명인 고유 축 수는 $+0.577$). 그런데 검정 과정에서 훨씬 나쁜 것이 나왔다. 아이돌을 출처로 두고 λ 만 0.5에서 3.0까지 훑으니 전이 상관이 꿈쩍하지 않는다 — 스무 셀 평균이 0.381에서 0.387 사이이고 셀별 표준편차 평균이 0.004다. 움직인 것은 예측의 퍼짐이었다 — 예측 SD ÷ 대상 y SD가 0.67에서 0.38로 줄어든다. 대상 라벨은 표준화돼 SD가 1이고 전이 상관이 0.27–0.46 이므로 MAE를 최소화하는 예측 스케일은 그 근처다. λ 를 키우면 인자 공간 분산이 커져 능형 계수가 작아지고, 그래서 우연히 축소가 걸렸다. 순위는 그대로인데 눈금만 맞았고, 순열 검정이 MAE 기준이라 그것을 개선으로 읽었다. 축소를 명시적으로 걸어 확인하니 평균 이득은 $+0.0463$ 에서 $+0.0549$ 로 오르는데 유의는 17에서 13으로 떨어진다 — 귀무분포도 같은 축소를 받기 때문이다. 노트 41의 19/20을 철회하고 λ 를 유도값으로 되돌렸다.

Figure 1: 도메인별 최선 λ 와 두 설명 변수.Table 1: 도메인별 최선 λ .

도메인	n	고유 축	최선 λ	합계
아이돌	62	2	1.25	
팝업	75	2	1.25	
도서	242	1	1.00	
편당	360	1	1.25	
$\log_{10}(n)$ 과의 상관				-0.412
고유 축 수와의 상관				$+0.577$

Table 2: 아이돌 출처 λ 에 따른 전이 상관.

	1.0	1.2	1.4	1.6	1.8	2.0
대상	$\lambda=1.0$	유도 축소		1.5	2.0	
팝업	+0.458	+0.458		+0.457	+0.458	
게임	+0.295	+0.299		+0.298	+0.295	
도서	+0.269	+0.269		+0.269	+0.269	
편당	+0.225	+0.226		+0.227	+0.228	

1. 반증 조건대로 검정했다

노트 41은 설명과 함께 반증 조건을 적었다.

“ λ 가 정보량이라면 표본이 큰 도메인일수록 큰 λ 가 좋아야 한다. 도메인별 λ 를 나눠 재면 그 예측을 검정할 수 있고, 관계가 없으면 이 설명이 틀린 것이다.”

도메인마다 자기 출처 λ 만 훑고 나머지는 1.5에 고정 한 채, 그 도메인이 출처인 셀들의 평균 전이 상관을 봤다. 게임은 공통 축 셋만 관측해 고유 축이 없으므로(손잡이 자체가 없다) 제외했다.

부호가 반대다. 정보량 설명은 반증됐다. 그리고 도메인별 최선이 전부 1.0–1.25로, 노트 41이 채택한 1.5가 아니다.

2. 전이 상관이 움직이지 않는다

왜 1.5가 19/20을 냈는지 보려고 아이돌 하나만 붙잡고 λ 를 훑었다.

순위 성능은 소수점 셋째 자리에서만 흔들리고, 눈금은 절반 가까이 줄어든다. 전체 스무 셀에서 확인해도 같다 — λ 를 0.5에서 3.0까지 훑을 때 평균 전이 상관이 0.381




Figure 2: 아이들을 출처로 쓴 네 방향. 왼쪽이 순위 성능, 오른쪽이 눈금이다.

Table 3: 같은 조건에서 예측 SD ÷ 대상 y SD.

대상	$\lambda=1.0$	1.25	1.5	2.0
팝업	0.67	0.59	0.51	0.38
게임	0.52	0.46	0.39	0.29
도서	0.59	0.52	0.45	0.33
편딩	0.59	0.53	0.45	0.34

에서 0.387 사이이고 셀별 표준편차 평균이 0.004다.

주장 1. λ 는 전이의 순위 성능을 바꾸지 않는다. 바꾸는 것은 예측의 눈금이며, λ 가 커지면 인자 공간 분산이 커져 능형 계수가 작아지고 예측이 덜 퍼진다. 노트 41의 19/20은 전이가 좋아진 것이 아니라 눈금이 맞은 것이다.

반증 조건. 순위 성능이 λ 에 반응하는 도메인 쌍이 나오면 이 진단이 좁은 것이다.

대상 라벨은 도메인 안에서 표준화돼 SD가 1이다. 전이 상관이 r 이면 MAE를 최소화하는 예측 스케일은 r 근처다(회귀 축소). 상관이 0.27~0.46인데 예측이 0.67로 퍼져 있었으니, λ 를 키워 0.38까지 줄인 것이 우연히 최적에 가까워진 것이다.

3. 축소를 명시적으로 걸어 봤다

λ 로 돌려 맞추는 것이 아니라 예측을 표준화한 뒤 계수 c 로 다시 퍼면 된다. 순열 귀무분포도 같은 처리를 받게 했다.

† 대상 라벨이 필요하므로 실전에서는 못 쓴다. 상한 참고용이다.

이득은 18% 오르는데 유의는 떨어진다. 축소가 관측 예측만이 아니라 무작위 라벨로 학습한 귀무 예측도 똑같이 개선하기 때문이다. 점정력이 오르지 않는다.

주장 2. 순열 점정(MAE 기준)과 전이 상관(순위 기준)은 서로 다른 것을 잴다. 눈금만 바꾸는 조작은 앞의 것을 움직이고 뒤의 것을 움직이지 않는다. 지금까지 채택 결정을 유의 개수로 해 왔는데, 그 기준은 눈금 조작에 취약하다.




Figure 3: 명시적 축소 계수에 따른 두 지표. 점선이 축소 없는 현행이다.

Table 4: 명시적 축소.

축소 계수 c	유의	평균 이득
없음(현행)	17/20	+0.0463
0.30	13/20	+0.0528
0.35	13/20	+0.0549
0.40	14/20	+0.0549
0.50	12/20	+0.0483
출처 자기상관	14/20	+0.0393
대상 자기상관†	14/20	+0.0554

반증 조건. 눈금을 건드리지 않는 조작에서 두 지표가 같려면 이 구분으로도 부족하다.

4. 무엇을 되돌렸나

- 철회 — 노트 41의 “출처 $\lambda = 1.5$ 로 19/20”. 전이 상관이 바뀌지 않았으므로 개선이 아니다. λ 를 겹침 유도값으로 되돌렸고 현재 상태는 17/20, 평균 이득 +0.0463이다.
- 철회 — 노트 41의 “ λ 는 정보량 손잡이다”. 표본 크기와 부호가 반대다.
- 유지 — 노트 41이 관찰한 사실 자체(줄이면 나빠지고 키우면 좋아진다)는 재현된다. 해석만 틀렸다.
- 유지 — 노트 40의 상충 법칙. 그것은 배선에 대한 것이고 이 노트가 다른 것은 λ 다.

노트 41은 “법칙을 손잡이로 쓴다”로 시작해 예측이 틀린 것을 확인하고 반대 방향에서 개선을 얻었다고 썼다. 실제로는 손잡이가 다른 기계에 붙어 있었다 — 신호가 아니라 눈금을 돌리고 있었고, 내가 쓴 자가 눈금에 반응하는 자였다.

축소는 언제 필요한가. 순위가 목적이면 축소는 단조 변환이라 무의미하다. 절대값이 목적이면 필요하고, 그 자리는 노트 26·32에서 다른 눈금 보정이다 — 대상 도

메인 8-20건을 재서 중심과 산포를 맞추는 절차. 전이 단계에서 축소로 MAE를 낮추는 것은 그 보정을 미리 반쯤 해 두는 것에 지나지 않는다.

5. 한계

- 도메인별 최선 λ 를 네 점으로 켜고 응답 곡선이 매우 평평하다 (팝업은 0.367-0.369). argmax 가 잡음을 고를 수 있다.
- “전이 상관이 λ 에 무관”은 현재 다섯 도메인·현재 배선에서의 관찰이다. 고유 축이 셋 이상인 도메인이 없다.
- 명시적 축소를 상수와 두 규칙으로만 시험했다. 셀별로 다른 c 를 라벨 없이 정하는 문제는 노트 32의 미해결 문제와 같은 것이다.
- 순열 검정을 상관 기준으로 다시 짜지 않았다. 그렇게 하면 눈금에 둔감한 검정이 되는데 이 노트에서는 하지 않았다.
- 노트 39의 이중 배선은 유의 개수로 채택했다. 같은 취약점이 있는지 다시 봐야 한다.

6. 다음

1. 순열 검정을 전이 상관 기준으로 다시 짠다 — 눈금에 둔감한 판정.
2. 그 기준으로 노트 39의 이중 배선을 재검정한다.
3. 창작자 색인 완성 → 편당 매장 노출도 → 20셀 재검정.
4. 순위 성능을 실제로 올리는 조작이 무엇인지 — 지금까지 확인된 것은 배선(노트 34·35·37)과 도메인 추가뿐이다.

참고문헌

- Hoerl, A. E., Kennard, R. W. (1970). Ridge regression: biased estimation for nonorthogonal problems. *Technometrics*, 12(1), 55-67.
- Stein, C. (1956). Inadmissibility of the usual estimator for the mean of a multivariate normal distribution. *Proc. Third Berkeley Symp.*, 1, 197-206.
- Copas, J. B. (1983). Regression, prediction and shrinkage. *JRSS B*, 45(3), 311-354.
- Good, P. (2005). *Permutation, Parametric, and Bootstrap Tests of Hypotheses*, 3rd ed. Springer.
- Ben-David, S. et al. (2010). A theory of learning from different domains. *Machine Learning*, 79(1-2), 151-175.