

IP 파운데이션 월드모델 연구 노트 43

자를 바꾸니 결정 둘이 무너졌다

눈금에 둔감한 순위 검정을 만들어 과거 채택 결정을 전부 재감사한다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 42가 판정 도구의 결함을 드러냈다 — 순열 검정의 통계량이 MAE라서 예측의 눈금만 바꾸는 조작이 성적을 움직였다. 통계량을 스피어만 순위 상관으로 바꿔 다시 만들었다. 단조 변환에 완전히 불변이고, 팝업 기획 여럿의 반응 순위를 알고 싶은 제품 목적과도 맞는다. 검정 자체를 먼저 확인했다 — λ 를 유도값에서 3.0까지 바꿔도 스무 셀 평균 ρ 가 0.3439, 0.3438, 0.3372로 평평하다. 그다음 귀무분포를 들여다보니 판정 기준 자체를 옮겨야 했다. 귀무는 같은 인자 공간에 무작위 계수인데, 대상이 팝업($n=75$)이면 SD가 0.334이고 도서($n=242$)면 0.177이다. 유의 개수가 모델이 아니라 대상 표본 크기에 지배된다. 그래서 채택 판정을 유의 개수에서 평균 ρ 로 옮겼다. 새 자로 과거 결정 넷을 재감사했다. 둘은 유지되고 둘은 무너졌다 — 공통 축을 둘에서 셋으로 늘린 것(+0.3301→+0.3438)과 쌍별 정렬(+0.3724→+0.3742)은 살아남았고, 게임 매장 노출도를 켜 것(+0.3438→+0.3516, 끄는 쪽이 낫다)과 노트 39의 이중 배선(+0.3439→+0.3430)은 개선이 아니었다. 되돌린 뒤 현재 평균 ρ = +0.3516이다. 다만 노트 33과 40의 두 관계는 순위 기준에서도 그대로다 — 대상 간 분산이 출처 간 분산의 18.1배이고, 자기 상관과 대상 전이가 +0.959, 출처 전이가 -0.952다. 상충은 지표 인공물이 아니었다.

Table 1: 검정이 눈금에 둔감한지 확인.

설정	유의	평균 ρ
유도값	10/20	+0.3439
출처 $\lambda=1.5$	11/20	+0.3438
출처 $\lambda=3.0$	11/20	+0.3372

1. 새 자를 만든다

노트 42의 결론은 이랬다 — 순열 검정이 MAE 기준이라 눈금 조작을 개선으로 읽었다. 통계량을 바꾼다.

스피어만 순위 상관. 예측에 무엇을 곱하든 더 하든 값이 같다. 팝업 기획 여럿의 반응 순위를 알고 싶은 것이지 절대 방문자 수를 맞히려는 것이 아니다 — 절대값은 노트 26·32의 눈금 보정이 따로 담당한다.

귀무가설은 그대로다. 출처 라벨을 섞어 다시 적합하고 같은 순위 상관을 켜다.

평균 ρ 가 평평하다. 노트 41이 19/20을 얻었던 $\lambda = 1.5$ 가 순위 기준으로는 아무것도 바꾸지 않는다 — 노트 42의 철회가 확인된다.

2. 유의 개수를 버린다

새 검정으로 재니 유의가 10/20으로 떨어졌다. 왜 그런지 보려고 귀무분포를 직접 그렸다.




Figure 1: 대상별 귀무분포. 관측이 95분위에 붙어 있다.

귀무 SD가 대상 도메인마다 두 배씩 차이 난다. 유의 여부가 전이 품질보다 대상 표본 크기에 더 크게 달려 있다는 뜻이다.

주장 1. 유의 개수는 채택 판정에 쓸 수 없다. 귀무분포의 폭이 대상 도메인의 표본 크기에 지배되므로, 같은 품질의 전이라도 대상이 작으면 유의하지 않고 크면 유의하다. 판정은 평균 ρ 로 한다.

반증 조건. 표본 크기를 통제해 검정을 만들었을 때 결론이 달라지면 이 처방이 성급한 것이다.

Table 2: 귀무 ρ 의 폭.

대상	n	귀무 SD	95분위	관측
아이돌	62	0.353	+0.490	+0.458
팝업	75	0.334	+0.461	+0.469
도서	242	0.177	+0.229	+0.230
편딩	360	0.187	+0.245	+0.245
게임	482	0.254	+0.370	+0.353

Table 3: 재감사.

결정	판정	전	후
노트 37 공통 축 2→3	유지	0.3301	0.3438
노트 40 쌍별 정렬	유지	0.3724	0.3742
노트 37 게임 매장축 켜기	철회	0.3438	0.3516 [†]
노트 39 이중 배선	철회	0.3439	0.3430

Table 4: 게임 매장 노출도 축을 끌 때의 ρ 변화.

	검	곰	차이
아이돌 → 게임	+0.302	+0.374	+0.072
편딩 → 게임	+0.309	+0.353	+0.044
팝업 → 게임	+0.309	+0.343	+0.034
도서 → 게임	+0.306	+0.329	+0.022
게임이 출처인 네 셀	0.3439	0.3430	0.0009
평균 변화			-0.004




Figure 2: 과거 채택 결정을 평균 순위 상관으로 다시 봤.

귀무가 무엇인지 다시 보자. 이 귀무는 인자 공간은 그대로 두고 계수만 무작위로 만든다. 인자 공간이 이미 대상 라벨과 정렬돼 있으면 무작위 방향도 꽤 맞는다. 그래서 관측이 95분위에 붙는 것은 검정이 가혹해서가 아니라 인자 공간 자체가 일의 대부분을 하고 있다는 사실을 드러낸다. 성분이 둘뿐이라 무작위 방향의 자유도가 작다.

3. 결정 넷을 재감사한다

유의 개수로 채택한 결정이 넷 있었다.

[†] 끄는 쪽 값이다. 켜면 0.3438이므로 노트 37의 결정을 되돌렸다.

게임 매장 노출도. 노트 28이 꺾고 노트 37이 꺾었다. 순위 기준으로 재나 끄는 쪽이 낮고, 이득이 게임을 대상으로 한 네 셀에 전부 몰린다.

노트 28의 원래 판단이 옳았다. 다만 공통 축 목록에서 빼는 것은 아니다 — 다른 세 도메인은 이 축을 관측하고, 쌍별 정렬이 도메인별 관측 차이를 허용하므로 게임만 두 축으로 정렬하면 된다.

쌍별 정렬의 진짜 가치. 재감사하다 알게 된 것이 있다. 전역 기준 정렬은 모든 도메인이 같은 공통 축 집합을 관측해야 하므로 편딩(돌만 관측)을 애초에 넣을 수 없다. 노트 40은 쌍별 정렬을 성적(+0.0547→+0.0561)으로 정당화했는데, 실제 가치는 성능이 아니라 적용 가능성이었다.

4. 상충은 지표 인공물이 아니었다

노트 38과 40의 상충이 MAE 기준이었으니 새 자로 다시 재야 했다.

MAE 기준의 +0.992와 -0.992보다 조금 약하지만 결론은 같다. 상충은 실악남았다. 그리고 다 실패해진 것이 있다. 같은 대상이면 출처가 무엇이든 ρ 가 거의 같다 — 게임을 대상으로 한 네 셀이 0.329–0.374, 도서를 대상으로 한 넷이 0.223–0.230이다. 대상 간 분산이 출처 간 분산의 18.1배다.

노트 24가 “대상이 출처보다 네 배 중요”를 얻었고 노트 33이 “출처 선택은 무의미”로 밀고 갔다가 노트 38이 “출처 배선은 유의미”로 정정했다. 순위 기준에서 보면 셋 다 맞다 — 출처를 고르는 것은 무의미하고(18.1배), 출처를 어떻게 재는지는 유의미하다(-0.952).

5. 현재 상태

유의가 10에서 7로 줄었지만 그것은 이제 판정 기준이 아니다.

6. 한계

- 평균 ρ 에 신뢰구간을 붙이지 않았다. 0.3438과 0.3516의 차이가 표본 요동보다 큰지 확인하지 않았다.
- 귀무분포를 “인자 공간 고정, 계수 무작위”로 두었다. 인자 공간까지 무작위로 만드는 더 강한 귀무를 쓰면 유의가 크게 늘 것이고, 어느 쪽이 옳은 질문인지 정하지 않았다.
- 표본 크기를 통제한 검정을 만들지 않고 판정 기준만 옮겼다.
- 노트 38·39·40의 결론 중 MAE로 얻은 수치들을 전부 다시 재지는 않았다. 상충 두 관계만 확인했다.
- 노트 41 이전의 결정들(노트 34·35의 배선 변경 등)은 재감사하지 않았다. 그때는 자기 상관을 기준으로 골랐고 그것은 눈금과 무관하지만, 확인은 필요하다.




Figure 3: 왼쪽 — 도메인별 두 역할과 셀 간 폭. 오른쪽 — 자기 상관과의 관계.

Table 5: 순위 기준 역할 분석.

도메인	자기 ρ	대상으로	출처로
아이돌	+0.471	+0.480	+0.311
팝업	+0.364	+0.461	+0.316
게임	+0.286	+0.307	+0.357
펀딩	+0.207	+0.243	+0.367
도서	+0.197	+0.228	+0.368
자기 ρ 와의 상관		+0.959	-0.952

Table 6: 되돌린 뒤. 다섯 도메인 · 쌍별 정렬 · 유도 λ .

	평균 ρ	유의
노트 43 이전	+0.3438	10/20
되돌린 뒤	+0.3516	7/20

7. 다음

1. 평균 ρ 의 بوت스트랩 신뢰구간 — 0.008 차이가 의미 있는지.
2. 노트 34·35의 배선 결정을 순위 기준으로 재감사한다.
3. 창작자 색인 완성 → 펀딩 매장 노출도 → 재검정.
4. 인자 공간이 일의 대부분을 한다면, 계수를 아예 쓰지 않는 전이(공통 축 부호만 맞추기)와 비교해 볼 만하다.

참고문헌

- Spearman, C. (1904). The proof and measurement of association between two things. *American Journal of Psychology*, 15(1), 72–101.
- Good, P. (2005). *Permutation, Parametric, and Bootstrap Tests of Hypotheses*, 3rd ed. Springer.
- Ben-David, S. et al. (2010). A theory of learning from different domains. *Machine Learning*, 79(1–2), 151–175.
- Schoppe, O. et al. (2016). Measuring the performance of neural models. *Frontiers in Computational Neuroscience*, 10, 10.
- Schönemann, P. H. (1966). A generalized solution of the orthogonal Procrustes problem. *Psychometrika*, 31(1), 1–10.