

IP 파운데이션 월드모델 연구 노트 44

여섯 노트가 잡음을 조각하고 있었다

신뢰구간을 붙이니 알고리즘 조정 셋은 전부 0을 포함하고 배선 하나만 살아남는다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 43은 판정 기준을 유의 개수에서 평균 순위 상관으로 옮기고 과거 결정 넷을 재검사했다. 그런데 근거로 쓴 차이가 0.3438 대 0.3516처럼 작았고 신뢰구간이 없었다. **자를 바꿨을 뿐 눈금을 읽지 않은 것이며, 그것은 노트 42가 지적한 것과 같은 실수다.** 연도 총화 짝지은 붓스트랩 300회로 구간을 붙였다. 결과가 가혹하다. **현행 평균 ρ 자체의 95% 구간이 [0.265, 0.406]으로 반폭이 0.071인데, 노트 37부터 43까지 여섯 노트가 다룬 설정 간 차이는 0.009–0.022였다.** 짝을 지어 분산을 상당히 견어내도 알고리즘 조정 셋 — 공통 축을 둘에서 셋으로(+0.0215), 게임 매장축 끄기(+0.0095), 이중 배선(−0.0094) — 의 구간이 **전부 0을 포함한다.** **하나만 살아남았다.** 노트 34가 도서 타깃 폭을 장르 수에서 판형으로 바꾼 것으로, 차이가 +0.0939, 95% 구간 [+0.046, +0.199]다. 나머지의 네 배에서 열 배다. 노트 33이 관찰로 얻었던 문장 — “전이 알고리즘을 더 손볼 이유가 없다. 남은 일은 각 도메인에서 무엇을 어떻게 채느냐뿐이다” — 이 이제 구간으로 확증된다. 알고리즘 조정을 중단하고 배선과 데이터로 돌아간다.

Table 1: 현행 설정의 평균 순위 상관.

평균 ρ	+0.3516
95% 붓스트랩 구간	[+0.265, +0.406]
구간 반폭	0.071
노트 37–43이 다룬 차이의 범위	0.009–0.022

1. 자를 바꾸고 눈금을 안 읽었다

노트 42는 판정 도구가 눈금 조작에 속는 것을 잡아냈다. 노트 43은 도구를 바꿔 결정 넷을 재검사했다. 그런데 그 재검사가 쓴 근거는 이런 것이었다.

“게임 매장축을 끄면 0.3438에서 0.3516으로 오른다. 노트 37의 결정을 되돌린다.”

0.008이다. 그것이 표본 요동보다 큰지 확인하지 않았다. **자를 바꿨을 뿐 눈금을 읽지 않은 것이고, 그것은 노트 42가 지적한 것과 같은 종류의 실수다.**

연도 총화 짝지은 붓스트랩 300회로 구간을 붙였다. 복제마다 도메인별 레코드를 복원추출하고, 축 유도과 인자 공간 추정을 다시 하고, 두 설정을 같은 복제 위에서 계산해 차이를 기록한다. 짝을 짓는 이유는 노트 6에서 확립한 그대로다 — 차이가 요동보다 훨씬 작을 때 독립 붓스트랩은 큰 분산 둘을 빼서 아무것도 못 본다.

2. 절대 구간이 얼마나 넓은가

반폭이 0.071인데 여섯 노트가 0.009에서 0.022 사이를 놓고 채택과 철회를 반복했다. 비율로 보면 논쟁의 대상이 불확실성의 8분의 1에서 3분의 1이었다.




Figure 1: 짝지은 붓스트랩 300회. 가로선이 95% 구간이다.

짝을 지으면 공통 요동이 상쇄돼 차이의 구간은 훨씬 좁아진다. 그래도 충분하지 않았다.

3. 넷 중 하나만 살아남는다

주장 1. 알고리즘 조정(공통 축 수, 정렬 방식, 역할별 배선, λ)의 효과는 현재 표본에서 전부 잡음과 구분되지 않는다. 측정 배선(무엇을 채느냐)만 구간이 0을 넘는다.

반증 조건. 도메인이나 표본이 늘어 구간이 좁아졌을 때 알고리즘 조정 중 어느 하나가 0을 넘으면 이 판정은 검정력 부족이었던 것이다 — 효과가 없다는 증명이 아니라 못 봤다는 뜻이다.


노트 34가 한 일은 이랬다. 도서 타깃 폭에 장르 수를

Table 2: 과거 결정의 효과와 구간.

결정	차이	95% 구간	P(>0)
이중 배선(노트 39)	-0.0094	[-0.072, +0.016]	0.11
게임 매장축 끄기	+0.0095	[-0.012, +0.025]	0.80
공동 축 2→3(노트 37)	+0.0215	[-0.013, +0.043]	0.86
도서 타깃 폭 배선(노트 34)	+0.0939	[+0.046, +0.199]	1.00

Table 3: 노트 33 이후의 작업 분류.

노트	무엇을 했나	판정
34	도서 배선	살아남음
35	도서 누출 제거	미검정
36	고유 축 확대	기각(자체)
37	공동 축 확대	구간 0 포함
38	상층 발견	(관찰)
39	이중 배선	구간 0 포함
40	다섯째 도메인	미검정
41	λ 조정	철회(노트 42)
42	지표 결합 발견	(도구)
43	지표 교체	(도구)

Figure 2: 결정 유형별 효과 크기. 점선이 평균 ρ 자체의 구간 반폭이다.

넣었는데 라벨과의 상관이 -0.073 으로 무효였고, 개별 변수를 훑으니 판형이 가장 강해서(-0.282) 바꿨다. 그 하나가 나머지 세 결정을 합친 것의 두 배 넘는 효과를 낸다.

4. 노트 33이 옳았다

노트 33은 이렇게 끝났다.

“전이 알고리즘을 더 손볼 이유가 없다. 정렬 방법도, 출처 선택도, 공동 학습도 상한에 붙어 있는 값을 바꾸지 못한다. 남은 일은 각 도메인에서 무엇을 어떻게 재느냐뿐이다.”

그때는 관찰이었다 — 전이 상관이 대상 자기 상관과 같다는 등식에서 추론한 것이다. 이제 구간으로 확증된다. 그리고 나는 그 문장을 쓴 뒤 여섯 노트 동안 정확히 금지된 일을 했다.

쓸모없지는 않았다. 노트 38·40의 상층, 노트 42의 지표 결합, 노트 43의 표본 크기 의존 — 이것들은 채택 결정이 아니라 무엇이 작동하는지에 대한 지식이고, 그 지식이 이 노트를 가능하게 했다. 다만 여섯 노트 중 성능을 실제로 올린 것은 하나도 없다.

5. 그래서 무엇을 하나

알고리즘 조정을 중단한다. 남은 두 지렛대는 배선과 데이터다. 배선은 효과가 크고(구간 [+0.046, +0.199]) 검정도 싸다. 데이터는 구

간 자체를 좁혀 앞으로의 모든 판정을 가능하게 한다.

당장 할 수 있는 것이 셋이다.

1. 노트 35가 도서에서 한 것(전자책 누출 제거)을 나머지 네 도메인에서 반복한다. 아직 구간을 붙이지 않았다.
2. 팝업 표본을 늘린다. 팝업이 대상일 때 귀무 SD가 0.334로 가장 넓다($n=75$).
3. 남은 배선 후보를 순위 기준으로 전수 검정한다. 노트 38의 탐색은 인자 공간 자기 상관을 목표로 했고 그것은 MAE 계열 지표였다.

6. 한계

- 붓스트랩 300회다. 구간 끝점이 ± 0.01 쯤 흔들린다.
- 복원추출을 레코드 단위로 했다. 같은 IP의 여러 레코드가 있으면 독립이 아니므로 구간이 좁게 나온다(노트 7의 군집 문제).
- 노트 35(도서 전자책 제외)와 노트 40(다섯째 도메인)은 구간을 붙이지 않았다. 둘 다 표본 자체를 바꾸므로 짝지는 붓스트랩이 그대로 적용되지 않는다.
- 네 결정을 각각 현행 대비로 켜다. 조합 효과는 보지 않았다.
- “알고리즘 조정은 효과가 없다”가 아니라 “현재 표본에서는 못 본다”가 정확한 서술이다. 검정력 계산을 하지 않았다.

7. 다음

1. 네 도메인에 결측 누출 검사를 순위 기준 구간과 함께 다시 돌린다.
2. 배선 후보 전수 검정 — 순위 기준, 짝지는 붓스트랩.
3. 팝업 표본 확대 — 구간을 좁히는 유일한 길.
4. 붓스트랩을 IP 군집 단위로 다시 켜다.

참고문헌

- Efron, B., Tibshirani, R. J. (1993). An Introduction to the Bootstrap. Chapman & Hall.
- Bouthillier, X. et al. (2021). Accounting for variance in machine learning benchmarks. MLSys, 3, 747–769.
- Dror, R. et al. (2018). The hitchhiker’s guide to testing statistical significance in natural language processing. ACL, 1383–1392.
- Ben-David, S. et al. (2010). A theory of learning from different domains. Machine Learning, 79(1–2), 151–175.
- Spearman, C. (1904). The proof and measurement of association between two things. American Journal of Psychology, 15(1), 72–101.