

IP 파운데이션 월드모델 연구 노트 45

배선도 바닥났다

후보 오십 개 중 문턱을 넘는 것이 없다 --- 그리고 알고리즘을 검증하려면 표본이 서른 배 필요하다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 44는 지렛대를 둘로 쪼갬 --- 배선과 데이터. 배선은 효과가 크고 (노트 34의 +0.0939, 구간 [+0.046, +0.199]) 검증도 짜드로 먼저 훑었다. 다섯 도메인의 슬롯별 후보 오십 개를 스무 셀 평균 순위 상관으로 전수 검증했다. 문턱(0.02)을 넘는 것이 하나도 없다. 최대가 게임 타깃 폭을 지원 언어 수로 바꾸는 +0.0134이고, 나머지 마흔아홉은 그 아래다. 현재 배선이 후보 공간 안에서 지역 최적이라는 뜻이며, 노트 44가 남긴 두 지렛대 중 하나가 소진됐다. 그러면 데이터를 얼마나 늘려야 하는지가 다음 질문이다. 부분추출로 구간 반폭이 표본에 어떻게 의존하는지 쟀다. 679건에서 0.186, 1,241건(현재)에서 0.061로 단조 감소한다. 보수적으로 $n^{-1/2}$ 를 가정하면 배선 급 효과(0.094)를 확실히 보려면 1.7배, 공통 축 급(0.022)은 31배, 이중 배선 급(0.009)은 186배가 필요하다. 측정된 기울기 (-1.77)로 외삽하면 각각 1.2배, 2.7배, 4.5배다. 어느 쪽이든 결론은 같다 --- 배선 급 효과는 지금도 볼 수 있고 알고리즘 급 효과는 볼 수 없다. 그리고 구간을 좁히는 가장 빠른 길은 레코드가 아니라 도메인이다. 도메인이 하나 늘면 셀이 20개에서 30개로 늘어 평균 자체가 안정된다.

Table 1: 상위 후보. 현재 평균 $\rho = +0.3516$.

도메인	슬롯	후보	$\Delta\rho$
게임	타깃 폭	지원 언어 수	+0.0134
게임	굿즈 규모	설치 용량	+0.0025
나머지 48개			$\leq +0.0000$

1. 배선을 전수로 훑는다

노트 38도 배선을 탐색했지만 목적함수가 인자 공간 자기 상관이었고 그것은 MAE 계열이라 눈금에 반응한다 (노트 42). 여기서는 스무 셀 평균 순위 상관을 직접 목적으로 쓴다.

두 단계로 나뉘었다. 후보마다 붓스트랩 300회를 돌리면 계산이 감당이 안 된다.

- 1단계 --- 후보 오십 개의 점추정 $\Delta\rho$. 한 후보에 한 번씩.
- 2단계 --- $|\Delta\rho| \geq 0.02$ 인 것만 짚지는 붓스트랩. 문턱은 노트 44에서 왔다 --- 알고리즘 조정 셋의 효과가 0.009-0.022였고 전부 구간이 0을 포함했으므로 그 아래는 볼 필요가 없다.

주장 1. 현재 배선은 관측 가능한 후보 공간 안에서 지역 최적이다. 오십 개 중 문턱을 넘는 것이 없고 최대가 +0.0134다.

반증 조건. 새 변수를 수집하면 후보 공간이 커지므로 이 결론은 “지금 가진 변수로는”이라는 조건 아래에서만 참이다.




Figure 1: 배선 후보 오십 개의 효과. 점선이 문턱, 위 점선이 노트 34의 효과다.

2단계는 돌릴 것이 없었다. 노트 44가 남긴 두 지렛대 중 하나가 소진됐다.

2. 그러면 데이터가 얼마나 필요한가

부분추출로 구간 반폭이 표본에 어떻게 의존하는지 쟀다. 도메인마다 연도 층화 비복원 추출로 줄이고, 각 크기에 서 붓스트랩 200회로 구간을 구한다.

측정된 기울기는 -1.77인데 부분추출 폭이 좁아 (679-1,241) 믿기 어렵다. $n^{-1/2}$ 를 보수 하한으로 두고 둘 다 적는다.

주장 2. 배선 급 효과(0.09)는 현재 표본의 1.2-1.7배면

Table 2: 표본과 구간 반폭.

비율	레코드	반폭	평균 ρ
0.20	679	0.1857	+0.2471
0.30	740	0.1457	+0.2576
0.45	830	0.0887	+0.3736
0.60	927	0.0819	+0.3199
0.80	1,112	0.0680	+0.3345
1.00	1,241	0.0614	+0.3320

Table 3: 효과를 구간 밖으로 밀어내는 데 필요한 레코드.

보려는 효과	필요 반폭	보수	적합
배선 급 (0.094)	0.047	1.7배	1.2배
공통 축 급 (0.022)	0.011	31배	2.7배
이중 배선 급 (0.009)	0.0045	186배	4.5배




Figure 2: 로그-로그, 두 외삽선 사이가 실제 필요량이다.

확실히 보이고, 알고리즘 급 효과(0.01–0.02)는 3–30배가 필요하다. 후자는 실질적으로 검정 불가능한 영역이다. 반증 조건, 도메인을 늘려 셀 수가 제곱으로 증가하면 필요량이 이 계산보다 훨씬 줄 수 있다. 그 경우 보수 외삽이 지나치게 비관적인 것이다.

레코드보다 도메인이 싸다. 구간은 스무 셀의 평균에 붙는 것이고, 셀 수는 도메인 수의 제곱으로 늘다. 다섯에서 여섯으로 가면 20셀이 30셀이 된다. 레코드를 1.5배 늘리는 것보다 도메인을 하나 더하는 쪽이 평균을 더 크게 안정시킬 개연성이 높다. 그리고 도메인은 새 배선 후보도 함께 가져온다 — 이 노트가 소진했다고 한 후보 공간을 넓히는 유일한 방법이다.

노트 33부터 44까지의 결론이 하나로 모인다. 알고리즘은 손떨 것이 없고(노트 33·44), 배선은 지금 가진 변수로는 최적이며(이 노트), 남은 것은 새로 채는 것 뿐이다 — 새 도메인이든 새 변수든.

3. 한계

- 후보 오십 개는 이미 수집한 변수들의 재배치일 뿐이다. 새 변수를 수집하면 후보 공간이 달라진다.
- 슬롯 하나씩만 바꿔 봤다. 둘을 동시에 바꿔야 좋아지는 배선은 못 찾는다 (노트 38의 좌표 상승법과 같은 한계다).

- 부분추출이 679건까지만 내려가 기울기 추정이 불안정하다. 더 작게 줄이면 인자 공간이 무너져 다른 것을 재게 된다.
- 부분추출은 현재 표본의 구조를 축소한 것이라 새 데이터의 다양성을 반영하지 못한다. 필요량은 하한으로 읽어야 한다.
- 팝업($n=75$)이 병목인데 그것은 내부 데이터라 이 루프에서 늘릴 수 없다. 외부에서 늘릴 수 있는 것은 다른 도메인뿐이다.

4. 다음

- 여섯째 도메인 — 셀을 20개에서 30개로, 구간을 좁히는 가장 싼 길이자 배선 후보를 넓히는 유일한 길.
- 기존 도메인에 새 변수 — 특히 팝업. 사람 태깅 대신 외부에서 관측 가능한 지표(검색량, 문서 존재 등)를 붙이면 후보 공간이 늘고 태깅 비용도 준다.
- 창작자 색인 완성 → 편딩 매장 노출도 → 재검정.
- 슬롯 쌍을 동시에 바꾸는 탐색 — 계산이 커지므로 점추정만.

참고문헌

- Efron, B., Tibshirani, R. J. (1993). An Introduction to the Bootstrap. Chapman & Hall.
- Politis, D. N., Romano, J. P., Wolf, M. (1999). Subsampling. Springer.
- Bouthillier, X. et al. (2021). Accounting for variance in machine learning benchmarks. MLSys, 3, 747–769.
- Cohen, J. (1988). Statistical Power Analysis for the Behavioral Sciences, 2nd ed. Lawrence Erlbaum.
- Ben-David, S. et al. (2010). A theory of learning from different domains. Machine Learning, 79(1–2), 151–175.