

IP 파운데이션 월드모델 연구 노트 54

내가 만든 결함을 내가 찾은 규칙이 잡았다

같은 후보에 두 검정이 정반대 답을 냈다 --- 하나는 노트 53이 해롭다고 밝힌 조건을 검정 코드 안에서 재현하고 있었다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 53이 남긴 과제 — 웹툰 매장 노출도를 강화하라 — 부터 처리했다. 작가를 첫 한 명만 매칭하고 있었는데 웹툰은 글작가와 그림작가가 따로인 경우가 절반이 넘는다(900건 중 454건). 전원 매칭에 이름 정규화까지 넣으니 이력 있는 레코드가 84건에서 135건으로, 라벨과의 상관이 $+0.064$ 에서 $+0.099$ 로 올랐다. 그런데 서른 셀 평균은 $+0.3447$ 에서 $+0.3440$ 으로 중립이다 — 노트 53이 예측한 대로 현행 축이 이미 담고 있었다. 정확성 근거로만 유지했다. 그다음 노트 36에서 기각했던 고유 축 확장을 지금 눈금($\lambda = 1.0$, 순위 기준)에서 다시 켜다. 팝업은 여전히 -0.0167 로 나쁘고 게임만 $+0.0066$ 으로 좋다 — 게임은 관측 축이 둘뿐이라 인자 공간이 사실상 회전만 하고 있었다. 짝지은 붓스트랩을 붙이니 95% 구간이 $[-0.167, -0.027]$ 로 완전히 음수였다($P=0.000$). 점추정과 정반대다. 검정 코드의 버그였다 — 고유 축을 복원추출 뒤에 붙여, 원본 순서의 축이 재추출된 행에 걸렸다. 노트 53이 “레코드 대응을 깨면 축이 해롭다”고 밝힌 바로 그 조건을 내 검정 코드가 만들고 있었다. 순서를 고치니 $[+0.0014, +0.0110]$, $P=0.985$ 로 채택이다. 노트 53의 발견이 없었다면 “게임 고유 축은 해롭다”를 그대로 기록했을 것이다. 정본에 통합해 현재 $\rho = +0.3506$ 이다.

Table 1: 웹툰 작가 매칭.

	이력 있는 것	건수 r	최대 r
첫 작가만	84/900	$+0.064$	$+0.049$
전원 + 정규화	135/900	$+0.099$	$+0.095$

1. 웹툰 매장 노출도부터

노트 53이 짚었다 — 웹툰 매장 노출도는 신호가 $+0.087$ 로 약한데 기여가 -0.0433 으로 가장 크니 개선 여지도 가장 크다.

원인은 매칭이었다. 작가를 첫 한 명만 보고 있었는데 웹툰은 글작가와 그림작가가 따로인 경우가 절반을 넘는다(900건 중 2인 이상이 454건).

이름 정규화도 함께 넣었다 — 노트 52에서 아이돌 소속사의 ‘SM’과 ‘SM엔터테인먼트’가 따로 세어지는 것을 발견했으므로 같은 결함을 미리 막았다.

그런데 서른 셀 평균은 $+0.3447$ 에서 $+0.3440$ 으로 중립이다. 노트 53이 예측한 그대로다 — 현행 축이 이미 담고 있어 개선이 안 옮겨진다. 성능 근거가 없으므로 정확성 근거로만 유지했다. 같은 작가를 다르게 세는 것은 명백한 버그다.

2. 고유 축 확장을 다시 켜다

노트 36은 고유 축 확장을 기각했다. 그때는 λ 가 겹침 유도였고 지표가 MAE 계열이었다. 지금 눈금에서 다시 켜다.

게임만 좋아진다. 이유가 분명하다 — 게임은 관측




Figure 1: 도메인별 고유 축 확장.

축이 둘(타깃 폭, 굵기 규모)뿐이라 성분 둘을 뽑으면 사실상 회전만 한다. 넷을 더하면 처음으로 인자 공간이 정보를 압축한다. 나머지는 이미 넷에서 다섯 축을 관측하고 있어 더할 것이 적다.

3. 그런데 구간이 정반대였다

점추정이 같은데 구간이 정반대다.

버그의 정체. 복제마다 이렇게 했다 — 도메인을 복원추출한 뒤 고유 축을 붙였다. 그런데 고유 축은 원본 순서로 계산돼 있다. 복원추출은 크기를 보존하므로 길이는 맞고 오류도 안 난다. 다만 어느 레코드의 값인지가 어긋난다. 노트 53이 바로 그 조건을 검정했다 — 실제 축 값을

Table 2: 고유 축을 더할 때, 현행 $\rho = +0.3440$.

도메인	ρ	Δ
게임	+0.3506	+0.0066
도서	+0.3423	-0.0017
아이돌	+0.3386	-0.0054
팝업	+0.3273	-0.0167

Table 3: 게임 고유 축의 짝지는 붓스트랩.

검정	점추정	95% 구간	P(>0)
버그 있는 것	+0.0066	[-0.167, -0.027]	0.000
고친 것	+0.0066	[+0.001, +0.011]	0.985

Table 4: 여섯 도메인 2,181건 · 서른 셀.

도메인	n	관측 축	자기 ρ	대상으로
아이돌	62	5	+0.472	+0.473
웹툰	900	4	+0.377	+0.376
팝업	75	5	+0.368	+0.452
게임	472	6	+0.364	+0.377
도서	242	4	+0.202	+0.225
편딩	400	4	+0.390	+0.199
평균 ρ				+0.3506




Figure 2: 같은 후보, 같은 점추정, 두 검정.

그대로 두고 레코드 대응만 섞으면 -0.0352로 축을 끄는 것과 같아진다. 내 검정 코드가 그 해로운 조건을 복제마다 만들고 있었다.

확장을 복원추출 앞으로 옮기고 두 확장본을 같은 행 인덱스로 뿔게 고쳤다.

주장 1. 검정 코드가 만드는 인공물은 결과의 부호까지 뒤집을 수 있다. 여기서는 노트 53이 독립적으로 밝혀 둔 성질 — 레코드 대응이 깨지면 축이 해롭다 — 덕분에 버그를 알아볼 수 있었다.

반증 조건. 이 진단이 맞다면 대응을 보존한 복제에서는 효과가 안정적이어야 한다. 200회 중 $P=0.985$ 이므로 그렇게 보이지만, 다른 씨앗에서 흔들리면 진단이 부족하다.

노트 53은 축의 성질을 알아내려고 쓴 노트였는데, 그 결과가 한 노트 뒤에 내 도구의 결함을 잡는 데 쓰였다. 시스템이 자기를 검사할 재료를 스스로 쌓는다.

4. 정본에 통합했다

게임 고유 축 넷(가격 · 연령 등급 · 최소 RAM · 기능수)을 파이프라인에 넣었다. 슬롯 다섯 개 밖에 붙는 고유 축이므로 정렬에 참여하지 않고, 도메인마다 개수가 달라도 된다.

게임이 대상일 때 +0.346에서 +0.377로 올랐다. 노트 36의 “고유 축 확장은 소용없다”를 게임에 한해 정정한다 — 관측 축이 적은 도메인에서는 성립한다.

5. 한계

- 버그를 고친 뒤의 구간이 [+0.001, +0.011]로 아래 끝이 0에 가깝다. 씨앗 하나로만 켜다.

게임 고유 축 넷 중 연령 등급은 관측률이 낮아 (54/482) 복제마다 결측 패턴이 달라진다. 그 불안정이 구간에 얼마나 들어갔는지 모른다.

- 같은 버그가 앞선 노트의 다른 검정에도 있었는지 전수 확인하지 않았다. 고유 축을 쓴 검정은 노트 36과 이 노트뿐이라 범위는 좁다.
- 웹툰 작가 매칭 개선을 성능 근거 없이 유지했다. 정확성이라는 근거는 노트 48의 λ 와 같은 종류이며, 그런 결정이 쌓이면 검정 없는 변경이 늘어난다.
- 게임 관측 축이 여섯이 되면서 다른 도메인과의 축 수 불균형이 커졌다. 그 영향을 따로 보지 않았다.

6. 다음

- 웹툰 전체 완결작 3,073건 수집 — 진행 중. 표본이 900에서 3,900이 되면 노트 49의 “큰 도메인을 늘리면 구간이 좁아지나”를 직접 검정한다.
- 도서 · 편딩에도 고유 축 후보를 찾는다. 둘 다 자기 ρ 가 0.2 언저리로 가장 낮다.
- 구간을 여러 씨앗으로 다시 재 게임 고유 축을 굳힌다.
- 검정 코드에 대응 보존을 강제하는 장치 — 같은 버그를 세 번째로 만들지 않도록.

참고문헌

- Efron, B., Tibshirani, R. J. (1993). An Introduction to the Bootstrap. Chapman & Hall.
- Meredith, W. (1993). Measurement invariance, factor analysis and factorial invariance. Psychometrika, 58(4), 525–543.
- Bouthillier, X. et al. (2021). Accounting for variance in machine learning benchmarks. MLSys, 3, 747–769.
- Gower, J. C., Dijksterhuis, G. B. (2004). Procrustes Problems. Oxford University Press.
- Ben-David, S. et al. (2010). A theory of learning from different domains. Machine Learning, 79(1–2), 151–175.