

IP 파운데이션 월드모델 연구 노트 59

순위는 다섯 배, 절대값은 두 배 반

순서를 잘 가르는 것과 값을 좁히는 것은 다른 일이었다 --- 그 간극을 숫자로 적는다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 58은 팝업 예측 상위 20%가 860명, 하위 20%가 157명으로 5.5배 갈린다고 했다. 그런데 그것은 순위다. 예측값에는 눈금이 없어 “이 기획은 몇 명”을 말하지 못한다. 노트 26 · 32에서 세운 절차 — 대상 도메인 몇 건을 실제로 재서 중심과 산포를 맞추다 — 를 여섯 도메인에서 다시 썼다. 열두 건을 재면 절대 예측 오차가 $\times \div 2.51$ 배다. 같은 열두 건으로 중앙값만 쓰면 $\times \div 2.82$ 배이므로 모델이 줄이는 뭉은 11%다. k 를 서른까지 늘려도 2.41배로 거의 안 줄어든다 — 눈금은 여덟에서 열둘이면 잡힌다는 노트 32의 결론이 여섯 도메인에서 확인된다. 문제는 눈금이 아니라 잔차다. 순위 상관이 +0.47이면 설명되는 분산이 22%이고 잔차 표준편차가 원래의 88%로 남는다. 순서는 5.5배로 가르는데 값은 2.5배 안으로 못 좁힌다. 443명이라고 예측하면 실체는 대략 180명에서 1,100명 사이다. 제품 진술을 정확히 쓰면 이렇게 된다 — 어느 기획을 먼저 밀지 고르는 데는 쓸 수 있고, 몇 명 올지 약속하는 데는 아직 못 쓴다.

Table 1: 보정 건수별 절대 오차. 400회 무작위 분할 평균.

k	모델+보정	중앙값만	배수 오차
5	0.4551	0.4903	2.85배
8	0.4210	0.4655	2.64배
12	0.3995	0.4500	2.51배
20	0.3892	0.4410	2.45배
30	0.3825	0.4381	2.41배

1. 순위에 눈금을 붙인다

노트 58의 수치는 전부 순위였다. 절대 수를 내려면 대상 도메인 몇 건을 실제로 재야 한다. 절차는 노트 26 · 32에서 세웠다.

1. 팝업에서 보정용 k 건을 뽑는다.
2. 나머지에서 예측 순위를 낸다 — 여기에는 팝업 라벨이 전혀 안 들어간다.
3. k 건의 실제 라벨로 중심 (중앙값) 과 산포 ($MAD \times 1.4826$)를 잡는다.
4. 예측을 표준화한 뒤 그 중심 · 산포로 편다. 기울기는 k 건에서 추정한 상관으로 축소하되, k 가 작으면 사전 값 쪽으로 당긴다($w = k/(k+6)$).
5. 남은 건에서 절대 오차를 잰다.

비교 기준은 “같은 k 건의 중앙값을 전부에 쓴다”이다. 모델 없이 같은 비용으로 할 수 있는 최선이다.




Figure 1: 왼쪽 — 보정 건수와 절대 오차. 오른쪽 — 순위와 절대값의 간극.

2. 열두 건이면 눈금이 잡힌다

$k = 8$ 에서 12로 가면 0.42에서 0.40으로 줄고, 30까지 늘려도 0.38이다. 노트 32의 “눈금 보정에는 여덟 건이면 된다”가 여섯 도메인에서 확인된다.

주장 1. 절대 예측 오차는 열두 건을 재면 $\times \div 2.51$ 배이고, 더 재도 크게 줄지 않는다. 모델이 중앙값 대비 줄이는 뭉은 11%다.

반증 조건. 보정용 표본을 층화 없이 무작위로 뽑았다. 연도나 규모로 층화하면 적은 k 에서 더 나을 수 있다.

Table 2: 같은 모델의 두 얼굴.

순위 — 상위 20% ÷ 하위 20%	5.5배
절대값 — 예측 오차($k=12$)	$\times \div 2.51$ 배
443명 예측의 실제 범위	약 180 – 1,100명

3. 간극이 어디서 오나

순위는 5.5배로 가르는데 절대 오차는 2.5배다. 모순이 아니라 서로 다른 것을 재는 것이다.

순위 상관이 ρ 면 설명되는 분산이 ρ^2 이고 잔차 표준편차가 $\sqrt{1-\rho^2}$ 배로 남는다. $\rho = +0.47$ 이면 22%를 설명하고 잔차가 원래의 88%다. 양 끝을 갈라 놓는 데는 그것으로 충분하고, 값을 좁히는 데는 턱없이 모자란다.

주장 2. 제품 진술은 이렇게 써야 한다 — 어느 기획을 먼저 밀지 고르는 데는 쓸 수 있고, 몇 명 올리 약속하는 데는 아직 못 쓴다.

반증 조건. 절대 오차를 줄려면 ρ 를 올려야 하고, ρ 를 올리는 길은 노트 33 이후 계속 대상 도메인의 측정뿐이다. 팝업 75건이 그 병목이다.

4. 한계

- 보정용 표본을 무작위로 뽑았다. 실무에서는 “비슷한 기획”을 골라 짤 것이고 그러면 더 나올 수 있다.
- 기울기 축소의 사전값 0.45를 노트 58의 관측 ρ 에서 가져왔다. 새 도메인에서는 그 값을 모른다.
- 400회 분할 평균이라 k 가 클수록 검정 표본이 줄어 오차 추정이 불안정하다.
- 팝업 라벨 자체의 잡음(계수 기준 · 출처 신뢰도)이 오차에 포함돼 있다. 노트 1–8에서 걸렸지만 남은 몫을 따로 재지 않았다.
- 이 숫자는 팝업 75건 기준이다. 표본이 늘면 ρ 와 함께 개선될 것이다.

5. 다음

1. 보정용 표본을 증화해서 뽑으면 적은 k 에서 얼마나 나아지는지.
2. 웹툰 전체 수집 완료 후 전면 재측정(1,315/3,973 진행 중).
3. ρ 를 올리는 유일한 길 — 팝업 표본과 축.
4. 절대값이 필요 없는 쓰임을 정리한다. 순위만으로 되는 의사결정이 무엇인지.

참고문헌

Copas, J. B. (1983). Regression, prediction and shrinkage. JRSS B, 45(3), 311 – 354.

Rousseeuw, P. J., Croux, C. (1993). Alternatives to the median absolute deviation. JASA, 88(424), 1273 – 1283.

Stein, C. (1956). Inadmissibility of the usual estimator for the mean of a multivariate normal distribution. Proc. Third Berkeley Symp., 1, 197 – 206.

Spearman, C. (1904). The proof and measurement of association between two things. American Journal of Psychology, 15(1), 72 – 101.

Ben-David, S. et al. (2010). A theory of learning from different domains. Machine Learning, 79(1–2), 151 – 175.