

IP 파운데이션 월드모델 연구 노트 60

인코더를 만들어 겨뤘고 졌다

공유 인코더에 도메인별 헤드 --- 프론티어 쪽 구성을 같은 규약으로 세웠더니 닫힌 해가 두 배 앞섰다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

현행 파이프라인은 도메인마다 주성분 둘을 뽑고 쌍마다 프로크루스테스로 회전을 맞춘다 — 정렬이 닫힌 해로 계산되고 학습되지 않는다. 다중 도메인 모델의 표준 구성은 다르다. 모든 도메인이 공유 인코더를 통과해 같은 잠재 공간에 놓이고 도메인마다 얇은 헤드만 따로 둔다. 그 구조를 같은 규약으로 세워 겨뤘다 — 입력은 다섯 축 값과 다섯 마스크, 잠재 차원은 둘(현행과 용량을 맞춤), 평가는 출처 헤드를 대상 잠재에 적용해 순위 상관. 졌다. 현행 선형이 $+0.3506$ 인데 공유 인코더는 $+0.1702 \pm 0.0178$, 출처 하나로만 학습하면 $+0.1630 \pm 0.0091$ 이다. 차이가 씨앗 표준편차의 10–20배라 판정이 가능한 패배다 — 노트 14에서 신경망 씨앗 분산이 효과의 4–5배라 아무것도 말할 수 없었던 것과 달라졌고, 표본이 커진 덕이다. 원인을 두 번 짚었다. 첫째 가설은 “프로크루스테스는 도메인별 회전을 자유롭게 두는데 공유 인코더는 하나로 강제한다”였고, 도메인별 사영을 앞에 붙여 검증하니 $+0.1665$ 로 변화가 없어 기각됐다. 둘째로 신경망 잠재에 프로크루스테스를 붙이니 $+0.2004$ 로 부분 회복한다. 즉 표현과 정렬 둘 다에서 진다 — 정렬을 되돌려 받아도 $+0.03$ 만 회복하고 나머지 $+0.15$ 는 표현 자체의 차이이다.

1. 같은 규약으로 세웠다

다중 과제 학습의 표준 구성을 그대로 옮겼다(Caruana 1997, Maurer 2016, 그리고 최근 표 형식 파운데이션 모델의 구성).

- 입력은 다섯 축 값과 다섯 마스크(10차원). 마스크를 함께 넣어 “결측을 0으로 채운 것”과 “관측된 0”을 구분하게 했다(노트 35 · 37의 교훈).
- 공유 인코더는 10→32→2의 두 층. 잠재 차원을 둘로 둔 것은 현행이 성분 둘이기 때문이다. 용량을 맞춰야 공정하다.
- 도메인마다 2→1 선형 헤드.
- 라벨은 도메인 안에서 탈출세 · 표준화. 현행과 같다.
- 평가는 셀 (출처 $s \rightarrow$ 대상 t)마다 s 의 헤드를 t 의 잠재에 적용하고 순위 상관을 쟀다. 대상 라벨은 학습에 안 쓴다.

두 변형을 뒀다 — 단독은 출처 하나로만 학습해 현행과 정보량을 맞추고, 공유는 대상을 뺀 다섯 도메인으로 인코더를 함께 학습한다. 뒤의 것이 파운데이션 모델이 하는 일이다.

2. 졌다

차이가 씨앗 표준편차의 10–20배다. 이번에는 판정할 수 있다. 노트 14에서 신경망 씨앗 분산이 효과 크기의 4–5배라 아무것도 말할 수 없었는데, 도메인이 여섯이고 레코드가 2,181건이 되면서 씨앗 분산이 0.009–0.018로 내려왔다.




Figure 1: 서른 셀 평균 순위 상관. 오차 막대는 씨앗 표준편차다.

공유가 단독보다 조금 낮다. $+0.1702$ 대 $+0.1630$ 이다. 다른 도메인에서 배운 표현이 도움이 되긴 한다. 다만 그 이득($+0.007$)이 선형과의 격차(-0.180)에 비해 미미하다.

3. 원인을 두 번 짚었다

첫째 가설 --- 회전 자유도. 프로크루스테스는 도메인마다 다른 회전을 허용하고 공통 축 적재로만 맞춘다. 공유 인코더는 모든 도메인을 같은 함수에 통과시키므로 회전이 하나로 강제된다. 그렇다면 도메인별 선형 사영을 인코더 앞에 붙이면 회복돼야 한다.

Table 1: 구성별 성적. 신경망은 씨앗 다섯(또는 셋) 개.

구성	평균 ρ
현행 선형(도메인별 PCA + 프로크루스테스)	+0.3506
NN 잠재 + 프로크루스테스	+0.2004 $\pm$ 0.0338
공유 인코더 + 도메인 헤드	+0.1702 $\pm$ 0.0178
도메인별 사영 추가	+0.1665 $\pm$ 0.0016
단독 인코더	+0.1630 $\pm$ 0.0091

Table 2: 도메인별 사영을 앞에 붙였을 때.

사영 없음	+0.1651 $\pm$ 0.0365
사영 있음	+0.1665 $\pm$ 0.0016

변화가 없다. 기각한다.

둘째 --- 정렬을 되돌려 준다. 신경망을 특징 추출기로만 쓰고, 잠재에 대해 현행과 같은 처리를 했다 — 공통 축 적재를 도메인마다 계산해 프로크루스테스로 맞춘 뒤 출처 회귀를 적용한다.

+0.2004로 +0.030 회복한다. 그러나 현행과는 여전히 +0.150 차이다.

주장 1. 신경망은 표현과 정렬 둘 다에서 진다. 정렬을 프로크루스테스로 되돌려 주면 +0.03 회복하고, 나머지 +0.15는 표현 자체의 차이 — 도메인별 주성분이 공유 인코더보다 낫다.

반증 조건. 잠재 차원을 둘로 묶은 것이 불리했을 수 있다. 넷이나 여덟로 늘리면 표현 격차가 줄 수 있고, 그러면 “용량을 맞췄다”는 공정성 전제가 잘못되었던 것이다.

4. 왜 이 문제에서 불리한가

- **표본이 작다.** 도메인당 62–900건이다. 신경망이 표형식 데이터에서 트리나 선형에 지는 전형적인 구간이다(Grinsztajn 2022).
- **특징 공학이 이미 끝나 있다.** 입력이 다섯 축뿐이고 그 축은 예순 노트에 걸쳐 검정으로 다듬은 것이다. 신경망이 찾을 상호작용이 별로 없다.
- **도메인마다 축의 관계가 다르다.** 공유 함수는 그것을 하나로 묶는다. 도메인별 PCA는 각자 자기 구조를 잡는다.
- **대상 적응이 구조로 주어져 있다.** 현행은 대상 도메인의 데이터로 대상의 인자 공간과 회전을 만든다. 노트 33의 “전이 상관 = 대상 자기 상관”이 바로 그 구조의 결과다.

학습된 공유 표현이 유리해지려면 도메인이 훨씬 많거나 도메인당 표본이 훨씬 커야 한다. 지금 구간에서는 달한 해가 낮고, 그것을 바꿀 이 유가 없다.

5. 한계

구조 하나(두 층 MLP, 잠재 둘)만 시험했다. 폭 · 깊이 · 정규화를 훑지 않았다.

학습 설정(Adam, lr 3e-3, 400에폭, weight decay 1e-3)을 고정했다. 조정하면 나아질 수 있고, 조정하면 선택 편향이 들어온다.

짜지은 붓스트랩을 안 붙였다. 차이가 씨앗 SD의 10배 이상이라 필요 없다고 보았지만 표본 요동은 따로 있다.

- 도메인 임베딩 · 어텐션 · 사전학습 같은 다른 구성은 안 봤다.
- 잠재 차원을 늘린 변형을 안 봤다 — 이 노트의 반증 조건이다.

6. 다음

1. 잠재 차원을 넷 · 여덟로 늘려 표현 격차가 줄어드는지 — 반증 조건.
2. 웹툰 전체 수집 완료 후 전면 재측정(1,315/3,973 진행 중).
3. 보정 표본 총화(노트 59의 남은 항목).
4. 도메인이 열을 넘으면 다시 겨룬다. 지금은 여섯이다.

참고문헌

- Caruana, R. (1997). Multitask learning. Machine Learning, 28(1), 41–75.
- Maurer, A., Pontil, M., Romera-Paredes, B. (2016). The benefit of multitask representation learning. JMLR, 17(81), 1–32.
- Grinsztajn, L., Oyallon, E., Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on typical tabular data? NeurIPS Datasets and Benchmarks.
- Schönmeyer, P. H. (1966). A generalized solution of the orthogonal Procrustes problem. Psychometrika, 31(1), 1–10.
- Bouthillier, X. et al. (2021). Accounting for variance in machine learning benchmarks. MLSys, 3, 747–769.