

IP 파운데이션 월드모델 연구 노트 61

라벨을 빼자 절반이 돌아왔다

신경망이 진 이유가 구조도 용량도 아니었다 --- 표현을 라벨로 학습한 것이 격차의 61퍼센트다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 60은 공유 인코더가 현행 선형 파이프라인에 크게 진다고 보고하고 (+0.1702 대 +0.3506) 반증 조건을 적었다 — “잠재 차원을 둘로 묶은 것이 불리했을 수 있다.” 걱정했다. 무관하다. 잠재를 2에서 16까지 늘려도 +0.108에서 +0.119 사이로 평평하고, 층을 하나 더 쌓으면 오히려 나빠진다 (+0.170 → +0.111). 용량이 문제가 아니다. 그러면 무엇인가. 도메인별 주성분 분석과 공유 인코더의 결정적 차이가 하나 남는다 — 주성분은 라벨을 안 쓰고 인코더는 쓴다. 그리고 노트 38 · 40이 이미 그 법칙을 찾아 두었다: 자기 라벨에 잘 맞출수록 남에게 못 옮겨진다. 표현 학습 층위에서 같은 일이 벌어진다면, 인코더를 비지도로 학습하면 회복돼야 한다. 오토인코더로 잠재를 만들고 같은 프로크루스테스 정렬을 붙였다. +0.2004에서 +0.3099로 올랐다. 격차 0.180을 셋으로 쪼개면 — 정렬을 되돌려 받은 몫 0.030(17%), 라벨을 뺐 몫 0.110(61%), 남은 표현 차이 0.041(23%). 신경망이 진 주된 이유는 표현을 라벨로 학습한 것이다. 프론티어 모델이 자기지도로 사전학습하는 이유가 여섯 도메인 2,181건에서 정량으로 재현된다.

Table 1: 잠재 차원과 폭을 늘릴 때, 씨앗 둘, 세 층 인코더.

잠재	폭	평균 ρ	씨앗 SD
2	32	+0.1106	0.0114
4	32	+0.1127	0.0133
8	64	+0.1187	0.0115
16	64	+0.1081	0.0327

1. 용량이 아니었다

노트 60의 반증 조건부터 처리했다.

평평하다. 그리고 세 층으로 깊게 한 이 표가 노트 60의 두 층(+0.1702)보다 전반적으로 나쁘다 — 표본이 작아 깊이가 해롭다.

용량을 늘리는 방향은 막혀 있다. 반증 조건이 발동하지 않았으므로 노트 60의 결론은 그대로 서 있고, 원인을 다른 데서 찾아야 한다.

2. 남은 차이는 라벨이었다

도메인별 주성분 분석과 공유 인코더의 차이를 하나씩 지웠는데 아직 안 지운 것이 있었다.

주성분은 라벨을 쓰지 않는다. 분산 구조만 본다. 인코더는 회귀 손실로 학습하므로 학습 도메인들의 라벨에 맞춘 표현을 만든다.

노트 38과 40이 그 상황의 법칙을 이미 찾아 두었다 — 도메인의 인자 공간이 자기 라벨에 잘 맞을수록 대상으로서 좋아지고 출처로서 나빠진다($r = -0.85$ 에서 -0.99). 인코더는 학습 도메인들의 라벨에 특수화되




Figure 1: 왼쪽 — 한 단계씩 되돌릴 때. 오른쪽 — 격차의 분해.

로, 그 법칙이 표현 학습 층위에서 반복된다면 비지도로 바꾸면 회복돼야 한다.

오토인코더로 잠재를 만들었다 — 같은 입력 10차원, 같은 잠재 2차원, 재구성 손실만. 그리고 노트 60과 같은 프로크루스테스 정렬을 붙였다.

주장 1. 신경망이 진 주된 이유는 구조도 용량도 정렬도 아니고 표현을 라벨로 학습한 것이다. 라벨을 빼면 격차의 61%가 회복된다. 노트 38 · 40의 상층 법칙이 표현 학습 층위에서 반복된다.

반증 조건. 오토인코더 잠재가 여전히 PCA에 0.041 뒤진다. 그 몫이 비선형 때문인지 최적화 때문인지 안 봤다. 선형 오토인코더로 재면 같린다.

Table 2: 격차를 단계로 되돌린다.

구성	평균 ρ
지도 인코더 헤드 직접	+0.1702
+ 프로크루스테스 정렬	+0.2004
+ 라벨 제거(오토인코더)	+0.3099
도메인별 PCA(현행)	+0.3506

Table 3: 격차 0.180의 분해.

원인	몫	비율
라벨로 표현을 학습한 것	0.110	61%
남은 표현 차이(PCA 대 오토인코더)	0.041	23%
정렬을 학습으로 대체한 것	0.030	17%

3. 프론티어가 왜 그렇게 하는가

큰 모델들이 자기지도로 사전학습하고 라벨은 마지막에 얇은 헤드로만 쓴다. 그 설계의 근거가 여기서 정량으로 나온다 — 라벨로 표현을 빚으면 그 라벨이 나온 분포에 표현이 묶인다.

이 프로젝트에서는 그것이 특히 아프다. 도메인이 여섯인데 각자 다른 시장이고, 한 시장의 라벨에 맞춘 표현은 다른 시장에서 쓸모가 준다. 반대로 축의 분산 구조는 시장을 건너 비슷하다 — 노트 33이 “전이 상관 = 대상 자기 상관”을 얻은 것도 결국 대상의 비지도 구조가 전이를 정한다는 뜻이었다.

현행 파이프라인은 우연히 옳은 설계였다. 도메인별 주성분(비지도) + 프로크루스테스 정렬(단힌 해) + 출처 회귀(얇은 헤드)는 자기지도 사전학습 뒤 선형 프로빙과 같은 구조다. 다만 사전학습이 학습이 아니라 계산이다.

4. 한계

- 오토인코더 잠재도 PCA에 0.041 뒤진다. 비선형이 이 자료에서 얻을 것이 없다는 뜻일 수 있고, 학습이 덜 됐다는 뜻일 수도 있다.
- 재구성 손실 하나만 썼다. 대조 학습이나 마스킹 복원 같은 다른 자기지도 목적은 안 봤다.
- 씨앗 셋으로 썼다. 오토인코더 씨앗 SD가 0.0039로 작아 충분해 보이지만 짝지은 구간은 안 붙였다.
- “상충 법칙이 표현 층위에서 반복된다”는 해석이지 직접 검정이 아니다. 인코더 학습에 쓴 도메인 수를 바꿔 가며 재면 검정된다.
- 여전히 현행 선형이 최선이다. 신경망 쪽에서 얻은 것은 설명이지 성능이 아니다.

5. 다음

- 선형 오토인코더로 재 남은 0.041이 비선형 탓인지 가른다.

- 마스킹 복원 — 축 하나를 가리고 맞히게 하는 자기지도. 결측이 많은 이 자료에 맞는다.
- 인코더 학습 도메인 수를 바꿔 상충 법칙 해석을 직접 검정한다.
- 웹툰 전체 수집 완료 후 전면 재측정(1,621/3,973 진행 중).

참고문헌

- Caruana, R. (1997). Multitask learning. *Machine Learning*, 28(1), 41–75.
- Grinsztajn, L., Oyallon, E., Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on typical tabular data? *NeurIPS D&B*.
- Chen, T. et al. (2020). A simple framework for contrastive learning of visual representations. *ICML*, 1597–1607.
- Ben-David, S. et al. (2010). A theory of learning from different domains. *Machine Learning*, 79(1–2), 151–175.
- Schönmann, P. H. (1966). A generalized solution of the orthogonal Procrustes problem. *Psychometrika*, 31(1), 1–10.