

IP 파운데이션 월드모델 연구 노트 62

네 번 짚었고 네 번 틀렸다

주성분이 오토인코더를 이기는 이유를 넷으로 좁혀 전부 검정했는데 전부 기각됐다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 61이 신경망 격차의 61%를 설명했다 — 표현을 라벨로 학습한 것. 라벨을 빼고 오토인코더로 바꾸니 +0.2004에서 +0.3078로 올랐다. 그런데 도메인별 주성분 분석(+0.3506)에는 여전히 0.043 뒤진다. 그 나머지를 설명할 후보를 넷으로 좁혀 전부 검정했다. 네 번 다 틀렸다. (1) 비선형이 불리한가 — 선형 오토인코더는 +0.2694로 더 나쁘다. (2) 공유가 불리한가 — 도메인마다 따로 학습한 오토인코더는 +0.2722로 더 나쁘다. (3) 프로크루스테스가 직교 회전이니 잠재도 직교 좌표계여야 하는가 — 백색화해도 +0.3083으로 변화가 없다. (4) 입력 열 절반이 마스크라 복원에 용량을 낭비하는가 — 값 열만 복원해도 +0.3009로 오히려 조금 나쁘다. 자가지도 변형도 하나 더 시험했다 — 축 하나를 가리고 맞히는 마스크 복원은 +0.2405로 가장 나쁘다. 결과적으로 여러 변형 중 가장 단순한 것(공유 오토인코더 · 전체 재구성)이 최선이고, 그것도 닫힌 해에 0.043 못 미친다. 원인을 모른다. 네 가지 그럴듯한 설명이 전부 틀렸다는 것만 안다.

Table 1: 변형별 서로 셀 평균 순위 상관. 씨앗 셋. 네 가설을 지웠는데 격차 0.043이 남는다




Figure 1: 일곱 변형. 붉은 것이 기각된 가설이다.

1. 후보를 넷으로 좁혔다

노트 61 이후 남은 격차는 0.043이다(도메인별 PCA +0.3506 대 공유 오토인코더 +0.3078). 설명할 만한 것이 넷 있었다.

가설 1 --- 비선형이 불리하다. PCA는 선형이고 오토인코더는 Tanh를 쓴다. 표본이 작으니 비선형이 과적합했을 수 있다. 선형 오토인코더가 +0.2694로 더 나쁘다. 비선형이 오히려 유리하다.

가설 2 --- 공유가 불리하다. PCA는 도메인마다 따로 계산되고 오토인코더는 하나를 공유한다. 도메인마다 축의 관계가 다르니 공유가 뭉개 수 있다. 도메인별 오토인코더가 +0.2722로 더 나쁘다. 도메인당 62-900

가설 3 --- 잠재가 직교하지 않다. 프로크루스테스는 직교 회전을 찾는다. 주성분은 서로 직교하고 분산 순으로 정렬돼 있는데 오토인코더 잠재는 아무 좌표계나 쓴다. 백색화해도 +0.3083으로 변화가 없다.

가설 4 --- 마스크 복원에 용량을 쓴다. 입력 열 열 개 중 다섯이 마스크다. 오토인코더가 그것까지 복원하느라 용량의 절반을 쓴다. 값 열만 복원해도 +0.3009로 오히려 조금 나쁘다 — 마스크 복원이 정규화 역할을 하고 있었다.

주장 1. 주성분이 오토인코더를 0.043 앞서는 이유를 모른다. 비선형 · 공유 · 직교성 · 복원 대상 넷을 검정해 전부 기각됐다.

반증 조건. 남은 후보는 최적이다 — PCA는 닫힌 해로 전역 최적이고 오토인코더는 경사하강으로 지역 최적에 머문다. 잠재 차원이 둘이라 지역 최적이 많지 않을 것 같지만 확인하지 않았다.

Table 2: 신경망과 선형의 격차 0.180.

원인	몫	상태
라벨로 표현을 학습(노트 61)	0.110	설명됨
정렬을 학습으로 대체(노트 60)	0.030	설명됨
나머지	0.043	미상

2. 자기지도 변형도 최선이 가장 단순한 것이었다

축 하나를 무작위로 가리고 맞춰게 하는 마스킹 복원을 시험했다. 결측이 많은 이 자료에 맞는 목적함수이고 표현식 사전학습에서 흔히 쓴다. +0.2405로 가장 나쁘다.

이유를 짐작하면 — 축 하나를 다른 축으로 맞추는 것은 축 간 상관을 학습하는 일이고, 그 상관이 도메인마다 다르다. 공유 인코더가 그것을 하나로 뭉개면 어느 도메인에서도 안 맞는 표현이 된다.

일곱 변형 중 가장 단순한 것 — 공유 오토인코더에 전체 재구성 — 이 최선이다. 그리고 그것도 닫힌 해에 못 미친다. 노트 60부터 세 노트에 걸쳐 신경망 쪽에서 얻은 것은 설명이지 성능이 아니다.

3. 여기까지의 정리

76%는 설명됐고 24%는 남았다. 그리고 설명된 부분이 실무에 주는 지침은 분명하다 — 다중 도메인 표현은 라벨로 빚지 말고, 정렬은 닫힌 해로 계산하라. 현행 파이프라인이 이미 둘 다 하고 있다.

4. 한계

- 최적화 가설을 검정하지 않았다. 여러 초기값에서 최선을 고르거나 학습률을 훑으면 갈린다.
- 각 변형을 씨앗 셋으로만 켜다. 선형 AE와 마스킹 복원은 씨앗 SD가 0.038–0.044로 커서 순위가 흔들릴 수 있다.
- 짝지은 붓스트랩을 안 붙였다. 0.043이 표본 요동보다 큰지 확인하지 않았다.
- 자기지도 목적함수를 둘만 시험했다. 대조 학습은 안 봤다.
- 잠재 차원을 둘로 고정했다. 노트 61에서 무관함을 봤지만 오토인코더에서는 다시 확인하지 않았다.

5. 다음

1. 최적화 가설 — 여러 초기값 중 최선을 골라 재면 갈린다.
2. 0.043에 짝지은 구간을 붙인다. 잡음이면 이 노트 전체가 과잉 해석이다.
3. 웹툰 전체 수집 완료 후 전면 재측정(1,854/3,973 진행 중).
4. 신경망 쪽은 여기서 멈춘다. 세 노트에 걸쳐 성능 이득이 없었다.

참고문헌

- Baldi, P., Hornik, K. (1989). Neural networks and principal component analysis. *Neural Networks*, 2(1), 53–58.
- Grinsztajn, L., Oyallon, E., Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on typical tabular data? *NeurIPS D&B*.
- Devlin, J. et al. (2019). BERT: pre-training of deep bidirectional transformers. *NAACL*, 4171–4186.
- Jolliffe, I. T. (2002). *Principal Component Analysis*, 2nd ed. Springer.
- Schönemann, P. H. (1966). A generalized solution of the orthogonal Procrustes problem. *Psychometrika*, 31(1), 1–10.