

IP 파운데이션 월드모델 연구 노트 63

등급이 자의적이지 않았다

오래 열려 있던 라벨 위생 항목을 닫는다 --- 개별 결함은 성능에 안 보이고, 신뢰 등급만 방향이 맞다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 1-8에서 팝업 라벨의 계수 기준과 스코프를 검증하며 레코드마다 신뢰 등급을 매겼다. 그때 남긴 미해결 항목이 예순 노트 동안 열려 있었다. 여섯 도메인 상태에서 닫는다. 먼저 확인한 것 — 내부 팝업 레코드는 위생 정보가 이미 충분히 붙어 있다. 레코드마다 신뢰 등급과 근거, 측정 도구, 라벨 기간과 일별 합 일치 여부, 원본 문서 인용이 있다. 분석 풀 75건의 등급은 A가 53건, B가 15건이고 C 이하가 없다. 미해결 세 건 중 둘은 이미 풀에서 걸러졌고 하나만 남아 있었다(일별 합 불일치). 그다음 검정 — 결함이 있는 레코드를 빼면 성능이 오르는가. 개별 결함은 안 보인다 — 일별 합 불일치 한 건을 빼면 -0.0002 , 기간 불연속 일곱 건을 빼면 -0.0001 이다. 그런데 신뢰 등급 B 열다섯 건을 빼면 $+0.0096$ 오른다 — 표본을 20% 버리는데도, 짝지는 구간이 $[-0.012, +0.028]$ 로 0을 포함해($P=0.820$) 채택하지 않았지만, 방향이 맞다는 것 자체가 결과다. 예순 노트 전에 사람이 매긴 등급이 지금 예측력과 같은 방향을 가리킨다. 등급 체계가 자의적이지 않았다는 뜻이다.

Table 1: 내부 팝업 레코드에 붙어 있는 위생 정보.

필드	내용
label_trust	등급과 근거 문장
measurement_instrument	현장 웨이팅 로그 등
label_scope	기간 · 일수 · 연속성 · 일별 합 일치
provenance	원본 문서 · 인용 · 열람 기록
label_history	변경 이력

Table 2: 분석 풀 75건의 신뢰 등급.

A	53건
B	15건
C 이하	0건
원본 미매칭	7건




Figure 1: 왼쪽 — 위생 필터별 성능. 오른쪽 — 등급 B 제외의 구간.

1. 오래 열려 있던 항목

노트 1-8은 팝업 라벨을 다뤘다 — 계수 기준이 입장인지 참여인지 주최 측 발표인지, 수치의 스코프가 단일 행사인지 합산인지, 출처가 무엇인지. 그 과정에서 레코드마다 신뢰 등급을 매겼고 미해결 항목을 남겼다.

여섯 도메인이 되고 판정 도구가 여러 번 바뀐 지금 다시 본다.

미해결 세 건 중 둘(출처 없음, 디지털 대리 지표)은 계수 기준 필터에서 이미 걸러져 분석 풀에 없다. 하나만 남아 있었다 — 일별 합이 총계와 안 맞는 건이다.

2. 개별 결함은 성능에 안 보인다

일별 합 불일치와 기간 불연속은 성능에 흔적이 없다. 각각 한 건과 일곱 건인데 빼도 소수점 넷째 자리에서만 움직인다.

등급 B를 빼면 $+0.0096$ 오른다. 표본을 75에서 60으로 20% 줄이는데도 오른다는 것이 요점이다 — 표본이 줄면 보통 나빠진다.

3. 그런데 채택하지 않는다

노트 44 이후의 기준으로 구간이 0을 포함하면 채택하지 않는다. 그리고 여기서는 표본 20%를 버리는 대가가 확실한데 이득이 불확실하다.

Table 3: 결합 레코드를 뺐을 때.

필터	팝업 n	ρ	Δ
없음(현행)	75	+0.3506	—
일별 합 불일치 제외	74	+0.3504	-0.0002
기간 불연속 제외	68	+0.3504	-0.0001
등급 B 제외	60	+0.3602	+0.0096
셋 다 제외	56	+0.3583	+0.0077

Table 4: 등급 B 제외의 짝지는 붓스트랩.

$\Delta\rho$	+0.0096
95% 구간	$[-0.012, +0.028]$
$P(>0)$	0.820
판정	보류

주장 1. 개별 위생 결합(일별 합 불일치 · 기간 불연속)은 전이 성능에 보이지 않는다. 신뢰 등급만 방향이 맞다 — B를 빼면 +0.0096 오르지만 구간이 0을 포함한다.

반증 조건. 팝업이 75건이라 어떤 부분집합 실험도 검정력이 낮다. 표본이 두 배가 되면 이 +0.0096이 갈릴 것이다.

4. 등급이 자의적이지 않았다

이것이 이 노트의 진짜 결과다.

등급은 예순 노트 전에, 전이 실험이 있기 훨씬 전에, 사람이 출처와 계측 방식을 읽고 매긴 것이다. 그 등급이 지금 전이 예측력과 같은 방향을 가리킨다. 확인은 안 됐지만 부호가 맞고, 개별 결합 지표들은 부호조차 안 맞는다.

라벨 품질을 사람이 판단한 것이 기계적 결합 지표보다 낫다는 뜻이며, 노트 49에서 팝업 축 태깅이 위키백과를 이긴 것과 같은 방향이다. 이 프로젝트에서 사람이 읽어 매긴 값은 두 번 다 자동 지표를 이겼다.

5. 한계

- 75건 중 7건은 원본 레코드를 못 찾아 등급을 모른다. 그 7건이 어느 쪽인지에 따라 결과가 흔들린다.
- 등급 A와 B의 구분 기준을 이 노트에서 다시 검토하지 않았다. 노트 1-8의 정의를 그대로 썼다.
- 측정 도구가 안 적힌 레코드가 60건이 넘는다. 등급은 A인데 도구가 없는 경우가 많아, 그 필드는 위생 지표로 쓸 수 없다.
- 다른 다섯 도메인의 라벨 위생은 보지 않았다. 전부 기계 수집이라 사람 등급이 없다.
- 미해결 세 건을 “닫는다”고 했지만 실제로는 둘이 이미 필터에 걸려 있었고 하나는 성능에 안 보인다는 것을 확인한 것이다. 원인을 고친 것이 아니다.

6. 다음

1. 원본을 못 찾은 7건의 등급을 확인한다.
2. 웹툰 전체 수집 완료 후 전면 재측정(2,006/3,973 진행 중).
3. 팝업 표본이 두 배가 되면 등급 B 제외를 다시 판정한다.
4. 측정 도구 필드를 채우거나 버린다. 지금은 있으나 마나다.

참고문헌

- Kaufman, S., Rosset, S., Perlich, C. (2012). Leakage in data mining. ACM TKDD, 6(4), 1-21.
- Efron, B., Tibshirani, R. J. (1993). An Introduction to the Bootstrap. Chapman & Hall.
- Krippendorff, K. (2004). Content Analysis: An Introduction to Its Methodology, 2nd ed. Sage.
- Northcutt, C. G., Athalye, A., Mueller, J. (2021). Pervasive label errors in test sets. NeurIPS D&B.
- Ben-David, S. et al. (2010). A theory of learning from different domains. Machine Learning, 79(1-2), 151-175.