

IP 파운데이션 월드모델 연구 노트 64

진단 코드가 세 번 거짓말했다

본 파이프라인은 규약을 지키는데 그것을 검사하려고 급히 쓴 코드가 안 지켰다 --- 세 노트에서 같은 일이 났다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 63이 남긴 항목 둘을 처리하다가 패턴을 발견했다. 첫째, “원본을 못 찾은 7건”은 다른 디렉터리에 있었다 — 시장 레코드다. 미매칭은 0건이다. 둘째, 노트 52가 “아이돌 소속사 정규화가 빠져 있다”고 지적한 것을 고치려고 본 코드를 열었더니 `norm_agency`가 이미 있었다 — ‘SM Entertainment’ / ‘SM 엔터테인먼트’ / ‘SM’을 하나로 묶는다. 정규화가 빠져 있던 것은 파이프라인이 아니라 노트 52를 쓸 때 급히 짰 진단 코드였다. 그러고 보니 노트 54에서도 같은 일이 있었다 — 게임 고유 축의 짝지은 구간이 $[-0.167, -0.027]$ 로 나와 “해롭다”고 입을 뻔했는데, 원인은 복원추출 뒤에 고유 축을 붙여 레코드 대응이 깨진 것이었다. 고치니 $[+0.001, +0.011]$ 로 부호가 뒤집혔다. 세 번 다 본 파이프라인은 옳았고 진단 코드가 틀렸다. 공통 원인이 하나다 — 진단을 급히 짜면서 본 코드가 지키는 규약(이름 정규화 · 레코드 대응 · 데이터 경로)을 재현하지 않았다. 처방은 단순하다. 진단은 본 코드의 함수를 불러 쓴다. 부수로 확인한 것도 있다. 정규화하면 아이돌 소속사가 68개에서 54개로 줄고 2건 이상이 5개에서 13개로 느는데, 이력 보유 레코드는 여전히 17/81이라 노트 52의 “표본 부족” 결론 자체는 유지된다.

1. 두 항목을 처리하다가

미매칭 7건. 노트 63은 분석 풀 75건 중 68건만 원본을 찾았다고 적었다. 디렉터리를 넓혀 다시 찾으니 나머지 7건은 `data/market_records`에 있었다 — 내부 팝업이 아니라 외부 보도 기반 시장 레코드다. 미매칭은 0건이다. 노트 63의 한계 항목 첫 줄을 지운다.

소속사 정규화. 노트 52는 이렇게 적었다 — “‘SM’과 ‘SM 엔터테인먼트’가 따로 세어진다. 정규화가 빠져 있다.” 고치려고 `ingest/idol_axes.py`를 열었더니 이미 있었다.

`norm_agency` — “‘SM Entertainment’ / ‘SM 엔터테인먼트’ / ‘SM’을 하나로 묶는다. 정규화 전 205개 고유값 중 상당수가 같은 회사의 표기 차이였다.”

정규화가 빠져 있던 것은 노트 52를 쓸 때 급히 짰 진단 코드였다.

2. 세 번째다

노트 54가 가장 심했다. 게임 고유 축의 짝지은 구간이 $[-0.167, -0.027]$ 로 나와 점추정($+0.0066$)과 정반대였다. 원인은 복원추출 뒤에 고유 축을 붙여 원본 순서의 축이 재추출된 행에 걸린 것이다. 길이가 맞아 오류도 안 났다. 고치니 $[+0.001, +0.011]$ 로 채택이 됐다.

아이돌 소속사 --- 본 코드는 이미 묶고 있었다




Figure 1: 왼쪽 — 아이돌 소속사. 오른쪽 — 세 오진.

주장 1. 세 번 다 본 파이프라인은 옳았고 진단 코드가 틀렸다. 공통 원인은 진단을 급히 짜면서 본 코드가 지키는 규약 — 이름 정규화, 레코드 대응, 데이터 경로 — 을 재현하지 않은 것이다.

반증 조건. 네 번째가 나오면 규율로는 안 되는 것이고 구조로 막아야 한다. 지금은 “진단은 본 코드의 함수를 불러 쓴다”는 규칙만 세운다.

왜 하필 진단 코드인가. 본 코드는 노트를 쓸 때마다 검정을 통과해야 하고 다음 노트에서 다시 쓰인다. 진단 코드는 한 번 쓰고 버린다. 그래서 규약이 안 실린다. 그런데 판정을 내리는 것은 진단 코드다 — 본 코드는 값을

Table 1: 진단 코드가 만든 오진.

노트	오진	실제
52	정규화가 없다	있었다
54	고유 축이 해롭다	이롭다(부호 반전)
63	미매칭 7건	0건

Table 2: 아이돌 소속사. 표본 81건.

	정규화 없이	정규화
고유 소속사	68개	54개
2건 이상	5개	13개
사전 이력 보유 레코드	5건	17건

만들고 진단 코드가 그 값을 해석한다. 검증이 가장 약한 자리에서 결론이 나온다.

3. 정규화 결과는 결론을 안 바꾼다

2건 이상 소속사가 두 배 반이 되고 이력 보유가 세 배가 된다. 그래도 17/81이라 상관을 재기에 부족하다(문턱 25건). 노트 52의 “아이돌은 표본 부족으로 못 낸다”는 유지된다 — 이유가 정확해졌을 뿐이다. 정규화를 안 해서가 아니라 81건에 소속사가 54개라서다.

4. 한계

- 세 사례를 모아 패턴이라 했지만 노트 예순넷 중 셋이다. 진단 코드를 쓴 횟수로 나누면 비율은 모른다.
- “진단은 본 코드의 함수를 불러 쓴다”를 규칙으로만 세웠고 강제하지 않았다.
- 앞선 노트들의 진단 코드를 전수 재검토하지 않았다. 같은 종류의 오진이 더 있을 수 있다.
- 아이돌 이력을 정규화해서 다시 봤지만 17건이라 상관을 못 냈다. 문턱을 낮추면 재겠지만 그 자체가 자의적이다.
- 노트 63의 “7건 미매칭”을 지웠는데, 그 7건이 시장 레코드라 등급 체계가 다르다. 노트 63의 등급 분포(A 53 · B 15)는 68건 기준이다.

5. 다음

1. 앞선 노트들의 진단 코드를 훑어 같은 오진이 더 있는지 본다.
2. 시장 레코드 7건의 라벨 신뢰를 따로 매긴다.
3. 웹툰 전체 수집 완료 후 전면 재측정(2,006/3,973 진행 중).
4. 진단에 쓸 공용 함수를 모듈로 뽑는다 — 규칙보다 구조가 낫다.

참고문헌

Hoare, C. A. R. (1981). The emperor's old clothes. CACM, 24(2),

75–83.

Northcutt, C. G., Athalye, A., Mueller, J. (2021). Pervasive label errors in test sets. NeurIPS D&B.

Efron, B., Tibshirani, R. J. (1993). An Introduction to the Bootstrap. Chapman & Hall.

Bouthillier, X. et al. (2021). Accounting for variance in machine learning benchmarks. MLSys, 3, 747–769.

Ben-David, S. et al. (2010). A theory of learning from different domains. Machine Learning, 79(1–2), 151–175.