

IP 파운데이션 월드모델 연구 노트 244

적게 보면 더 잘 보인다

안쪽이 작은 변화를 못 읽는 것은 조각이 적어서가 아니라 옛 시대를 섞어서다

Sweetspot 월드모델 연구

2026년 7월 31일

초 록

노트 243은 안쪽 눈금 $|\Delta| \leq 0.010$ 에서 동전 던지기임을 잰다 (spearman +0.36). 왜인지 같았다. **예측을 먼저 적고 잰다** — 조각이 셋뿐이라 분산이 크니 여섯으로 늘리면 나아질 것이다. **틀렸다**: 반해 여섯이 +0.21, 해 다섯이 +0.20 으로 셋(+0.36)보다 나쁘다. 두 번째 가설은 “그 크기가 아예 측정 바닥 아래”였다. 유보를 무작위로 반 갈라 같은 변화를 두 번 재니 **반쪽끼리 spearman +0.63 · 부호 11/13** 이다 (스피어만-브라운으로 온전한 유보의 신뢰도 ≈ 0.78). 유보는 그 칸을 읽는다. 남은 답은 하나였다 — 조각을 줄이고 경계에 붙이면 어떻게 되나. 2024 한 조각(평가 1,121건)이 +0.51 로 해 셋(3,245건)의 +0.36 을 이긴다. 자료를 3분의 1만 쓰는데 더 잘 읽는다. 안쪽의 약점은 분산이 아니라 시대 섞기였다 — 2022 · 2023 조각은 2025를 닮지 않았고, 평균을 내면 그 편향이 신호를 덮는다. 노트 200이 “접힘 교차는 시간을 섞어 부호를 반대로 본다”고 적은 것과 같은 병이 한 층 위에서 났다. 신뢰도로 환산하면 안쪽은 해 셋에서 ≤ 0.16 , 한 조각에서 ≤ 0.34 다 (유보 0.78 대비). `tune.inner_split` 은 이미 앞으로 한 번만 가르고 있었다 — 실험실은 맞게 하고 있었고, 틀린 것은 내가 노트 241 · 243 에서 근거로 쓴 세 조각 평균이다.

1. 예측을 적고 잰다

노트 243이 남긴 표의 첫 줄은 “안쪽 조각을 셋에서 다섯 · 여섯으로 늘리면 작은 칸이 보이나”였다. 늘리면 나아질 것이라는 예측에는 이유가 있다 — 조각마다 평가 표본이 1,000건 남짓이니 평균이 흔들릴 것이고, 조각을 늘리면 그 흔들림이 준다.

예측을 먼저 적어 두고 잰다. 노트 243이 만든 열일곱 점(축 하나씩 빼기)의 유보 값은 그대로 두고 안쪽만 다시 계산했다.

안쪽 방식	조각	전체	작은 칸
해 셋 (지금)	3	+0.691	+0.357
해 다섯	5	+0.627	+0.203
반해 여섯	6	+0.632	+0.214

늘리니 나빠졌다. 예측이 반증됐다.

2. 바닥이 아니다

두 번째 가설 — $|\Delta| \leq 0.010$ 은 유보 2,565건으로도 못 채는 크기라 안쪽이 아니라 양쪽이 잡음이다. 이게 맞다면 실험실이 다루는 변화의 대부분이 잡음이라는 뜻이라, 먼저 확인해야 했다.

유보를 도메인마다 무작위로 반 갈라, 같은 열일곱 변화를 두 반쪽에서 따로 잰다.

	spearman	부호
열일곱 전부	+0.781	15/17
작은 것 열셋	+0.633	11/13




Figure 1: 유보 반쪽 A 대 반쪽 B. 초록 열셋이 작은 칸인데, 반쪽끼리도 같은 방향으로 움직인다.

반쪽(1,283건)끼리 +0.633 이면 스피어만-브라운으로 온전한 유보의 신뢰도는 $2r/(1+r) \approx 0.78$ 이다. 유보는 그 칸을 잘 읽는다. 바닥이 아니었다.

3. 줄이고 경계에 붙였다

늘려서 나빠졌으니 줄여 봤다. 그리고 어디에 두느냐를 같이 봤다 — 실제 과제는 “2025 이전 전부로 배워 2025 이후를 맞힌다”이므로, 그것을 제일 닮은 안쪽은 **경계 바로 앞 한 조각**이다.

안쪽 방식	평가 건수	전체	작은 칸
해 셋	3,245	+0.691	+0.357
해 둘 (2023 · 2024)	2,149	+0.760	+0.478
2024 한 조각	1,121	+0.775	+0.511

자료를 3분의 1만 쓰는데 더 잘 읽는다. 분산 이야기




Figure 2: 안쪽 평가에 쓴 레코드 수와 작은 칸 읽기. 자료를 많이 쓸수록 못 읽는다.

였다면 있을 수 없는 방향이다. 남은 설명은 **편향**이다 — 2022 · 2023 조각은 2025를 담지 않았고, 그것을 평균에 넣으면 답이 아니라 다른 질문의 답이 섞인다.

이 실험실은 이 병을 이미 한 번 앓았다. 노트 200이 “접힘 교차는 시간을 섞어 부호를 반대로 본다”고 적고 도메인별 풀링 격차를 앞으로 두 토막으로 재도록 고쳤다. 같은 병이 한 층 위, 조각을 **평균**하는 자리에서 다시 났다.

4. 신뢰도로 환산하면

관측 상관은 $r_{\text{obs}} = \sqrt{\rho_i \rho_h} r_{\text{true}}$ 이다. $\rho_h = 0.78$ 이고 $r_{\text{true}} \leq 1$ 이니 안쪽 신뢰도의 상한이 나온다.

안쪽 방식	작은 칸 r	신뢰도 상한
해 셋	+0.357	≤ 0.16
2024 한 조각	+0.511	≤ 0.34
유보(온전)	—	0.78

한 조각으로 바뀌도 유보의 절반에 못 미친다. 작은 칸에서 안쪽은 여전히 약하다 — 다만 쓸모없지는 않다.

5. 실험실은 맞게 하고 있었다

고칠 곳을 찾아 `lab/tune.py` 를 열었더니 `inner_split` 은 이미 학습 구간을 시간으로 한 번만(7 대 3) 가르고 있었다. 조각을 평균하는 곳은 `tune.stable` 의 다섯 자리 뿐인데, 그 다섯을 최근 쪽 (0.70~0.90)으로 옮겨도 판이 넷째 자리까지 안 움직인다 — 지금 판에서 τ 가 어차피 꺼져 있기 때문이다(노트 243).

그러니 고칠 것은 코드가 아니라 **나**다. 노트 241과 243에서 내가 근거로 쓴 안쪽 숫자는 손으로 짤 세 조각 평균이었고, 그게 제일 나쁜 방식이었다. 노트 241의 결론(도메인별 기울기 거부)은 그대로다 — 한 조각으로 다시 재도 그 쌍들은 여전히 작은 칸에 있고, 안쪽 신뢰도 상한이 0.34 라 근거가 못 된다.

남은 것.

갈래	왜
왜 2022가 다른가 안쪽 0.34	시대 편향의 정체. 라벨 누적(노트 209)인가 더 올릴 길이 있다. 아니면 작은 칸을 포기하나
<code>entry_friction</code>	빼면 -0.0637 — 판에서 제일 무거운 손 축
<code>venue_prominence</code>	안쪽 -0.0010 인데 유보 -0.0089

규약. 안쪽 숫자를 근거로 쓸 때는 **경계 바로 앞 한 조각**에서 쥔다. 조각을 여럿 평균하지 않는다 — 옛 조각은 표본을 더 주는 게 아니라 다른 시대를 섞는다.