

IP 파운데이션 월드모델 연구 노트 66

도구가 서른 노트 전을 재현했다

새 감사 모듈로 노트 34의 최대 채택을 다시 재니 구간이 겹치고 폭은 절반이 됐다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 65가 만든 감사 모듈에 배선 설정 함수를 넣었다. 배선 후보 열은 원본 순서로 계산되므로, 복원추출 뒤에 적용하려면 같은 인덱스로 다시 뽑아야 한다 — 노트 54의 버그가 바로 이 지점이었다. 구조로 처리하고 자기 점검을 다섯으로 늘렸다. 둘이 정확히 0을 낸다 — 이미 꺼진 축을 다시 끄는 것과 현행 배선을 다시 적용하는 것이다. 뒤의 것이 배선 함수가 인덱스를 제대로 다룬다는 직접 증거다. 그리고 도구를 과거 결과로 검증했다. 노트 34는 도서 타깃 폭을 장르 수에서 판형으로 바꿔 $+0.0939$ [$+0.046$, $+0.199$]를 얻었고, 그것이 지금까지 구간을 통과한 배선 결정 중 가장 큰 것이다. 새 모듈로 반대 방향(판형→장르 수)을 재니 -0.0832 [-0.143 , -0.055]다. 부호를 뒤집으면 $+0.0832$ [$+0.055$, $+0.143$]로 원래 구간과 겹치고 점추정이 11% 차이다. 그리고 구간 폭이 0.153에서 0.088로 좁아졌다 — 도메인이 다섯에서 여섯이 되고 웹툰 표본이 늘어난 덕이다. 도구가 서른 노트 전의 결론을 재현하고, 그 사이 쌓인 데이터가 구간을 실제로 좁혔다는 것을 한 번에 보인다.




Figure 1: 왼쪽 — 노트 34의 재현. 오른쪽 — 자기 점검 다섯.

Table 1: 답을 아는 조건. 짝지는 북스트랩 60회. 답을 아는 조건 다섯

조건	$\Delta\rho$	참고
게임 매장축 끄기 (이미 꺼짐)	+0.0000	정확히 0
두 번째 배선 재적용	+0.0000	정확히 0
두 번 끄기	-0.0077	한 번 끄기와 같음
판형 매장축 끄기	-0.0077	노트 52
웹툰 대응 꺼기	-0.0341	노트 53

Table 2: 도서 타깃 폭 배선(장르 수 → 판형)의 효과.

조건	효과	95% 구간	폭
노트 34 (5도메인)	$+0.0939$ [$+0.046$, $+0.199$]	-0.06 to 0.04	0.153
노트 66 (6도메인)	$+0.0832$ [$+0.055$, $+0.143$]	-0.02 to 0.02	0.088

1. 배선 함수와 인덱스

노트 65의 모듈에는 축 끄기와 대응 꺼기만 있었다. 배선 변경을 넣으면서 한 가지를 처리해야 했다.

배선 후보 열(판형 · 장르 수 · 태그 수...)은 원본 레코드 순서로 계산된다. 복원추출 뒤에 적용하면 원본 순서 열이 재추출된 행에 걸린다 — 노트 54의 버그다. 그래서 `cfg_wire`가 복원추출 인덱스를 받아 후보 열을 같은 인덱스로 다시 뽑는다.

2. 자기 점검 다섯

두 번째 줄이 새로 넣은 것이다. 도서 타깃 폭에 지금 쓰고 있는 배선을 다시 적용하면 아무 일도 안 일어나야

한다. 구간까지 $[+0.0000, +0.0000]$ 이다. 배선 함수가 복원추출 인덱스를 제대로 다룬다는 뜻이며, 노트 54의 버그가 있었다면 여기서 0이 아닌 값이 나온다.

세 번째 줄도 새것이다 — 같은 축을 두 번 끄면 한 번 끈 것과 정확히 같은 값이 나온다(-0.0077 로 네 번째 줄과 일치).

3. 서른 노트 전을 재현한다

도구를 만들었으면 과거 결과로 검증해야 한다. 노트 34의 도서 배선이 지금까지 구간을 통과한 배선 결정 중 가장 크므로 그것을 골랐다.

주장 1. 새 감사 모듈이 서른 노트 전의 결론을 재현한다 — 점추정이 11% 차이, 구간이 겹친다. 그리고 그 사이 쌓인

데이터가 구간 폭을 0.153에서 0.088로 42% 줄였다.

반중 조건. 두 측정은 눈금이 다르다 — 노트 34는 다섯 도메인 · 겹침 유도 λ 이고 지금은 여섯 도메인 · $\lambda = 1$ 이다. 완전히 같은 조건에서 재는 것이 아니므로 “재현”이라는 말은 느슨하다.

이 표가 두 가지를 동시에 말한다.

- 도구가 맞다 — 완전히 다시 짠 코드가 같은 답을 낸다.
- 데이터가 일한다 — 노트 44 이후 “구간을 좁히려면 데이터”라고 계속 말했는데, 실제로 좁아진 것을 같은 대상에서 처음 확인한다.

폭이 절반이 되면 지금까지 보류한 것들 중 일부가 판정 가능해진다 — 노트 51의 이중 배선(+0.008), 노트 57의 웹툰 공통/고유 역전(+0.0045), 노트 63의 등급 B 제외(+0.0096). 아직은 아니지만 방향은 맞다.

4. 한계

- 재현이라 했지만 눈금이 다르다. 노트 34의 조건을 그대로 복원해 재는 것은 안 했다.
- 자기 점검 다섯 중 둘만 “정확히 0”을 요구한다. 나머지 셋은 과거 값과 비슷하기만 하면 통과한다.
- 배선 함수가 후보 열을 매번 다시 계산한다 — 복제 200회면 200번이라 느리다.
- 다른 과거 결정은 재현하지 않았다.
- 웹툰이 아직 수집 중이라(2,510/3,973) 이 숫자도 곧 바뀐다.

5. 다음

1. 웹툰 전체 수집 완료 후 전면 재측정 — 보류 항목을 한꺼번에 판정한다.
2. 자기 점검을 늘린다. “축을 끄고 같은 값으로 다시 쳐면 원래대로”처럼.
3. 노트 46 · 48의 웹툰 배선 결정도 새 도구로 재현해 본다.
4. 후보 열을 미리 계산해 두어 배선 함수를 빠르게 만든다.

참고문헌

- Efron, B., Tibshirani, R. J. (1993). An Introduction to the Bootstrap. Chapman & Hall.
- Bouthillier, X. et al. (2021). Accounting for variance in machine learning benchmarks. MLSys, 3, 747–769.
- Peng, R. D. (2011). Reproducible research in computational science. Science, 334(6060), 1226–1227.
- Hoare, C. A. R. (1981). The emperor’s old clothes. CACM, 24(2), 75–83.
- Ben-David, S. et al. (2010). A theory of learning from different domains. Machine Learning, 79(1–2), 151–175.