

IP 파운데이션 월드모델 연구 노트 70

반쯤 아는 방향은 모르느니만 못했다

노트 69의 뒤집기를 정당한 절차로 바꾸니 라벨 넷으로는 손해였고 서른둘부터 값을 했다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 69는 애니메이션의 축 방향을 답을 보고 뒤집었다 — 진단이지 채택이 아니었다. 정당한 절차로 바꿨다. 대상 라벨 k 건만 보고 방향을 정한 뒤 나머지로 평가한다. 보정에 쓴 k 건은 평가에서 빼고, 라벨 탈추세도 k 건 안에서만 한다(전표본 추세 계수를 쓰면 나머지 $n - k$ 건이 새어 든다 — 노트 35 · 54 · 64와 같은 종류라 `factor_space`에 탈추세 전 라벨을 내보내게 고쳤다). 세 방식을 켜다. 놀랍게도 사후 부호가 구조 교정을 이긴다 — 셀별 $+0.2945$, 도메인별 $+0.2363$, 원 축을 실제로 뒤집는 축 정향 $+0.2250(k=40)$. 오정향이 도메인의 성질이 아니라 쌍의 성질이기 때문이다. 그리고 정작 중요한 결과는 작은 k 에 있다. $k=4$ 에서 보정은 손해다 — 짝지은 차이 -0.0583 , $k=8$ 에서 -0.0206 . 방향을 반쯤 알면 모르느니만 못하다. 틀린 뒤집기가 안 뒤집기보다 두 배 나쁘기 때문이다. 구간이 0을 넘는 것은 $k=32$ 부터이며($+0.1093$ [$+0.021$, $+0.149$]), 이것이 노트 69의 “35건 92%”를 대체하는 정보 수치다. 마지막으로 값을 치른 뒤에도 일곱 도메인 $+0.2945$ 는 여섯 도메인 $+0.3474$ 에 못 미친다 — 여섯 도메인 평균은 방향이 같은 것들만 모여 있어서 낙관적이었다.

Table 1: 유보 평가 42셀 평균 ρ . 복제 150회.

k	셀별 부호	도메인별	축 정향
0	$+0.1776$	$+0.1776$	$+0.1776$
4	$+0.1193$	$+0.0884$	$+0.1001$
8	$+0.1570$	$+0.1257$	$+0.1210$
16	$+0.2427$	$+0.1927$	$+0.1867$
32	$+0.2869$	$+0.2288$	$+0.2210$
40	$+0.2945$	$+0.2363$	$+0.2250$

Table 2: 보정 없음 대비 짝지은 차이. 같은 복제끼리 뺀다(노트 44).

k	Δ	95% 구간
4	-0.0583	$[-0.292, +0.088]$
8	-0.0206	$[-0.209, +0.129]$
16	$+0.0651$	$[-0.079, +0.134]$
24	$+0.0941$	$[-0.019, +0.147]$
32	$+0.1093$	$[+0.021, +0.149]$
40	$+0.1169$	$[+0.052, +0.149]$

1. 절차를 정당하게 만든다

노트 69의 뒤집기는 42셀 평균을 보고 골랐다. 이 프로세스가 노트 28 · 34 · 35에서 세 번 금지한 것이다. 규약을 바꾼다.

대상 도메인의 라벨 k 건만 본다 → 그 k 건으로 방향을 정한다 → 나머지로 평가한다. 복제마다 평가 집합을 먼저 고정하고($k_{\max}$ 를 뺀 크기) 보정 k 건은 나머지에서 뽑으므로 k 끼리 비교 된다.

노수를 하나 더 찾았다. 처음 짤 때 보정 상관을 전표본으로 탈추세한 라벨의 k 건으로 켜다. 추세 계수가 전표본에서 왔으므로 나머지 $n - k$ 건이 새어 든다. 노트 35(도서 판형) · 54(붓스트랩 순서) · 64(진단 코드)와 같은 종류다. `factor_space`가 탈추세 전 라벨과 시간을 함께 내보내게 고치고, 보정은 k 건 안에서만 탈추세한다.

2. 세 방식

사후 부호가 구조 교정을 이긴다. 축 정향은 노트 69가 규명한 결함을 직접 고치는데도 진다.

주장 1. 오정향은 도메인의 성질이 아니라 쌍의 성질이다. 출처와 대상 중 어느 한쪽만 뒤집혀도 그 셀이 뒤집히므로 두 방향의 배타적 논리합이며, 대상 도메인 하나에 부호 하나를 매기는 방식으로는 표현할 수 없다.

반증 조건. 축 정향이 작은 k 에서 결정을 셋 내리는데(공통 축이 셋) 사후 부호는 하나만 내린다. 결정 수의 차이일 수도 있고 쌍/도메인 구분 때문이 아닐 수도 있다.

성분 부호는 손떨 필요가 없다는 것도 확인했다. 인자 공간 성분에 $\text{diag}(\pm 1)$ 을 곱면 프로크루스테스 회전이 $R \rightarrow RD$ 로 흡수하고 덧셈이 직교변환에 등변이라 예측이 그대로다. 뒤집어야 하는 것은 성분이 아니라 축이다.


Figure 1: 왼쪽 — k 와 42셀 평균. 오른쪽 — 보정 없음 대비 짝지는 차이.

Table 3: 같은 유보 규약으로 낸 것들.

	평균 ρ	95% 구간
여섯 도메인 · 보정 없음	+0.3474	[+0.347, +0.348]
일곱 도메인 · 보정 없음	+0.1776	—
일곱 도메인 · 셀별 $k=40$	+0.2945	[+0.221, +0.354]

3. 반쯤 아는 방향은 손해다

$k=4$ 에서 보정이 손해다. 이유가 산술적이다 — 안 뒤집으면 원래 값을 유지하고 틀리게 뒤집으면 부호가 반대가 되므로, 틀린 뒤집기의 벌은 안 뒤집기의 두 배다. 정확도가 3분의 2쯤이면 기댓값이 음수가 된다.

주장 2. 새 카테고리에 방향 보정을 붙이려면 대상 라벨 32건이 필요하다. 그 아래에서는 방향을 추측하지 말고 그대로 쓰는 편이 낫다.

반증 조건. 애니 하나로 정한 문턱이다. 다른 도메인에서는 다를 것이고, 특히 전이 신호가 센 팝업 · 아이돌은 더 적게 들 것이다.

노트 69는 부호 판정 정확도로 “35건에 92%”라고 적었다. 그 92%가 곧바로 이득이 아니다 — 8%의 오판이 두 배로 벌을 받으므로 끝단 효과는 훨씬 늦게 양수가 된다. 정본 수치는 32건이다.

4. 값을 치르고도 여섯이 낫다

보정은 손실의 88%를 되찾는다(+0.1776 → +0.2945, 오라클이 +0.3175). 그런데 여섯 도메인에는 여전히 못 미친다. 다른 서른 셀은 애니를 넣어도 안 변하므로, 애니의 열두 셀만 -0.24에서 +0.18로 올라온 것이다.

그렇다면 여섯 도메인 +0.3480은 낙관적이었다. 그 여섯은 축 방향이 전부 같은 쪽을 가리키는 것들이었고, 그것은 설계가 아니라 우연이다. 새 카테고리 하나를 밖에서 데려오자 그

우연이 깨졌다. +0.2945가 “처음 보는 카테고리”에 붙었을 때”의 더 정직한 숫자다.

5. 한계

- 문턱 32건을 애니 하나로 정했다. 도메인마다 다를 것이 거의 확실하다.
- $k_{\max}=40$ 이라 평가 집합이 작은 도메인(아이돌 62건 → 22건)에서 유보 평가가 몹시 흔들린다. 큰 k 는 못 본다.
- 축 정향이 진 이유를 쌍/도메인 구분으로 설명했는데, 결정 수(3 대 1)의 차이일 수도 있다. 갈라 보지 않았다.
- 보정을 채택은 했으나 정본 파이프라인에 아직 안 넣었다. 파이프라인의 평가 규약(전표본)과 보정 규약(유보)이 달라 함께 놓는 방식을 정해야 한다.
- 유보 평가 자체가 전표본 평가보다 낮게 나온다. 여섯 도메인이 +0.3474로 전표본 +0.3480과 거의 같은 것은 표본이 커서이고, 작은 도메인에서는 다를 수 있다.

6. 다음

- 방향 보정을 정본 파이프라인에 넣는다 — 평가 규약을 유보로 통일할지 결정한다.
- 문턱 32건을 다른 도메인에서 다시 낸다. 애니를 빼고 웹툰을 “새 카테고리”로 가정하면 얼마인가.
- 축 정향이 진 이유를 가른다 — 공통 축 하나만 뒤집게 제한하면 사후 부호를 따라잡는가.
- 여덟째 도메인 — 방향이 또 뒤집힌 것이 오는지 본다. 두 번째 사례가 나오면 “우연”이 아니라 “절반”이다.

참고문헌

Wang, Z. et al. (2019). Characterizing and avoiding negative transfer. CVPR, 11293–11302.

- Rosenstein, M. T. et al. (2005). To transfer or not to transfer. NIPS Workshop on Inductive Transfer.
- Kaufman, S., Rosset, S., Perlich, C. (2012). Leakage in data mining. ACM TKDD, 6(4), 1–21.
- Efron, B., Tibshirani, R. J. (1993). An Introduction to the Bootstrap. Chapman & Hall.
- Ben-David, S. et al. (2010). A theory of learning from different domains. Machine Learning, 79(1–2), 151–175.