

IP 파운데이션 월드모델 연구 노트 71

판정하던 자와 파는 물건이 달랐다

서른여덟 노트 동안 셀별 전이의 평균으로 판정했는데 제품이 쓰는 것은 출처를 합친 앙상블이다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 33부터 일흔까지 판정치는 줄곧 셀별 전이의 평균이었다 — “출처 하나로 대상 하나를 얼마나 맞히나.” 제품이 쓰는 것은 그게 아니다 — “가진 것 전부로 대상 하나를 맞히면 얼마나 맞나.” 둘을 나란히 썼다. 앙상블이 일곱 대상 전부에서 이긴다. 팝업이 +0.3263에서 +0.4685로(Δ +0.1340 [+0.072, +0.194]), 전체가 +0.1797에서 +0.2612로 오른다. 여섯 대상 모두 짝지은 구간이 0을 넘는다. 그리고 앙상블은 최선 단일 출처(+0.4762)에 거의 닿는다 — 라벨 없이는 어느 출처가 최선인지 못 고르는데 합치면 공짜로 거기 간다. 팝업 출처 여섯 중 하나(애니)가 -0.3096으로 반대를 가리키는데도 앙상블이 안 무너진다. 그래서 과거 판정을 다시 했다 — 넷 중 하나가 뒤집힌다(노트 48 웹툰 굿즈 배선: 보류 → 되돌리기 채택). 예상이 하나 빗나갔다 — 앙상블이 방향 결정을 싸게 만들 줄 알았는데 더 비싸게 만든다. 결정이 여섯에서 하나로 줄어 해지가 사라지기 때문이며, $k=32$ 에서도 구간이 0을 포함한다. 마지막으로 제품 수치의 구간을 처음 썼다 — 6.13배 [2.12, 10.98]. 순위는 확실히 좋아졌고 배수는 아직 말할 수 없다.

1. 두 개의 자

연구 질문 게임으로 팝업을 맞히면 얼마나 맞나 — 42셀 평균.
제품 질문 가진 것 전부로 팝업을 맞히면 얼마나 맞나 — 앙상블.

노트 58·59가 낸 제품 수치는 이미 다섯 출처를 합쳐 냈다. 그러니까 제품 수치는 틀리지 않았다. 틀린 것은 판정 척도다 — 배선· λ ·축 결정 서른 몇 개를 전부 셀 평균으로 채고 있었다.

순위로 합친다. 출처마다 예측의 눈금이 다르므로(노트 59가 눈금 보정을 따로 다룬 이유다) 값이 아니라 순위를 평균한다. 가중치는 안 준다 — 출처의 자기 상관으로 가중하면 노트 38·40의 상충 법칙 때문에 오히려 나쁜 출처에 힘이 실린다. z 평균과 순위 평균은 사실상 같다(일곱 대상 최대 차 0.008). 어떻게 합치느냐가 아니라 합치느냐가 문제다.

2. 일곱 대상 전부에서 이긴다

여섯 대상 전부 구간이 0을 넘는다. 애니만 음수인데 그것은 방향이 뒤집힌 상태라 앙상블이 일관되게 반대로 간다는 뜻이다 — 합치기가 실패한 게 아니다.

주장 1. 판정치를 셀 평균에서 앙상블로 바꾼다. 제품이 쓰는 것이 그것이고, 일곱 대상 전부에서 더 높으며, 여섯에서 짝지은 구간이 0을 넘는다.

반증 조건. 앙상블은 출처가 많을수록 유리하므로 도메인 수에 더 민감하다. 도메인이 적은 초기 노트와 비교할 때는 눈금이 다르다.

Table 1: 대상별, 짝지은 붓스트랩 400회.

대상	셀 평균	앙상블	Δ	95% 구간
팝업	+0.3263	+0.4685	+0.1340	[+0.072, +0.194]
아이돌	+0.3269	+0.4433	+0.1159	[+0.048, +0.178]
웹툰	+0.2923	+0.3951	+0.1027	[+0.094, +0.111]
게임	+0.2555	+0.3562	+0.0996	[+0.074, +0.123]
도서	+0.1567	+0.2397	+0.0816	[+0.038, +0.121]
편딩	+0.1604	+0.1929	+0.0325	[+0.013, +0.055]
애니	-0.2599	-0.2674	-0.0076	[-0.010, -0.005]
전체	+0.1797	+0.2612		

3. 반대로 가는 출처가 있어도 안 무너진다

여섯 중 하나가 반대를 가리키는데 앙상블이 +0.4685다. 최선 단일(+0.4762)에 1.6% 차이로 닿는다. 어느 출처가 최선인지는 대상 라벨 없이 못 고른다. 앙상블은 그 선택을 안 해도 되게 만든다.

애니를 아예 빼면 +0.4703, 부호를 뒤집어 넣으면 +0.4528이다. 셋이 전부 ± 0.02 안에 있다 — 나쁜 출처를 어떻게 처리하든 차이가 없다.

4. 과거 판정을 다시 했다

넷 중 셋은 그대로다. 하나가 뒤집힌다 — 노트 48이 웹툰 굿즈 규모를 연재 밀도에서 참여 작가 수로 바꾼 결정인데, 앙상블 자로 재면 되돌리는 쪽이 채택이다(+0.0132 [+0.0032, +0.0286]). 노트 67이 이미 “표본이 세 배가 되자 사라졌다”고 적었던 그 결정이며, 이제 자를 바꾸니 반대로 판정된다.




Figure 1: 왼쪽 — 대상별 셀 평균과 앙상블. 오른쪽 — 팝업의 출처별 성적.

Table 2: 팝업을 맞히는 출처 여섯.

아이돌	+0.4762
펀딩	+0.4729
도서	+0.4497
게임	+0.4451
웹툰	+0.4234
애니	-0.3096
셀 평균	+0.3263
앙상블	+0.4685

Table 3: 같은 결정, 두 자. 하나가 뒤집힌다.

결정(되돌리는 방향)	셀 평균	앙상블
도서 타깃 폭 끄기	악화	악화
게임 고유 축 떼기(노트 54)	악화	악화
웹툰 굿즈 되돌리기(노트 48)	보류	채택
애니 방향 뒤집기(노트 69)	채택	채택

주장 2. 판정 척도를 바꾸면 결정이 바뀐다 — 넷 중 하나가. 셀 평균으로 내린 과거 판정 전부가 재검토 대상이다.

반증 조건. 넷만 다시 썼다. 나머지를 다 재려면 계산이 크고, 대부분은 효과가 반쪽 아래라 어차피 보류로 나올 것이다.

5. 예상이 빗나갔다 --- 앙상블은 방향을 더 비싸게 만든다

노트 70에서 셀별 부호는 $k=32$ 에 채택됐다. 앙상블은 $k=32$ 에도 구간이 0을 포함한다. 이유가 분명하다 — 셀별은 대상마다 여섯 번 결정하고 앙상블은 한 번 결정한다. 여섯 번 중 넷만 맞아도 평균이 살아남지만, 한 번 틀리면 대상 전체가 뒤집힌다.

Table 4: 앙상블의 방향을 k 건으로 정한다(노트 70과 같은 유보 규약).

k	Δ	95% 구간
2	-0.1906	$[-0.411, +0.076]$
8	-0.0916	$[-0.352, +0.077]$
16	+0.0001	$[-0.147, +0.078]$
32	+0.0496	$[-0.073, +0.078]$

Table 5: 팝업 예측 상하위 20% 일평균 방문자 배수. 붓스트랩 600회.

	배수	95% 구간
앙상블 여섯	6.13	$[2.12, 10.98]$
최선 단일(아이돌)	5.24	$[2.41, 10.91]$
앙상블 - 개별 평균 ($\log_{10}$ 배수)	+0.201	$[-0.051, +0.378]$

주장 3. 합치기는 예측을 좋게 하고 방향 결정을 나쁘게 한다. 평균이 잡음을 줄이는 것과 같은 이유로 방향 오판의 해지도 함께 사라진다.

반증 조건. 앙상블 부호를 셀별 부호의 다수결로 정하면 둘 다 얻을지 모른다. 안 해 봤다.

6. 제품 수치에 구간을 붙인다

노트 58이 5.5배라고 적은 이래 이 수치에 구간을 붙인 적이 없다. 붙여 보니 $[2.12, 10.98]$ 이다. 팝업이 75건이고 각 구간이 15건이라 그렇다. 짝지는 차이도 0을 포함한다.

순위는 확실히 좋아졌고 배수는 아직 말할 수 없다. 순위 상관은 75건 전부를 쓰지만 배수는 양 끝 15건씩만 쓴다. “6.13배”를 제품 문구로 쓰면 안 되고, 쓸 수 있는 것은 여전히 노트 59의 문장이다 — 어느 기획을 먼저 밀지 고르는

데는 쓸 수 있고, 몇 명 올지 약속하는 데는 아직 못 쓴다.

7. 한계

- 앙상블을 정본 파이프라인의 기본 판정치로 바꾸지 않았다. `audit`에 `rho_ens`를 넣어 둘 다 썰 수 있게만 했다.
- 과거 결정 넷만 다시 썰다.
- 배수의 구간이 너무 넓어 앙상블이 배수를 올렸는지 모른다. 팝업 표본이 늘기 전에는 못 좁힌다.
- 애니가 방향이 뒤집힌 채로 들어가 있다. 노트 70이 문턱 32건을 냈지만 정본에 아직 안 넣었다.
- 앙상블 가중치를 균등으로 고정했다. 라벨 몇 건으로 가중치를 정하는 것은 안 해 봤다.

8. 다음

1. 판정치를 앙상블로 바꾸고 파이프라인 출력을 다시 낸다.
2. 앙상블 부호를 셀별 다수결로 정해 본다 — 예측 이득과 방향 해지를 둘 다 얻는지.
3. 노트 48 웹툰 굿즈 배선을 되돌린다(앙상블 자로 채택됐다).
4. 여덟째 도메인. 앙상블은 출처가 많을수록 유리하므로 도메인 추가의 값이 셀 평균으로 볼 때보다 크다.

참고문헌

- Breiman, L. (1996). Bagging predictors. *Machine Learning*, 24(2), 123–140.
- Dietterich, T. G. (2000). Ensemble methods in machine learning. *MCS*, 1–15.
- Caruana, R. et al. (2004). Ensemble selection from libraries of models. *ICML*, 18.
- Kuncheva, L. I., Whitaker, C. J. (2003). Measures of diversity in classifier ensembles. *Machine Learning*, 51(2), 181–207.
- Efron, B., Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall.