

IP 파운데이션 월드모델 연구 노트 73

게이트를 먹인 것은 마흔둘이 아니라 여섯이었다

출처들끼리 라벨 없이 서로의 방향을 알아보지만, 도메인을 건너 가중치를 배우는 것은 아직 이르다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

방향에 라벨이 든다는 것을 노트 70이 정했고(32건) 노트 72가 그 이유를 밝혔다. 그런데 안 쓴 정보가 하나 있었다 — 다른 출처들의 의견. 팝업을 맞히는 여섯 중 다섯이 +0.4대로 같은 쪽이고 애니만 -0.31이면, 애니가 뒤집혔다는 것을 팝업 라벨을 한 건도 안 보고 알 수 있다. 부호를 둘로 쪼갠다 — 상대 방향(출처들끼리 맞추기, 라벨 0건)과 전역 방향(맞춰진 전체가 어느 쪽인지, 라벨 필요). 합의 정향은 일곱 대상 전부에서 애니를 정확히 지목한다(팝업 가중치: 다섯이 +0.83~+1.00, 애니 -0.799). 그런데 고쳐도 판정치가 안 는다 — +0.0073 [-0.0035, +0.0214], 보류. 노트 72가 밝힌 희석 때문이고, 대상별로 부호가 갈린다(아이돌 +0.064 이득, 팝업 -0.024 손해). 팝업에서는 뒤집힌 출처를 그냥 두는 것이 뒤집거나 빼는 것보다 낫다 — 음의 상관 구성원이 상관된 오차를 상쇄한다. 얻은 것은 성적이 아니라 단순함이다: 결정 여섯을 하나로 줄여도 같은 자리다 ($k=32$ 에서 +0.3327 대 +0.3367). 그리고 게이트를 만들었다 — 쌍의 성질로 셀 성적을 예측해 가중치를 정하는, 대상 라벨 0건짜리 혼합 전문가. 진다(+0.2473 대 +0.2744). 진단이 정확하다 — 대상 수준 특징은 대상 안에서 상수라 유효 학습 표본이 셀 42개가 아니라 도메인 6개다. 빼면 게이트가 합의로 되돌아간다(+0.2836). 여덟째 도메인의 값이 여기서 분명해진다 — 셀 42→56, 게이트 유효 표본 6→7.

Table 1: 팝업을 맞히는 여섯의 합의 가중치. 팝업 라벨 0건.

출처	합의 가중치	실제 ρ
게임	+0.997	+0.445
도서	+0.995	+0.450
편딩	+0.883	+0.473
아이돌	+0.863	+0.476
웹툰	+0.826	+0.324
애니	-0.799	-0.310

Table 2: 균등 대비 짝지은 차이. 붓스트랩 200회.

	Δ	95% 구간
합의 뒤집기	+0.0064	[-0.0085, +0.0213]
소프트 가중	+0.0066	[-0.0070, +0.0238]
클립 가중	+0.0073	[-0.0035, +0.0214]

Table 3: 팝업 — 뒤집힌 출처를 어떻게 할까.

그냥 둔다(균등 여섯)	+0.4594
빼다(다섯)	+0.4551
뒤집는다	+0.4348

1. 부호를 둘로 쪼갠다

상대 방향 출처들끼리 같은 쪽을 보게 맞추는 것 — 라벨 0건
전역 방향 맞춰진 전체가 어느 쪽인지 — 라벨이 든다

지금까지 둘을 구분하지 않아 여섯 결정을 전부 라벨로 샀다. 상대 방향은 각 출처를 뺀 나머지의 순위 평균과 비교해 반대면 뒤집는 것으로, 수렴할 때까지 반복한다. 전역 부호는 다수결로 고정한다 — 대부분의 출처가 옳게 정향돼 있다는 가정이다.

주장 1. 뒤집힌 출처는 대상 라벨 없이 찾을 수 있다 — 나머지 출처들의 합의와 반대면 그것이다. 일곱 대상 전부에서 애니를 정확히 지목한다.

반증 조건. 뒤집힌 것이 대상이면 여섯이 다 같이 틀린 쪽을 보므로 합의로는 못 찾는다.

2. 찾아도 고칠 것이 별로 없다

셋 다 보류다. 노트 72가 이미 이유를 냈다 — 양상블이 나쁜 출처를 여섯 중 하나로 희석하므로 고칠 손상이 이미 절반이다.

주장 2. 음의 상관 구성원을 그냥 두는 것이 뒤집거나 빼는 것보다 나을 수 있다 — 팝업이 그렇다. 그 구성원의 오차가 나머지 다섯의 상관된 오차를 상쇄하기 때문이다.

반증 조건. 팝업 하나에서 본 것이고 $n=75$ 다. 아이돌에서는 반대로 뒤집는 쪽이 +0.064 낫다.

3. 여섯 결정이 하나가 된다

$k=32$ 에서 +0.3327 대 +0.3367 — 사실상 같다. 결정을 여섯 번에서 한 번으로 줄여도 같은 자리다. 성적 이득은




Figure 1: 왼쪽 — 방향 결정의 값. 오른쪽 — 게이트의 특징 집합별 판정지.

Table 4: 유보 평가 양상블 ρ . 복제 150회.

k	셀마다 부호 (6번)	합의+ 전역 (1번)
0	+0.2748	+0.2800
16	+0.2945	+0.2888
24	+0.3223	+0.3206
32	+0.3367	+0.3327

Table 5: 게이트. 대상 라벨 0건.

특징 집합	판정지	웹툰
전체 8개	+0.2473	+0.2259
대상 특징 제외 6개	+0.2836	+0.4806
합의+잔차	+0.2835	+0.4782
합의만	+0.2838	+0.4792
균등(기준)	+0.2744	+0.4818

아니지만 절차가 단순해지고, $k=0$ 쪽은 합의가 +0.005 앞선다(공짜).

4. 게이트를 만들었다

다른 여섯 대상에서는 정답을 안다 — 그 대상들은 라벨이 있으므로 어느 쌍이 잘 되는지 이미 안다. 거기서 배워 새 대상에 옮기면 대상 라벨이 0건이다. 혼합 전문가(Jacobs 1991)의 게이트 망과 같은 자리이고, 학습 표본이 셀 42개뿐이라 망 대신 능형 회귀를 쓴다. 대상 t 의 가중치를 정할 때 t 가 대상인 셀은 학습에서 전부 뺀다.

전체 특징으로는 진다. 그리고 웹툰 하나에서 +0.4818이 +0.2259로 무너진다.

주장 3. 도메인 수준 특징(대상 n · 대상 축 수)은 한 대상 안에서 상수이므로 게이트에 정보를 안 주고 자유도만 먹는다. 셀 42개로 보이는 학습 표본이 실제로는 도메인 6개다.

Table 6: 게이트가 본 것(표준화 계수, 전체 42셀 적합, $R^2=0.587$).

공통 축 수	-0.137
출처 축 수	-0.120
log 대상 n	-0.120
대상 축 수	-0.116
합의 가중치	+0.114
정렬 잔차	-0.024
출처 자기 ρ	+0.003

반증 조건. 능형 회귀 하나로 본 것이고 별점을 조율하지 않았다. 더 센 정규화로는 다를 수 있다.

특징을 빼면 게이트가 합의로 되돌아간다(+0.2836 대 합의 클립 +0.2836). 합의 가중치가 지금 데이터에서 배울 수 있는 것의 전부다.

$R^2=0.587$ 이 특징 8개에 표본 42개다. 상위 넷 중 셋이 도메인 수준이라 사실상 “어느 도메인인가”를 외운 것이다.

5. 한계

- 합의 정향도 게이트도 채택하지 않았다. 진단 도구로만 남긴다.
- 합의는 뒤집힌 것이 대상일 때 무력하다. 애니가 대상인 셀은 -0.277 그대로다.
- 게이트를 능형 회귀 하나로만 시도했다. 망도, 별점 조율도, 비선형도 안 했다.
- 팝업에서 “그냥 두는 것이 낫다”를 $n=75$ 로 봤다. 다양성 효과인지 우연인지 못 가른다.
- 노트 72의 셀마다 부호와 여기의 합의+전역이 $k=32$ 에서 0.004 차이인데, 복제 150회의 잡음이 그보다 크다. “같다”고만 말할 수 있다.

6. 다음

1. 여덟째 도메인. 값이 여기서 분명해졌다 — 셀 42→56, 게이트 유효 표본 6→7, 합의 투표자 6→7.
2. 쌍 수준 특징을 더 만든다 — 도메인 수준 특징이 쓸모없다면 남은 길은 쌍의 성질을 더 재는 것이다.
3. 대상이 뒤집힌 경우를 합의로 잡을 방법 — 출처들의 쌍끼리 관계를 보면 될지 모른다.
4. 팝업의 다양성 효과를 다른 대상에서 확인한다.

참고문헌

- Jacobs, R. A. et al. (1991). Adaptive mixtures of local experts. *Neural Computation*, 3(1), 79–87.
- Wolpert, D. H. (1992). Stacked generalization. *Neural Networks*, 5(2), 241–259.
- Breiman, L. (1996). Stacked regressions. *Machine Learning*, 24(1), 49–64.
- Kuncheva, L. I., Whitaker, C. J. (2003). Measures of diversity in classifier ensembles. *Machine Learning*, 51(2), 181–207.
- Shazeer, N. et al. (2017). Outrageously large neural networks: the sparsely-gated mixture-of-experts layer. *ICLR*.