

IP 파운데이션 월드모델 연구 노트 253

더 모아도 안 된다

도서의 여지를 “수집 문제”로 적은 지 한 사이클 만에 스스로 반증한다 --- 학습을 덜어 내면 오히려 좋아진다

Sweetspot 월드모델 연구

2026년 7월 31일

초 록

노트 252는 도서를 유일한 진짜 여지로 짚고(+0.177, 몫 6.2%) 원인을 수집이라고 적었다 — 학습 80건에 유보 163건으로 학습이 유보보다 적은 유일한 도메인이라서다. 그 진단이 틀렸다. 값싼 확인이 있었는데 안 했다: 학습을 덜어 내 보는 것. 80 → 60 → 40 으로 줄이면 도서가 0.3212 → 0.3347 → 0.3604 로 올라간다. 기울기가 $-0.019/\ln$ 이다 — 도서 제 학습 자료가 도서를 해치고 있다. 20~28 건만 남기면 0.3482 로 굳는데, 그 값은 시대를 어떻게 잘라도 똑같이 나온다. 풀링으로 되돌아간 값이고, 지금 판(0.3212)은 그보다 아래다. 가는 김에 제일 그럴듯한 수집안도 달았다 — book_records 396건 중 153건이 전자책으로 빠져 있고 그중 58건이 2025년 이전이라 학습을 80에서 138로 키울 수 있어 보였다. 못 쓴다: 전자책 여부가 라벨과 $\rho = -0.81$ (학습)이고 판형 · 무게가 전자책 0.0% 대 종이책 99.6% 라 결국 무늬가 완벽한 형식 깃발이다. sales_point 자체가 두 매장의 서로 다른 계수기다. 노트 35의 제외는 옳았다. 학습을 최근으로 자르는 것(+0.041)도 $t=1.52$ 에 판 -0.0006 이라 채택 못 한다. 남은 결론: 도서의 여지는 양이 아니라 모집단의 문제이고, 같은 자리에서 더 모으는 것으로는 못 메운다.

1. 한 사이클 만에 틀렸다

노트 252는 프로그램 수준의 결론을 냈다 — 축 열일곱의 여지가 +0.013 뿐이고, 그중 실제로 큰 곳은 도서 하나(+0.177)이며, 원인은 라벨을 안 보고도 보인다:

도서는 학습 80건에 유보 163건으로 학습이 유보보다 적은 유일한 도메인이고 ... 도서의 여지는 모형이 아니라 수집이다.

그렇듯했고, 표를 보면 정말 그렇게 보인다. 그런데 그 문장은 안 재고 쓴 것이다. 재는 법이 값싼데도 — 학습을 덜어 내 보면 된다. 자료가 모자라서 못 하는 것이라면 덜어 낼수록 나빠져야 한다.

2. 덜어 내면 좋아진다

남긴 학습	도서 ρ	SD	판
80 (전부)	0.3212	—	0.4569
60	0.3347	0.020	0.4567
40	0.3604	0.007	0.4549
28	0.3482	0.000	0.4540
20	0.3482	0.000	0.4540

기울기가 $d\rho/d\ln n = -0.019$ 다. 도서의 제 학습 자료가 도서를 해친다.

20~28건에서 0.3482 로 굳는 것도 말을 한다. 시대를 어떻게 잘라도 — 2020년 이후만 남겨도, 2015년 이전만 남겨도 — 정확히 0.3482 다. 그 값은 모형이 도서 제 계수를 안 쓰고 풀링으로 되돌아간 값이다(F21의




Figure 1: 왼쪽 — 도서 학습 행을 무작위로 덜어 내며 갯 유보 ρ (씨앗 셋). 오른쪽 — 전자책을 못 넣는 이유.

min_rows=150 이 도서 80건을 이미 걸러내고 있고, 남는 것은 F18 나무다). 그리고 지금 판의 도서(0.3212)는 그 되돌림보다 아래다.

3. 제일 그럴듯한 수집안을 달았다

수집이 답이라면 어디서 모으냐. book_records.json 을 열어 보니 396건 중 243건만 판에 실려 있었다. 빠진 153건이 전자책이고, 그중 58건이 2025년 이전이다 — 넣으면 학습이 80에서 138로 늘고 유보 분모는 안 건드릴 수도 있다. 노트 35가 “판형 결측이 형식을 누출한다”고 제외해 둔 것인데, 지금 판에는 노트 213 · 214 이후로 그런 누출을 다루는 법이 생겼으니 다시 볼 만했다. 됐다.

	전자책	종이책
건수	153	243
판형(width) 있음	0.0%	99.6%
무게 있음	0.0%	99.6%
쪽수 · 정가 있음	100%	99.6%
log ₁₀ sales point	3.31	4.30

$\rho(\text{전자책 여부, 라벨}) = -0.811 (\text{학습}), -0.656 (\text{유보}).$

Mann-Whitney $p = 3 \times 10^{-39}$ 이다. 결국 무늬(판형 · 무게)가 완벽한 형식 깃발이고 그 깃발이 라벨의 대부분을 설명한다. 넣으면 판이 오르겠지만 모형이 배우는 것은 “전자책인가”뿐이다. 게다가 sales_point 는 두 매장의 다른 계수기라, 노트 224가 가른 “라벨 두 종류”를 한 도메인 안에서 섞는 셈이다.

노트 35의 제외는 옳았다. 2년 전 결정이 지금 규약으로도 옳다는 것을 확인한 셈이다.

4. 최근으로 자르는 것도 안 된다

학습이 해롭다면 해로운 부분만 자르면 된다. 도서 학습 80건은 1999-2025에 흩어져 있다(1995-99:1 · 2000-04:13 · 2005-09:4 · 2010-14:12 · 2015-19:16 · 2020-24:34).

도서 학습	n	도서 차	짜 SE	t
2015 이후만	50	+0.0408	0.0269	1.52
2020 이후만	34	+0.0270	0.0285	0.95

둘 다 잡음 안이고 판은 오히려 내려간다($-0.0006 \cdot -0.0028$). 노트 248의 규약대로 도메인 수는 SE 와 함께 읽어야 하는데, 도서 SE 가 0.073 이라 +0.04 는 근거가 못 된다. 채택 안 한다.

5. 양이 아니라 모집단이다

정리하면 도서에 대해 아는 것은 이렇다.

- 유보 안에서 CV 로 배우면 0.498 이 나온다(노트 252). 축이 도서 2025+ 를 설명할 힘은 있다.
- 그런데 도서 학습으로 배우면 0.321 이고, 학습을 버리면 0.348 로 오른다. 학습이 가르치는 관계가 유보의 관계와 다르다.
- 학습을 늘리는 길(전자책)은 라벨이 달라 막혀 있다.
- 학습을 최근으로 좁히는 길은 잡음 안이다.

양의 문제가 아니라 모집단의 문제다. 도서 레코드는 베스트셀러 목록 스크랩이라 2026년이 209건 · 2025년 이 49건인데 2010년대는 다 합쳐 30건 남짓이다. “2020년 이전 베스트셀러”는 “지금 잘 팔리는 옛 책”이고, “2026년 베스트셀러”는 “지금 잘 팔리는 새 책”이다. 이름만 같은 두 모집단이다. 노트 209가 라벨의 누적성을 지적한 것과 같은 병의 다른 얼굴이다.

노트 252의 마지막 줄 — “다음 이득은 새 정보에서 온다” — 은 살아남는다. 다만 “새 정보”가 “같은 자리에 서 더”는 아니라는 단서가 붙는다.

남은 것.

갈래	왜
도서 학습이 해롭다	판에서 빠면? 되돌림 0.348 > 지금 0.321
같은 검사 아홉 곳	다른 도메인도 제 학습이 해로운가
웹툰 +0.051	뭇 27%, 도서보다 판에 크다
고정 창 라벨	노트 209의 숙제. 모집단 문제의 뿌리

규약. “자료가 모자라서”라고 쓰기 전에 덜어 내 본다. 덜어서 안 나빠지면 모자란 게 아니다. 한 줄짜리 실험이고, 이번에 그것을 안 해서 노트 하나를 틀리게 썼다.