

IP 파운데이션 월드모델 연구 노트 254

아홉 중 하나만 그렇다

제 학습이 해로운 도메인은 도서뿐이다 --- 그리고 그 사실로는 판을 못 바꾼다

Sweetspot 월드모델 연구

2026년 7월 31일

초 록

노트 253은 도서의 제 학습 자료가 도서를 해친다는 것을 잰다(80건 → 40건에서 ρ 0.321 → 0.360). 남은 물음은 그게 도서만의 일인가였다. 여덟 도메인에 같은 검사를 했다 — 제 학습을 무작위로 절반 덜어 내고 유보 ρ 를 본다. 도서만 오른다(+0.042). 나머지 일곱은 평평하거나 내려가고, 애니는 크게 내려간다(−0.038, $t = -4.02$). 학습 크기로는 설명이 안 된다 — spearman(학습 크기, 줄인 이득) = −0.02 다. 도서는 작아서 이상한 게 아니라 다른 모 집단이라 이상하다(노트 253). 그런데 이 노트의 더 중요한 절반은 그래서 무엇을 할 수 있나이고, 답은 아무것도다. 도서를 고쳐도 판은 +0.0026 움직인다(몫 $6.2\% \times 0.042$) — 노트 245가 그 0.010 선 한참 아래라 안쪽으로도 유보로도 정할 수 없다. **옳다고 아는 변경을 채택할 수 없는 자리이고**, 이 실험실이 그 자리를 만난 것은 처음이 아니다(노트 216 · 224 · 234 · 241 · 247). 다만 이번엔 방향이 반대다 — 앞의 다섯은 “판이 오르는데 고를 수 없어서” 거부했고, 이번은 “고를 수 있는데 판이 안 움직여서” 못 채택한다. 제품 중에서는 답이 다르다: 도구가 파는 것은 판 ρ 가 아니라 한 도메인의 예측이므로 (노트 247), 도서를 쓰는 사용자에게는 도서 학습 행을 빼는 것이 맞다. 판정 단위와 배포 단위가 다르다는 것을 처음으로 정면으로 적는다.




Figure 1: 제 학습을 절반으로 줄였을 때, 오른쪽으로 가면 제 자료가 해롭다는 뜻.

1. 여덟 곳에 같은 검사를 했다

노트 253의 검사는 한 줄이다 — 제 학습을 덜어 내고 유보에서 재라. 도서에서 −0.019/ln 이 나왔다. 같은 것을 학습 30건 이상인 여덟 도메인에 다 했다 (무작위 절반, 씨앗 둘).

도메인	학습	지금	절반만	차
도서	80	0.321	0.363	+0.042
게임	259	0.640	0.639	−0.001
모바일	1,559	0.537	0.535	−0.002
세계애니	2,648	0.520	0.511	−0.009
편딩	320	0.236	0.220	−0.016
웹툰	2,106	0.381	0.349	−0.032
애니	1,467	0.487	0.449	−0.038
아이돌	54	0.154	0.109	−0.045

도서 하나만 오른다. 애니는 $t = -4.02$ 로 뚜렷하게 내려간다 — 제 자료가 확실히 쓸모 있다는 뜻이다.

크기 이야기가 아니다. spearman(학습 크기, 줄인 이득) = −0.02 로 아무 관계가 없다. 학습 54건인 아이돌은 −0.045 이고 2,648건인 세계애니는 −0.009 다. 도서는 작아서가 아니라 다른 모 집단이라 이상하다 — 노트 253 이 깊은 대로 “2020년 이전 베스트셀러”는 “지금 잘 팔리는 옛 책”이다.

한 가지 흠. 표의 짝 SE 와 t 는 씨앗 하나로 잰 것이고 “차”는 씨앗 둘의 평균이라, 둘이 어긋나는 줄이 있다(웹툰은 차가 −0.032 인데 씨앗 0 만 보면 +이다). 도서와 애니는 0 에서 충분히 멀어 읽을 수 있지만 가운데 다섯 줄의 t 는 안 읽는 게 맞다.

2. 그래서 무엇을 할 수 있나 --- 아무것도

도서가 이상하다는 것은 알았다. 고치면 얼마인가.

$$0.042 \times 0.062 = +0.0026.$$

노트 245가 그 0.010 선의 4분의 1 이다. 그 자리는 안쪽 신뢰도가 0.34 이고 (노트 244) 유보로 정하면 옛보기다(노트 245). **옳다고 아는 변경인데 채택할 수 없다.**

이 실험실이 이 벽을 만난 것은 여섯 번째다. 그런데 앞의 다섯과 방향이 반대다.

노트	무엇	왜 못 하나
216	과제별 혼합 가중	판 +0.0050 인데 고를 수 없다
224	웹툰 회차 간격	판 +0.0294 인데 사후다
234	공유 시리즈 채움	값이 틀렸다
241	도메인별 기울기	판 +0.0102 인데 안쪽이 거꾸로
247	도메인 안 백분위	상쇄돼 판이 안 움직인다
254	도서 학습 빼기	옳은데 판이 안 움직인다

앞의 넷은 “판이 오르는데 근거가 없어서” 거부했다. 254는 근거가 있는데 판이 안 움직여서 못 채택한다. 판 ρ 가 순위 기준인 한 이 둘은 똑같이 “안 함”으로 끝난다.

3. 판정 단위와 배포 단위가 다르다

그런데 “안 함”이 정말 옳은가. 노트 247이 지나가듯 적은 문장을 정면으로 꺼낼 때가 됐다.

도구가 파는 것은 판 ρ 가 아니라 한 도메인의 예측이다.

도서를 쓰는 사용자에게 도서 ρ 는 0.321 이 아니라 0.363 일 수 있다. 그 사용자에게 “판 전체로는 0.0026 이라 안 했습니다”는 답이 아니다. 반대로 애니 사용자에게 같은 처방을 하면 -0.038 이다.

판정은 판 ρ 로 하되 배포는 도메인별로 한다 — 이것이 지금 자료가 지지하는 형태다. 근거는 노트 252의 표에 이미 있었다: 다섯 도메인은 여지가 음수라 손대면 안 되고, 도서는 제 자료가 해롭다. 하나의 전역 설정이 아홉 도메인에 다 맞을 이유가 없다.

다만 이것을 실제로 하려면 도메인별 결정을 도메인별로 정당화해야 하고, 도서 하나의 +0.042 는 짝 SE 0.024 로 $t=1.49$ 다. 아직 근거가 모자란다. 이 노트는 규약을 바꾸자는 제안이 아니라, 바꿔야 할 자리를 처음으로 정확히 짚는 것이다.

남은 것.

갈래	왜
도메인별 배포	판정과 배포를 가르면 무엇이 필요한가
애니 -0.038	제 자료가 제일 값진 도메인. 무엇이 다른가
도서 $t=1.49$	근거가 모자란다. 씨앗을 늘리면 되나
웹툰	씨앗에 부호가 걸린다. 절반 줄이기가 불안정

규약. “판이 안 움직인다”와 “효과가 없다”를 가른다. 뭇이 6%인 도메인은 제 ρ 가 0.04 움직여도 판에 0.0026 이다. 노트 247의 상쇄와 다른 이유로 같은 일이 생긴다 — 그때는 부호가 엇갈려서, 이번엔 뭇이 작아서.