

IP 파운데이션 월드모델 연구 노트 77

기획서 한 장씩 넣어도 같은 자리였다

마지막 두 누출을 막았다 --- 전도적 가정과 설계 결정의 시간 누출

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 76이 시간을 갈랐지만 누출 둘을 남겼다. 첫째, 대상의 인자 공간을 미래 레코드 전체로 만들었다 — 신아홉 건을 한꺼번에 보고 주성분을 뽑는 것은 제품이 쓰이는 방식이 아니다. 제품은 기획서 한 장을 들고 온다. 규약 넷을 비교했다. 전부 같은 자리다 — 한꺼번에 +0.5324, 하나 빼고(LOO) +0.5313, 과거 공간에 미래 묶음 +0.5279, 완전 한 건씩 +0.5216 [+0.246, +0.711]. 전도적 가정의 값이 0.011이다. 넷째가 제품 그대로다 — 2025년 이전에 연 팝업 16건으로 공간을 만들고 새 기획을 하나씩 넣어 “지금까지 연 것 중 상위 몇 퍼센트”를 낸다. 둘째, 배선과 축을 전체 데이터로 골랐다. 2025년 이전만 보고 후보 79개를 다시 돌리니 전체 데이터의 Δ 와 $r = +0.867$ 로 맞고, 특히 애니 타깃 폭에서 태그 수가 과거 데이터로도 -0.0557이라 2025년을 못 본 분석가도 같은 배선을 골랐다. 다만 상위 순위는 안 옮겨간다 — 과거만 데이터의 상위 다섯이 전체에서 +0.0027~ -0.0038로 전부 잡음이고, 그중 하나는 노트 67이 누출로 판정했던 웹툰 회차 수다. 표본을 자르면 누출이 다시 좋아 보인다.

Table 1: 시점 2025 · 미래 팝업 59건. 공간 적합용 과거는 16건.

규약	ρ	95% 구간
① 한꺼번에	+0.5324	—
② 하나 빼고(LOO)	+0.5313	—
③ 과거 공간 + 미래 묶음	+0.5279	[+0.270, +0.722]
④ 완전 한 건씩	+0.5216	[+0.246, +0.711]

Table 2: 애니 타깃 폭 · 굿즈 규모 후보, 현행 대비 Δ .

슬롯	후보	과거만	전체
타깃 폭	연령 등급(현행)	± 0.0000	± 0.0000
타깃 폭	태그 수	-0.0557	-0.0513
타깃 폭	연령 등급(역)	-0.0982	-0.0794
타깃 폭	장르 수	-0.1027	-0.0781
굿즈 규모	태그 수	-0.0130	-0.0175
굿즈 규모	화수	-0.0316	-0.0322

1. 한 장씩 넣는다

한꺼번에 대상 인자 공간을 평가 대상 전체로 만든다(노트 76까지)
 하나 빼고 레코드 i 를 뺀 나머지로 만들고 i 를 투영한다
 과거 공간 T 이전 대상 레코드로 만들고 미래를 묶어서 투영한다
 완전 한 건씩 같은 공간에 미래를 하나씩 넣는다 — 제품 그대로

주장 1. 전도적 가정은 값을 안 치른다 — 가장 느슨한 규약과 가장 엄격한 규약의 차이가 0.011이다. 기획서를 한 장씩 넣어도 묶어서 넣은 것과 같은 성적이 나온다.

반증 조건. 네 규약 모두 팝업 하나 · 시점 하나에서 왔다. 구간 반폭이 0.23이라 0.011짜리 차이는 어차피 못 가른다 — “같다”는 것은 “다르다는 증거가 없다”는 뜻이다.

한 건은 줄을 못 세운다. 구현에서 합정을 하나 만났다. 앙상블이 순위 평균인데 레코드가 하나뿐이면 rankdata가 항상 1을 낸다. 처음 짰 코드가 $\rho = -0.006$ 을 냈고

그것이 버그였다. 새 기획 하나를 적합 집합과 함께 투영해 그 안에서 자리를 쟁다. 제품이 내는 문장도 그것이다 — “지금까지 연 팝업 중 상위 몇 퍼센트인가.”

2. 2025년을 못 본 분석가

배선과 축은 여전히 전체 데이터로 골랐다. 2025년 이전만 남기고 후보 79개를 다시 돌렸다(팝업은 과거가 16건뿐이라 이 분석에서 빠지고 일곱 도메인이다).

노트 75의 결정 — 태그 수를 버리고 연령 등급으로 — 이 과거 데이터로도 그대로 나온다(-0.0557). 2025년을 못 본 분석가도 같은 배선을 골랐다.

주장 2. 채택된 설계 결정은 시간 누출이 아니다. 후보 79개에서 과거만 Δ 와 전체 Δ 의 상관이 +0.867이고, 채택된 것들은 전부 $|\Delta| > 0.03$ 인 큰 결정이라 부호가 바뀌지 않는다.

반증 조건. +0.867은 큰 결정들이 끌어올린 값이다. 작은 결정에서는 상관이 훨씬 낮다 — 바로 다음 절이 그것이다.




Figure 1: 왼쪽 — 규약 넷의 미래 팝업 ρ . 오른쪽 — 과거만 데이터와 전체 데이터에서 본 배선 후보의 Δ .

Table 3: 과거만 데이터에서 가장 좋아 보이는 다섯. 전체에서는 전부 잡음이다.

도메인	후보	과거만	전체
애니	더빙	+0.0080	+0.0027
웹툰	회차 수	+0.0068	-0.0038
아이돌	인원 수	+0.0034	-0.0034
웹툰	작가 수	+0.0031	+0.0001
웹툰	작가 수	+0.0027	+0.0014

Table 4: 누출 점검표.

대상 라벨을 모형이 보는가	안 본다(설계상)
출처가 미래를 보는가	안 본다(노트 76)
대상 공간이 미래를 보는가	안 본다(규약 ④)
평가가 보정 표본을 쓰는가	안 쓴다(노트 70)
설계 결정이 미래를 보는가	본다 — 그러나 결과가 같다

3. 자르면 누출이 다시 좋아 보인다

둘째 줄이 눈에 띈다. 웹툰 회차 수는 노트 46이 “연재 기간에 비례해 사후 누적된다”며 뺀 것이고 노트 67이 -0.1019 로 명확히 나빠짐을 확인한 누출 후보다. 과거만 데이터에서는 $+0.0068$ 로 좋아 보인다.

주장 3. 표본을 시간으로 자르면 사후 누적 변수가 다시 좋아 보인다. 자른 표본에서는 누적 기간이 짧아 누출 신호가 약해지고, 남은 상관이 진짜처럼 보인다.

반증 조건. 과거만 $+0.0068$ 도 반쪽 아래라 애초에 채택 대상이 아니다. “속을 뻘뻘했다”가 아니라 “속을 수 있는 구조다”까지만 말할 수 있다.

4. 남은 것

이것으로 알고 있던 누출을 전부 막았다.

마지막 줄만 형식적으로 열려 있다. 배선을 전체 데이터로 골랐다는 사실 자체는 남아 있고, “골랐어도 결과가

같다”는 것을 이 노트가 보였을 뿐이다. 완전히 막으려면 앞으로의 결정을 과거 데이터로만 내려야 한다.

5. 한계

- 규약 넷의 차이가 0.011인데 구간 반폭이 0.23이다. 넷이 같다는 것은 “다르다는 증거가 없다”는 뜻이다.
- 과거 공간을 팝업 16건으로 만든다. 다섯 축에 16건이라 주성분이 몹시 불안정할 텐데 성적이 안 떨어진 것이 오히려 이상하다.
- 시간 분할 배선 탐색에서 팝업이 빠졌다(과거 16건 < 문턱 40). 팝업 배선 결정은 이 검사를 못 받았다.
- 누출 점검표의 마지막 줄은 여전히 열려 있다.
- 애니 후보 하나가 과거만 0.000, 전체 -0.115 로 크게 어긋난다. 안 봤다.

6. 다음

1. 앞으로의 설계 결정은 과거 데이터로만 내리고 미래로 검증한다. 규약을 코드에 넣는다.
2. 아홉째 도메인 — 배선이 닫혔으므로(노트 76) 남은 지렛대는 이것뿐이다.
3. 팝업 과거 표본이 16건이라 규약 ④가 불안정하다. 시점을 옮겨 가며 민감도를 본다.
4. 애니가 시간을 자를 때 좋아지는 이유(노트 76의 남은 숙제).

참고문헌

- Kaufman, S., Rosset, S., Perlich, C. (2012). Leakage in data mining. ACM TKDD, 6(4), 1–21.
- Bergmeir, C., Benitez, J. M. (2012). On the use of cross-validation for time series predictor evaluation. Information Sciences, 191, 192–213.
- Cawley, G. C., Talbot, N. L. C. (2010). On over-fitting in model

selection and subsequent selection bias in performance evaluation.
JMLR, 11, 2079–2107.

Vapnik, V. (1998). Statistical Learning Theory. Wiley.

Efron, B., Tibshirani, R. J. (1993). An Introduction to the Bootstrap. Chapman & Hall.