

IP 파운데이션 월드모델 연구 노트 83

둘째 출처가 나머지 여섯보다 값졌다

도메인은 정확도가 아니라 정밀도를 산다 --- 그리고 노트 81의 신뢰도 하나를 철회한다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

먼저 철회할 것이 있다. 노트 81이 애니 라벨 신뢰도를 +0.784(32건)로 적고 “웹툰↔만화의 +0.524와 겹치지 않으니 두 쌍의 신뢰도가 실제로 다르다”고 했다. 매칭을 32건에서 87건으로 늘리니 +0.5554 [+0.336, +0.734]로 내려온다. 원래 32건은 제목이 정확히 맞는 것만 걸린 유명작 편향이었다. 두 쌍이 0.52와 0.56으로 겹치고, 천장 추정은 0.72~0.75로 좁혀진다. 본론은 노트 82가 남긴 질문이다 — 출처 하나를 빼는 것이 무해하다면 몇 개까지 빼도 되나. 대상 집합을 고정하고 출처를 m 개만 써서 앙상블했다. 곡선이 $m=2$ 에서 이미 평평하다 — $m=1 \rightarrow 2$ 가 +0.0139인데 $m=2 \rightarrow 8$ 이 다 합쳐 +0.0099다. 둘째 출처가 나머지 여섯을 합친 것보다 값진다. 적합이 $\rho(m) = 0.383 + 0.0109 \ln m$ 이라 출처를 스몰로 늘려도 +0.4157, 서론으로 늘려도 +0.4201이다(지금 여덟이 +0.4030). 도메인을 더 모으는 것은 정확도를 거의 안 산다. 그런데 노트 81에서 열째 도메인이 반쪽을 0.0388에서 0.0334로 줄였다. 도메인은 정확도가 아니라 정밀도를 산다. 그러면 정확도의 남은 지렛대는 하나뿐이다 — 배선은 닫혔고(노트 76) 부분집합도 닫혔고(노트 80) 도메인도 닫혔으니 새 물리량이다.

Table 1: 같은 작품을 두 플랫폼이 겐 값의 상관.

쌍	n	ρ	95% 구간
웹툰 ↔ 만화(노트 79)	327	+0.524	—
애니 ↔ 세계애니(노트 81)	32	+0.784	[+0.625, +0.870]
애니 ↔ 세계애니(정정)	72	+0.555	[+0.336, +0.734]

Table 2: 출처 m 개로 앙상블. 열 대상 평균, 조합마다 60회 표집.

m	평균 ρ	직전 대비
1	+0.3792	—
2	+0.3931	+0.0139
3	+0.3973	+0.0042
4	+0.4004	+0.0031
5	+0.4019	+0.0015
6	+0.4017	−0.0002
7	+0.4027	+0.0010
8	+0.4030	+0.0003

1. 철회 --- 애니 신뢰도 0.784

노트 81의 32건은 라프텔 한국어 제목이 AniList 제목과 정확히 맞는 것만 걸린 것이라 유명작에 쏠려 있었다. AniList 검색 API로 라프텔 제목 2,073개를 직접 조회해 87건(중복 제거 72건)으로 늘리니 +0.5554로 내려온다.

주장 1. 노트 81의 “두 쌍의 신뢰도가 실제로 다르다”를 철회한다. 두 쌍이 +0.524와 +0.555로 겹치고, 라벨 신뢰도는 0.52~0.56, 천장은 0.72~0.75로 좁혀진다.

반증 조건. 정정한 72건에는 시즌 오매칭이 섞여 있다 (AniList 검색이 “진격의 거인”에 최종 시즌을 준다). 그 잡음이 ρ 를 낮추므로 진값은 0.555보다 높을 것이다.

천장이 0.72~0.75면 현재 위치는 — 팝업 제품 수치 +0.527이 71%, 판정치 +0.404가 55%다.

2. 출처는 둘이면 거의 다 온다

주장 2. 앙상블은 출처 두 개에서 이미 포화한다. $m=1 \rightarrow 2$ 가 +0.0139이고 $m=2 \rightarrow 8$ 이 여섯 개를 더해 +0.0099

Table 3: $\rho(m) = 0.3829 + 0.0109 \ln m$ 의 외삽.

출처 수	예상 ρ
8 (지금)	+0.4030
12	+0.4101
20	+0.4157
30	+0.4201

다 — 둘째 출처가 나머지 여섯을 합친 것보다 값진다.

반증 조건. 조합을 무작위로 뽑아 평균했으므로 “어떤 둘이냐”는 안 봤다. 좋은 둘을 고르면 더 높고 나쁜 둘은 더 낮을 것이며, 고르려면 대상 라벨이 든다(노트 71).

도메인을 지금의 세 배로 늘려도 +0.017이다. 정확도를 사려면 도메인이 아니다.


Figure 1: 왼쪽 — 출처 m 개로 앙상블할 때 (회색이 대상별). 오른쪽 — 라벨 신뢰도 두 쌍과 정정.

Table 4: 도메인을 하나 더할 때 무엇이 바뀌나.

	9도메인	10도메인
판정치	+0.4003	+0.4038
구간 반폭	0.0388	0.0334

Table 5: 지렛대 점검표.

배선 재탐색	단행(노트 76, 후보 92개 전부 문턱 아래)
잠음 부분집합	단행(노트 80, 45개 중 채택 0)
도메인 추가	정밀도만(이 노트)
도메인 제거	무의미(노트 82, 전부 보류)
방향 교정	무의미(노트 73 · 82의 희석)
학습된 가중치	무의미(노트 73, 게이트가 균등과 같음)
레코드 추가	포화(노트 68)
새 물리량	미탐색

3. 도메인은 정밀도를 산다

노트 81의 짝지는 측정이다. 평균은 +0.0035 오르는데 반폭은 14% 줄었다. 도메인의 값은 정밀도에 있다.

둘을 나눠 보면 로드맵이 정리된다. 구간을 좁히려면 도메인(노트 69의 셀 수 법칙, 다섯에서 열까지 유지). 평균을 올리려면 도메인이 아니다 — 배선은 닫혔고(노트 76) 부분집합도 닫혔고(노트 80) 도메인도 닫혔다. 남은 것은 새 물리량이다.

4. 남은 지렛대

노트 76이 배선을 닫으며 반증 조건을 이렇게 적었다 — “후보 풀이 내가 등록한 것뿐이다. 새 물리량을 수집해 후보에 넣으면 다를 수 있다.” 그것이 지금 유일하게 안 열어 본 문이다.

5. 한계

- 학습 곡선을 무작위 조합으로 냈다. 실제로는 출처를 고를 수 있으므로 상한이 더 높다 — 다만 고르려면 대상 라벨이 든다.
- $\ln m$ 적합한 여덟 점이다. 스물 · 서른의 외삽은 가정이다.
- 정정한 애니 신뢰도 72건에 시즌 오매칭이 섞여 있어 아래로 편향됐다.
- “새 물리량이 유일한 지렛대”는 지금까지 시도한 것들의 목록에서 나온 말이다. 안 떠올린 것이 있을 수 있다.
- 곡선을 판정치(대상 평균)로 냈다. 팝업만 보면 다를 수 있는데 노트 75가 팝업으로는 못 켜다고 했다.

6. 다음

1. 새 물리량을 수집한다. 기존 도메인에 지금 없는 축 재료를 붙인다 — 예를 들어 가격대별 판매 구성, 리뷰 텍스트 길이, 출시 시기의 경쟁 밀도.
2. 좋은 출처 둘을 고르는 값 — 대상 라벨 k 건으로 상위 둘을 고르면 무작위 둘보다 얼마나 나은가.
3. 팝업 라벨의 신뢰도. 천장이 0.72~0.75인지 팝업에서도 그런지.
4. 열한째 도메인은 정밀도가 필요할 때만.

참고문헌

- Breiman, L. (1996). Bagging predictors. *Machine Learning*, 24(2), 123–140.
- Kuncheva, L. I., Whitaker, C. J. (2003). Measures of diversity in classifier ensembles. *Machine Learning*, 51(2), 181–207.
- Lord, F. M., Novick, M. R. (1968). *Statistical Theories of Mental Test Scores*. Addison-Wesley.

Ben-David, S. et al. (2010). A theory of learning from different domains. *Machine Learning*, 79(1–2), 151–175.

Efron, B., Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall.