

IP 파운데이션 월드모델 연구 노트 84

뒷개울 0.6이 가장 센 축을 버리고 있었다

새 물리량은 있었다 --- 못 받은 것은 구조였다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 83이 “새 물리량이 유일하게 안 열어 본 문”이라 했다. 셋을 만들어 열었다. 경쟁 밀도(자기보다 먼저 같은 창에 나온 것의 수)는 공통 축으로도 고유 축으로도 -0.02 다. 전형성(태그가 도메인 전형에 얼마나 가까운가)은 -0.0085 다. 둘 다 실패. 직전작 성적(같은 창작자의 자기보다 먼저 나온 작품의 라벨)은 다르다 — 도메인 안 상관이 모바일 $+0.709$, 펀딩 $+0.649$, 게임 $+0.629$ 다. 모바일의 $+0.709$ 는 그 도메인 인자 공간의 자기 상관($+0.656$)보다 높다. 축 하나가 여섯 축을 이긴다. 그런데 모형에 넣으면 $\Delta -0.0008$ 이고, 여덟 도메인 중 일곱에서 정확히 ± 0.0000 이다. 희석이 아니라 완전 무시다. 범인을 찾았다 — factor_space 의 min_cov=0.6. 직전작 성적의 뒷개울이 12~58%라 전부 문턱 아래로 버려지고, 92%인 세계애니만 통과해 그것만 $+0.0279$ 였다. 관측된 레코드에서만 재면 모바일 자기 ρ 가 $+0.665$ 에서 $+0.784$ 로, 애니가 $+0.324$ 에서 $+0.426$ 으로 오른다(일곱 중 다섯 상승). 문턱이 있는 이유도 분명하다 — 인자 공간이 완전 케이스만 쓰므로 뒷개울 36%인 축을 넣으면 표본이 36%로 준다. 물리량은 있었고 구조가 못 받았다. 노트 83의 로드맵을 고친다 — 남은 지렛대는 물리량이 아니라 구조이고, 그것이 노트 60–62의 신경망 질문을 다시 연다.

Table 1: 판정지 효과. 현행 $+0.4038$.

경쟁 밀도(공통 축, 창 365일)	-0.0195
경쟁 밀도(고유 축)	-0.0218
전형성(고유 축)	-0.0085
직전작 성적(고유 축)	-0.0008

Table 2: 직전작 성적과 라벨의 도메인 안 순위 상관.

	ρ	관측
모바일	$+0.709$	722
펀딩	$+0.649$	48
게임	$+0.629$	184
애니	$+0.365$	1204
도서	$+0.337$	120
웹툰	$+0.305$	1104
세계애니	$+0.085$	2723
만화	$+0.049$	624

1. 새 물리량 셋

경쟁 밀도는 열 도메인이 문자 그대로 같은 것을 재는 것 양이라 네 번째 공통 축 후보였다(노트 37: 공통 축이 성분보다 적으면 회전이 과소결정된다). 창을 90일에서 1,825일까지 바꿔도 전부 $-0.017 \sim -0.024$ 다. 축이 이미 시간으로 탈추세돼 있어 시간과 거의 같은 양을 다시 넣는 셈이기 때문으로 보인다.

2. 직전작 성적은 다르다

지금 매장 노출도는 창작자의 사전 작품 수만 센다. 그 작품들이 얼마나 잘됐는지는 안 쓴다. 같은 창작자의 먼저 나온 작품의 라벨은 출시 시점에 이미 알려진 값이라 누출이 아니고, 제품 관점에서도 맞다 — 우리는 우리 과거 팝업의 성적을 안다.

주장 1. 직전작 성적은 이 프로젝트에서 나온 가장 강한 단일 변수다. 모바일에서 $\rho = +0.709$ 로 그 도메인 인자 공간 전체의 자기 상관($+0.656$)보다 높다.


반증 조건. 여덟 중 둘(만화 $+0.049$, 세계애니 $+0.085$)은 거의 0이다. 두 도메인 다 제작사/스튜디오를 키로 썼는데 대형 스튜디오가 작품 수가 많아 직전작이 대표성이 없기 때문일 수 있다.

3. 그런데 모형이 안 받는다

정확히 0이다. 희석이면 작은 값이라도 나와야 한다. 세계애니 하나만 다르고, 그 하나가 유일하게 뒷개울 92%다.

주장 2. factor_space 의 min_cov=0.6 문턱이 직전작 성적을 통째로 버리고 있었다. 뒷개울이 12~58%라 여덟 중 일곱이 문턱 아래이고, 문턱을 넘은 하나만 $+0.0279$ 를 냈다.

반증 조건. 문턱에는 이유가 있다 — 인자 공간은 완전 케이스만 쓰므로 뒷개울 36%인 축을 넣으면 표본이 36%로 준다. 문턱을 그냥 내리면 표본이 무너진다.

Figure 1: 왼쪽 — 직전작 성적이 관측된 레코드에서만 켄 자기 ρ , 오른쪽 — 새 물리량 셋의 판정치 효과.Table 3: 도메인 안 자기 ρ — 직전작 축을 더할 때.

	현행	+ 직전작	Δ
게임	+0.3645	+0.3645	± 0.0000
도서	+0.2016	+0.2016	± 0.0000
편딩	+0.1899	+0.1899	± 0.0000
웹툰	+0.4803	+0.4803	± 0.0000
애니	+0.2913	+0.2913	± 0.0000
모바일	+0.6559	+0.6559	± 0.0000
만화	+0.4773	+0.4773	± 0.0000
세계애니	+0.4182	+0.4461	+0.0279

Table 4: 직전작이 관측된 레코드에서만 켄 자기 ρ .

	뒷개울	없이	넣고	Δ
모바일	36%	+0.665	+0.784	+0.119
애니	58%	+0.324	+0.426	+0.102
게임	38%	+0.444	+0.505	+0.061
웹툰	39%	+0.481	+0.516	+0.035
세계애니	92%	+0.421	+0.446	+0.025
도서	49%	+0.215	+0.203	-0.012
만화	35%	+0.504	+0.477	-0.027

4. 관측된 곳에서는 크게 오른다

일곱 중 다섯이 오르고 모바일이 +0.784에 달는다 — 노트 83이 낸 라벨 천장 추정 0.72~0.75보다 높다. 둘 중 하나다. 천장 추정이 낮거나 (웹툰/애니 쌍에서 켜), 모바일 라벨의 신뢰도가 그 둘보다 높거나.

5. 로드맵을 고친다

노트 83은 지렛대 점검표에서 “새 물리량”만 미탐색으로 남기고 그것이 유일한 길이라 했다. 틀렸다. 물리량은 있었고 — 단일 상관 +0.709짜리가 — 구조가 못 받았다.

남은 지렛대는 구조다. 인자 공간이 완전 케이스를 요구하는 한, 뒷개울이 낮은 축은 아무리 세도 못 쓴다. 마스크를 입력으로 받는 모형은 그 요구가 없다 — 노트 60-62의 공유 인코더가 정확히 그 구조였고 (값 다섯 + 마스크 다섯), 그때는 PCA+프로크루스테스에 졌다. 그때는 못 쓸 축이 없었기 때문이다. 지금은 있다.

6. 한계

- “관측된 곳에서만” 켄 자기 ρ 는 표본이 다르므로 전체와 직접 비교 못 한다. 부분집합이 유리한 쪽으로 치우쳤을 수 있다.
- 직전작 성적은 대상 라벨(다른 레코드의)을 쓴다. 전이 설정에서 대상에 쓰려면 그 도메인의 과거 라벨을 알아야 한다 — 팝업은 알지만 새 카테고리 모른다.
- 팝업에는 창작자/IP 키가 레코드에 없어 직전작 성적을 못 만들었다. 제품에서 가장 값진 자리인데 못 켜.
- 문턱을 실제로 내려서 재 보지 않았다. 표본이 얼마나 무너지는지 안 봤다.
- 경쟁 밀도의 실패를 “시간과 겹쳐서”로 설명했는데 확인 안 했다.

7. 다음

- 마스크를 입력으로 받는 모형을 다시 만든다(노트 60-62의 재도전). 이번에는 못 쓸 축이 있다는 점이 다르다.
- 팝업 레코드에 IP/브랜드 키를 붙여 직전작 성적을 만든다. 제품에서 가장 값진 자리다.
- $\min_cov$ 를 내리며 표본 손실과 이득의 교환을 켜 — 구조를 안 바꾸고 얻을 수 있는 몫이 얼마인지.
- 모바일 자기 ρ +0.784가 천장 추정을 넘는 것 — 천장을 다시 켜.

참고문헌

- Little, R. J. A., Rubin, D. B. (2019). Statistical Analysis with Missing Data, 3rd ed. Wiley.
- Josse, J. et al. (2019). On the consistency of supervised learning with missing values. arXiv:1902.06931.
- Ilin, A., Raiko, T. (2010). Practical approaches to principal component analysis in the presence of missing values. JMLR, 11, 1957–2000.
- Yoon, J. et al. (2018). GAIN: missing data imputation using generative adversarial nets. ICML, 5689–5698.
- Ben-David, S. et al. (2010). A theory of learning from different domains. Machine Learning, 79(1–2), 151–175.