

IP 파운데이션 월드모델 연구 노트 264

채우는 쪽을 적어 두기

손으로 두 번 찾은 것을 가드로 옮겼다 --- 그리고 그 가드가 첫 판에 자기가 안 보는 값으로 판정했다

Sweetspot 월드모델 연구

2026년 7월 31일

초 록

노트 262 · 263이 새는 축을 둘 찾았는데 둘 다 손으로 찾았다 — 소스를 읽다가 우연히 봤다. 같은 틈이 또 있으면 또 우연에 기대야 한다. 그 틈의 정체는 분명하다: **provenance.WHEN** 은 축 이름에 뜻을 붙이는데 (**entry_friction** = “기획서 태깅”) 손 축 다섯은 도메인마다 다른 필드로 채워진다. 그래서 채우는 쪽 표 (**SOURCE**, 20쌍)를 적고 가드 열여덟 쌍임을 붙였다 — 레코드에서 원본 필드를 꺼내 라벨을 안 보고 둘을 켜다: 연도와의 순위 상관, 유보 평균 대 학습 평균의 비. 첫 실행에서 걸렸다: 모바일 **media_push**(← **n_shot**), 연도 -0.33, 비 4%. 고치려고 재 보니 판이 정확히 +0.0000 — 노트 187의 제일 값싼 검사다. **n_shot** 이 0 이면 축 빌더가 이미 마스크 0 으로 내리고 있었고(86.4%가 0 이다), 내 가드는 모형을 안 보는 값으로 판정하고 있었다. 관측된 행에서만 재도록 고치니 무늬가 사라진다. 고친 가드를 막기 전 판에 돌리니 손으로 찾은 둘을 그대로 묻다 — 웹툰 **entry_friction**(연도 -0.44, 비 32%)과 **goods_scale**(연도 -0.49, 비 45%). 지금 판에서는 원본 필드 13개를 검사하고 통과한다. 가드가 자기 검사에 한 번 걸린 것이 이 노트의 값이다 — 가드도 축과 같은 규칙을 지켜야 한다.

1. 두 번 다 우연이었다

노트 262는 **venue_prominence** 의 정의를 확인하려고 소스를 열었다가 **entry_friction** 이 **daily_pass** 인 것을 봤다. 노트 263은 그 노트가 남긴 숙제를 따라 나머지를 훑다가 **goods_scale** 이 **n_episode** 인 것을 봤다. 둘 다 손으로 찾았다.

틈의 정체는 분명하다.

WHEN 이 아는 것	entry_friction : PRE “기획서 태깅”
실제로 채우는 것	웹툰 daily_pass · 애니 가격 · 모바일 가격 · 만화 성인 여부 ...

한 이름에 뜻 하나를 붙였는데 아홉 도메인이 아홉 필드로 채운다. 여덟은 뜻이 맞고 하나는 안 맞았다.

2. 채우는 쪽 표와 가드 열여덟

provenance.SOURCE 에 (도메인, 축) → 원본 필드를 20 쌍 적었다. 가드 쌍임이 그 표를 읽어 레코드에서 필드를 꺼내 두 가지를 켜다.

검사	왜
연도와의 순위 상관	쌍이는 양은 옛것일수록 크다
유보 평균 / 학습 평균	쌍이는 양은 최근이 작다

라벨을 안 본다 — 노트 214의 한철, 노트 240의 접말과 같은 부류다. 그리고 노트 263의 교훈대로 유보 표본이 30건 미만이면 건너뛰다(만화는 유보 여섯 건이라 “학습 113 대 유보 44”가 여섯 건의 평균이었다).




Figure 1: 왼쪽 — 가드가 처음 문 것. 오른쪽 — 고친 가드를 막기 전 판에 돌린 결과.

3. 가드가 자기 검사에 걸렸다

첫 실행에서 하나 걸렸다.

모바일 **media_push**(**n_shot**) 연도 -0.33 비 4%
— 예측 시점 뒤에 사라다

비 4% 는 웹툰(45%)보다 훨씬 심하다. 그런데 스크린샷은 쌍이지 않는다. 분포를 보니 0 인 비율이 최근일수록 오른다 — 68% → 91% → 93% → 99%. 쌍임이 아니라 수집이 최근 것을 놓친 것이다.

고치려고 두 가지를 켜다 — 0 을 결측으로 돌리기, 축을 통째로 막기.

	판	짝 차
지금	0.4842	—
0 을 결측으로	0.4842	+0.0000
축 통째로 막음	0.4836	-0.0006

정확히 +0.0000. 노트 187의 제일 값싼 검사다 — “판이 넷째 자리까지 안 움직이면 효과가 없는 게 아니라 모형에 안 닿은 것”. 소스를 보니 `mobile_axes.py` 가 `if ns:` 안에서만 값을 넣는다. 0 인 행은 이미 마스크 0 이었다.

즉 내 가드는 모형이 한 번도 안 보는 값 86.4%를 섞어 무늬를 만들고 있었다. 축이 지켜야 하는 규칙 — 관측된 행에서만 읽는다 — 을 가드가 안 지켰다.

4. 고치니 되짚어 묻다

관측 마스크를 씌우도록 고쳤다. 지금 판에서는 원본 필드 13개를 검사하고 통과한다. 그리고 막기 전 판(노트 262 이전)에 돌리면

웹툰 `entry_friction(daily_pass)` 연도 -0.44
비 32% · 웹툰 `goods_scale(n_episode)` 연도
-0.49 비 45%

손으로 찾은 둘을 그대로 묻다. 우연에 기대던 것이 이제 자동이다.

가드	개수	
지금 판	9/9	쌓임 포함 전부 통과
막기 전 판	8/9	쌓임 실패 (둘 지목)

5. 가드도 축과 같은 규칙을 지켜야 한다

이 노트에서 실제로 배운 것은 표나 가드가 아니라 그 다음이다. 나는 노트 231에서 “판정치가 죽은 것을 숨긴다”를 고쳤고, 노트 248에서 “도메인별 수는 SE 와 함께”를 세웠고, 노트 261에서 “실린 무게로 기여를 읽지 않는다”를 적었다. 전부 재는 쪽의 규칙이다.

그런데 가드를 새로 쓸 때 그 규칙을 안 적용했다. 가드는 축을 검사하는 코드지 검사에서 면제된 코드가 아니다. 이번엔 노트 187의 값싼 검사가 잡아 졌는데, 그 검사를 안 돌렸으면 모바일 축 하나를 근거 없이 막았을 것이다 — 그리고 판이 안 움직이니 눈치도 못 챘을 것이다.

남은 것.

갈래	왜
SOURCE 채우기	20쌍 적었다. 손 축 × 도메인은 45쌍이다
수집 편중	<code>n_shot</code> 0 이 최근 99% — 다시 굵으면
23축 천장	두 번 막았으니 다시 재야 한다
라벨 자체	노트 209의 누적 라벨. 축만 고쳤다

규약. 새 가드를 붙이면 그 가드가 이미 아는 사건을 되짚어 무는지 먼저 확인한다. 이번엔 노트 262 · 263의 두 축이 시험지였고, 그것을 안 돌렸으면 가드가 틀린 채로 통과했을 것이다.