

IP 파운데이션 월드모델 연구 노트 86

무라벨 전제의 값을 처음 줬다

팝업에서 0.39다 --- 라벨을 쓰면 인코더가 천장에 닿는다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 85가 공유 인코더의 패배를 “쌍별 정렬 자유도 상실”로 진단했다. 검정했다 — 인코더로 표현을 만들고 정렬만 쌍별 프로크루스테스로 되돌리니 +0.3575에서 +0.3692다. 현행 +0.4038과의 격차 0.0463 중 4분의 1만 회복된다. 진단은 부분적으로 맞았다 — 아이돌이 +0.161에서 +0.252로 크게 살아난다(작은 도메인에서 정렬이 중요하다). 나머지 4분의 3을 찾다가 이 프로젝트에서 가장 큰 수를 만났다. 그 도메인의 라벨을 쓰면 인코더가 팝업을 +0.7104, 아이돌을 +0.7986으로 맞힌다 — 노트 83이 낸 라벨 천장 추정 0.72~0.75에 닿는다. 라벨 지도를 빼면 +0.3199 · +0.3461로 떨어진다. 무라벨 전제의 값이 팝업에서 0.39, 아이돌에서 0.45다. 지금까지 모든 개선이 0.01 단위였는데 전제 하나가 0.39다. 그래서 제품에서 풀어 봤다 — 2025년 이전 팝업 16건의 라벨은 우리가 안다. 썼더니 오히려 내렸다 (+0.5192 → +0.3866). 16건으로는 머리를 못 적합하고 출처 아홉의 앙상블을 버리는 값이 더 크다. 전이 모형의 한계는 구조가 아니라 전제이며, 전제를 풀려면 팝업 라벨이 수백 건 필요하다 — 노트 75가 다른 길로 낸 510건과 같은 자리다.

Table 1: 판정치.

	ρ	
현행 인자 공간	+0.4038	—
인코더만	+0.3575	-0.0463
인코더 + 프로크루스테스	+0.3692	-0.0346

Table 2: 인코더 표현의 자기 ρ , 라벨 지도의 유무로 가른다.

	인자 공간	라벨 안 씀	라벨 씀
아이돌	+0.472	+0.346	+0.799
팝업	+0.368	+0.320	+0.710
애니	+0.291	+0.317	+0.523
모바일	+0.656	+0.552	+0.672
게임	+0.365	+0.456	+0.530
웹툰	+0.480	+0.470	+0.528
평균	+0.392	+0.377	+0.528

1. 진단은 4분의 1만 맞았다

노트 85는 공유 인코더가 프로크루스테스를 얹은 것이 패인이라고 봤다. 표현은 인코더로 두고 정렬만 되돌린다 — 잠재 차원과 공통 축의 상관을 적재로 써서 쌍마다 프로크루스테스를 건다.

정렬을 되돌려 +0.0117을 회복한다 — 격차의 25%다. 대상별로는 아이돌이 +0.161에서 +0.252로 크게 살아나고 팝업은 +0.459에서 +0.387로 내린다.

주장 1. 쌍별 정렬 자유도는 격차의 4분의 1이다. 작은 도메인에서 특히 크다(아이돌 +0.09). 나머지 4분의 3은 다른 데 있다.

반증 조건. 프로크루스테스 적재를 고유벡터가 아니라 상관으로 근사했다. 인코더가 비선형이라 정확한 적재가 없어 쓴 대리이며, 그 근사가 회복을 깎았을 수 있다.

2. 라벨을 쓰면 천장에 닿는다

나머지를 찾다가 표현 자체를 재 봤다 — 도메인 안 교차 검증 자기 ρ .

라벨을 안 쓰면 인코더가 인자 공간과 비슷하다 (+0.377 대 +0.392). 쓰면 +0.528이고, 팝업 +0.710 ·

아이돌 +0.799는 노트 83의 라벨 천장 추정(0.72~0.75)에 닿거나 넘는다.

주장 2. 전이 모형이 +0.40에 머무는 것은 구조나 물리량 때문이 아니라 대상 라벨을 안 쓴다는 전제 때문이다. 그 전제를 풀면 팝업이 +0.320에서 +0.710으로, 아이돌이 +0.346에서 +0.799로 간다 — 값이 0.39와 0.45다.

반증 조건. “라벨 씀”은 그 도메인의 라벨 전부를 지도에 넣고 최종 능형만 교차검증한 것이다. 인코더 자체는 라벨을 봤으므로 낙관적이다 — 얼마나 낙관적인지는 다음 절이 보인다.

지금까지의 개선은 전부 0.01 단위였다 — 배선 +0.068(노트 75), 도메인 추가 +0.004, 결측 표시자 +0.014. 전제 하나가 0.39다.




Figure 1: 왼쪽 — 그 도메인 라벨을 쓸 때와 안 쓸 때의 자기 ρ . 오른쪽 — 인코더 격차의 분해.

Table 3: 미래 팝업 59건. 시점 2025.

	ρ	95% 구간
라벨 안 씀(노트 77 규약)	$+0.5192$	$[+0.298, +0.694]$
과거 16건 라벨 사용	$+0.3866$	$[+0.184, +0.584]$

Table 4: 팝업 표본이 사는 것.

지금 75건	순위 $+0.52$, 설계 판정 불가
~510건	실제 결정을 팝업 기준으로 판정(노트 75)
~수백 건	무라벨 전제를 풀어 $+0.71$ 쪽으로(이 노트)

3. 제품에서 풀어 보면 --- 아직 못 산다

제품은 무라벨이 아니다. 스위트스팹은 지금까지 연 팝업의 성적을 안다. 노트 77의 규약은 과거 팝업의 축만 쓰고 라벨은 안 썼다. 시점 2025로 가르면 과거 16건의 라벨을 쓸 수 있다.

오히려 내린다. 16건으로는 머리를 못 적합하고, 그러느라 출처 아홉의 양상블을 버리는 값이 더 크다.

주장 3. 과거 라벨 16건으로는 무라벨 전제를 못 산다. 전제의 값이 0.39라는 것과 그것을 16건으로 살 수 있다는 것은 다른 말이다.

반증 조건. 16건으로 머리를 적합하는 방식만 봤다. 양상블과 섞거나 사전분포를 강하게 주면 다를 수 있는데 안 해 봤다.

4. 두 길이 같은 곳을 가리킨다

노트 75는 다른 길로 왔다 — 팝업 75건으로는 설계 결정을 판정할 수 없고, 0.02짜리 효과를 가리려면 약 510건이 필요하다. 이 노트는 다른 쪽에서 같은 결론에 닿는다 — 무라벨 전제를 풀면 0.39를 얻는데, 16건으로는 못 사고 수백 건이 든다.

모델 쪽 지렛대는 대부분 닫혔고(노트 76 배선 · 80

부분집합 · 82 도메인 제거 · 83 도메인 추가 · 85 구조) 남은 것은 팝업 표본이다.

5. 한계

- “라벨 씀” 수치는 인코더가 라벨을 봤으므로 낙관적이다. 진짜 상한은 그보다 낮다 — 얼마나인지 안 됐다.
- 과거 16건 실험을 한 방식(머리 적합)으로만 했다.
- 인코더 설정을 넓게 안 훑었다(노트 85의 한계 그대로).
- 프로크루스테스 적재를 상관으로 근사했다.
- 팝업 라벨(일평균 방문자)의 신뢰도를 여전히 모른다. 천장이 0.72~0.75인지 팝업에서도 그런지 확인 못 했다.

6. 다음

- “라벨 씀”의 정직한 상한을 쟀다 — 인코더 학습에서도 교차검증 분할을 지켜 낙관 편향을 없앴다.
- 과거 라벨을 양상블에 섞는 방식을 시도한다 — 머리를 갈아 끼우지 말고 출처 하나로 더한다.
- 라벨 k 건으로 얻는 값의 곡선 — $16 \cdot 30 \cdot 50$ 건에서 언제 넘어서는가.
- 팝업 라벨 신뢰도. 같은 팝업을 두 번 쟀 자료(현장 계수 대 정산 데이터 등)가 있는지 확인한다.

참고문헌

- Ben-David, S. et al. (2010). A theory of learning from different domains. *Machine Learning*, 79(1–2), 151–175.
- Rebuffi, S.-A. et al. (2017). Learning multiple visual domains with residual adapters. *NIPS*, 506–516.
- Grinsztajn, L. et al. (2022). Why do tree-based models still outperform deep learning on typical tabular data? *NeurIPS*.

Lord, F. M., Novick, M. R. (1968). Statistical Theories of Mental Test Scores. Addison-Wesley.

Kaufman, S., Rosset, S., Perlich, C. (2012). Leakage in data mining. ACM TKDD, 6(4), 1–21.