

IP 파운데이션 월드모델 연구 노트 87

## 어제의 0.39는 0.006이었다

노트 86의 헤드라인을 철회한다 --- 신경망이 작은 도메인을 외운 것을 실력으로 읽었다

Sweetspot 월드모델 연구

2026년 7월 29일

## 초 록

노트 86이 “무라벨 전제의 값이 팝업에서 0.39”라고 적었다. 그 수는 인코더가 팝업 라벨 75건을 전부 보고 학습한 뒤 최종 능력만 교차검증한 값이었다. 정직하게 다시 잴다 — 인코더 학습에도 폴드를 지켜 그 폴드의 라벨을 빼고 학습한 뒤 그 폴드를 투영한다. 팝업이 +0.3199에서 +0.3260이다. 값은 0.39가 아니라 0.006이다. 아이돌도 +0.7986이 +0.3901로 내려온다. 노트 86의 헤드라인을 철회한다. 그리고 왜 그랬는지가 깨끗하다 — 낙관 편향(낙관 - 정직)이 도메인 크기와  $r = -0.857$ 로 붙는다. 팝업(75건) +0.384, 아이돌(81건) +0.409, 모바일(2,000건) -0.000이다. 노트 86은 가장 작은 두 도메인의 수를 헤드라인으로 삼았고, 거기가 편향이 가장 큰 자리였다. 남는 것도 있다. 정직한 값의 열 도메인 평균이 +0.3772에서 +0.4144로 +0.0372이고, 이는 현행 인자 공간(+0.4038)도 넘는다. 그리고 값이 표본 크기와  $r = +0.480$ 으로 붙는다 — 라벨은 표본이 클 때만 값을 한다(애니 2,073건 +0.147, 팝업 75건 +0.006). 노트 75 · 86이 다른 길로 낸 결론과 같은 자리다.

Table 1: 도메인 안 자기  $\rho$ . 세 절차.

|      | $n$  | 라벨 안 씬  | 정직      | 노트 86   |
|------|------|---------|---------|---------|
| 팝업   | 75   | +0.3199 | +0.3260 | +0.7104 |
| 아이돌  | 81   | +0.3461 | +0.3901 | +0.7986 |
| 도서   | 243  | +0.1840 | +0.1851 | +0.2399 |
| 편딩   | 400  | +0.2235 | +0.1890 | +0.2578 |
| 게임   | 482  | +0.4564 | +0.4343 | +0.5296 |
| 만화   | 1789 | +0.4535 | +0.4964 | +0.5124 |
| 모바일  | 2000 | +0.5518 | +0.6725 | +0.6724 |
| 애니   | 2073 | +0.3166 | +0.4636 | +0.5231 |
| 웹툰   | 2817 | +0.4697 | +0.4993 | +0.5282 |
| 세계애니 | 2948 | +0.4510 | +0.4880 | +0.5032 |
| 평균   |      | +0.3772 | +0.4144 | +0.5276 |

Table 2: 낙관 편향(노트 86 - 정직).

|      | $n$  | 편향     |
|------|------|--------|
| 아이돌  | 81   | +0.409 |
| 팝업   | 75   | +0.384 |
| 게임   | 482  | +0.095 |
| 편딩   | 400  | +0.069 |
| 애니   | 2073 | +0.060 |
| 도서   | 243  | +0.055 |
| 웹툰   | 2817 | +0.029 |
| 만화   | 1789 | +0.016 |
| 세계애니 | 2948 | +0.015 |
| 모바일  | 2000 | -0.000 |

## 1. 정직하게 다시 잴다

노트 86의 “라벨 씬” 절차는 이랬다 — 인코더를 모든 도메인의 라벨로 학습하고, 그 뒤 잠재→라벨 능력만 5폴드 교차검증했다. 인코더가 이미 라벨을 봤으므로 잠재 자체에 정답이 새어 있다.

고쳤다. 도메인  $d$ 를 3폴드로 나누고, 폴드마다 그 폴드의 라벨을 빼고 인코더를 학습한 뒤 학습된 인코더로 그 폴드를 투영한다. 능력도 학습폴드에서만 적합한다. 인코더가 평가 레코드의 라벨을 한 번도 안 본다.

주장 1. 노트 86의 “무라벨 전제의 값이 팝업에서 0.39”를 철회한다. 정직하게 재면 +0.3199→+0.3260으로 0.006이다. 아이돌도 0.45가 아니라 0.044다.

반증 조건. 3폴드나, 5폴드나 leave-one-out 이면 조금 다를 수 있는데, 방향이 바뀔 크기는 아니다 — 팝업 편향이 +0.384였다.

## 2. 왜 그랬나 --- 작을수록 외운다

$\log_{10} n$  과 편향의 상관인  $-0.857$ 이다. 열 점에서 거의 직선이다.

주장 2. 신경망의 도메인 안 성적은 그 도메인이 작을수록 낙관적이다 —  $\log_{10} n$  과 편향이  $r = -0.857$ 이다. 팝업(75건) · 아이돌(81건)에서 +0.4쯤, 2,000건대에서 0




Figure 1: 왼쪽 — 낙관 편향과 표본 크기, 오른쪽 — 도메인별 세 값.

Table 3: 정직한 값과 표본 크기.

|      | $n$  | 값      |
|------|------|--------|
| 애니   | 2073 | +0.147 |
| 모바일  | 2000 | +0.121 |
| 만화   | 1789 | +0.043 |
| 아이돌  | 81   | +0.044 |
| 세계애니 | 2948 | +0.037 |
| 웹툰   | 2817 | +0.030 |
| 도서   | 243  | +0.001 |
| 팝업   | 75   | +0.006 |
| 게임   | 482  | -0.022 |
| 펀딩   | 400  | -0.035 |

이다.

반증 조건, 편향을 “외움”으로 불렀지만 인코더는 공유다 — 작은 도메인의 레코드가 전체의 0.6%인데도 편향이 크다. 도메인별 머리가 외우는 것으로 보이는데 갈라 확인하지 않았다.

노트 86은 가장 작은 두 도메인의 수를 헤드라인으로 삼았다. 그리고 거기가 편향이 가장 큰 자리였다. 이 프로젝트가 여러 번 되풀이한 실수의 신경망 판이다 — 노트 4의 선택 편향, 노트 67의 작은 표본 배선, 노트 82의 분모 효과.

### 3. 남는 것

철회하고도 남는 것이 둘이다.

첫째, 평균은 여전히 오른다 — +0.3772에서 +0.4144다. 그리고 그 값이 현행 인자 공간(+0.4038)도 넘는다. 대상 라벨을 쓸 수 있으면 인코더가 파이프라인보다 낫다.

둘째, 값이 표본 크기와 붙는다 —  $\log_{10} n$  과  $r = +0.480$ 이다. 2,000건대 도메인이 +0.12~+0.15를 얻고 75건 팝업은 +0.006이다.

주장 3. 라벨은 표본이 클 때만 값을 한다. 팝업 75건에서 라벨의 값은 0.006으로 사실상 0이고, 2,000건대에서 +0.12~+0.15다.

반증 조건. 도메인마다 라벨 종류와 축 구성이 달라 표본 크기만의 효과가 아닐 수 있다. 게임 · 펀딩은 표본이 400~500인데 값이 음수다.

노트 75가 “팝업 510건이면 설계 결정을 판정할 수 있다”고 했고 노트 86이 “전제를 풀려면 수백 건”이라 했다. 이 노트가 세 번째 길로 같은 자리에 닿는다 — 팝업 표본이 커지기 전에는 팝업 라벨이 아무것도 안 산다.

### 4. 한계

- 3폴드다. 폴드가 적으면 학습 표본이 3분의 2로 줄어 정직값이 아래로 편향된다 — 진값은 +0.4144보다 조금 높을 것이다.
- 편향을 “도메인별 머리가 외운다”로 추정했으나 확인 안 했다. 머리를 빼고 공유 인코더만으로 재면 갈릴 것이다.
- 게임 · 펀딩에서 값이 음수인 이유를 모른다.
- 정직한 인코더(+0.4144)가 현행(+0.4038)을 넘지만 그것은 대상 라벨을 쓰는 모형이라 전이 모형과 비교 대상이 아니다.
- 노트 86의 제품 실험(과거 16건)은 애초에 정직한 절차였고 그 결론(+0.5192→+0.3866, 내려간다)은 유효하다.

### 5. 다음

- 작은 도메인의 신경망 수치를 전부 재검한다 — 노트 60-62 · 85 · 86에서 인코더 관련 수치 중 팝업 · 아이들이 들어간 것.
- 편향의 출처를 가른다 — 도메인별 머리를 빼고 공유 인코더만으로.

3. 정직한 절차를 `state/masked_encoder.py` 의 기본으로 만든다. 낙관 절차는 지우거나 이름에 표시한다.
4. 팝업 표본. 세 노트가 같은 곳을 가리킨다.

---

#### 참고문헌

- Cawley, G. C., Talbot, N. L. C. (2010). On over-fitting in model selection and subsequent selection bias in performance evaluation. *JMLR*, 11, 2079–2107.
- Kaufman, S., Rosset, S., Perlich, C. (2012). Leakage in data mining. *ACM TKDD*, 6(4), 1–21.
- Varoquaux, G. (2018). Cross-validation failure: small sample sizes lead to large error bars. *NeuroImage*, 180, 68–77.
- Grinsztajn, L. et al. (2022). Why do tree-based models still outperform deep learning on typical tabular data? *NeurIPS*.
- Bouthillier, X. et al. (2021). Accounting for variance in machine learning benchmarks. *MLSys*, 3, 747–769.