

IP 파운데이션 월드모델 연구 노트 88

에폭이 늘수록 팝업만 잘 맞았다

낙관 편향의 출처를 둘로 갈랐다 --- 학습 시간과 도메인별 머리

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 87이 노트 86의 헤드라인을 철회하며 낙관 편향이 도메인 크기와 $r = -0.857$ 로 붙는다고 했다. 출처를 갈랐다. 첫째, 학습 시간이다 — 팝업(75건)의 편향이 100에폭에서 +0.010인데 700에폭에서 +0.570이다. 아이돌(81건)도 +0.096 → +0.512다. 그런데 모바일(2,000건)은 +0.003 → +0.011로 거의 안 는다. 작은 도메인에서는 학습 시간이 곧 편향이다. 노트 85 · 86이 쓴 400에폭에서 팝업 편향이 +0.375였고 노트 87이 관측한 +0.384와 맞는다. 둘째, 도메인별 머리다 — 머리를 공유로 바꾸면 평균 편향이 +0.0624에서 +0.0296으로 절반이 되고 정직 성적은 +0.4144에서 +0.4110으로 거의 그대로다. 편향의 절반은 공짜로 버릴 수 있다. 그리고 프로젝트의 신경망 수치를 전부 훑었다 — 노트 60-62 · 85 · 86의 전이 수치는 모두 대상 라벨을 뺀 평가라 영향이 없고, 영향받은 것은 노트 86의 표 하나이며 이미 철회했다. 마지막으로 정직 절차를 state/masked_encoder.py 의 honest_selfr() 로 넣어 기본으로 만들었다.

Table 1: 낙관 편향(낙관 - 정직). 도메인별 머리, 3폴드.

에폭	팝업(75)	아이돌(81)	모바일(2000)
100	+0.010	+0.096	+0.003
250	+0.212	+0.278	+0.005
400	+0.375	+0.407	+0.007
700	+0.570	+0.512	+0.011

Table 2: 머리 구조와 편향. 250에폭.

	도메인별 머리	공유 머리
팝업	+0.2124	+0.1259
아이돌	+0.2778	+0.1038
게임	+0.0623	+0.0095
모바일	+0.0052	+0.0027
평균 편향	+0.0624	+0.0296
정직 평균	+0.4144	+0.4110

1. 학습 시간이 곧 편향이다

팝업 편향이 57배가 되는 동안 모바일은 3.7배다. 같은 학습, 같은 인코더인데 75건짜리 도메인만 외운다.

주장 1. 작은 도메인에서 낙관 편향은 학습 시간에 거의 비례한다. 팝업(75건)이 100에폭 +0.010에서 700에폭 +0.570이고 모바일(2,000건)은 +0.003에서 +0.011이다. 에폭 수를 보고하지 않은 신경망 수치는 읽을 수 없다.

반증 조건. 에폭 넷만 봤고 학습률 · 정규화를 고정했다. 가중치 감쇠를 세게 하면 곡선이 늑장지만 그러면 큰 도메인의 성적도 내려갈 것이다 — 교환을 안 했다.

노트 85 · 86이 400에폭을 썼고 그 지점의 팝업 편향이 +0.375다. 노트 87이 다른 실행에서 관측한 +0.384와 맞는다 — 그 수는 잡음이 아니라 설정의 함수였다.

2. 도메인별 머리가 절반이다

주장 2. 편향의 절반은 도메인별 머리에서 나오고, 머리를 공유로 바꾸면 정직 성적을 +0.0034만 잃고 편향을 절반으로 줄인다. 공짜에 가깝다.

Table 3: 신경망 수치 재검.

	절차	판정
노트 60-62 전이	대상 라벨 제외	영향 없음
노트 85 +0.3575	대상 라벨 제외	영향 없음
노트 86 +0.3692	대상 라벨 제외	영향 없음
노트 86 “라벨 씌”	인코더가 라벨 봄	철회(87)
노트 86 과거 16건	정직	영향 없음
노트 87 +0.4144	정직	유효

반증 조건. 공유 머리는 도메인마다 다른 축 → 라벨 관계를 하나로 강제한다. 지금은 손해가 작지만 도메인이 더 이질적이면 커질 것이다.

남은 절반은 공유 인코더 자체다. 3폴드에서 인코더는 그 도메인의 나머지 3분의 2 라벨을 보므로, 작은 도메인 일수록 그 3분의 2가 평가 폴드와 닮아 있다.




Figure 1: 왼쪽 — 학습 에폭과 낙관 편향. 오른쪽 — 머리 구조와 편향.

3. 프로젝트 전체를 훑었다

전이 수치는 전부 대상 도메인의 라벨 지도를 빼고 학습한다 — 그것이 이 프로젝트의 기본 규약이었고, 그래서 영향이 없다. 한 번 어긴 자리가 노트 86의 표 하나였고 그것만 무너졌다.

규약을 하나 더 둔다. 도메인 안 성적을 신경망으로 보고할 때는 정직 절차(폴드마다 그 폴드의 라벨을 빼고 학습)로만 내고, 낙관값을 함께 적어 편향을 드러낸다. 에폭 수도 함께 적는다.

4. 코드에 넣었다

state/masked_encoder.py 에 honest_selfr() 를 넣었다 — 폴드마다 그 폴드의 라벨을 빼고 학습한 뒤 encode() 로 그 폴드를 투영한다. 기본값은 공유 머리 · 250에폭이다.

```
honest_selfr(data, folds=3, epochs=250,
              shared_head=True)
```

노트 65가 진단 코드를 state/audit.py 로 모은 것과 같은 조치다 — 규칙은 사람이 어기고 구조는 안 어긴다.

5. 한계

- 에폭 넷 · 머리 둘만 봤다. 정규화 · 폭 · 학습률은 안 훑었다.
- 3폴드라 인코더가 그 도메인의 3분의 2 라벨을 본다. leave-one-out 이면 편향이 더 줄겠지만 계산이 n 배다.
- 공유 머리가 손해를 거의 안 낸다는 것은 지금 열 도메인에서다.
- 재검을 “절차가 대상 라벨을 뺐는가”로 판정했다. 다른 종류의 누출은 안 봤다.
- 노트 60–62의 수치는 이전 세션의 것이라 코드를 다시 돌려 확인하지 않았다.

6. 다음

1. 제품 도구를 만든다 — 새 팝업 기획서를 넣으면 백분위와 예상 구간을 내는 스크립트. 노트 77의 가장 엄격한 규약을 그대로 쓴다. 모델 쪽 지렛대가 닫혔으므로 남은 것은 쓸 수 있게 만드는 일이다.
2. 정규화를 세게 해 편향 곡선을 높히고 큰 도메인 손해를 쥔다.
3. 노트 60–62를 정직 절차로 다시 돌린다.
4. 팝업 표본 — 세 노트가 같은 곳을 가리킨다($75 \cdot 86 \cdot 87$).

참고문헌

- Varoquaux, G. (2018). Cross-validation failure: small sample sizes lead to large error bars. *NeuroImage*, 180, 68–77.
- Cawley, G. C., Talbot, N. L. C. (2010). On over-fitting in model selection and subsequent selection bias in performance evaluation. *JMLR*, 11, 2079–2107.
- Zhang, C. et al. (2017). Understanding deep learning requires re-thinking generalization. *ICLR*.
- Belkin, M. et al. (2019). Reconciling modern machine-learning practice and the classical bias–variance trade-off. *PNAS*, 116(32), 15849–15854.
- Bouthillier, X. et al. (2021). Accounting for variance in machine learning benchmarks. *MLSys*, 3, 747–769.