

IP 파운데이션 월드모델 연구 노트 91

어느 카테고리에 쓸 수 있나

도구를 열 도메인으로 넓히고 자기 검사를 붙였다 --- 성분 수는 전역 상수가 아니었다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 89의 도구는 팝업 전용이었다. 규약 자체는 도메인을 안 가리므로 열 개 전부로 넓히고 자기 검사를 붙였다 — 그 도메인의 과거 레코드를 폴드 밖으로 빼고 매겨 순위 상관을 낸다(200건 미만은 하나씩, 그 이상은 10겹). 쓸 만한 카테고리화 아닌 카테고리가 갈린다 — 모바일 +0.614 · 만화 +0.483 · 팝업 +0.471 · 세계애니 +0.417 · 웹툰 +0.387은 쓸 수 있고, 도서 +0.180 · 펀딩 +0.197은 못 쓴다. 노트 90이 남긴 신호 — “팝업만은 성분 $k=1$ 이 낮다” — 도 열 도메인에서 확인했다. 평균은 같다($k=2$ +0.3628, $k=1$ +0.3531). 그런데 도메인마다 갈린다 — 팝업 +0.021 · 모바일 +0.033 · 애니 +0.021은 $k=1$ 이 낮고 게임 -0.069 · 도서 -0.058은 $k=2$ 가 낮다. 성분 수는 전역 상수가 아니라 도메인의 성질이다. 도메인마다 좋은 쪽을 고르면 +0.3703인데, 열 번의 이지선다라 선택 편향이 섞여 있어 채택하지 않는다(노트 67 · 80). 구현에서 버그도 하나 잡았다 — 대상만 $k=1$ 로 두면 프로크루스테스 적재의 모양이 안 맞는다. `spaces()` 에 성분 수를 뚫었다.

Table 1: 도구 자기 검사. 성분 $k=2$.

	n	ρ
모바일	1,991	+0.614
만화	1,214	+0.483
팝업	75	+0.471
세계애니	2,853	+0.417
웹툰	2,817	+0.387
아이돌	62	+0.309
게임	472	+0.293
애니	1,420	+0.277
펀딩	400	+0.197
도서	242	+0.180

Table 2: $k=1$ 대 $k=2$.

	$k=2$	$k=1$	Δ
모바일	+0.614	+0.647	+0.033
팝업	+0.471	+0.493	+0.021
애니	+0.277	+0.298	+0.021
만화	+0.483	+0.481	-0.002
세계애니	+0.417	+0.410	-0.007
웹툰	+0.387	+0.376	-0.011
펀딩	+0.197	+0.186	-0.011
아이돌	+0.309	+0.296	-0.013
도서	+0.180	+0.121	-0.058
게임	+0.293	+0.223	-0.069
평균	+0.3628	+0.3531	-0.010

1. 도구를 넓혔다

```
python3 -m state.score --table
python3 -m state.score -- selftest --
domain 웹툰
python3 -m state.score -- plan plan.json
--k 1
```

규약은 노트 77의 규약 ④ 그대로다 — 그 도메인의 과거 레코드로 공간을 만들고 새 레코드 하나를 투영한다. 자기 검사는 그것을 폴드로 반복한다 — 200건 미만은 하나씩 빼고, 그 이상은 10겹으로 나눈다(큰 도메인에서 LOO 는 계산이 n 배라 못 돌린다).

2. 쓸 만한 카테고리

주장 1. 도구를 쓸 수 있는 카테고리와 없는 카테고리가 갈린다. 다섯(모바일 · 만화 · 팝업 · 세계애니 · 웹툰)은 $\rho \geq +0.39$ 이고 다섯은 +0.31 아래다.

반증 조건. 자기 검사 ρ 가 파이프라인의 “대상으로” 수치보다 낮다(웹툰 +0.387 대 +0.457). 규약이 더 엄격 해서다 — 인자 공간을 폴드 안에서만 만들고 폴드 밖을 투영한다. 같은 것을 재는 두 숫자가 아니다.

팝업이 표본 75건으로 셋째다. 표본 크기가 아니라 축과 라벨의 관계가 성적을 정한다 — 노트 74의 법칙 ($r = +0.99$, 자기 상관이 대상 전이를 결정한다)이 도구 수준에서도 보인다.

3. 성분 수는 도메인의 성질이다




Figure 1: 왼쪽 — 도메인별 자기 검사. 오른쪽 — 성분 수 $k=1$ 대 $k=2$.

주장 2. 성분 수는 전역 상수가 아니라 도메인의 성질이다. 평균은 $k=1$ 과 $k=2$ 가 -0.010 밖에 안 다른데 도메인별로 는 $+0.033$ 에서 -0.069 까지 갈린다.

반증 조건. 도메인마다 좋은 쪽을 고르면 $+0.3703$ 이지만 열 번의 이지선다라 선택 편향이 섞인다. 노트 67 · 80이 같은 함정을 보였다 — 채택하지 않는다.

$k=1$ 이 나은 셋(모바일 · 팝업 · 애니)과 나쁜 둘(게임 · 도서)의 차이가 무엇인지는 모른다. 관측 축 수(게임 6 · 도서 4 · 팝업 5 · 모바일 4)로도, 표본 크기으로도 안 갈린다.

4. 버그 하나

대상 공간만 $k=1$ 로 만들면 프로크루스테스가 $c \times 1$ 적재와 $c \times 2$ 적재를 맞추려다 모양이 안 맞는다. `spaces()`가 성분 수를 안 받고 있었고 기본값 2로 고정돼 있었다. 뚫었다.

설정이 두 곳에 나뉘어 있으면 한쪽만 바뀐다. 노트 65가 진단 코드를 모으고 노트 88이 정직 절차를 코드에 넣은 것과 같은 종류의 정리다.

5. 한계

- 큰 도메인은 10겹이고 작은 도메인은 하나씩이라 규약이 다르다. 10겹이 더 낙관적일 수 있다(학습 표본이 90%).
- 도메인별 k 를 고르는 것이 왜 안 되는지(선택 편향)를 계산으로 보이지 않았다. 씨앗 넷 규약으로 판정하지도 않았다.
- 자기 검사가 순위만 잰다. 도구가 내는 “비슷한 자리의 방문자 범위”는 검사하지 않았다.
- 도서 · 편딩이 왜 낮은지 모른다. 축이 얇아서로 보이지만 확인 안 했다.

- 도구는 여전히 팝업의 열 속성 중 다섯만 쓴다(노트 89 · 90).

6. 다음

1. 도메인별 성분 수를 씨앗 넷 규약으로 판정한다. 선택 편향을 감당할 만큼 큰지 본다.
2. 도서 · 편딩이 낮은 이유 — 축이 얇아서인지 라벨이 시끄러워서인지.
3. 도구의 “방문자 범위”를 검사한다. 순위는 검사했는데 범위는 안 했다.
4. 팝업 표본. 다섯 노트가 같은 곳을 가리킨다(75 · 86 · 87 · 90 · 91).

참고문헌

- Ben-David, S. et al. (2010). A theory of learning from different domains. *Machine Learning*, 79(1–2), 151–175.
- Schoenemann, P. H. (1966). A generalized solution of the orthogonal Procrustes problem. *Psychometrika*, 31(1), 1–10.
- Cawley, G. C., Talbot, N. L. C. (2010). On over-fitting in model selection and subsequent selection bias in performance evaluation. *JMLR*, 11, 2079–2107.
- Varoquaux, G. (2018). Cross-validation failure: small sample sizes lead to large error bars. *NeuroImage*, 180, 68–77.
- Efron, B., Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall.