

IP 파운데이션 월드모델 연구 노트 92

도구는 신 건이면 다 배운다

다섯 노트가 가리키던 팝업 표본 병목을 갈랐다 --- 제품은 이미 쓸 수 있고 못 하는 것은 연구다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 91이 도메인마다 좋은 성분 수가 다르다고 했다. 고르는 것이 값을 하는지 **반을 갈라** 검정했다 — A반에서 k 를 고르고 B반에서 $k=2$ 를 전역으로 유지한다. 그리고 반을 가르다 보니 더 큰 것이 보였다 — 도구 성적이 그 도메인에 쌓인 레코드 수에 어떻게 반응하는가. **신 건이면 거의 포화한다**. 팝업은 20~75건에서 +0.24~+0.53으로 요동할 뿐 추세가 없고, 모바일은 800건에서 멈추며, 웹툰은 50건 +0.468에서 2,817건 +0.387로 오히려 내린다. 이것이 지난 다섯 노트(75 · 86 · 87 · 90 · 91)가 “팝업 표본이 병목”이라 한 것을 갈라 준다. 팝업 표본은 도구 정확도의 병목이 아니다. 병목인 것은 둘뿐이다 — 설계 결정을 팝업 기준으로 판정하는 것 (510건, 노트 75)과 팝업 라벨을 모형에 쓰는 것(수백 건, 노트 86 · 87). 제품은 이미 쓸 수 있고, 못 하는 것은 모형을 더 좋게 만드는 일이다.

Table 1: A반에서 k 를 고르고 B반에서 $k=2$ 를 고르면 손해다.

	A반 고른 k	B반 고른 것	B반 $k=2$	Δ
애니	1	+0.301	+0.251	+0.050
모바일	1	+0.655	+0.629	+0.026
펀딩	1	+0.280	+0.299	-0.019
아이돌	1	-0.046	+0.141	-0.187
나머지 여섯	2	—	—	± 0.000
평균		+0.3272	+0.3402	-0.0130

Table 2: 과거 레코드 수와 도구 자기 검사 ρ .

	50	100	400	800	전체
모바일	+0.455	+0.563	+0.552	+0.642	+0.614
만화	+0.392	+0.549	+0.507	+0.446	+0.485
웹툰	+0.468	+0.419	+0.368	+0.413	+0.387
세계애니	+0.249	+0.389	+0.406	+0.412	+0.417
팝업: 20건	+0.530 · 30건 +0.244 · 40건 +0.421				
50건	+0.486 · 60건 +0.502 · 75건 +0.471				

1. 고르면 손해다

주장 1. 도메인별 성분 수 선택은 값을 안 한다 — A반에서 고르고 B반에서 재면 -0.0130이다. 노트 91이 본 “도메인마다 고르면 +0.3703”은 선택 편향이었다.

반증 조건. 반을 한 번 갈랐다. 다른 분할이면 다를 수 있는데, 아이돌의 -0.187이 워낙 커서 부호가 바뀌기는 어렵다.

노트 67(작은 표본 배선) · 80(부분집합) · 82(분모)에 이어 같은 함정의 네 번째 사례다. 이번에는 미리 갈라 놓고 걸렸다.

2. 도구는 신 건이면 다 배운다

주장 2. 도구의 성적은 그 도메인에 쌓인 과거 레코드 수에 거의 반응하지 않는다 — 신 건이면 포화한다. 웹툰은 50건에서 2,817건으로 가며 오히려 -0.081 내린다.

반증 조건. 50건 아래는 표본이 작아 자기 검사 자체가

몹시 흔들린다(팝업 30건 +0.244, 40건 +0.421). “신 건이면 된다”는 그 위쪽이 평평하다는 뜻이지 신 건이 안 전하다는 뜻이 아니다.

왜 안 늘어나는가. 도구는 그 도메인의 과거로 인자 공간만 만들고 예측은 아홉 출처에서 온다. 인자 공간은 축 넷다섯 개의 주성분이라 신 건이면 충분히 안정된다. 과거를 더 쌓아도 배울 것이 없다.

3. 병목을 갈랐다

지난 다섯 노트가 모두 “팝업 표본”을 가리켰다. 무엇이 병목인지 갈라야 한다.

팝업 75건은 도구를 쓰기에 충분하다. 모자란 것은 연구용이다 — 설계 결정을 팝업 기준으로 판정하는 것, 팝업 라벨을 모형에 넣는 것, “몇 명 올리”를 말하는 것.

주장 3. 제품은 이미 쓸 수 있다. 팝업 표본이 병목인 것은 모형을 더 좋게 만드는 일이지 모형을 쓰는 일이 아니다.




Figure 1: 왼쪽 — 도구의 학습 곡선. 오른쪽 — 성분 수 선택의 A/B 검증.

Table 3: 팝업 표본이 사는 것과 안 사는 것.

	필요	근거
도구 정확도	~50건	이 노트
설계 판정	~510건	노트 75
라벨 활용	수백 건	노트 86 · 87
배수 구간	~1,650건	노트 75

반증 조건. 도구 정확도가 $\rho \approx +0.47$ 에 머문다는 것은 그대로다. 쉰 건이면 포화한다는 것은 “더 쌓아도 안 좋아 진다”는 뜻이므로, 좋게 만들려면 다른 길이 필요하다.

4. 한계

- 학습 곡선을 표본 추출 세 번의 평균으로 냈다. 구간을 안 붙였고, 작은 크기에서 요동이 크다.
- 웹툰이 내려가는 이유를 모른다. 큰 표본에서 오래된 작품이 섞여 들어오는 구성 변화로 보이지만 확인 안 했다.
- 성분 수 A/B 검정을 한 번의 분할로 했다.
- “쉰 건이면 포화”는 지금 아홉 출처가 있을 때다. 출처가 적으면 그 도메인의 과거가 더 중요할 것이다.
- 도구 정확도 $\rho \approx +0.47$ 이 라벨 천장(0.72~0.75, 노트 83)의 3분의 2다. 남은 3분의 1을 어디서 얻을지는 여전히 모른다.

5. 다음

1. 도구를 실제로 쓰게 만든다 — 기획 단계에서 채우는 양식과 출력 형식을 다듬는다. 표본이 병목이 아니면 남은 것은 사용성이다.
2. 웹툰이 표본에 따라 내려가는 이유 — 구성 변화인지 확인한다.

3. 출처 수와 과거 레코드 수의 교환 — 출처가 적을 때 과거가 더 중요하다.
4. 천장까지 남은 3분의 1. 지금까지 닫힌 지렛대 목록(노트 76 · 80 · 82 · 83 · 85–88 · 90)을 다시 훑어 빠진 것을 찾는다.

참고문헌

- Cawley, G. C., Talbot, N. L. C. (2010). On over-fitting in model selection and subsequent selection bias in performance evaluation. JMLR, 11, 2079–2107.
- Varoquaux, G. (2018). Cross-validation failure: small sample sizes lead to large error bars. NeuroImage, 180, 68–77.
- Ilin, A., Raiko, T. (2010). Practical approaches to principal component analysis in the presence of missing values. JMLR, 11, 1957–2000.
- Ben-David, S. et al. (2010). A theory of learning from different domains. Machine Learning, 79(1–2), 151–175.
- Kish, L. (1965). Survey Sampling. Wiley.