

IP 파운데이션 월드모델 연구 노트 93

남은 3분의 1은 축에 없다

안 건드린 자리 일곱을 전부 열어 보고 격차를 셋으로 갈랐다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 92가 물었다 — 도구가 라벨 천장(0.72~0.75)의 3분의 2에 머무는데 표본도 배선도 도메인도 구조도 축도 다 닫혔다면 남은 것은 어디인가. 닫힌 목록을 훑어 손 안 댄 자리 일곱을 찾아 전부 열었다. 회귀 별점 (α 를 0.03에서 100까지) — ± 0.0005 , 완전히 무감각하다. 축 순위 변환(손으로 고른 눈금을 백분위로) $+0.0048$. 라벨 순위 변환 -0.0007 . 합치기를 중앙값 -0.0011 · 질사평균 $+0.0017$. 일곱 중 하나도 구간 반쪽(0.033)의 6분의 1을 못 넘는다. 그래서 반대로 물었다 — 축이 닫은 것을 다 쓰고 있다. 도메인 안에서 주성분 둘 대신 원 축을 그대로 쓰고 부스팅 나무를 얹으면 $+0.3849$ 에서 $+0.4778$ 로 간다($+0.093$). 축은 안 비었다. 그런데 그 이득이 도메인을 건너면 사라진다 — 정렬 없이 공통 축 위에서 바로 전이하면 -0.032 (능형) · -0.064 (부스팅) 다. 비선형은 도메인 안에서만 산다. 이것으로 남은 격차가 셋으로 갈린다: 전이 $+0.404 \rightarrow$ 도메인 안 상한 $+0.478$ (전이의 값 0.074) $\rightarrow$ 라벨 천장 0.734 (축에 없는 것 0.256). 남은 3분의 1의 대부분은 축에 없다.

Table 1: Δ 판정치. 구간 반쪽은 0.033.

	Δ	팝업
별점 α 0.03	-0.0000	+0.4501
별점 α 100	+0.0005	+0.4514
축 순위 변환	+0.0048	+0.4472
라벨 순위 변환	-0.0007	+0.4448
합치기 중앙값	-0.0011	+0.4549
합치기 질사평균	+0.0017	+0.4620
직접 전이(정렬 없음)	-0.0322	+0.3941
직접 전이 GBM	-0.0644	+0.3785

Table 2: 도메인 안 자기 ρ . 표본 80건 이상인 여덟.

	주성분 2	원 축 능형	원 축 GBM
애니	+0.291	+0.349	+0.506
게임	+0.365	+0.367	+0.486
웹툰	+0.480	+0.478	+0.598
도서	+0.202	+0.216	+0.317
세계애니	+0.418	+0.493	+0.530
모바일	+0.656	+0.690	+0.696
만화	+0.477	+0.505	+0.464
편딩	+0.190	+0.213	+0.225
평균	+0.3849	+0.4136	+0.4778

1. 안 건드린 자리 일곱

주장 1. 회귀 별점은 판정치에 전혀 영향이 없다 — α 를 3,000배 바꿔도 ± 0.0005 다. 인자 공간이 2차원이고 표준화돼 있어 정규화할 것이 없기 때문이다.

반증 조건. 성분 수를 늘리면 별점이 살아날 것이다. 노트 90이 $k=3$ 을 봤는데 그때는 별점을 안 바꿨다.

2. 축은 안 비었다

반대로 물었다 — 축이 닫은 것을 다 쓰고 있다. 주성분 둘 대신 원 축을 그대로 쓰고 부스팅 나무를 얹었다(도메인 안 5폴드 교차검증).

주장 2. 2차원 선형 병목이 축에서 $+0.093$ 을 버리고 있다. 원 축에 부스팅 나무를 얹으면 도메인 안 자기 상관인 $+0.3849$ 에서 $+0.4778$ 로 간다.

Table 3: 정렬 없이 공통 3축 위에서 바로 전이.

	판정치	팝업
현행(주성분 2 + 프로크루스테스)	+0.4038	+0.4501
직접 · 능형	+0.3716	+0.3941
직접 · GBM	+0.3394	+0.3785
직접 · GBM(얹게)	+0.3545	+0.3989

반증 조건. 도메인 안 성적이지 전이 성적이 아니다. 다음 절이 그 구분을 만든다.

3. 그런데 건너가면 사라진다

프로크루스테스 정렬은 주성분의 회전이 임의라서 필요했다. 그런데 공통 축 자체는 회전이 없다 — 슬롯 j 는 어느 도메인에서나 슬롯 j 다. 그러면 정렬 없이 바로 전이할 수 있다.




Figure 1: 왼쪽 — 안 건드린 자리 일곱. 오른쪽 — 남은 격차의 분해.

Table 4: 남은 격차의 분해.

	ρ
전이(현행)	+0.404
	↓ 전이의 값 0.074
도메인 안 상한(원 축 GBM)	+0.478
	↓ 축에 없는 것 0.256
라벨 천장(노트 83)	+0.734

주장 3. 비선형은 도메인 안에서만 산다. 원 축 부스팅이 도메인 안에서 +0.093을 얻는데 도메인을 건너면 -0.064를 잃는다. 출처에서 배운 비선형 모양이 대상에 안 맞기 때문이며, 프로크루스테스의 선형 회전은 그 불일치를 흡수한다.

반증 조건. 직접 전이는 대상이 여덟뿐이다(공통 3축을 다 관측하는 도메인만). 현행은 열이다. 분모가 다르므로 -0.032가 과장됐을 수 있다.

노트 40이 전역 정렬을 버리고 쌍별 정렬로 간 이유, 노트 85 · 86의 공유 인코더가 진 이유, 그리고 여기서 부스팅이 진 이유가 전부 같다 — 도메인마다 축과 라벨의 관계가 다르고, 그 차이를 흡수할 자유도가 필요하다.

4. 격차를 셋으로 가른다

남은 3분의 1의 대부분은 축에 없다. 라벨 천장까지 0.330이 남았는데 그중 0.256이 “축이 안 담은 정보”이고 0.074만 “전이가 치르는 값”이다. 그리고 전이의 값을 줄이려는 시도(직접 전이 · 공유 인코더 · 게이트)는 지금까지 전부 더 나빴다.

주장 4. 모델을 더 좋게 만드는 길은 새 축뿐이다. 지금 축으로는 도메인 안에서도 +0.478이 상한이고, 전이는

그보다 0.074 아래다.

반증 조건. “축에 없는 0.256”에는 라벨 잡음도 섞여 있다 — 노트 83의 천장은 두 플랫폼 라벨의 상관에서 왔고 그 자체가 추정이다.

5. 한계

- 도메인 안 GBM 상한을 5폴드로 냈다. 하이퍼파라미터를 안 훑었으므로 +0.478도 상한이 아니라 한 설정의 값이다.
- 직접 전이의 대상이 여덟이라 분모가 다르다(노트 82의 합정).
- 팝업 · 아이돌은 표본이 작아 GBM 상한을 못 냈다(80건 문턱).
- “축에 없는 0.256”을 라벨 잡음과 못 갈랐다.
- 절사평균이 팝업에서 +0.4620으로 현행보다 낮다(+0.0119). 채택 검토를 안 했다.

6. 다음

- 새 축을 수집한다 — 이제 근거가 분명하다. 노트 84 · 89 · 90이 기존 데이터에서 만들 수 있는 축을 다 시도했으므로, 새로 긁어야 한다. 후보: 리뷰 텍스트, 이미지, 가격 이력, 검색량.
- 절사평균을 씨앗 넷 규약으로 판정한다.
- 도메인 안 GBM 상한을 제대로 훑는다 — 진짜 상한이 얼마인지.
- 팝업 · 아이돌의 GBM 상한을 표본이 작은 채로 재는 법.

참고문헌

Grinsztajn, L. et al. (2022). Why do tree-based models still outperform deep learning on typical tabular data? NeurIPS.

- Ke, G. et al. (2017). LightGBM: a highly efficient gradient boosting decision tree. NIPS, 3146–3154.
- Schoenemann, P. H. (1966). A generalized solution of the orthogonal Procrustes problem. Psychometrika, 31(1), 1–10.
- Ben-David, S. et al. (2010). A theory of learning from different domains. Machine Learning, 79(1–2), 151–175.
- Lord, F. M., Novick, M. R. (1968). Statistical Theories of Mental Test Scores. Addison-Wesley.