

IP 파운데이션 월드모델 연구 노트 96

없는 축이 돕는다

임베딩의 첫 성분은 길이였는데, 그 축을 출처에 붙일 때마다 축이 없는 팝업이 출처 하나당 +0.0035씩 올랐다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 95가 두 가지를 남겼다 — 겹침 56%가 무엇끼리인지 안 같았고, 손 특징 다섯 대신 임베딩을 안 뽑았다. 둘 다 했다. 겹침은 새 축끼리가 아니었다 — 직전작 성적과 문장 수의 상관은 다섯 도메인 중 셋에서 0.03 아래고, 대신 둘 다 기존 다섯 축과 겹친다(직전작 ↔ 모바일 입장료 -0.495, 문장 수 ↔ 타깃 폭 +0.13~ +0.20). 임베딩은 문자 2-4 그램 TF-IDF 60,000차원을 SVD 로 줄여 만들었다(모형 없이, 12,103건). 첫 성분은 길이였다 — 손 특징 “문자 수”와 +0.47~ +0.82로 붙는다. 축으로 넣으면 +0.0104, 문장 수(+0.0096)와 사실상 같은 크기이고 둘을 같이 넣으면 -0.0141로 나빠진다. 여기까지는 또 하나의 영이다. 그런데 팝업이 +0.4501에서 +0.4723으로 올랐다 — 팝업에는 설명문이 없는데도. 노트 94의 표지에서도 같은 일이 있었다. 이번엔 같았다. 여섯 출처 중 k 개에만 축을 붙이며 63가지 조합을 다 돌리니 완벽한 단조 직선이 나온다 — 출처 하나당 +0.0035. 뒤섞은 축은 +0.0005로 평평하다. 기제도 확인했다 — 출처의 자기 ρ 가 오른 만큼 그 출처의 팝업 전이가 오른다 ($r = +0.796$). 팝업은 자기에게 없는 축으로 좋아진다.

Table 1: 새 축끼리의 순위 상관(둘 다 관측된 레코드).

	직전작·문장수	표시자·문장수	n
애니	+0.188	-0.055	1,199
모바일	+0.283	+0.035	722
웹툰	+0.027	+0.096	1,101
만화	-0.002	+0.043	624
세계애니	+0.010	+0.089	2,723

Table 2: 새 축과 기존 다섯 공통 축의 상관. 절댓값 0.13 이상만.

	기존 축	r
직전작 · 모바일	입장료	-0.495
직전작 · 애니	매장 노출	-0.267
직전작 · 모바일	미디어 홍보	+0.262
직전작 · 모바일	굿즈 규모	+0.220
직전작 · 모바일	타깃 폭	+0.203
문장 수 · 세계애니	타깃 폭	+0.201
문장 수 · 모바일	굿즈 규모	+0.200
문장 수 · 웹툰	타깃 폭	+0.197

1. 겹침은 새 축끼리가 아니었다

노트 95는 세 축을 합쳐 +0.0351이 나와야 하는데 +0.0155가 나온 것을 보고 “56%가 겹친다”고만 적었다. 무엇끼리 겹치는지 재 보았다.

주장 1. 노트 95의 겹침은 새 축끼리가 아니라 새 축과 기존 축 사이다. 직전작과 문장 수는 다섯 중 셋에서 상관이 0.03 아래인데, 둘 다 기존 다섯 축과는 0.20~0.50으로 붙는다.

반증 조건. 상관은 선형 관계만 잡는다. 인자 공간에 들어가면 주성분 둘로 줄어들므로 여기서 안 겹쳐도 거기서 겹칠 수 있다.

이것이 실무적으로 뜻하는 바는 분명하다 — 서로 다른 새 축을 여럿 모으는 전략은 안 통한다. 새 축은 서로가 아니라 이미 있는 것과 싸운다.

2. 60,000차원을 줄였더니 길이였다

노트 95는 손으로 고른 특징 다섯을 썼다. 문장 임베딩 모형을 못 내려받으므로 문자 n -그램 TF-IDF + SVD 로 대신했다. 한국어 · 일본어 · 영어가 섞여 형태소 분석이 안 되는데 문자 2-4 그램은 언어를 안 가린다.

게임은 캐시에 스템 `about_the_game` 이 이미 1,494 건 있었다. 축 레코드 482건과 482/482로 전부 맞는다. 여섯째 설명문 도메인이 공짜로 생겼다.

주장 2. 60,000차원 문자 n -그램의 첫 주성분은 길이다. 다섯 도메인 전부에서 문자 수와 +0.47~ +0.82로 붙는다. 노트 95의 손 특징 다섯은 임베딩이 잡을 것을 이미 거의 다 잡고 있었다.

반증 조건. 성분 하나만 봤다. $c1 \cdot c2$ 는 길이와 털 붙이지만 축으로 넣으면 +0.0069 · +0.0043으로 더 작다.

같은 것을 두 번 넣으면 인자 공간이 그쪽으로 쏠려




Figure 1: 왼쪽 — 출처 수 곡선. 가운데 — 기제. 오른쪽 — 임베딩 첫 성분의 정제.

Table 3: 임베딩을 만든 코퍼스. 여섯 도메인 전부 덮개를 100%.

	건수	출처
애니	2,068	라프텔 줄거리
모바일	2,000	앱스토어 소개문
웹툰	2,817	네이버 시놉시스
만화	1,788	AniList
세계애니	2,948	AniList
게임	482	스팀(이번에 불임)
합	12,103	어휘 60,000

Table 4: 첫 성분 c0 과 손 특징 다섯의 순위 상관.

	애니	모바일	웹툰	만화	세계애니
길이	+.61	+.47	+.57	+.76	+.82
문장 수	+.63	+.18	+.58	+.49	+.66
문장 길이	-.13	+.45	+.02	+.32	+.39
어휘 다양성	-.20	-.47	-.16	-.54	-.60
숫자 비율	+.27	+.04	+.21	-.03	+.02

오히려 나빠진다. 노트 95의 “작은 것들은 더해지지 않는다”가 여기서 극단적으로 나타난다.

3. 팝업엔 없는 축인데 팝업이 오른다

임베딩은 판정치에서 +0.0104로 문턱(구간 반쪽 0.033) 아래고 씨앗 넷 전부 보류다. 그런데 팝업이 +0.0222 오른다 — 지금까지 어떤 새 축보다 크다. 팝업에는 설명문이 없고 축이 하나도 안 붙는데도 그렇다.

노트 94에서 표지 축을 넣었을 때도 팝업이 다섯 설정 모두에서 올랐고 (+0.003~+0.007) 그때는 “잡음과 못가른다”고 적고 넘어갔다. 두 번째로 같은 일이 일어났으므로 이번엔 같았다.

주장 3. 대상에 없는 축이 대상을 돕고, 그 도움은 축을 받은 출처 수에 비례한다 — 출처 하나당 팝업 +0.0035.

Table 5: 축으로 넣은 결과. 여섯 도메인.

	ρ	Δ	팝업
현행	+0.4038	—	+0.4501
임베딩 c0	+0.4142	+0.0104	+0.4723
문장 수(노트 95)	+0.4134	+0.0096	+0.4481
둘 다	+0.3897	-0.0141	+0.4734

Table 6: 여섯 출처 중 k개에만 축을 붙인다. 63가지 조합 전부.

k	조합	ρ	팝업	뒤섞은 축
0	1	+0.4038	+0.4501	+0.4501
1	6	+0.4060	+0.4542	+0.4513
2	15	+0.4078	+0.4567	+0.4520
3	20	+0.4097	+0.4603	+0.4533
4	15	+0.4114	+0.4635	+0.4531
5	6	+0.4128	+0.4666	+0.4533
6	1	+0.4142	+0.4723	+0.4534
기울기(출처 하나당)		+0.0017	+0.0035	+0.0005

63가지 조합에서 단조이고 거의 직선이다. 같은 자리에 뒤섞은 축을 넣으면 기울기가 +0.0005로 평평해지므로 차원이 아니라 정보다.

반증 조건. 뒤섞은 축도 절편은 +0.0035쯤 올린다 — 축 하나를 더하는 것 자체에 작은 이득이 있다. 기울기만 정보의 몫이다.

주장 4. 기제는 노트 74의 법칙이다 — 출처의 자기 ρ 가 오른 만큼 그 출처의 대상 전이가 오른다. 여기서는 그 법칙이 변화량에도 성립한다($r = +0.796$). 설명문 축이 애니의 자기 ρ 를 +0.082 올리고, 애니의 팝업 전이가 +0.205 오른다.

반증 조건. 여섯 점의 상관이다. 애니 하나가 지렛대라 그것을 빼면 r 이 크게 떨어진다.

Table 7: 기제 — 출처의 자기 ρ 와 그 출처의 팝업 전이.

	자기 ρ		→ 팝업	
	전	후	전	후
애니	+0.292	+0.374	+0.124	+0.328
모바일	+0.656	+0.674	+0.223	+0.399
웹툰	+0.479	+0.470	+0.324	+0.403
만화	+0.475	+0.456	+0.425	+0.447
세계애니	+0.419	+0.418	+0.474	+0.478
게임	+0.386	+0.386	+0.445	+0.446
두 변화량의 상관 $r = +0.796$				

새 축을 대상에 붙일 필요가 없다. 지금까지 새 축을 찾을 때마다 “팝업엔 그 데이터가 없어서 못 붙인다”가 걸림돌이었다(노트 94 · 95의 한계 항목). 그런데 팝업이 얻는 이득은 출처가 깨끗해진 데서 온다. 팝업에 없는 종류의 데이터도 값을 한다.

4. 그래서 얼마나 필요한가

기울기가 있으면 셈이 된다. 팝업의 순 정보 기울기는 +0.0035에서 뒤섞은 축의 +0.0005를 뺀 **+0.0030**이다. 라벨 천장(0.734, 노트 83)까지 남은 0.284를 이것으로만 메우려면

$$0.284 / 0.0030 \approx 96\text{개}$$

의 설명문 있는 출처 도메인이 필요하다. 지금 여섯이다.

주장 5. 처음으로 남은 격차가 살 수 있는 단위로 환산됐다. 노트 93은 “축에 없는 것 0.256”이라고만 했고 노트 95는 “+0.01짜리 스물다섯 개”라 했는데, 둘 다 크기를 몰랐다. 이제 안다 — 출처 도메인 96개.

반증 조건. 여섯 점에 직선을 맞춰 열여섯 배 밖으로 외삽했다. 표에서 이미 감속이 보인다(k 1→2 에서 +0.0025, 5→6 에서 +0.0057이지만 3→4 는 +0.0032). 96은 하한이 아니라 낙관적 눈금이다.

5. 한계

- 임베딩이 진짜 문장 임베딩이 아니다. 문자 n -그램은 의미를 못 잡는다 — 감정 · 주제 · 고유명사는 여전히 못 쓴다.
- 판정치는 씨앗 넷 전부 보류다(+0.0104, 구간 $[-0.020, +0.019]$). 팝업도 넷 다 보류다(+0.0222, 구간 $[-0.042, +0.087]$). 채택 안 한다.
- 출처 수 곡선은 한 축(c_0)으로만 났다. 다른 축도 같은 기울기인지 모른다.
- 96개라는 셈은 여섯 점의 직선 외삽이다. 감속이 있으면 훨씬 크다.
- 노트 94의 표지 무작위 재표집은 이번에도 안 했다.

6. 다음

- 기울기가 축 종류에 따라 다른가 — 표지 축(노트 94)으로 같은 출처 수 곡선을 낸다. 기울기가 비슷하면 “출처 하나당”이 법칙이고, 다르면 축의 질이 따로 있다.
- 출처 도메인을 더 늘린다 — 이제 늘릴 이유가 분명하다. 노트 83은 “도메인 추가는 정확도를 안 산다”고 했지만 그것은 축 없이 도메인만 더할 때다. 설명문 있는 도메인은 다르다.
- 팝업 · 아이돌 · 도서 · 편당의 설명문을 찾는다. 게임이 캐시에서 공짜로 나왔으니 남은 넷도 가능성이 있다.
- 진짜 문장 임베딩 — 다국어 모형을 구할 수 있으면 c_0 이 길이가 아닐 것이다.

참고문헌

- Deerwester, S. et al. (1990). Indexing by latent semantic analysis. JASIS, 41(6), 391–407.
- Reimers, N., Gurevych, I. (2019). Sentence-BERT: sentence embeddings using Siamese BERT-networks. EMNLP, 3982–3992.
- Ben-David, S. et al. (2010). A theory of learning from different domains. Machine Learning, 79(1–2), 151–175.
- Lord, F. M., Novick, M. R. (1968). Statistical Theories of Mental Test Scores. Addison-Wesley.
- Efron, B., Tibshirani, R. J. (1993). An Introduction to the Bootstrap. Chapman & Hall.