

IP 파운데이션 월드모델 연구 노트 289

아무도 안 주웠다

누출이 놓여 있었는데 모형이 안 쓴다 --- 표지를 지워도 0.0033 밖에 안 잃는다

Sweetspot 월드모델 연구

2026년 7월 31일

초 록

노트 288이 넓은 팝업 판에서 출처 표지를 찾았다 — 유보에서 관측 표시자 하나로 $|\rho|=0.4157$ 이고 같은 판의 실제 팝업 점수 0.3582 보다 크다. “표지가 모형을 이긴다”고 적고 노트 127 · 133의 채택 근거를 다시 보라고 남겼다. 됐다. 마스크를 상수로 만들어 표지를 지우니 팝업이 -0.0033 이다($0.3582 \rightarrow 0.3549$). 쓸 수 있는 0.4157 중에 실제로 쓰인 것이 0.0033 — 126배 차이다. 누출이 놓여 있었는데 아무도 안 주웠다. 그래서 노트 127 · 133의 이득은 표지가 아니다. 그리고 같은 실험에서 시장 행을 빼니 팝업이 $0.3582 \rightarrow 0.3980$ 으로 크게 올랐는데, 그건 채택 대상이 116행에서 65행으로 바뀐 것이라 그대로 못 읽는다. 같은 내부 유보 65행에 고정하고 시장 행을 학습에서만 빼니 $+0.0028$ — 학습행 56개가 사라지는데 아무 일도 안 난다. 분해가 닫힌다: 표지 기여 -0.0033 · 학습 기여 $+0.0028$ · 나머지 전부가 채택 대상 차이다. 결론 — 넓은 판의 시장 107행은 학습에 아무 기여도 안 하면서 채택만 어렵게 만든다. 노트 283 · 284가 “붙이지 말고 따로 열라”고 한 결정이 두 번째 독립된 이유로 올랐다. 첫 번째는 표지가 생긴다는 것이었고, 이번 것은 붙여도 얻는 게 없다는 것이다.

1. 쓸 수 있는 것과 실제로 쓴 것

노트 288이 넓은 팝업 판(189행 = 내부 82 + 시장 107)에서 손 축 마스크가 내부 98.8% 대 시장 0.0% 이고, 그 표시자 하나로 유보 $|\rho|=0.4157$ 이 나오는 것을 보였다. 실제 팝업 점수가 0.3582 이니 표지가 모형보다 잘 맞힌다.

그런데 모형이 그걸 쓰고 있나? 표지를 지워 봤다 — 손 축 다섯의 관측 표시자를 전부 1로 놓으면 값은 그대로(시장 행은 중립 0.5)인데 표지가 사라진다.

	팝업 ρ	판	출처 가드
그대로	0.3582	0.4076	실패
표지 지움	0.3549	0.4098	통과
차 -0.0033 (판은 오히려 $+0.0022$)			

0.4157을 낼 수 있는 열을 지웠는데 0.0033을 잃는다. 126배다.

왜 안 썼나. F18은 열린 도메인을 한 표로 놓고 적합한 배경 부스팅이다. 팝업은 유보 2,700여 행 중 116행이고, 그 표지는 스물세 열 중 다섯의 지표다. 나무가 팝업 하나를 위해 특화할 이유가 없다. 노트 259가 켜 것의 다른 얼굴이다 — 분기는 열린 도메인이 함께 내려가는 길이라 한 도메인에만 쓸모 있는 열은 뿌리 근처에 못 온다.

그러니 노트 127 · 133은 무사하다. 그 노트들이 넓은 판의 팝업 이득($+0.3688 \rightarrow +0.4495$)을 “팝업이 학습 풀에 들어가서”로 설명했고, 노트 288이 “출처 표지도 같은 크기를 낸다”는 대안을 세웠다. 그 대안이 지금 판에서 0.0033이다. 다른 판 · 다른 축이었으므로 완전한 면죄는 아니지만, 크기가 안 맞는다.

2. 그리고 첫 수를 그대로 읽으면 안 됐다

같은 실험에서 시장 행을 통째로 빼 봤더니 팝업이 0.3582 $\rightarrow$ 0.3980이었다. $+0.0398$ 이면 큰 수다.

그대로 읽으면 안 된다. 시장 행을 빼면 채택 대상도 116행에서 65행으로 바뀐다. 두 수는 다른 문제의 답이다.

그래서 내부 유보 65행에 고정하고 학습에서만 시장 행을 뺐다.

	학습	유보	팝업 ρ
시장 학습 포함	73	65	$+0.3952$
시장 학습 뺐	17	65	$+0.3980$
차 $+0.0028$			

학습행 56개가 사라지는데 아무 일도 안 난다. 노트 133이 넓은 판을 만든 목적이 바로 그 행들인데, 지금 판에서는 기여가 0이다.

분해가 닫힌다.

표지가 하는 일	-0.0033
시장 학습행이 하는 일	$+0.0028$
나머지 전부	채점 대상 차이

0.3582(유보 116, 시장 51 포함)와 0.3952(유보 65, 내부만)의 차이는 모형이 아니라 무엇을 채점했나. 시장 유보 행이 순위 매기기 더 어렵다.

누출이 있어도 쓰지 않으면 점수에 안 나온다




Figure 1: 왼쪽 — 표지 하나로 낼 수 있는 값과 표지를 지웠을 때 실제로 잃는 값. 오른쪽 — 네 판의 팝업 ρ . 위 둘은 유보 116행, 아래 둘은 내부 유보 65행에 고정된 것.

3. 그래서 붙이지 말라는 결론이 두 번째 이유를 얻는다

노트 283이 시장 층을 팝업에 붙이지 말라고 한 근거는 표지가 생긴다는 것이었다. 이번 노트가 두 번째를 더 한다.

있다), 점수를 설명할 때는 실제로 쓰였는지 재야 한다. 그리고 행을 빼는 실험은 채점 대상이 같은지 먼저 본다 — +0.0398 이 +0.0028 이 됐다.

붙이면 안 되는 이유

- | | |
|-------------------------|--------------------|
| ① 표지가 생긴다(노트 283 · 288) | 지금 모형은 안 쓰지만 놓여 있다 |
| ② 붙여도 얻는 게 없다 | 학습 기여 +0.0028 |
| ③ 채점만 어려워진다 | 유보에 어려운 행 51개가 섞인다 |

①은 잠재적 위험이고 ②③은 실제 비용이다. 노트 284가 열한 번째 도메인으로 따로 연 결정은 셋 다 피한다 — 시장 행은 제 도메인에서 $\rho=0.197$ 로 정직하게 채점되고, 팝업은 제 65행으로 채점된다.

넓힌 판을 어떻게 하나. wide* 축 세트에서 시장 107행을 빼는 것이 맞다. 얻는 게 없고 표지를 만들고 채점을 흐린다. 다만 그건 노트 133이 만든 판을 고치는 일이라 이 노트에서 바로 안 한다 — 넓은 판을 쓴 옛 노트들의 수가 바뀌므로 노트 284의 규약대로 기준선을 다시 놓는 일이 따라온다.

남은 것.

갈래	왜
wide* 정리	시장 107행 제거 · 기준선 재설정
다른 정식화로	F6 · F9 는 표지를 쓸까(청력이 높다)
표지를 일부러 준다면	능형은 0.4157 을 주울지도
노트 133 재현	옛 축 세트로 그때 수를 다시

규약. 누출이 있다는 것과 누출이 쓰인다는 것은 다르다. 가드는 있는 것을 막아야 하지만(다른 정식화가 주울 수